5G/4G обработка сигналов в базовых станциях

Бахурин С.А.

Последняя сборка файла: 11 сентября 2026 г.

Лекция 1. Современные системы беспроводной связи

§1.1. Историческая ретроспектива развития систем беспроводной связи

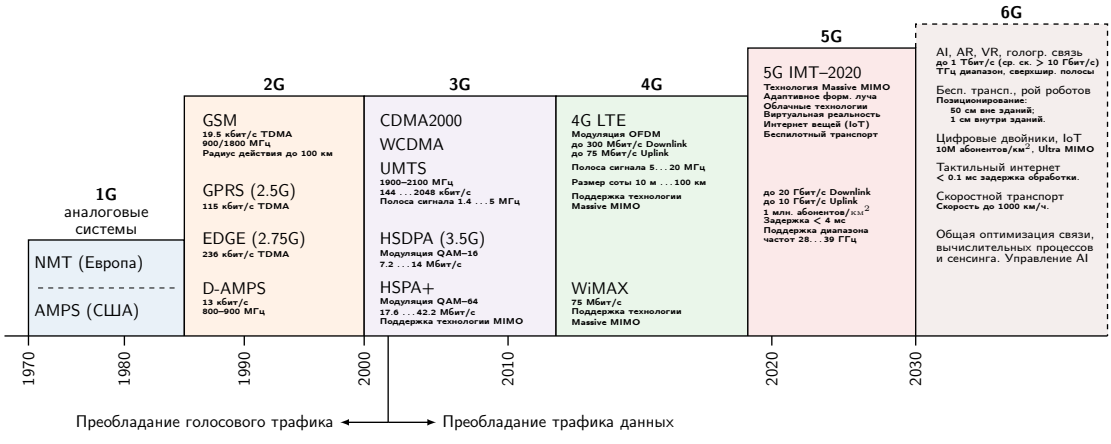

NMT — Nordic Mobile Telephony
AMPS — Advanced Mobile Phone Service
D-AMPS — Digital AMPS
GSM — Global System for Mobile Communications
GPRS — General Packet Radio Service
EDGE — Enhanced Data rates for GSM Evolution

TDMA — Time Division Multiple Access
WCDMA — Wideband Code Division Multiple Access
UMTS — Universal Mobile Telecommunications System
HSDPA — High-Speed Downlink Packet Access
HSPA+ — High-Speed Packet Access
LTE — Long-Term Evolution

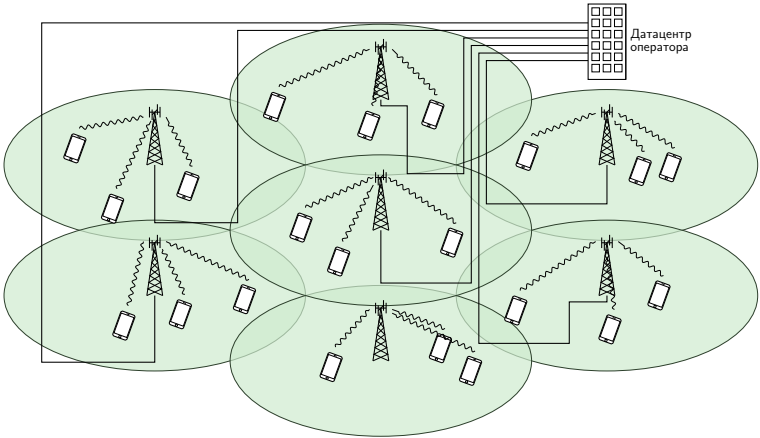

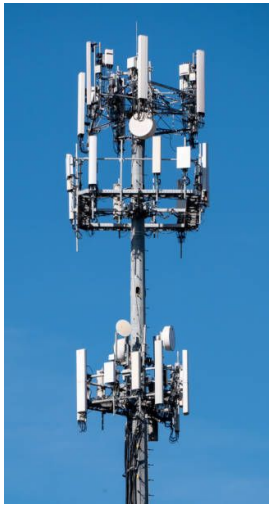

Мобильные терминалы производят обмен данными с базовой станцией, которая связана с дата-центром оператора. Обмен данными терминала и базовой станцией производится по радиоканалу.

Базовая станция состоит из радиомодуля, соединённого с антенной для связи с абонентами и с маршрутизатором для связи с дата-центром оператора.
Радиомодуль состоит из блока цифровой обработки и аналогового радиотракта

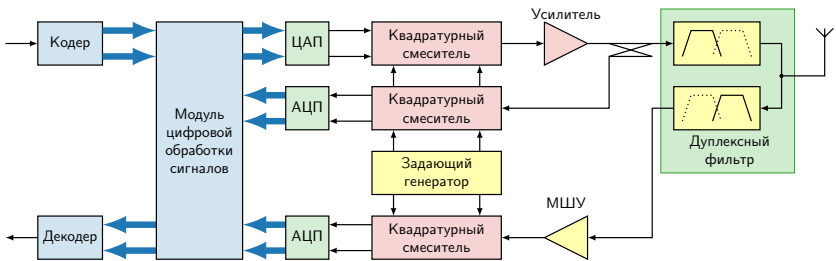

Выделены аналоговые радиотракты, подлежащие коррекции в модуле цифровой обработки сигналов.

Аналоговые тракты всегда имеют разброс параметров, вносят искажения в сигнал и требуют настройки и коррекции.

При этом увеличение пропускной способности каналов возможно лишь при использовании модуляций высоких порядков, что предъявляет особые требования к аналоговым трактам.

Для повышения качества аналоговых трактов аппаратуры связи используют цифровые адаптивные корректоры линейных искажений, а также нелинейные корректоры, позволяющие повысить КПД усилителя и обеспечить заданные характеристики устройств повышенной энергоэффективности, снижение массогабаритных показателей и цены.

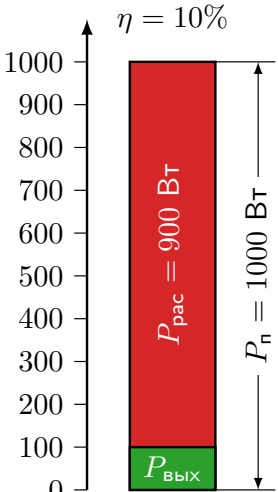

$\eta = 50\%$

$P_{\text{вых}} = 100$ Вт

$P_{\text{п}} = 200$ Вт

$P_{\text{рас}} = 100$ Вт

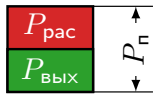

Например, линейный усилитель выходной мощности $P_{\text{вых}} = 100$ Вт при КПД $\eta = 10\%$ потребляет $P_{\text{п}} = 1000$ Вт мощности, причём $P_{\text{рас}} = 900$ Вт надо рассеять в виде тепла.

Если увеличить КПД усилителя до $\eta = 50\%$, то при той же выходной мощности $P_{\text{вых}} = 100$ Вт, потребляемая мощность будет составлять $P_{\text{п}} = 200$ Вт (в 5 раз ниже), а рассеиваемая мощность будет $P_{\text{рас}} = 100$ Вт (в 9 раз ниже).

Задачи, решаемые модулем цифровой обработки:

- Формирование комплексной огибающей радиосигнала.
- Адаптивная компенсация линейных искажений аналогового тракта и диплексора (адаптивные линейные эквалайзеры)
- Адаптивная компенсация нелинейных искажений высокоэффективного усилителя мощности (линеаризация усилителя).
- Адаптивная компенсация нелинейных эффектов квадратурного смесителя.
- Адаптивная коррекция аналоговых трактов фазированных решёток (для 5G)

Линеаризация усилителя — наиболее сложная задача, требующая больших вычислительных ресурсов. Решается с использованием нелинейных моделей, включая нейронные сети.

§1.2. Методы цифровой обработки сигналов в системах связи

Радиочастотный ресурс является наиболее дорогим, потому что все системы должны работать в эфире одновременно и не мешать друг другу.

Частоту будем обозначать f (Гц) или круговой частотой $\omega = 2\pi f$ (рад/с).

Принятые международные стандарты ограничивают полосы систем связи.

Частотное представление сигналов:

- Ряд Фурье;
- интеграл Фурье;
- дискретно-временное преобразование Фурье;
- дискретное преобразование Фурье.

Ряд Фурье

$$s(t) = \sum_{n=-\infty}^{\infty} S(\omega_n) \exp(j\omega_n t)$$

$$S(\omega_n) = \frac{1}{T} \int_{-\frac{T}{2}}^{\frac{T}{2}} s(t) \exp(-j\omega_n t)\ dt$$

$$\omega_n = \frac{2\pi}{T} n$$

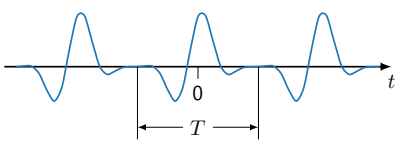

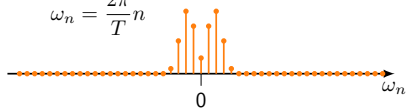

Интеграл Фурье

$$s(t) = \frac{1}{2\pi} \int_{-\infty}^{\infty} S(\omega) \exp(j\omega t)\ d\omega$$

$$S(\omega) = \int_{-\infty}^{\infty} s(t) \exp(-j\omega t)\ dt$$

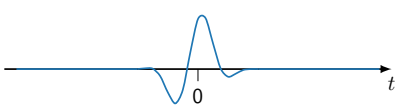

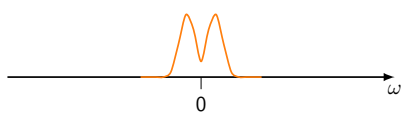

Дискретно-временное преобразование Фурье

$$s_n = \frac{1}{2\pi}\int_{-\pi}^{\pi} S(\omega)\exp(j\omega n)\,d\omega$$

$$S(\omega) = \sum_{n=-\infty}^{\infty} s_n \exp(-j\omega n)$$

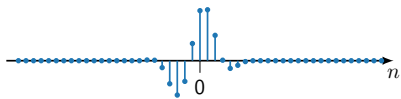

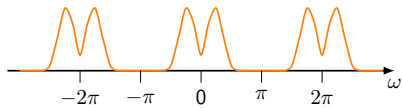

Дискретное преобразование Фурье, $n, k = 0 \ldots N-1$

$$s_n = \frac{1}{N}\sum_{k=0}^{N-1} S_n \exp(-j2\pi nk/N)$$

$$S_k = \sum_{n=0}^{N-1} s_n \exp(-j2\pi nk/N)$$

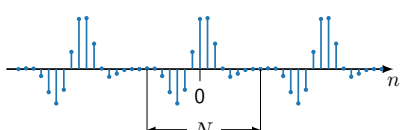

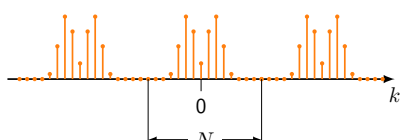

Радиосигнал $s(t)$ на несущей частоте f_0 Гц можно описать как:

$$s(t) = a(t)\cos\left(2\pi f_0 t + \varphi(t)\right) \tag{1.1}$$

Можно заметить, что

$$\begin{aligned} s(t) &= \mathrm{Re}\left[a(t)\cos(2\pi f_0 t + \varphi(t)) + j a(t)\sin(2\pi f_0 t + \varphi(t))\right] = \\ &= \mathrm{Re}\left[a(t)\exp(j[2\pi f_0 t + \varphi(t)])\right] \\ &= \mathrm{Re}\left[z(t)\exp(j2\pi f_0 t)\right], \end{aligned} \tag{1.2}$$

где

$$z(t) = a(t)\exp(j\varphi(t)) = \underbrace{a(t)\cos(\varphi(t))}_{I(t)} + j\,\underbrace{a(t)\sin(\varphi(t))}_{Q(t)} \tag{1.3}$$

носит название комплексной огибающей сигнала $s(t)$.

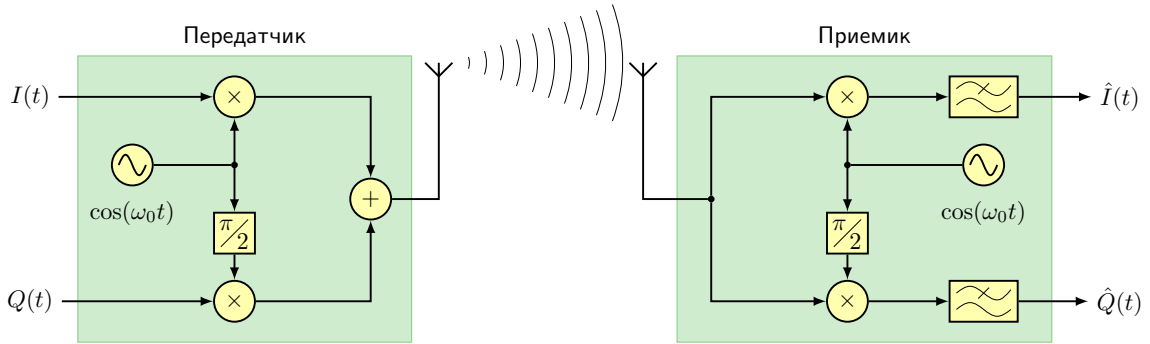

Согласно свойствам преобразования Фурье, полоса, занимаемая сигналом на несущей частоте f_0 равна полосе комплексной огибающей.

Т.о. мы можем сфокусироваться на формировании полосы комплексной огибающей $z(t)$ и можем быть уверены, что именно эту полосу будет занимать наш радиосигнал.

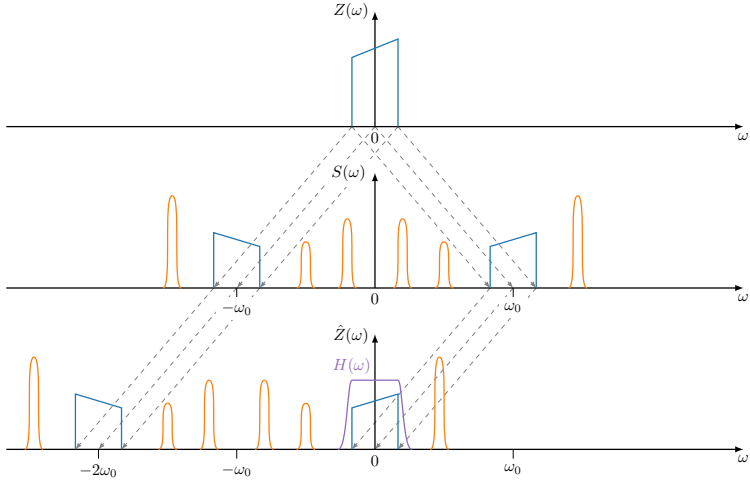

Передатчик использует квадратурный смеситель для формирования радиосигнала $s(t)$.
На приёмной стороне, комплексная огибающая восстанавливается из радиосигнала $s(t)$.

Лекция 1. Современные системы беспроводной связи

§1.3. Аналоговая частотная модуляция

Полосовой радиосигнал:

$$s(t) = \mathrm{Re}[z(t)\exp(j\omega_0 t)] = a(t)\cos(\omega_0 t + \varphi(t)). \tag{1.4}$$

Все сигналы отличаются лишь законом изменения амплитуды $a(t)$ и фазы $\varphi(t)$, которые задаются комплексной огибающей $z(t) = a(t)\exp(j\varphi(t))$
Мгновенная частота:

$$\omega(t) = \omega_0 + \frac{d}{dt}\varphi(t). \tag{1.5}$$

Тогда мгновенная частота сигнала с частотной модуляцией:

$$\omega(t) = \omega_0 + \omega_\text{д} s_m(t), \quad |s_m(t)| \leq 1, \tag{1.6}$$

и полная фаза сигнала с частотной модуляцией:

$$\Phi(t) = \int \omega(t)dt = \omega_0 t + \omega_\text{д} \int s_m(t)dt + \phi_0. \tag{1.7}$$

Окончательно сигнал с частотной модуляцией

$$s(t) = A_0 \cos\left(\omega_0 t + \omega_д \int s_m(t)dt + \phi_0\right). \tag{1.8}$$

Комплексная огибающая:

$$z(t) = A_0 \exp\left(j\omega_д \int s_m(t)dt + j\phi_0\right). \tag{1.9}$$

Синфазная и квадратурная компоненты:

$$I(t) = \cos\left(\omega_д \int s_m(t)dt + \phi_0\right); \tag{1.10}$$

$$Q(t) = \sin\left(\omega_д \int s_m(t)dt + \phi_0\right). \tag{1.11}$$

Структура частотного модулятора:

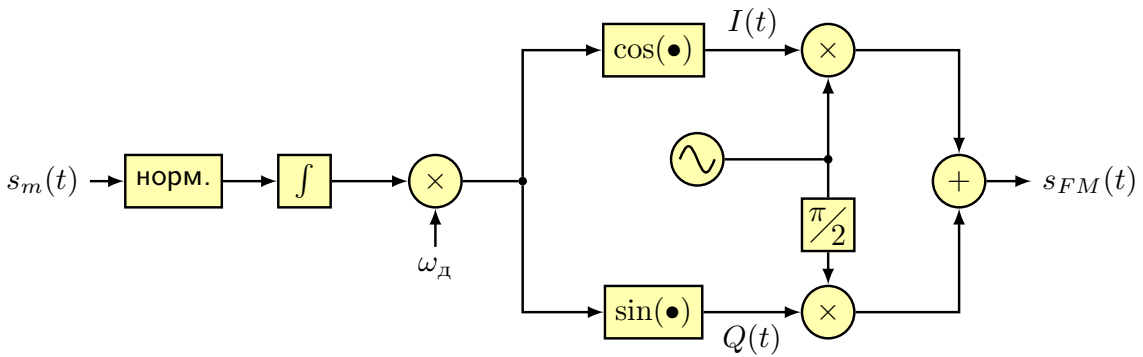

$$s_{FM}(t) = \mathrm{Re}\left[\big(I(t) + jQ(t)\big)\exp(j\omega_0 t)\right] \tag{1.12}$$

FM сигнал и его СПМ, несущая частота $f_0 = 500$ кГц, частота девиации $f_д = 100$ кГц:

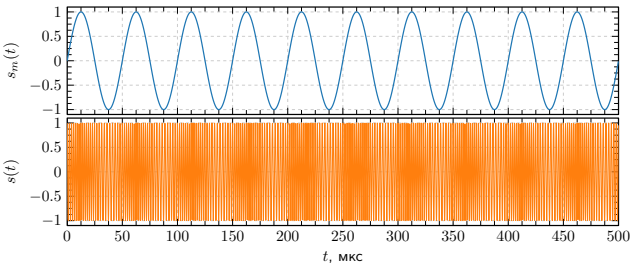

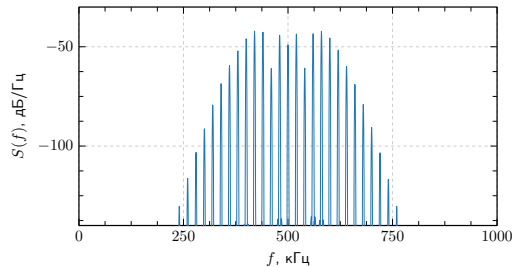

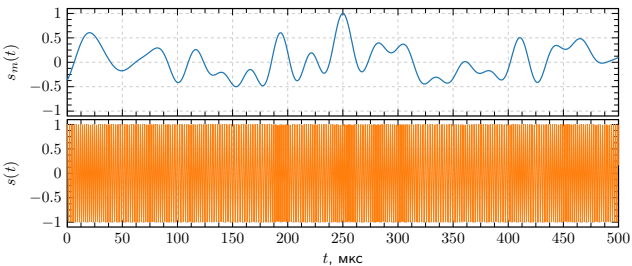

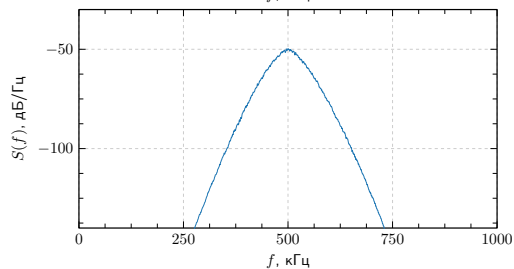

§1.4. Цифровая частотная манипуляция (FSK)

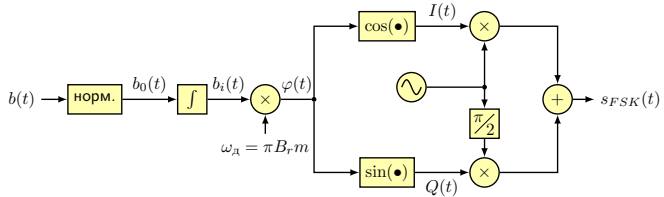

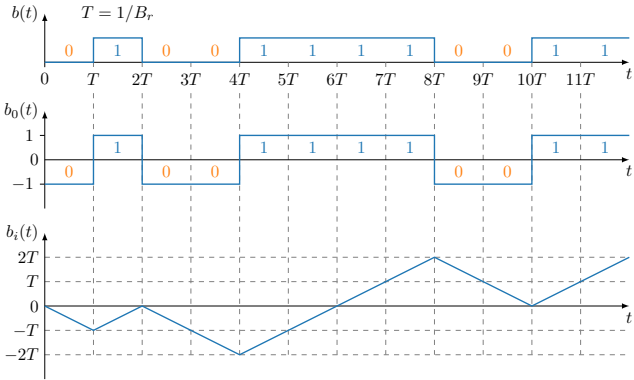

$T = 1/B_r$ — длительность символа,
$\omega_д = \pi B_r m$ рад/с, или
$f_д = B_r m/2$ Гц — частота девиации,
m — индекс модуляции.
Комплексная огибающая:

$$z(t) = I(t) + jQ(t) = \exp(j\varphi(t)),$$

где фазовая огибающая

$$\varphi(t) = \omega_д b_i(t) = \pi B_r m b_i(t).$$

Набег фазы комплексной огибающей на одном символе:

$$\Delta\varphi = \omega_д T = \pi m \underbrace{B_r T}_{1} = \pi m.$$

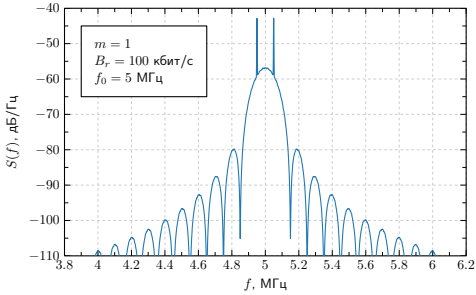
$m = 1$
$B_r = 100$ кбит/с
$f_0 = 5$ МГц
$S(f)$, дБ/Гц
f, МГц

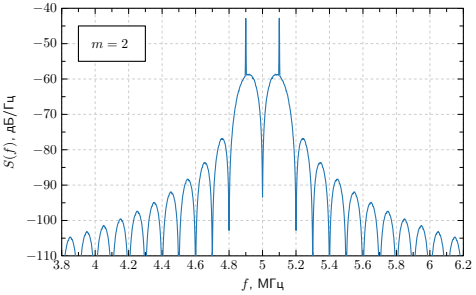
$m = 2$
$S(f)$, дБ/Гц
f, МГц

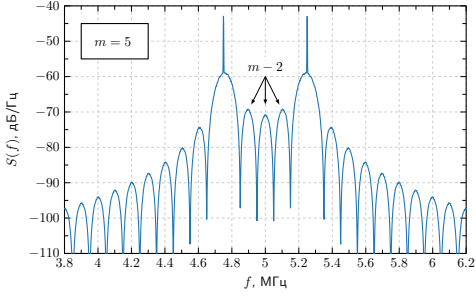
$m = 5$
$m - 2$
$S(f)$, дБ/Гц
f, МГц

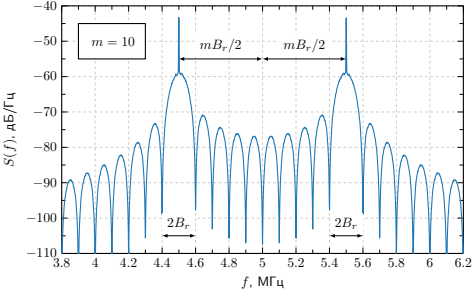
$m = 10$
$mB_r/2$
$mB_r/2$
$2B_r$
$2B_r$
$S(f)$, дБ/Гц
f, МГц

Фазовая диаграмма FSK сигнала при $m = 1$

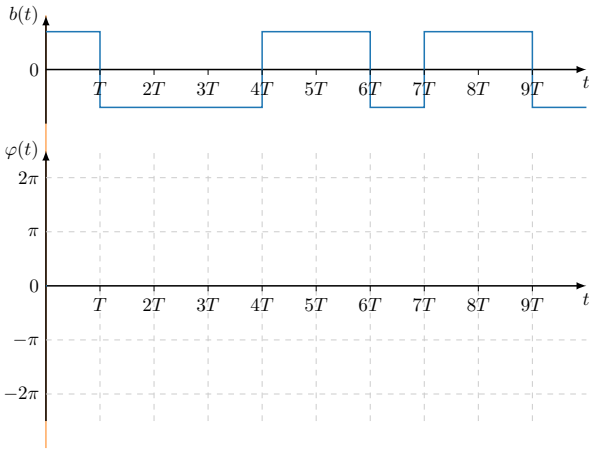

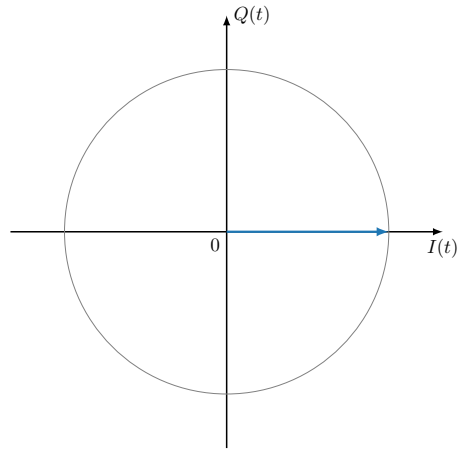

§1.5. Минимальная частотная манипуляция (MSK)

Пусть «0» и «1» цифровой информации передаются при помощи FSK модуляции.
Тогда логическому «0» будет соответствовать сигнал $s_0(t) = \cos((\omega_0 - \omega_д)t)$,
а логической единице будет соответствовать сигнал $s_1(t) = \cos((\omega_0 + \omega_д)t)$.
На интервале символа T, сигналы $s_0(t)$ и $s_1(t)$ будут ортогональны, если

$$\int_0^T s_0(t)s_1(t)dt = 0. \tag{1.13}$$

Тогда

$$\int_0^T \cos((\omega_0 - \omega_д)t)\cos((\omega_0 + \omega_д)t)dt = 0; \tag{1.14}$$

$$\underbrace{\int_0^T \cos(2\omega_0 t)dt}_{0} + \int_0^T \cos(2\omega_д t)dt = 0; \tag{1.15}$$

$$\int_0^T \cos(2\omega_д t)dt = 0; \tag{1.16}$$

$$\frac{1}{2\omega_д}\sin(2\omega_д T) = 0, \quad \text{откуда} \quad 2\omega_д T = \pi k, \quad k \in \mathbb{Z}. \tag{1.17}$$

$$2\pi m B_r T = \pi k, \tag{1.18}$$

учтем что $B_r T = 1$, тогда

$$2\pi m = \pi \quad \text{или} \quad m = 0.5. \tag{1.19}$$

Таким образом, $m = 0.5$ это минимальный индекс при котором можно разделить колебания нуля и единицы.

Набег фазы огибающей на одном символе MSK равен $\Delta\varphi = \pi/2$ рад.

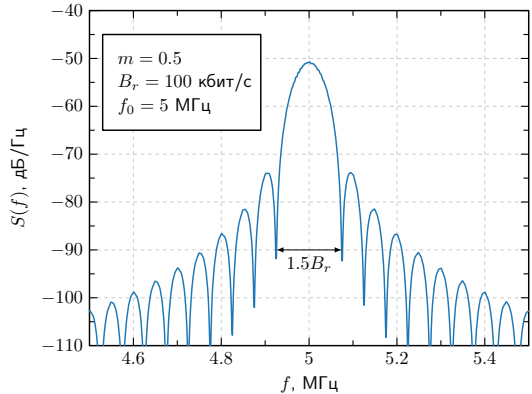

Основной недостаток — высокий уровень боковых лепестков спектральной плотности мощности.

§1.6. Гауссовская частотная манипуляция (GMSK)

Основная идея — сглаживание фронтов и фазовых переходов при изменении информационных символов.

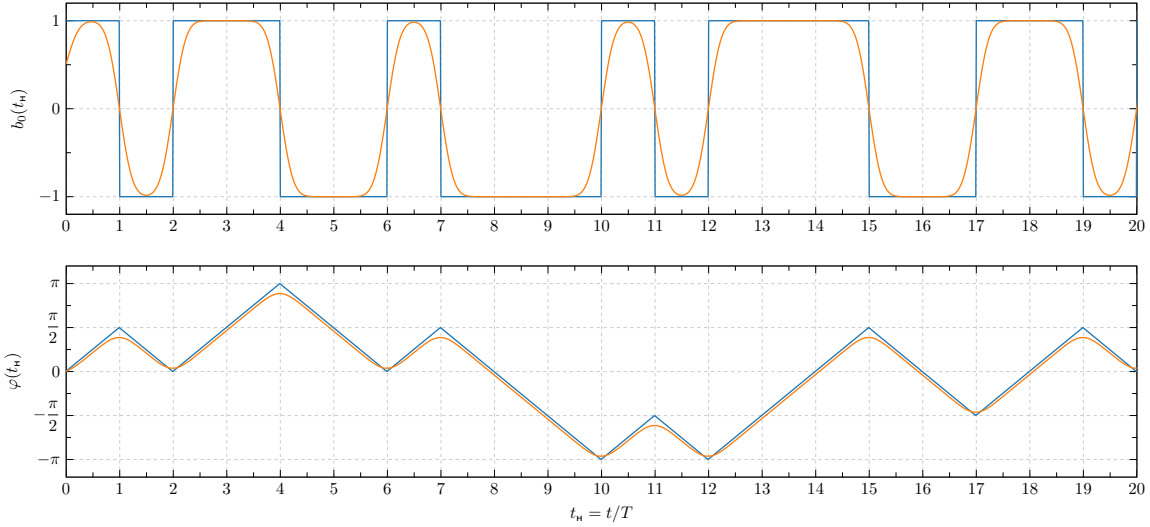

Для этого предложено использовать фильтра Гаусса

$$g(t) = \sqrt{\frac{2\pi B_T^2}{\ln(2)T^2}} \exp\left[-\frac{2\pi^2 B_T^2}{\ln(2)T^2} t^2\right], \qquad \int_{-\infty}^{\infty} g(t)dt = 1. \tag{1.20}$$

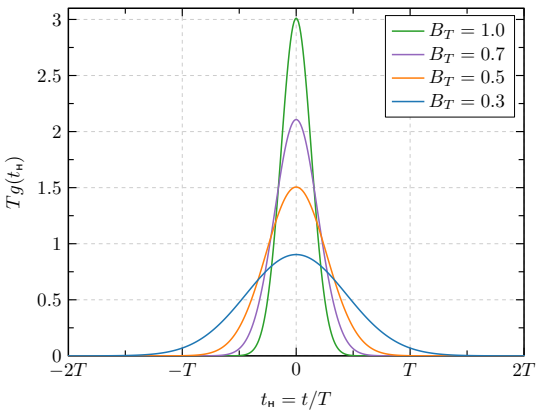

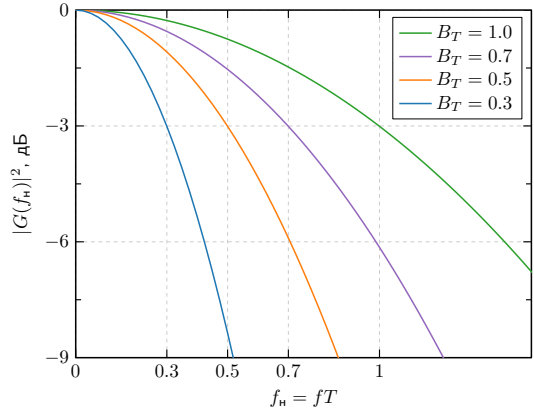

Структурная схема GMSK модулятора:

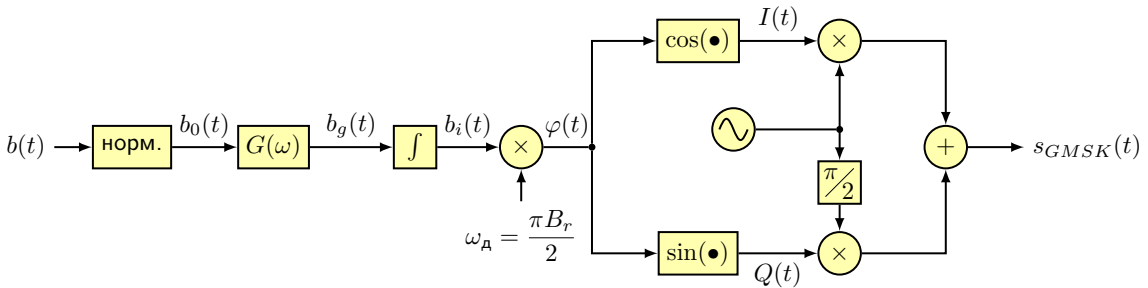

Фильтр Гаусса $G(\omega)$ производит сглаживание фронтов биполярного потока $b_0(t)$, в результате после интегрирования сглаженного битового потока, фаза $\varphi(t)$ становится гладкой.

Выход фильтра Гаусса и СПМ GMSK сигнала при различном значении параметра B_T.

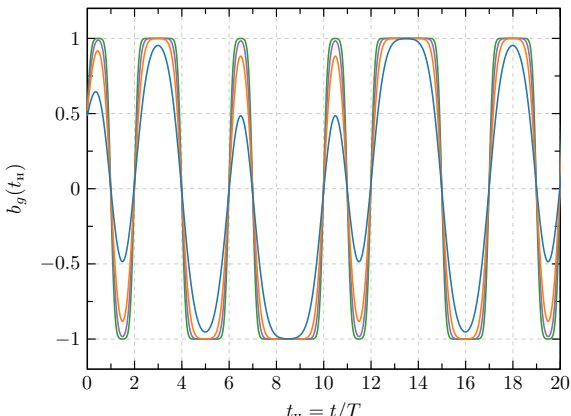

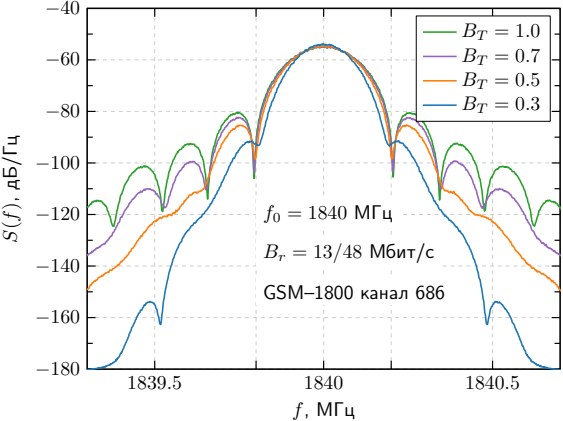

GMSK при $B_T = 0.3$ выбрана в качестве модуляции стандарта GSM ввиду максимальной спектральной эффективности при возможности компенсации межсимвольной интерференции.

§1.7. Сигналы с фазовой манипуляцией (BPSK, QPSK и 8PSK)

$$I(t) = \cos\big(\pi b_0(t)\big);$$
$$Q(t) = \sin\big(\pi b_0(t)\big). \tag{1.21}$$

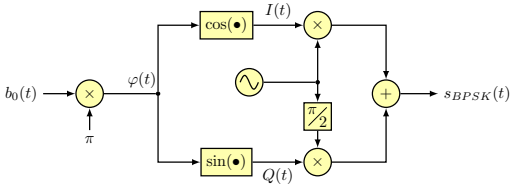

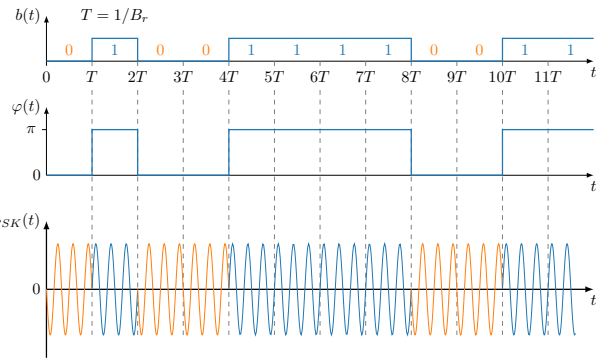

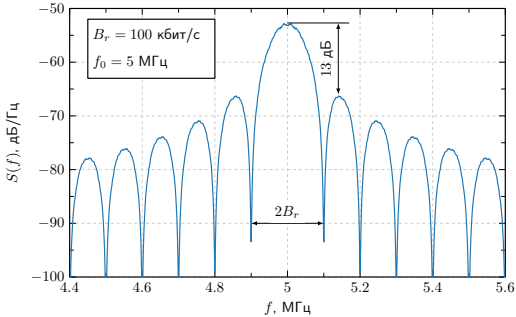

BPSK кодирует одним символом 1 бит информации. Обладает максимальной помехоустойчивостью, но низкой спектральной эффективностью.

Идея QPSK — кодировать одним символом 2 бита информации.

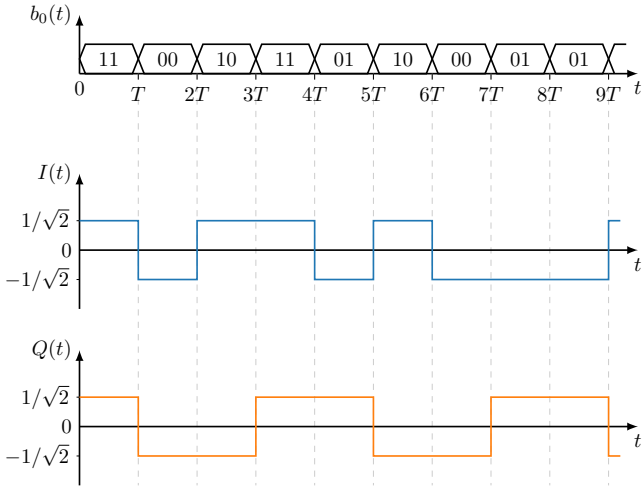

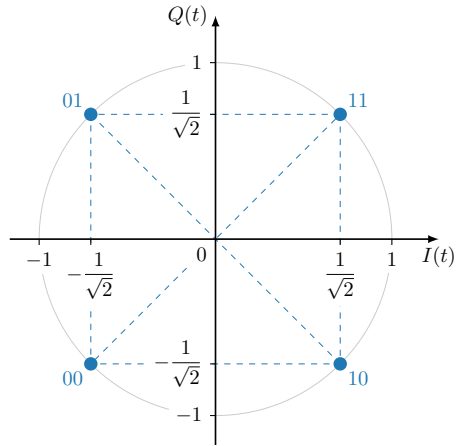

Для уменьшения ошибок демодуляции используют код Грея (соседние точки созвездия отличаются одним битом).

Созвездия сигналов с фазовой манипуляцией

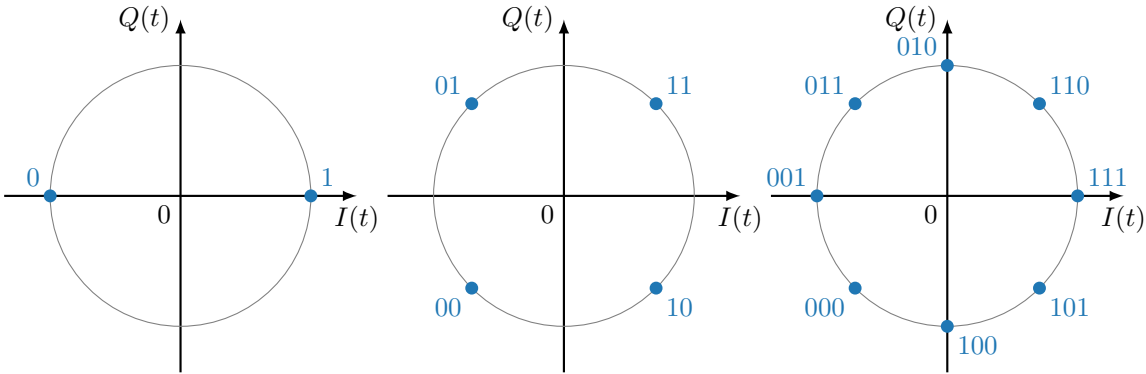

8PSK модуляция используется в стандарте EDGE.

Чем ближе точки созвездия друг к другу, тем ниже помехоустойчивость, но мы можем кодировать несколько бит одним символом, кратно увеличивая скорость передачи информации.

Увеличение скорости передачи информации путем кодирования одной точкой созвездия нескольких бит информации приводит к повышенным требованиям к отношению сигнал-шум в приемнике при демодуляции.

При работе приемника в канале при наличии белого гауссовского шума возникают ошибки приема информации.

Для измерения вводят характеристику зависимости вероятности битовой ошибки BER от отношения сигнал-шум SNR.

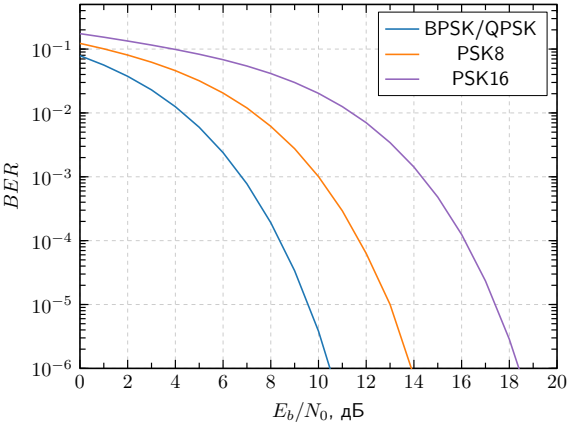

$$SNR = \frac{E_b}{N_0} \quad \left[\frac{\text{Дж}}{\text{Вт/Гц}} = \frac{\text{Дж/с}}{\text{Вт}} = \frac{\text{Вт}}{\text{Вт}}\right], \qquad SNR = 10\lg\left(E_b/N_0\right) \quad \text{дБ}. \tag{1.22}$$

Здесь E_b — энергия одного информационного бита, принимаемого на фоне белого гауссовского шума со спектральной плотностью мощности N_0.

§1.8. Сигналы с квадратурной амплитудной манипуляцией (QAM)

Увеличение точек созвездия PSK до 16 приводит к их очень близкому расположению на окружности.
Следствие — ухудшение помехоустойчивости.
Для улучшения помехоустойчивости точки созвездия можно расположить на плоскости.

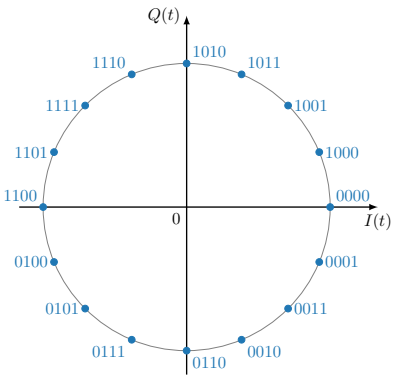

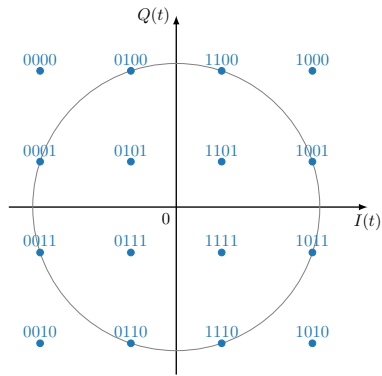

В результате получим манипуляцию как по фазе, так и по амплитуде.

Таким образом можно кодировать больше бит одним символом при увеличении порядка модуляции QAM16–QAM64–QAM256

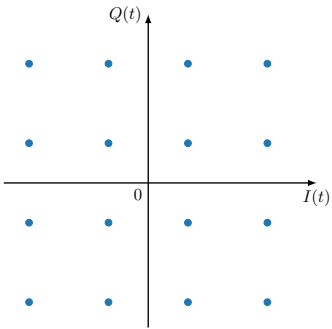

QAM16 (1 символ 4 бита)

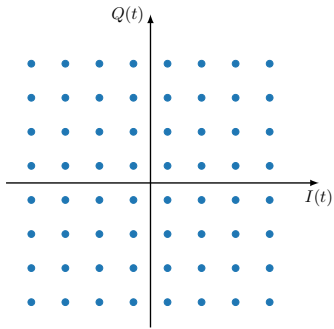

QAM64 (1 символ 6 бит)

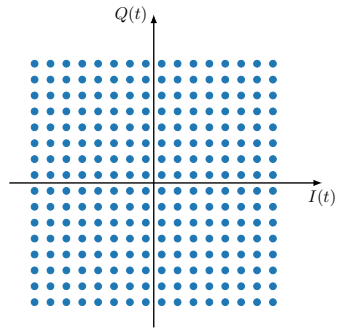

QAM256 (1 символ 8 бит)

PSK и QAM модулятор можно построить по универсальной схеме:

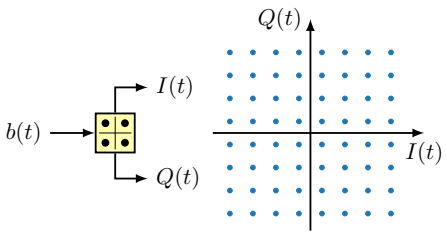

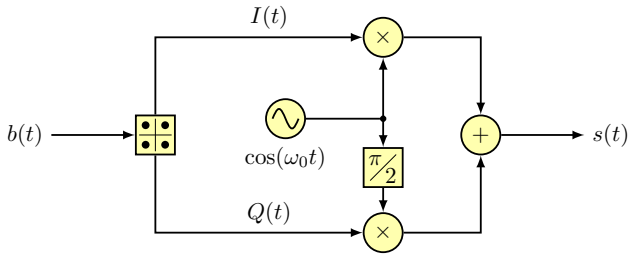

Цифровой поток $b(t)$ подается на карту созвездия, с выхода которой сигналы синфазного $I(t)$ и квадратурного $Q(t)$ каналов подаются на смеситель для переноса сигнала на несущую частоту ω_0.

Карта созвездия может меняться во времени. Например, при изменении отношения сигнал-шум в приемнике, порядок модуляции может быть повышен (QAM16–QAM64) или понижен (QAM16–QAM4).

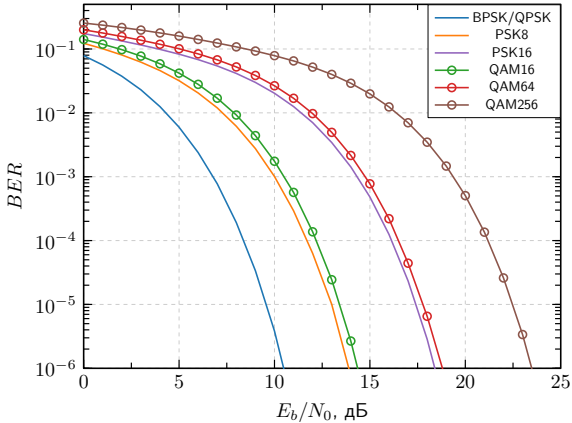

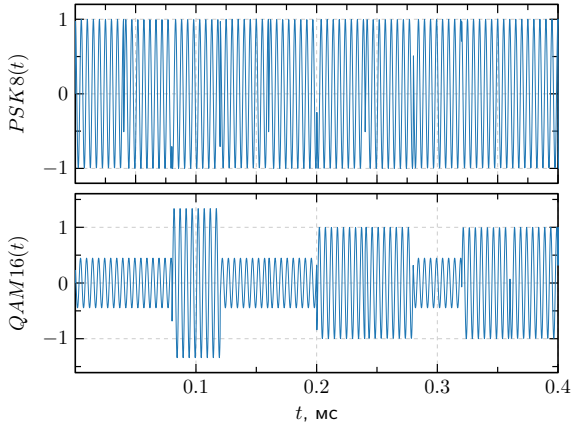

Кривые вероятности битовой ошибки для QAM16 близки к PSK8, а для QAM64 к PSK16. Таким образом, QAM выглядит более предпочтительно.

Однако QAM модуляция более чувствительна к АЧХ канала связи и линейности тракта, поскольку амплитуда сигнала несет информацию.

QAM модуляция требует адаптивные эквалайзеры при демодуляции.

Изменение амплитуды сигнала $s(t)$ характеризуется параметром пик-фактора CF:

$$CF = \max\big(|s(t)|\big) / \operatorname{RMS}\big[s(t)\big], \qquad \operatorname{RMS}\big[s(t)\big] = \lim_{T\to\infty} \sqrt{\frac{1}{2T}\int_{-T}^{T} |s(t)|^2\, dt}, \tag{1.23}$$

здесь $\max\big(|s(t)|\big)$ — максимальная амплитуда сигнала $s(t)$, $\operatorname{RMS}\big[s(t)\big]$ — его среднеквадратическое значение (действующее значение).
В случае дискретного сигнала s_n, $n = 0 \dots N-1$:

$$CF = \max\big(|s_n|\big) / \operatorname{RMS}\big[s_n\big], \qquad \operatorname{RMS}\big[s_n\big] = \sqrt{\frac{1}{N}\sum_{n=0}^{N-1} |s_n|^2}. \tag{1.24}$$

С параметром пик-фактора связан параметр отношения пиковой мощности к средней мощности $PAPR = CF^2$, выраженный в логарифмическом масштабе:

$$PAPR = 10\lg CF^2 = 10\lg\Big(\max\big(|s(t)|^2\big) / \operatorname{RMS}^2\big[s(t)\big]\Big), \quad \text{дБ}. \tag{1.25}$$

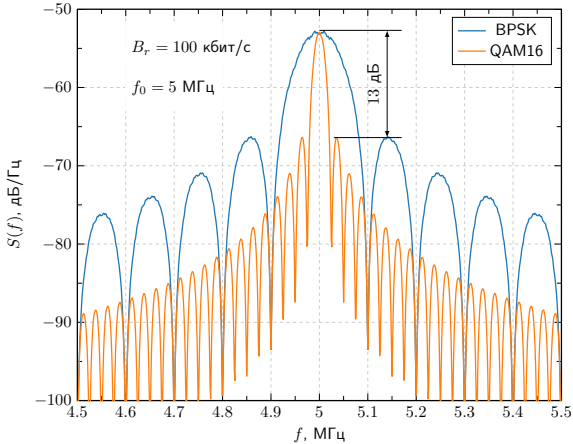

Кодирование одним символом n бит позволяет существенно снизить ширину главного лепестка $S(f)$ в n раз.

В приведенном примере QAM16 кодирует $n = 4$ бит одним символом, соответственно ширина главного лепестка в 4 раза меньше.

Основная проблема в скачках фазы сигнала при смене символов. В результате уровень боковых лепестков QAM модуляции такой же, как и уровень боковых лепестков BPSK 13 дБ.

§1.9. Формирование спектра при передаче сигналов с фазовой манипуляцией

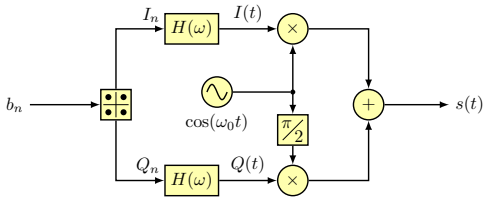

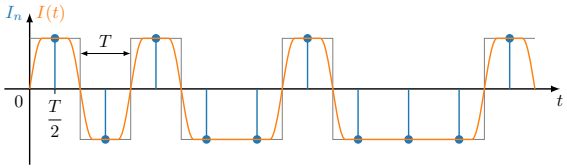

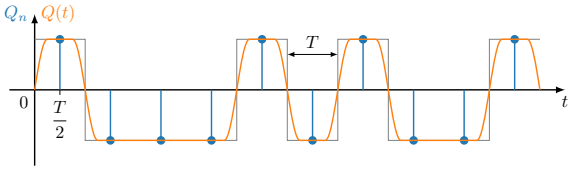

Уменьшение уровня боковых лепестков достигается за счет сглаживания фронта импульса формирующим фильтром $H(\omega)$.

В результате скачок фазы заменяется плавным перетеканием одного символа в другой.

Возникает межсимвольная интерференция из-за влияния соседних символов друг на друга.

Условия исключения межсимвольной интерференции при демодуляции:

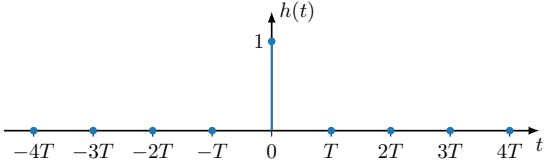

Фильтр приподнятого косинуса (raised-cosine filter) относительно нормированной частоты fT:

$$|H(fT)| = \begin{cases} 1, & \text{если} \quad |fT| < \dfrac{1-\beta}{2}; \\ \dfrac{1}{2} + \dfrac{1}{2}\cos\left(\dfrac{\pi}{\beta}\left(|fT| - \dfrac{1-\beta}{2}\right)\right), & \text{если} \quad \dfrac{1-\beta}{2} < |fT| < \dfrac{1+\beta}{2}; \\ 0, & \text{если} \quad |fT| > \dfrac{1+\beta}{2}. \end{cases} \tag{1.26}$$

Импульсная характеристика относительно нормированного времени t/T:

$$h(t/T) = \operatorname{sinc}(\pi t/T)\frac{\cos(\pi\beta t/T)}{1 - 4\beta^2 t^2/T^2} \tag{1.27}$$

АЧХ и импульсные характеристики фильтра приподнятого косинуса при различном параметре β.

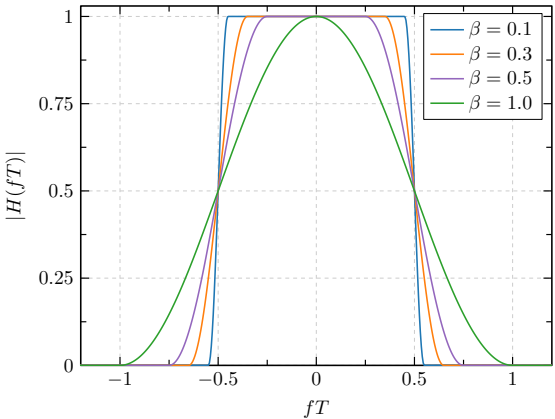

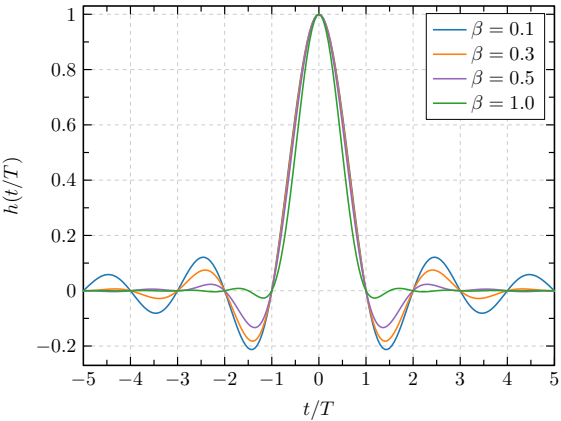

На практике фильтр приподнятого косинуса используют как каскад двух фильтров вида «корень из приподнятого косинуса» (root raised cosine RRC).
Один RRC-фильтр используют в канале передатчика, а второй в канале приемника

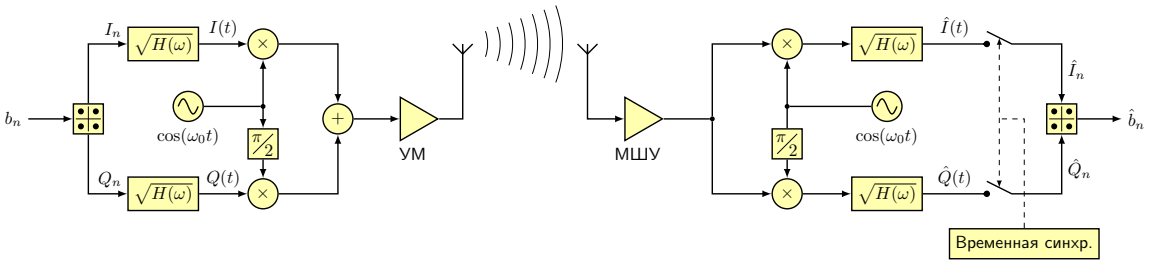

$$h_{RRC}(t/T) = \frac{1}{T} \cdot \frac{\sin\big(\pi t/T(1-\beta)\big) + 4\beta t/T \cos\big(\pi t/T(1+\beta)\big)}{\pi t/T\big(1-(4\beta t/T)^2\big)} \qquad (1.28)$$

При расчете необходимо раскрывать неопределенности в моменты времени t/T при которых знаменатель обращается в ноль.

АЧХ и импульсные характеристики фильтра корень из приподнятого косинуса при различном параметре β.

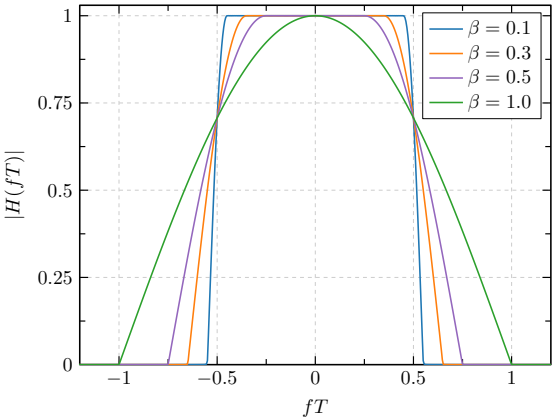

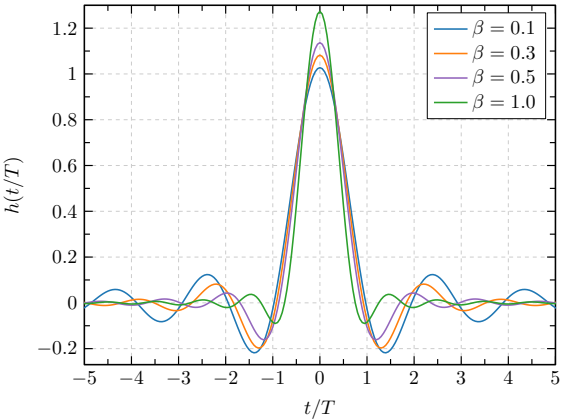

Заметим, что импульсная характеристика не обращается в ноль при $t/T = 0, \pm 1, \pm 2, \ldots$. Однако при свертке импульсных характеристик с самими собой обеспечивается отсутствие межсимвольной интерференции при демодуляции.

Фазовая диаграмма QPSK при использовании фильтра приподнятого косинуса $\beta = 0.7$.

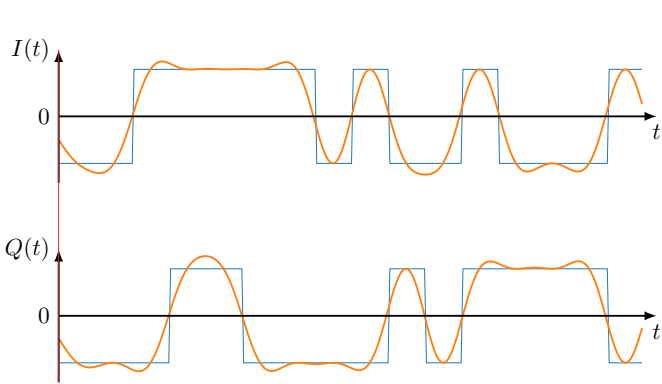

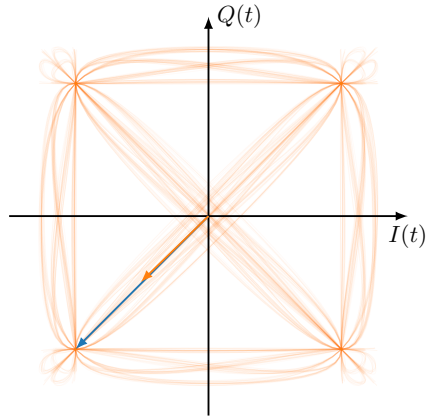

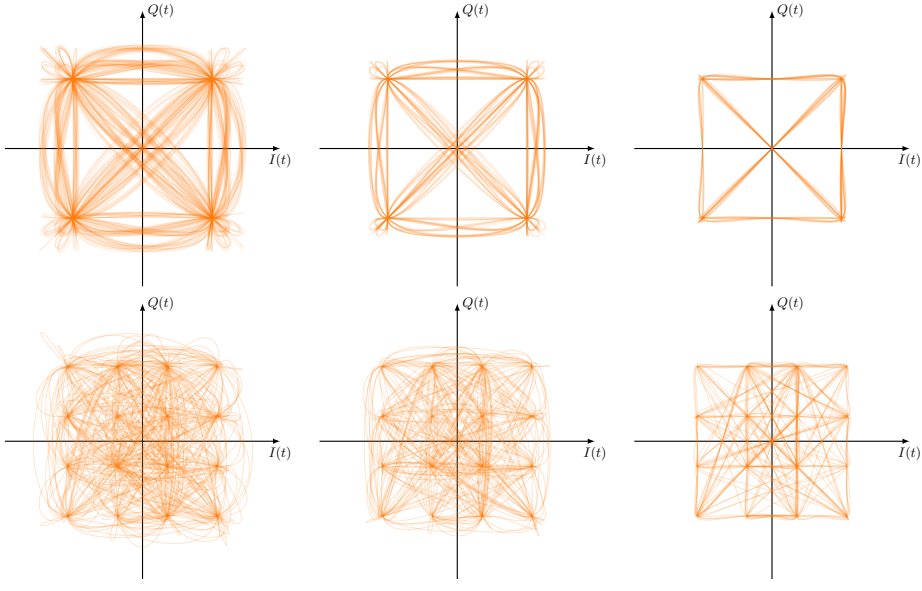
Q(t)
I(t)
Q(t)
I(t)
Q(t)
I(t)
Q(t)
I(t)
Q(t)
I(t)
Q(t)
I(t)
β = 0.5
β = 0.7
β = 1.0

QPSK радиосигнал и его спектральная плотность мощности при использовании RRC фильтра с различными параметрами β.

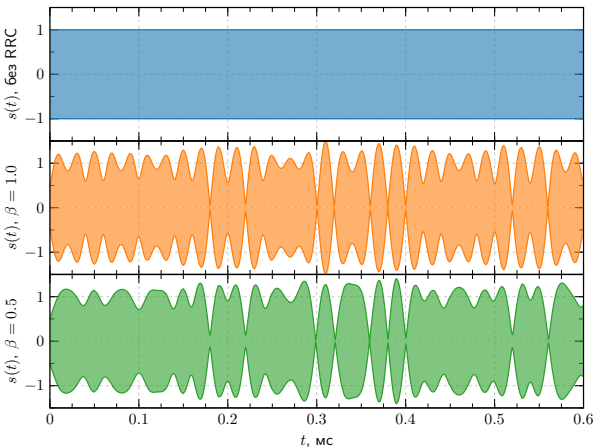

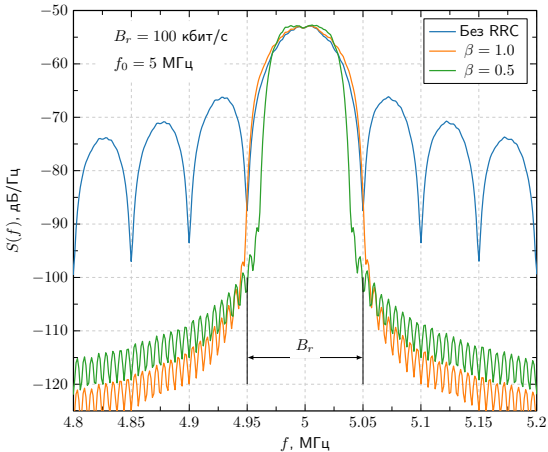

§1.10. Мультиплексирование с ортогональным частотным разделением каналов (OFDM)

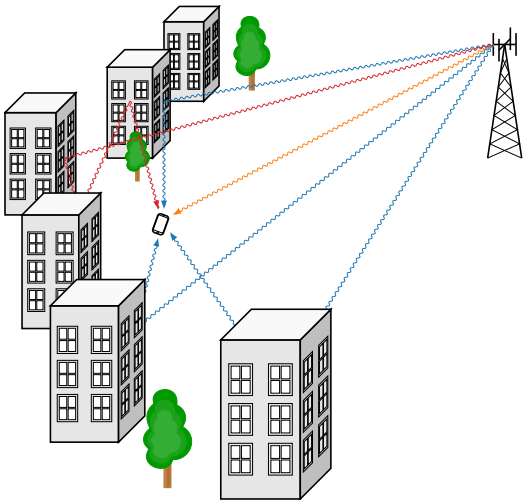

На практике системы мобильной связи работают в условиях многолучевого распространения.

В результате множественных переотражений принимается суперпозиция передаваемого сигнала (оранжевый) и его задержанных отраженных копий (синий и красный) из-за разницы времени распространения лучей в пространстве.

Это приводит к дополнительной межсимвольной интерференции и ограничивает скорость передачи информации при использовании QAM модуляции.

Радиосигнал $s(t)$ на основе комплексной огибающей $z(t) = I(t) + jQ(t)$ имеет вид:

$$s(t) = I(t)\cos(\omega_0 t) - Q(t)\sin(\omega_0 t) \tag{1.29}$$

Пусть на приемнике наблюдается сигнал $r(t)$ как результат суперпозиции отраженных сигналов $s(t)$ от N различных источников с коэффициентами α_n и задержанных на τ_n:

$$\begin{aligned} r(t) &= \sum_{n=0}^{N-1} \alpha_n s(t-\tau_n) = \\ &= \sum_{n=0}^{N-1} \alpha_n I(t-\tau_n)\cos\big(\omega_0(t-\tau_n)\big) - \sum_{n=0}^{N-1} \alpha_n Q(t-\tau_n)\sin\big(\omega_0(t-\tau_n)\big) = \\ &= \sum_{n=0}^{N-1} \alpha_n I(t-\tau_n)\cos(\omega_0 t + \varphi_n) - \sum_{n=0}^{N-1} \alpha_n Q(t-\tau_n)\sin(\omega_0 t + \varphi_n), \end{aligned} \tag{1.30}$$

здесь $\varphi_n = -\omega_0 \tau_n$ — набег фазы несущей, возникающий при задержке распространения τ_n.

$$\hat{I}(t) = r(t)\cos(\omega_0 t) = \sum_{n=0}^{N-1} \alpha_n I(t-\tau_n)\cos(\omega_0 t + \varphi_n)\cos(\omega_0 t) -$$
$$- \sum_{n=0}^{N-1} \alpha_n Q(t-\tau_n)\sin(\omega_0 t + \varphi_n)\cos(\omega_0 t) =$$
$$= \frac{1}{2}\sum_{n=0}^{N-1} \alpha_n I(t-\tau_n)\cos(\varphi_n) +$$
$$+ \frac{1}{2}\sum_{n=0}^{N-1} \alpha_n I(t-\tau_n)\cos(2\omega_0 t + \varphi_n) -$$
$$- \frac{1}{2}\sum_{n=0}^{N-1} \alpha_n Q(t-\tau_n)\sin(\varphi_n) -$$
$$- \frac{1}{2}\sum_{n=0}^{N-1} \alpha_n Q(t-\tau_n)\sin(2\omega_0 t + \varphi_n). \qquad (1.31)$$

/* удаляется ФНЧ */

/* удаляется ФНЧ */

$$
\begin{aligned}
\hat{Q}(t) = r(t)\big(-\sin(\omega_0 t)\big) &= -\sum_{n=0}^{N-1} \alpha_n I(t-\tau_n)\cos(\omega_0 t+\varphi_n)\sin(\omega_0 t) + \\
&+ \sum_{n=0}^{N-1} \alpha_n Q(t-\tau_n)\sin(\omega_0 t+\varphi_n)\sin(\omega_0 t) = \\
&= -\frac{1}{2}\sum_{n=0}^{N-1} \alpha_n I(t-\tau_n)\sin(-\varphi_n) - \\
\text{/* удаляется ФНЧ */} \quad &- \frac{1}{2}\sum_{n=0}^{N-1} \alpha_n I(t-\tau_n)\sin(2\omega_0 t+\varphi_n) + \\
&+ \frac{1}{2}\sum_{n=0}^{N-1} \alpha_n Q(t-\tau_n)\cos(\varphi_n) - \\
\text{/* удаляется ФНЧ */} \quad &- \frac{1}{2}\sum_{n=0}^{N-1} \alpha_n Q(t-\tau_n)\cos(2\omega_0 t+\varphi_n).
\end{aligned}
\tag{1.32}
$$

$$
\begin{aligned}
\hat{I}(t) =& \frac{1}{2}\sum_{n=0}^{N-1}\alpha_n I(t-\tau_n)\cos(\varphi_n) - \frac{1}{2}\sum_{n=0}^{N-1}\alpha_n Q(t-\tau_n)\sin(\varphi_n);\\
\hat{Q}(t) =& \frac{1}{2}\sum_{n=0}^{N-1}\alpha_n I(t-\tau_n)\sin(\varphi_n) + \frac{1}{2}\sum_{n=0}^{N-1}\alpha_n Q(t-\tau_n)\cos(\varphi_n);
\end{aligned}
\tag{1.33}
$$

$$
\begin{aligned}
\hat{z}(t) = \hat{I}(t) + j\hat{Q}(t) =& \frac{1}{2}\sum_{n=0}^{N-1}\alpha_n I(t-\tau_n)\big(\cos(\varphi_n) + j\sin(\varphi_n)\big) +\\
/*\quad \times\frac{j}{j}\quad */ \qquad &+ \frac{1}{2}\sum_{n=0}^{N-1}\alpha_n Q(t-\tau_n)\big(j\cos(\varphi_n) - \sin(\varphi_n)\big) =\\
&= \frac{1}{2}\sum_{n=0}^{N-1}\alpha_n \exp(j\varphi_n)\big(I(t-\tau_n) + jQ(t-\tau_n)\big) =\\
&= \frac{1}{2}\sum_{n=0}^{N-1}\alpha_n \exp(j\varphi_n) z(t-\tau_n)
\end{aligned}
\tag{1.34}
$$

Таким образом мы можем описать эффект многолучевого распространения на входе приемника как выход трансверсального фильтра.

$$\hat{z}(t) = \sum_{n=0}^{N-1} \alpha_n \exp(j\varphi_n) z(t - \tau_n), \qquad \text{/* } 1/2 \text{ учтена в } \alpha_n \text{ */} \tag{1.35}$$

При движении приемника относительно передатчика коэффициенты α_n и φ_n меняются во времени $\alpha_n(t)$ и $\varphi_n(t)$ и в результате возникает эффект замирания сигнала, когда сигнал и его копии в результате интерференции с изменяющимися амплитудами и фазами искажают сигнал, делая невозможной его демодуляцию.

При увеличении скорости передачи информации передаваемый символ укорачивается во времени и многолучевость делает невозможным качественную демодуляцию.

Например, при разнице хода лучей в 60 метров, время распространения будет $\tau = 60/3 \cdot 10^8 = 2 \cdot 10^{-7}$ с.

Тогда при символьной скорости $1/\tau = 5 \cdot 10^6$ символов демодуляция будет невозможна, потому что символы будут интерферировать между собой.

Для уменьшения влияния многолучевости необходимо увеличивать длительность символа. Но при этом скорость передачи QAM снижается. Это противоречие неразрешимо. И хотя QAM модуляция использовалась в стандартах HSPA+, но дальнейшее развитие данной ветви виделось тупиковым.

К счастью, с 60-х годов прошлого века начались теоретические исследования технологии OFDM (orthogonal frequency-division multiplexing), которая окончательно сформировалась и была апробирована к середине 90-х годов.

Основная идея:

- Увеличить длительность символа, перейдя от N последовательно идущих символов к N параллельным.
- Спектр каждого из «удлиненного» символа станет узким.
- N узких по частоте символов передавать на N поднесущих, чтобы можно было их разделить на приемнике.
- Добавить защитные интервалы по времени и частоте, чтобы исключить влияние многолучевости.

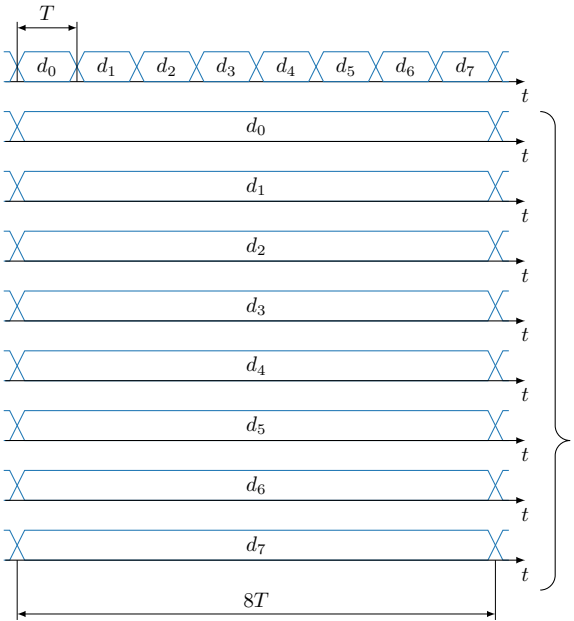

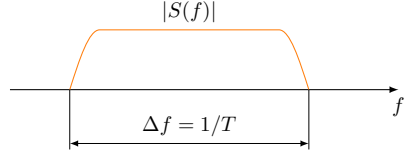

Перенос на поднесущие

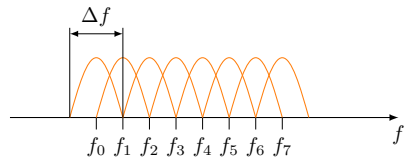

При переносе N параллельных символов из временно́й области на частотные поднесущие необходимо исключить их взаимное влияние.

Для этого необходимо ортогональное преобразование, в качестве которого выступает дискретное преобразование Фурье:

$$\begin{aligned} S_k &= \sum_{n=0}^{N-1} s_n \exp\left(-j\frac{2\pi nk}{N}\right), \qquad k = 0 \dots N-1; \\ s_n &= \frac{1}{N}\sum_{n=0}^{N-1} S_k \exp\left(j\frac{2\pi nk}{N}\right), \qquad n = 0 \dots N-1. \end{aligned} \tag{1.36}$$

Для передачи необходимо сформировать сигнал во времени, поэтому целесообразно кодировать поднесущие в частотной области по амплитуде и фазе и переходить во временну́ю область через ОДПФ.

На приемной стороне амплитуды и фазы поднесущих получаются в результате прямого ДПФ.

Для формирования амплитуды и фазы поднесущих в частотной области используется созвездие QAM.
Расчет ОДПФ производится с использованием алгоритмов быстрого преобразования Фурье.

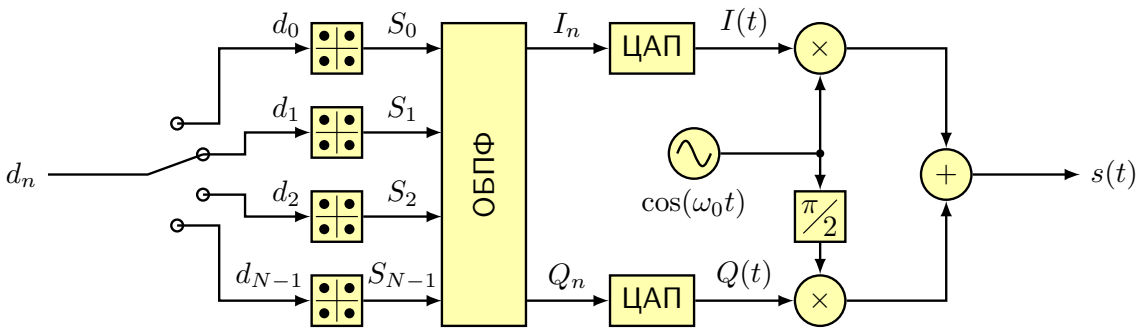

В результате длительность символа OFDM может быть неизменной при увеличении скорости передачи за счет увеличения числа поднесущих.

На приемной стороне выделяется комплексная огибающая $\hat{z}_n = \hat{I}_n + j\hat{Q}_n$ во времени n. Формируются буферы данных $\hat{z}_n$ размерности соответствующей N поднесущим и при использовании БПФ производится оценка амплитуд и фаз передаваемых поднесущих $\hat{S}_n$.

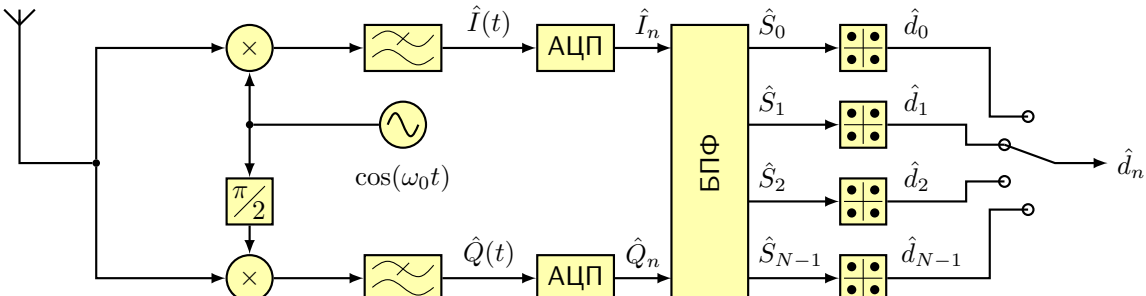

Амплитуды и фазы переводятся в цифровой код $\hat{d}_n$ через созвездие QAM и параллельные данные преобразуются в последовательный битовый поток.

Осциллограмма и спектральная плотность мощности сигнала LTE 20 МГц на частоте 1840 МГц

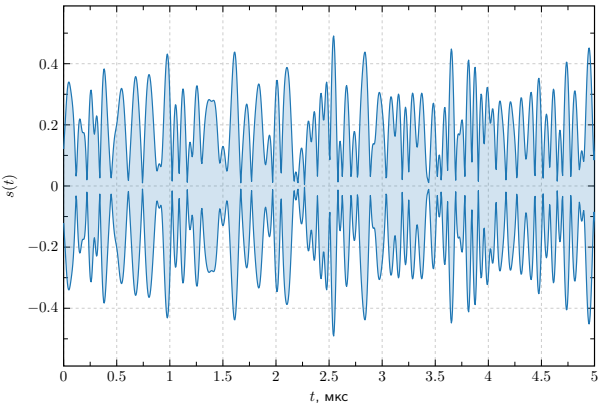

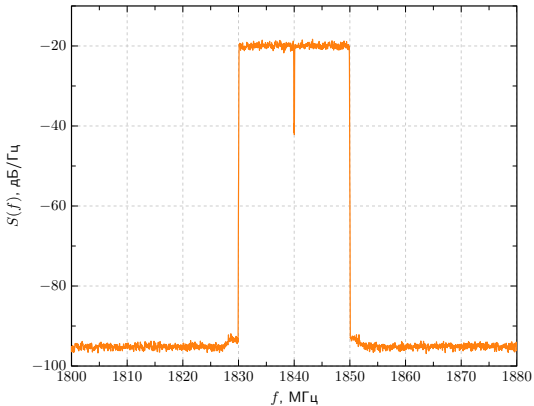

OFDM сигнал обладает очень высоким пик-фактором $PAPR \approx 12$ дБ.

§1.11. Неортогональный множественный доступ (NOMA)

Абоненты TDD

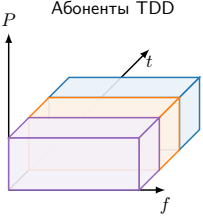

Абоненты FDD

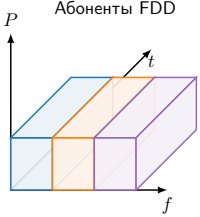

Абоненты OFDM

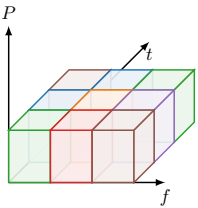

Абоненты NOMA

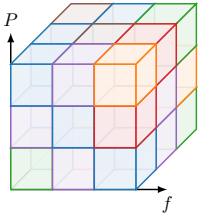

Новейшая, активно развивающаяся технология множественного доступа, которая выглядит как претендент на построение сетей 6G.

Основная идея — использовать совместное разделение по частоте, времени и мощности.

Позволяет существенно увеличить емкость сети за счет дополнительной адаптивной обработки на приемной стороне.

Принцип работы: несколько абонентов с разными уровнями мощности в одной полосе частот, которые влияют друг на друга, но могут быть разделены в приемнике.

Пример двухэтапного разделения двух неортогональных сигналов

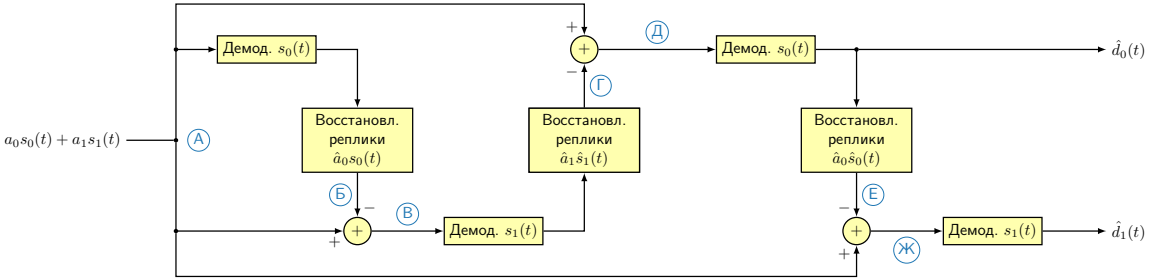

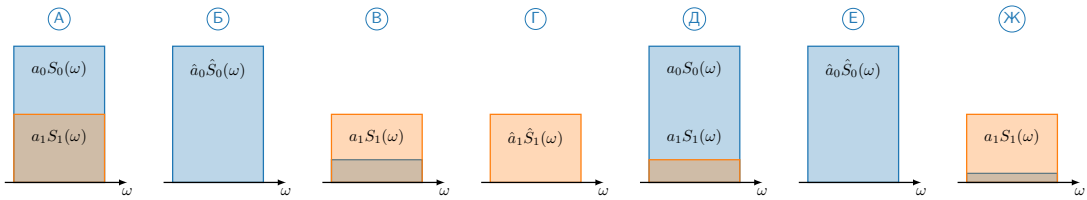

Лекция 2. Структуры адаптивных фильтров и их применение

§2.1. Структура цифрового КИХ-фильтра и его характеристики

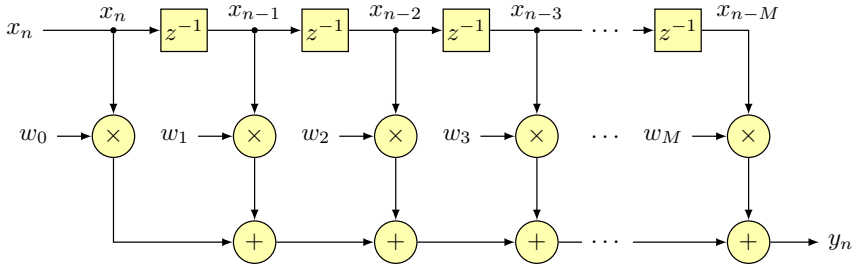

x_n и $y_n \in \mathbb{C}$ — входной и выходной дискретные сигналы, $w_m \in \mathbb{C}$ — коэффициенты фильтра порядка M: $m = 0 \dots M$. Порядок фильтра равен числу элементов задержки z^{-1}. Число коэффициентов КИХ-фильтра равно $M + 1$.

Выход КИХ-фильтра рассчитывается как свёртка входного сигнала и вектора коэффициентов:

$$y_n = \sum_{m=-\infty}^{\infty} x_{n-m} w_m = \sum_{m=0}^{M} x_{n-m} w_m. \tag{2.1}$$

Коэффициенты КИХ-фильтра полностью описывают его временну́ю импульсную характеристику h_n:

$$h_n = \begin{cases} w_n, & 0 \le n \le M; \\ 0, & n < 0, \quad \text{или} \quad n > M. \end{cases} \tag{2.2}$$

Для анализа частотных свойств фильтра вводят передаточную характеристику (функцию) $H(z)$ фильтра как результат z-преобразования импульсной характеристики:

$$H(z) = \sum_{n=0}^{M} h_n z^{-n} = \sum_{n=0}^{M} w_n z^{-n}, \tag{2.3}$$

а также комплексный коэффициент передачи $H(\mathrm{e}^{j\omega})$.
Комплексный коэффициент передачи $H(\mathrm{e}^{j\omega})$ получается подстановкой $z = \mathrm{e}^{j\omega}$ в передаточную функцию $H(z)$:

$$H(\mathrm{e}^{j\omega}) = \sum_{n=0}^{M} h_n \, \mathrm{e}^{-j\omega n} = \sum_{n=0}^{M} w_n \, \mathrm{e}^{-j\omega n} \, . \tag{2.4}$$

Модуль комплексного коэффициента передачи (2.4) описывает амплитудно-частотную характеристику фильтра (АЧХ) $H(\omega) = \left|H(\mathrm{e}^{j\omega})\right|$. АЧХ задает изменение **амплитуды сигнала** на выходе в зависимости от частоты.

Часто используют квадрат АЧХ в логарифмическом масштабе в единицах децибел:

$$|H(\omega)|^2 = 10\lg\left(\left|H(\mathrm{e}^{j\omega})\right|^2\right) = 20\lg\left(\left|H(\mathrm{e}^{j\omega})\right|\right), \quad \text{дБ} \tag{2.5}$$

Квадрат АЧХ определяет избирательные свойства фильтра, т.е. **зависимость изменения мощности сигнала** для различных частот при прохождении через фильтр.

Фазочастотная характеристика (ФЧХ) определяется как зависимость фазы $H(\mathrm{e}^{j\omega})$ от частоты:

$$\Phi(\omega) = \arctan\left(\frac{\mathrm{Im}\left[H(\mathrm{e}^{j\omega})\right]}{\mathrm{Re}\left[H(\mathrm{e}^{j\omega})\right]}\right). \tag{2.6}$$

ФЧХ определяет фазовые сдвиги, приобретаемые гармоническим сигналом на выходе фильтра в зависимости от частоты входного сигнала.

Групповое время запаздывания (ГВЗ), или групповая задержка фильтра $\tau(\omega)$ равна производной ФЧХ с отрицательным знаком:

$$\tau(\omega) = -\frac{d\Phi(\omega)}{d\omega}, \tag{2.7}$$

определяет зависимость временной задержки огибающей выходного сигнала относительно входного от частоты входного сигнала.

Важное практическое значение имеют КИХ-фильтры с постоянным ГВЗ (линейно-фазовые фильтры), потому что они обеспечивают одинаковую задержку выходного сигнала во всей полосе частот, которая может быть учтена при необходимости временного выравнивания сигналов.

Все вышеприведённые формулы справедливы как для фильтров с вещественными, так и для фильтров с комплексными коэффициентами.

Пример цифрового линейно-фазового КИХ-фильтра нижних частот порядка $M = 32$:

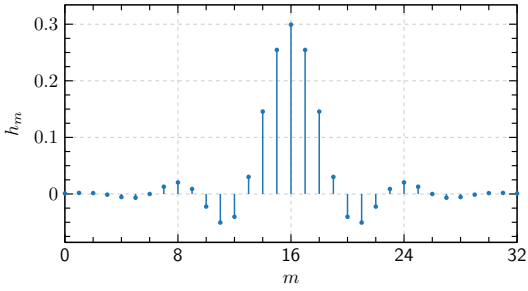

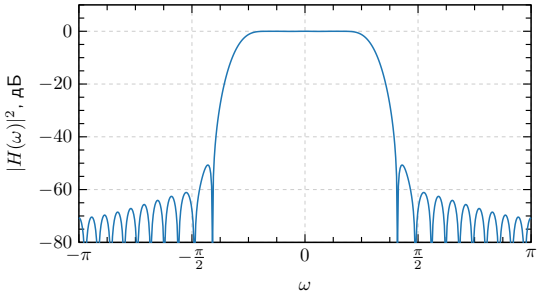

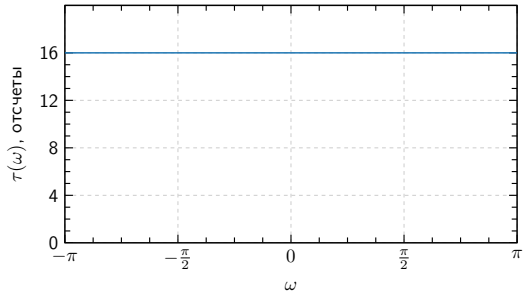

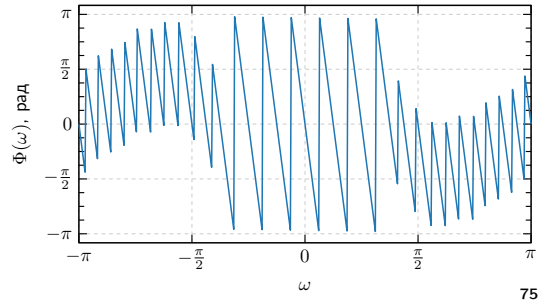

Лекция 2. Структуры адаптивных фильтров и их применение

§2.2. Описание КИХ-фильтра через вектор состояния

Вернемся к рассмотрению структуры КИХ-фильтра и введем понятие вектора состояния КИХ-фильтра $\mathbf{u}_n$ и вектора коэффициентов $\mathbf{w}$:

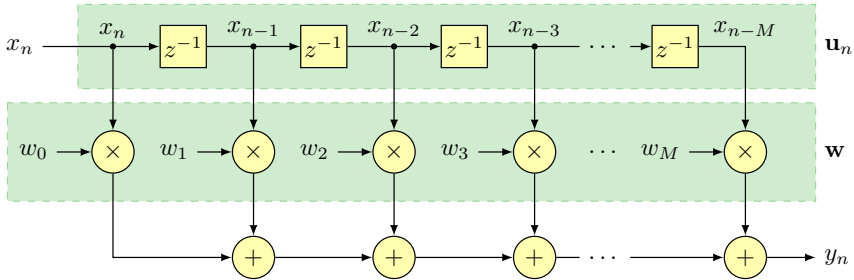

$$\mathbf{u}_n = \begin{bmatrix} x_n \\ x_{n-1} \\ x_{n-2} \\ \vdots \\ x_{n-M} \end{bmatrix}, \qquad \mathbf{w} = \begin{bmatrix} w_0 \\ w_1 \\ w_2 \\ \vdots \\ w_M \end{bmatrix}, \tag{2.8}$$

Тогда выход фильтра y_n можно представить в виде скалярного произведения вектора состояния $\mathbf{u}_n$ и вектора коэффициентов $\mathbf{w}$:

$$y_n = \sum_{m=0}^{M} x_{n-m} w_m = \mathbf{u}_n^T \mathbf{w} = \mathbf{w}^T \mathbf{u}_n. \tag{2.9}$$

Вектор $\mathbf{u}_n$ зависит от времени и каждый такт вектор состояния сдвигается, последний отсчет x_{n-M-1} выходит из вектора и добавляется новый отсчет x_n.

Важно отметить, что векторы состояния $\mathbf{u}_n$ в общем случае комплексные, но в выражении (2.9) используется именно транспонированный $\mathbf{u}_n^T$, а не эрмитово-сопряженный вектор $\mathbf{u}_n^H$.

Пусть входной сигнал задан блоком из N отсчётов, который представляет собой вектор $\mathbf{x}$ размера $[N \times 1]$:

$$\mathbf{x} = [x_0, \quad x_1, \quad x_2, \quad \ldots, \quad x_{N-1}]^T, \tag{2.10}$$

тогда $\mathbf{y}$ — вектор сигнала на выходе фильтра размера $[N \times 1]$.

Фильтр порядка M задан вектором коэффициентов $\mathbf{w}$ размера $[(M+1) \times 1]$.

Вектор выходного сигнала равен

$$\mathbf{y} = [y_0, \quad y_1, \quad y_2, \quad \ldots, \quad y_{N-1}]^T, \tag{2.11}$$

где каждый элемент y_n выходного вектора рассчитывается через скалярное произведение (2.9):

$$y_n = \mathbf{u}_n^T \mathbf{w}. \tag{2.12}$$

Объединив строки $\mathbf{u}_n^T$ в матрицу $\mathbf{U}$ размера $[N \times M+1]$, можно выходной вектор $\mathbf{y}$ представить как:

$$\mathbf{y} = \mathbf{U}\mathbf{w}, \tag{2.13}$$

где матрица $\mathbf{U}$ имеет вид:

$$\mathbf{U} = \begin{bmatrix} x_0 & 0 & 0 & \dots & 0 \\ x_1 & x_0 & 0 & \dots & 0 \\ x_2 & x_1 & x_0 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_M & x_{M-1} & x_{M-2} & \dots & x_0 \\ x_{M+1} & x_M & x_{M-1} & \dots & x_1 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{N-1} & x_{N-2} & x_{N-3} & \dots & x_{N-M-1} \end{bmatrix}. \tag{2.14}$$

Каждая строка матрицы $\mathbf{U}$ представляет собой транспонированный вектор состояния $\mathbf{u}_n^T$ для момента времени n.

§2.3. Понятие адаптивного КИХ-фильтра. Опорный сигнал и ошибка адаптации

Рассматривая характеристики КИХ-фильтра, мы предполагали, что его коэффициенты фиксированы. Однако для практических приложений часто требуется реализовать адаптивный фильтр, коэффициенты которого меняются во времени:

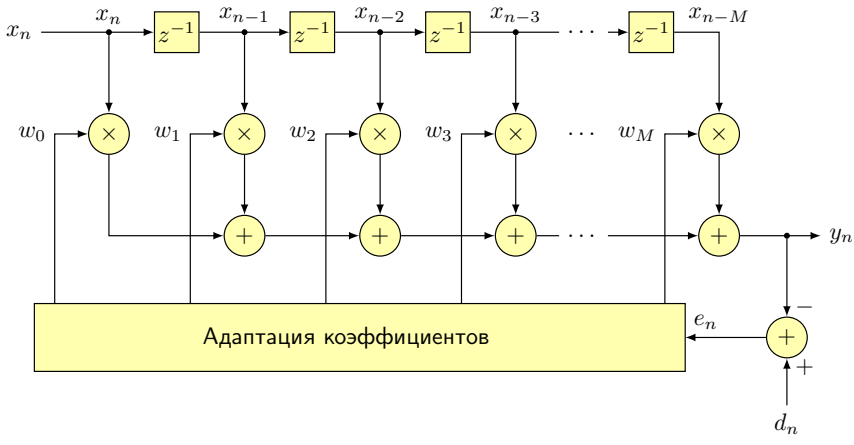

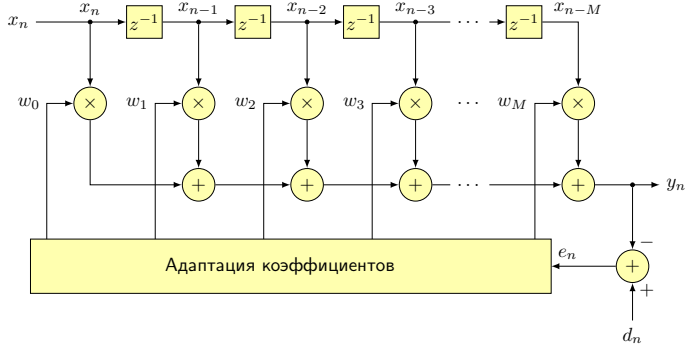

Адаптация коэффициентов фильтра производится с целью «максимального приближения» выхода фильтра y_n к опорному сигналу d_n, путем минимизации ошибки e_n:

$$e_n = d_n - y_n = d_n - \mathbf{u}_n^T \mathbf{w}. \tag{2.15}$$

В общем случае все сигналы и коэффициенты фильтра комплексные d_n, x_n, $y_n \in \mathbb{C}$.

§2.4. Типовые схемы применения адаптивных фильтров в системах передачи информации

Идентификация физического объекта

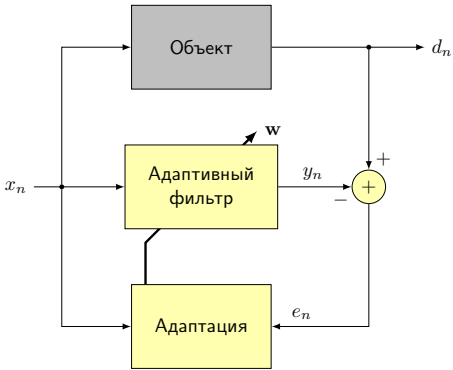

Пусть имеется неизвестный объект (чёрный ящик), через который мы можем пропускать сигнал x_n, и получить сигнал на выходе. Параллельно исследуемому объекту включается адаптивный фильтр, цель которого повторить выход исследуемого объекта при одинаковом входном сигнале.

В этом случае опорным сигналом d_n является выход исследуемого объекта, а ошибка $e_n = d_n - y_n$, где y_n — выход адаптивного фильтра.

Если в процессе идентификации ошибка e_n станет равной нулю, то это будет означать, что исследуемый объект полностью описывается фильтром с вектором коэффициентов $\mathbf{w}$.

Цифровой эквалайзер (предистортер)

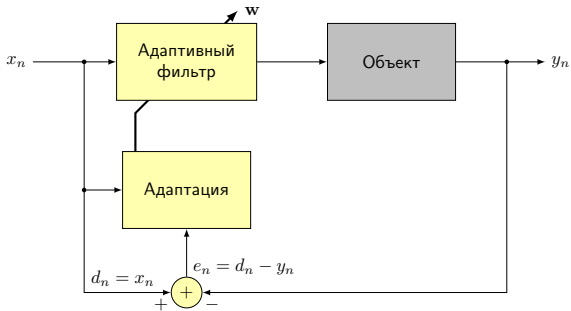

Адаптация заключается в минимизации искажений сигнала при прохождении через объект, т.е. в максимальном приближении выхода системы ко входу.

Если имеется некий радиотракт или устройство, как правило аналоговое, которое вносит некоторые искажения во входной сигнал, то можно применить адаптивный эквалайзер, который предысказит входной сигнал таким образом, что при прохождении предыскаженного сигнала через объект искажения объекта будут скомпенсированы.

Опорным сигналом в этом случае выступает входной сигнал $d_n = x_n$, при этом y_n описывает выход каскада адаптивный фильтр–объект.

Посткорректор

Если предистортер, как правило, используется в трактах передатчика, то для коррекции искажений на приемной стороне часто применяют посткорректор:

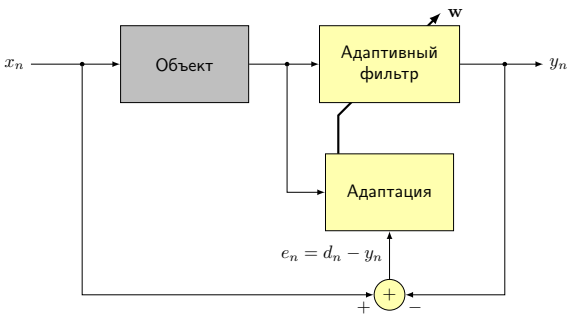

Вход адаптивного фильтра представляет собой выход корректируемого тракта, вносящего частотные искажения в передаваемый сигнал x_n.

Адаптация фильтра заключается в приближении выхода адаптивного фильтра ко входному сигналу.

Одной из задач при реализации посткорректора является получение чистого входного сигнала на приемной стороне системы. В качестве опорного сигнала $d_n = x_n$ в этом случае используют известные пилот-сигналы, по которым производят синхронизацию и адаптацию коэффициентов адаптивного фильтра.

Адаптивный предсказатель

Если в качестве объекта посткорректора используется элемент задержки, то получим структурную схему адаптивного предсказателя

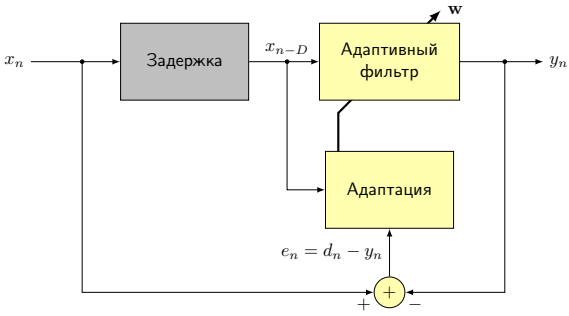

Поскольку элемент задержки включен перед адаптивным фильтром, то адаптивный фильтр наблюдает задержанные отсчеты входного сигнала x_{n-D}, где D — задержка входного сигнала.

В качестве опорного сигнала выступает незадержанный входной сигнал $d_n = x_n$. Таким образом адаптивный фильтр будет стремиться оценить текущий x_n по его задержанным отсчетам, т.е. предсказать x_n по его предыдущим отсчетам.

Разумеется, качество работы адаптивного предсказателя зависит от ширины пика автокорреляционной функции входного сигнала, т.е. от предсказуемости сигнала в будущем по его текущим отсчетам.

Активное шумоподавление

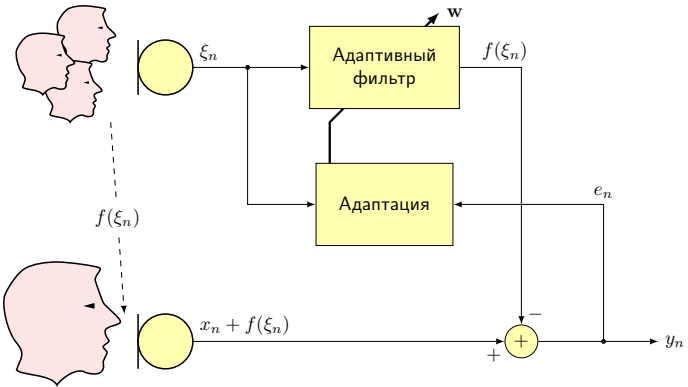

Как правило, дополнительный

Функция $f(x)$ описывает акустический канал между верхним и нижним микрофонами, учитывает задержку, ослабление и другие искажения шума ξ_n при прохождении сигнала от одного микрофона до другого. Адаптивный фильтр производит оценку этой функции и позволяет обеспечить шумоподавление в выходном сигнале y_n.

Активное эхоподавление

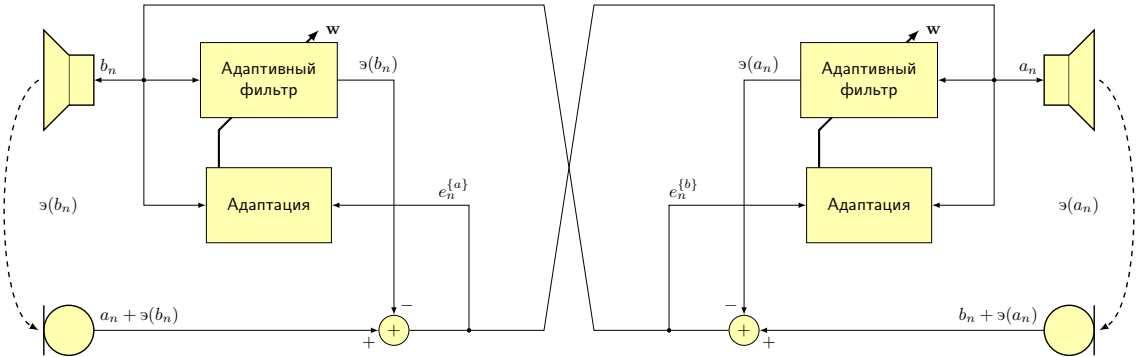

Сигналы a_n и b_n представляют собой сообщения двух абонентов в режиме разговора. В результате акустический сигнал с динамика попадает в микрофон абонента и добавляется к сообщению. Распространяясь по радиоканалу между абонентами возникает эхо, которое может быть подавлено при помощи адаптивного фильтра.

Акустические эхоподавители нашли широкое распространение в системах связи и позволяют работать в дуплексном режиме.

Активный научный интерес представляют технологии **Full Duplex** дуплексного режима при передаче сигналов канала uplink (от мобильного телефона к базовой станции) и downlink (от базовой станции к мобильному телефону) в одной полосе частот и разделение каналов посредством аналого-цифровых адаптивных фильтров.

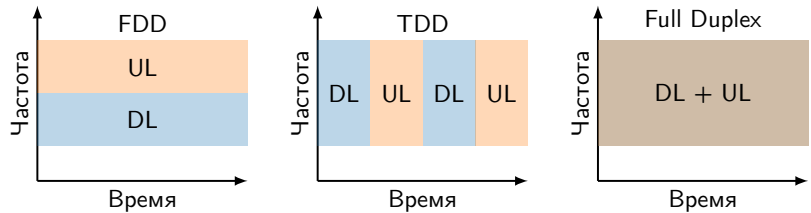

Решение данной задачи требует крайне высоких уровней подавления (более 120 дБ), что сопряжено со многими техническими сложностями, но интерес к данной технологии крайне высок ввиду возможности экономии самого дорогого частотного ресурса беспроводной системы связи.

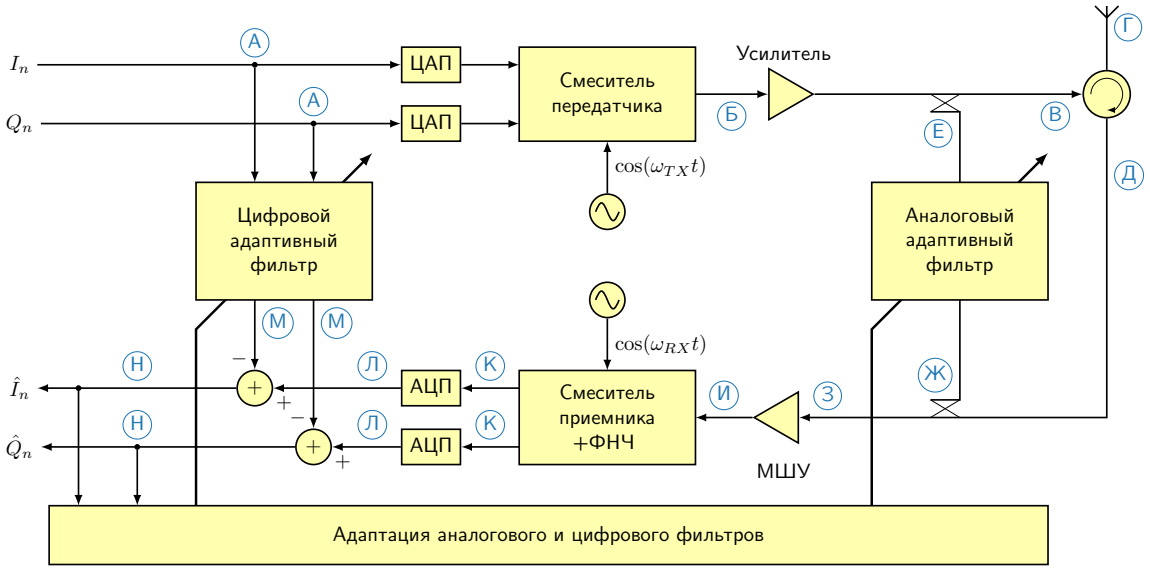
I_n
Q_n
А
А
ЦАП
ЦАП
Смеситель передатчика
Усилитель
Б
Г
В
Д
Е
$\cos(\omega_{TX}t)$
Цифровой адаптивный фильтр
Аналоговый адаптивный фильтр
М
М
$\cos(\omega_{RX}t)$
Н
Н
$\hat{I}_n$
$\hat{Q}_n$
Л
Л
К
К
АЦП
АЦП
Смеситель приемника +ФНЧ
И
З
Ж
МШУ
Адаптация аналогового и цифрового фильтров

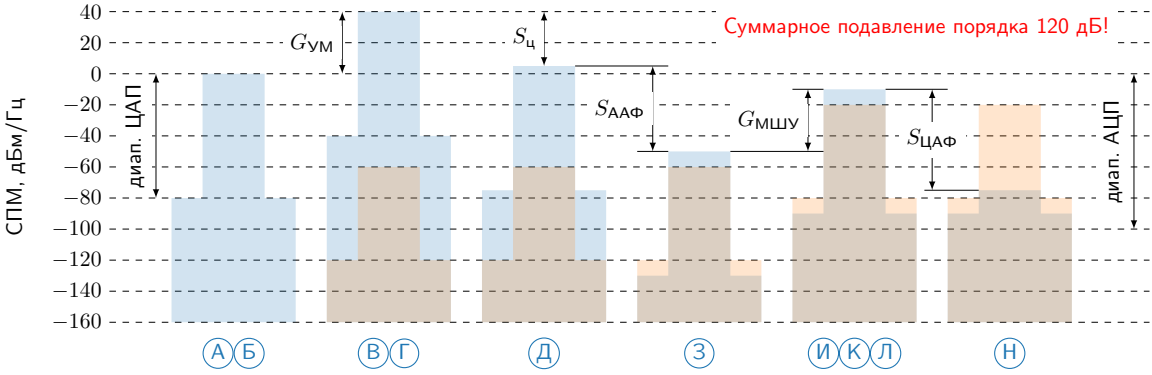

$G_{УМ}$ — коэффициент усиления передатчика;

$S_{ц}$ — ослабление циркулятором сигнала передатчика;

$S_{ААФ}$ — компенсация адаптивным аналоговым фильтром сигнала передатчика;

$G_{МШУ}$ — коэффициент усиления МШУ приемника;

$S_{ЦАФ}$ — компенсация адаптивным цифровым фильтром сигнала передатчика.

§2.5. Временны́е соотношения в линейном адаптивном фильтре

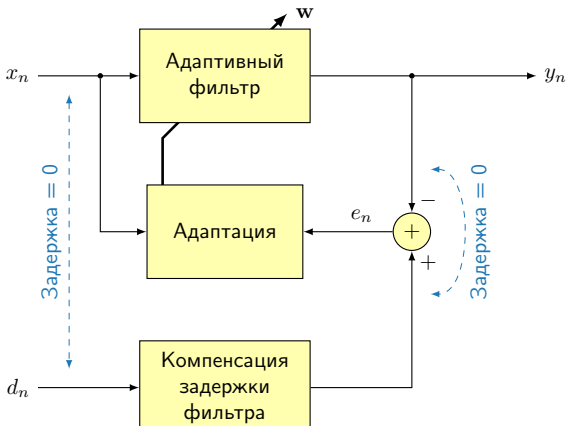

При прохождении сигнала x_n через фильтр выходной сигнал будет задержан на некоторую величину, в зависимости от порядка фильтра и его коэффициентов.

При адаптации коэффициентов фильтра $\mathbf{w}$ его задержка меняется.

Возникает противоречие: нам надо знать задержку фильтра для адаптации, которая зависит от неизвестных коэффициентов фильтра.

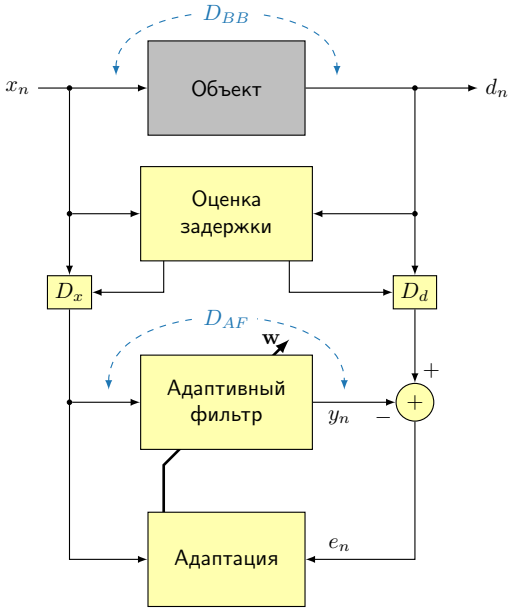

Пусть дан чёрный ящик и линейный адаптивный КИХ-фильтр для идентификации его параметров.

Поскольку мы знаем порядок адаптивного КИХ-фильтра, который производит идентификацию, то можем задать задержку выхода адаптивного фильтра равную $D_{AF} = M/2$ при чётном порядке M, или $D_{AF} = (M-1)/2$ при нечетном порядке фильтра.

Удобным понятием, которое используется при построении адаптивной системы, является понятие центра модели.

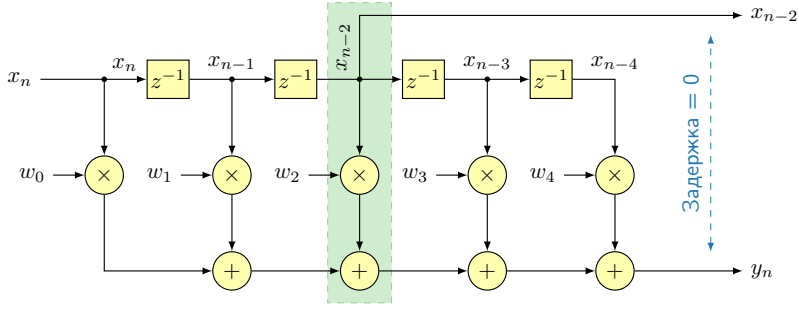

Задержка сигнала на выходе данного фильтра будет равна $D_{AF} = M/2 = 2$ отсчета, и если мы задержим входной сигнал на 2 отсчета, то выход и вход фильтра будут выровнены во времени.

В этом случае при задании вектора коэффициентов в виде

$$\mathbf{w} = [0,\ 0,\ 1,\ 0,\ 0]^T, \tag{2.16}$$

выход фильтра $y_n = x_{n-2}$.

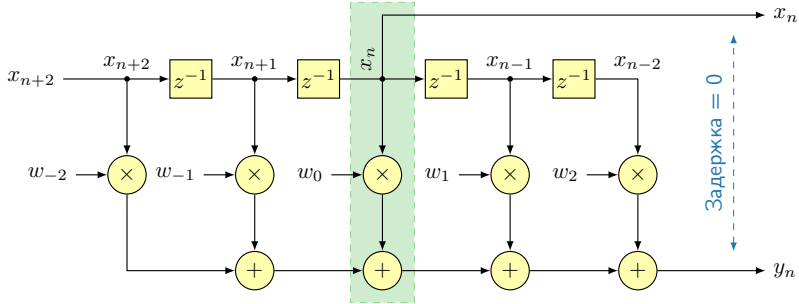

Данный фильтр использует два задержанных отсчёта x_n и два отсчета «из будущего» x_{n+1} и x_{n+2}.

Выход данного фильтра с нулевой задержкой:

$$y_n = \sum_{m=-D}^{D} w_m x_{n-m}, \qquad D = M/2, \tag{2.17}$$

для четного порядка M.

Векторы состояния фильтра при $M = 4$ для выборки сигнала длины N отсчетов при $n = 0 \dots N - 1$ имеют вид:

$$
\begin{array}{rccccc}
\mathbf{u}_0^T = [& x_2, & x_1, & x_0, & 0, & 0 &]; \\
\mathbf{u}_1^T = [& x_3, & x_2, & x_1, & x_0, & 0 &]; \\
\mathbf{u}_2^T = [& x_4, & x_3, & x_2, & x_1, & x_0 &]; \\
\mathbf{u}_3^T = [& x_5, & x_4, & x_3, & x_2, & x_1 &]; \\
\vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \\
\mathbf{u}_{N-4}^T = [& x_{N-2}, & x_{N-3}, & x_{N-4}, & x_{N-5}, & x_{N-6} &]; \\
\mathbf{u}_{N-3}^T = [& x_{N-1}, & x_{N-2}, & x_{N-3}, & x_{N-4}, & x_{N-5} &]; \\
\mathbf{u}_{N-2}^T = [& 0, & x_{N-1}, & x_{N-2}, & x_{N-3}, & x_{N-4} &]; \\
\mathbf{u}_{N-1}^T = [& 0, & 0, & x_{N-1}, & x_{N-2}, & x_{N-3} &].
\end{array}
\tag{2.18}
$$

Если задать в фильтре с нулевой задержкой центральный коэффициент $w_0 = 1$, а остальные $w_{-2} = w_{-1} = w_1 = w_2 = 0$, то сигнал на выходе фильтра будет в точности повторять входной сигнал.

§2.6. Критерий адаптации коэффициентов фильтра

В общем случае, все сигналы и коэффициенты фильтра комплексные. Соответственно, ошибка адаптации e_n также комплексная.

Для комплексных чисел не определены операции сравнения больше-меньше, а значит комплексное значение не может быть мерой качества работы.

Например, если один прибор показывает $1 + 3j$, а второй $3 + 1j$, то мы не можем сказать кто из них лучше, а кто хуже.

С другой стороны, входной и опорный сигналы, в общем случае, имеют случайный характер. Ошибка также в общем случае случайна. Критерий качества должен показывать некоторую усреднённую статистическую оценку.

В теории вероятности вводят параметр среднего квадрата отклонения (СКО) как показатель степени разброса сигнала относительно среднего значения. В данном случае СКО ошибки e_n от нуля будет естественным образом показывать степень отклонения выходного сигнала y_n от опорного d_n.

Тогда рассмотрим функцию $J(\mathbf{w})$, зависящую от значений вектора коэффициентов $\mathbf{w}$, которая может быть представлена в виде:

$$J(\mathbf{w}) = \mathrm{E}\left[|e_n|^2\right] = \mathrm{E}\left[e_n e_n^*\right], \tag{2.19}$$

где $\mathrm{E}[\bullet]$ — оператор математического ожидания, e_n^* — комплексно-сопряженная ошибка в момент времени n.

Функция $J(\mathbf{w})$ представляет собой зависимость среднего квадрата ошибки e_n от вектора коэффициентов $\mathbf{w}$ и может выступать в качестве критерия качества адаптивного фильтра.

Функция $J(\mathbf{w})$ является веществennозначной функцией комплексного векторного аргумента $\mathbf{w}$. Это значит, что для каждого произвольного вектора коэффициентов $\mathbf{w}$, функция $J(\mathbf{w})$ вернет вещественное неотрицательное число, которое будет характеризовать качество работы адаптивного фильтра (чем $J(\mathbf{w})$ меньше тем лучше).

Процесс адаптации фильтра заключается в изменении вектора коэффициентов $\mathbf{w}$ с целью минимизации $J(\mathbf{w})$:

$$J(\mathbf{w}) = \mathrm{E}\left[e_n e_n^*\right] \to \min_{\mathbf{w}}. \tag{2.20}$$

Таким образом, задача адаптации цифрового КИХ-фильтра сводится к задаче минимизации функции (2.20), относительно вектора коэффициентов $\mathbf{w}$.

Функция среднего квадрата ошибки является наиболее подходящей в качестве критерия качества ввиду того, что $J(\mathbf{w})$ является квадратичной функцией векторного аргумента $\mathbf{w}$, если ошибка e_n линейно зависит от вектора коэффициентов.

Лекция 3. Основные статистические свойства сигнала

§3.1. Статистические свойства сигналов

Цифровой сигнал x_n можно рассматривать как ансамбль дискретных случайных величин, которые можно наблюдать на входе (выходе) фильтра.

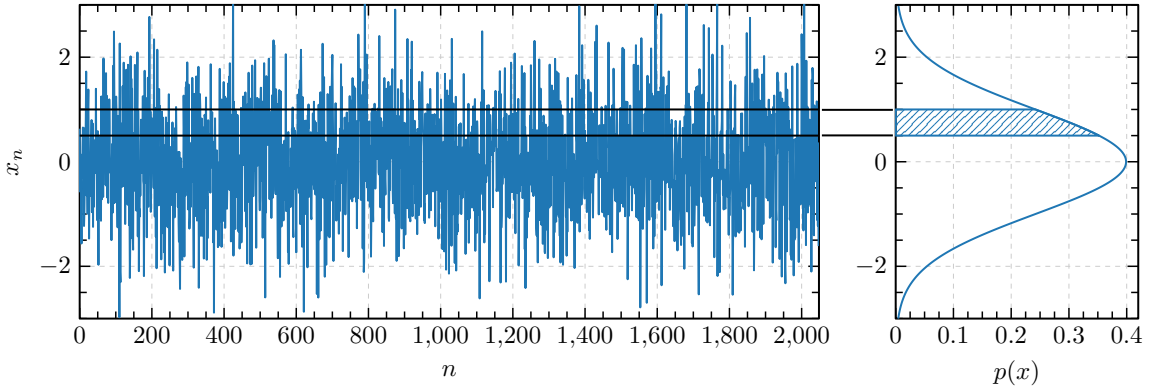

Функция плотности вероятности $p(x)$, показывает вероятность $\Pr\left[a < x_n \leq b\right]$ появления x_n в заданном интервале значений $(a,\ b]$:

$$\Pr\left[a < x_n \leq b\right] = \int_a^b p(x)\,dx. \tag{3.1}$$

Функция плотности вероятности $p(x)$ всегда возвращает неотрицательные значения, при этом вероятность появления значения x_n в интервале $-\infty < x_n < \infty$ равна единице:

$$\Pr\left[-\infty < x_n < \infty\right] = \int_{-\infty}^{\infty} p(x)\,dx = 1. \tag{3.2}$$

Математическим ожиданием (средним значением) называется величина

$$\mathrm{E}\left[x_n\right] = \int_{-\infty}^{\infty} xp(x)\,dx. \tag{3.3}$$

Начальным моментом порядка k процесса x_n называют величину μ_k равную

$$\mu_k = \mathrm{E}\left[x_n^k\right] = \int_{-\infty}^{\infty} x^k p(x)\,dx. \tag{3.4}$$

Практический интерес представляет второй начальный момент (средний квадрат):

$$\mu_2 = \mathrm{E}\left[x_n^2\right] = \int_{-\infty}^{\infty} x^2 p(x)\, dx. \tag{3.5}$$

Если $x_n \in \mathbb{C}$, то средний квадрат равен:

$$\mu_2 = \mathrm{E}\left[x_n x_n^*\right]. \tag{3.6}$$

Центральным моментом процесса x_n называют величину ν_k равную

$$\nu_k = \mathrm{E}\left[\Big(x_n - \mathrm{E}\left[x_n\right]\Big)^k\right] = \int_{-\infty}^{\infty} \Big(x - \mathrm{E}\left[x_n\right]\Big)^k p(x)\, dx, \tag{3.7}$$

где k обозначает порядок центрального момента.

Второй центральный момент называется дисперсией $\mathrm{Var}\left[x_n\right] = \nu_2$ и определяет среднюю мощность флуктуаций x_n относительно среднего значения:

$$\mathrm{Var}\left[x_n\right] = \nu_2 = \mathrm{E}\left[\left(x_n - \mathrm{E}\left[x_n\right]\right)^2\right] = \int_{-\infty}^{\infty}\left(x - \mathrm{E}\left[x_n\right]\right)^2 p(x)\,dx \tag{3.8}$$

Если $x_n \in \mathbb{C}$, то дисперсия равна:

$$\mathrm{Var}\left[x_n\right] = \underbrace{\mathrm{E}\left[\left(x_n - \mathrm{E}\left[x_n\right]\right)\left(x_n - \mathrm{E}\left[x_n\right]\right)^*\right]}_{\mathrm{E}\left[\left|x_n - \mathrm{E}[x_n]\right|^2\right]}. \tag{3.9}$$

Пусть x и y — случайные величины. Тогда взаимной ковариацией называется величина $\mathrm{Cov}[x,\, y]$ равная:

$$\mathrm{Cov}\left[x,\, y\right] = \mathrm{E}\left[\left(x - \mathrm{E}[x]\right)\left(y - \mathrm{E}[y]\right)^*\right]. \tag{3.10}$$

Коэффициентом корреляции случайных величин x и y называется r_{xy} равная:

$$r_{xy} = \frac{\mathrm{Cov}[x,\, y]}{\sqrt{\mathrm{Var}[x]\,\mathrm{Var}[y]}}. \tag{3.11}$$

Если x_n — случайный процесс, то вводят понятие автоковариации $c_{xx}[n,\, m]$ процесса в различные моменты времени n и m:

$$c_{xx}[n,\, m] = \mathrm{E}\left[\left(x_n - \mathrm{E}[x_n]\right)\left(x_m - \mathrm{E}[x_m]\right)^*\right], \tag{3.12}$$

а также понятие автокорреляции $r_{xx}[n,\, m]$

$$r_{xx}[n,\, m] = \mathrm{E}\left[x_n x_m^*\right]. \tag{3.13}$$

Можно заметить, что

$$c_{xx}[n,\, m] = \mathrm{E}\left[x_n x_m^*\right] - \mathrm{E}\left[x_n\right]\mathrm{E}\left[x_m^*\right] = r_{xx}[n,\, m] - \mathrm{E}\left[x_n\right]\mathrm{E}\left[x_m^*\right], \tag{3.14}$$

и для процесса с нулевым средним автокорреляция равна автоковариации.

Заметим, что в вышеприведенных выражениях $r_{xx}[n,\, m]$ и $c_{xx}[n,\, m]$ имеют двумерную зависимость как от n так и от m, это говорит, что они могут менять свои характеристики во времени (процессы нестационарны).

§3.2. Стационарность и эргодичность случайных процессов. Автокорреляционная функция и ее свойства

Процесс x_n называется стационарным в широком смысле[1], если:

$$\mathrm{E}\left[x_n\right] = \mathrm{const}, \quad \text{(не зависит от } n\text{)}, \tag{3.15}$$

$$\mathrm{Var}\left[x_n\right] = \mathrm{const}, \quad \text{(не зависит от } n\text{)}, \tag{3.16}$$

$$r_{xx}[n_1,\, n_2] = r_{xx}[m], \quad m = n_1 - n_2. \tag{3.17}$$

Для стационарного процесса можно рассматривать одномерную автокорреляционную функцию вида:

$$r_{xx}[m] = \mathrm{E}\left[x_{n+m}x_n^*\right] \tag{3.18}$$

Если заданы два стационарных процесса x_n и y_n, то можно говорить о взаимно-корреляционной функции $r_{xy}[m]$:

$$r_{xy}[m] = \mathrm{E}\left[x_{n+m}y_n^*\right] \tag{3.19}$$

[1] Случайный процесс называют стационарным в узком смысле, если все его характеристики зависят не от значений аргументов, а лишь от их взаимного расположения.

Пример автокорреляционной функции стационарного комплекснозначного случайного процесса.

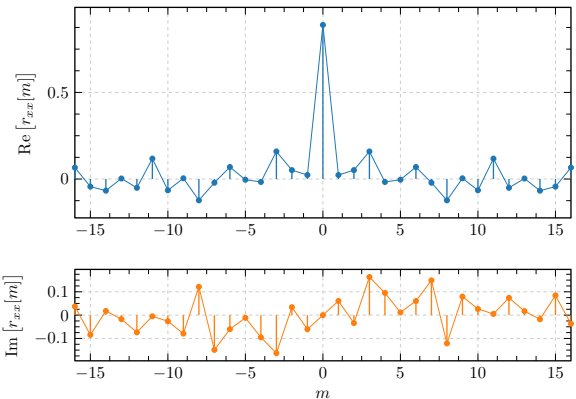

Свойства автокорреляционной $r_{xx}[m]$ и взаимно корреляционной функций $r_{xy}[m]$ стационарного процесса:

$$r_{xx}[0] \geq \left|r_{xx}[m]\right|; \tag{3.20}$$

$$r_{xx}[0]r_{yy}[0] \geq \left|r_{xy}[m]\right|^2; \tag{3.21}$$

$$r_{xx}[-m] = r^*_{xx}[m]; \tag{3.22}$$

$$r_{xy}[-m] = r^*_{yx}[m]. \tag{3.23}$$

§3.3. Спектральная плотность мощности случайного процесса

Теорема Винера-Хинчина устанавливает однозначную связь между автокорреляционной функцией $r_{xx}[m]$ стационарного процесса и его СПМ $X(f)$:

$$X(f) = \frac{1}{F_s} \sum_{m=-\infty}^{\infty} r_{xx}[m] \exp(-j2\pi f m / F_s), \tag{3.24}$$

где $T = 1/F_s$ — интервал дискретизации.
СПМ есть дискретно-временное преобразование Фурье автокорреляционной функции дискретного стационарного процесса (f — непрерывная частота!).

Единицы измерения СПМ [Вт/Гц], также для удобства вводят логарифмические шкалы:

$$10 \lg \Big(X(f) \Big), \ \text{[дБВт/Гц]}, \qquad 10 \lg \Big(X(f) \Big) + 30, \ \text{[дБм/Гц]}. \tag{3.25}$$

Для безразмерного цифрового сигнала СПМ имеет единицы измерения [1/Гц], или в логарифмическом масштабе [дБ/Гц].

Восстановление корреляционной функции путем взятия обратного дискретно-временного преобразования Фурье:

$$r_{xx}[m] = \frac{1}{T} \int_{-\frac{1}{2T}}^{\frac{1}{2T}} X(f) \exp(j2\pi f m T)\, df \tag{3.26}$$

$$r_{xx}[0] = \frac{1}{T} \int_{-\frac{1}{2T}}^{\frac{1}{2T}} X(f)\, df \tag{3.27}$$

Заметим, что для дискретного процесса интегрирование по частоте производится на одном периоде повторения СПМ от $-F_s/2 = -1/(2T)$ до $F_s/2 = 1/(2T)$ Гц.

Исходя из свойств симметрии корреляционной функции $r_{xx}[m]$, а также с учетом свойств преобразования Фурье, нетрудно показать, что $X(f)$ — вещественная, неотрицательная функция частоты f.

Спектральная плотность мощности — важнейший параметр показывающий распределение мощности сигнала по частоте. Информацию о спектральной плотности мощности часто используют в именовании процесса.

Огромное практическое значение имеет процесс в виде белого гауссовского шума. Термин «белый» в этом случае используют для обозначения СПМ как постоянной N_0 для всех частот.

СПМ и функция плотности вероятности дают полную информацию о характере стационарного процесса.

Обеспечение заданных спектральных масок — одно из основных назначений адаптивных фильтров (как линейных так и нелинейных) в составе системы.

§3.4. Выборочные оценки статистических параметров

Для **эргодического случайного процесса** можно заменить усреднение по ансамблю усреднением по времени. Таким образом можно производить оценки параметров сигнала по выборке данных, записанной в вектор $\mathbf{x}$ ограниченного размера N отсчётов.

Оценка статистических параметров, произведённая по ограниченной выборке (ансамблю выборок) называется выборочной оценкой **и является случайной величиной с собственным законом распределения, мат. ожиданием и дисперсией.**

Предположим мы имеем возможность произвести множество экспериментов по выборочной оценки $\widehat{\xi}$ некоторого известного параметра ξ: мат. ожидания, дисперсии, корреляционной функции, т.д.

Введем параметр смещения оценки

$$\Delta\left[\,\widehat{\xi}\,\right] = \xi - \mathrm{E}\left[\,\widehat{\xi}\,\right]. \tag{3.28}$$

При $\Delta\left[\,\widehat{\xi}\,\right] = 0$ оценка называется несмещенной.
Оценка $\widehat{\xi}$ называется состоятельной, если, с увеличением размера N выборки исходного сигнала $\mathbf{x}$, дисперсия оценки $\mathrm{Var}\left[\,\widehat{\xi}\,\right]$ уменьшается и

$$\lim_{N\to\infty} \mathrm{Var}\left[\,\widehat{\xi}\,\right] = 0, \tag{3.29}$$

Состоятельность говорит о том, что флюктуации оценки уменьшаются с ростом N, хотя смещение может сохраняться.

§3.5. Выборочные оценки математического ожидания, дисперсии, автокорреляционной функции и вектора взаимной корреляции

Выборочная несмещенная состоятельной оценка математического ожидания:

$$\widehat{\mathrm{E}}\big[x_n\big] = \frac{1}{N}\sum_{n=0}^{N-1} x_n \tag{3.30}$$

Выборочная несмещенная состоятельная оценка дисперсии:

$$\widehat{\mathrm{Var}}\big[x_n\big] = \frac{1}{N}\sum_{n=0}^{N-1} \big(x_n - \mu\big)\big(x_n - \mu\big)^*, \quad \text{при} \quad \mu = \mathrm{E}\left[x_n\right]; \tag{3.31}$$

$$\widehat{\mathrm{Var}}\big[x_n\big] = \frac{1}{N-1}\sum_{n=0}^{N-1} \big(x_n - \mu\big)\big(x_n - \mu\big)^*, \quad \text{при} \quad \mu = \widehat{\mathrm{E}}\big[x_n\big]. \tag{3.32}$$

Если в качестве значения математического ожидания μ используется истинное значение, то необходимо использовать выражение (3.31).
Если же истинное значение математического ожидания неизвестно, то можно использовать выборочную оценку $\widehat{\mathrm{E}}\big[x_n\big]$, и в этом случае несмещенная оценка дисперсии рассчитывается согласно (3.32).

Автокорреляционная функция $r_{xx}[m]$ дискретного случайного процесса x_n равна:

$$r_{xx}[m] = \mathrm{E}\left[x_{n+m}x_n^*\right]. \tag{3.33}$$

Если выборка исходного сигнала ограничена N отсчётами, то используя выборочную оценку среднего получим несмещенную состоятельную оценку автокорреляционной функции:

$$\widehat{r}_{xx}[m] = \widehat{\mathrm{E}}\left[x_{n+m}x_n^*\right] = \begin{cases} \dfrac{1}{N-m}\displaystyle\sum_{n=0}^{N-m-1} x_{n+m}x_n^*, & 0 \le m < N; \\ \dfrac{1}{N+m}\displaystyle\sum_{n=0}^{N+m-1} x_n x_{n-m}^*, & -N < m < 0. \end{cases} \tag{3.34}$$

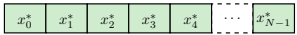

x_{n+m} для отрицательных $m < 0$

$$\widehat{r}_{xx}[m] = \widehat{\mathrm{E}}[x_{n+m}x_n^*] = \frac{1}{N+m}\sum_{n=0}^{N+m-1} x_n x_{n-m}^*$$

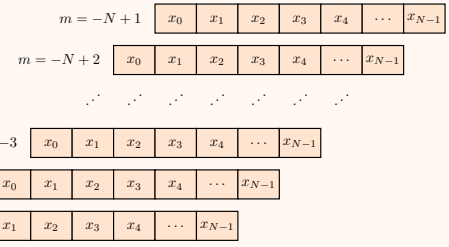

$$\widehat{r}_{xx}[0] = \widehat{\mathrm{E}}[x_n x_n^*] = \frac{1}{N}\sum_{n=0}^{N-1} x_n x_n^*$$

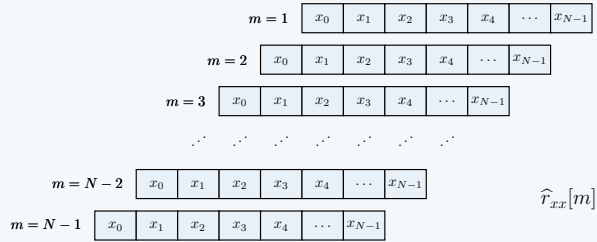

x_{n+m} для положительных $m > 0$

$$\widehat{r}_{xx}[m] = \widehat{\mathrm{E}}[x_{n+m}x_n^*] = \frac{1}{N-m}\sum_{n=0}^{N-m-1} x_{n+m}x_n^*$$

Расчет автокорреляционной функции через линейную дискретную свертку:

$$\widehat{r}_{xx}[m] = \mathrm{Conv}\left[x_n,\ \mathrm{Flip}\left[x_n^*\right]\right], \tag{3.35}$$

здесь $\mathrm{Conv}[\bullet]$ — оператор линейной свертки, а $\mathrm{Flip}[\bullet]$ — оператор зеркального отражения во времени.

Смещённая состоятельная оценка $\check{r}_{xx}[m]$ автокорреляционной функции:

$$\check{r}_{xx}[m] = \begin{cases} \dfrac{1}{N} \displaystyle\sum_{n=0}^{N-m-1} x_{n+m} x_n^*, & 0 \le m < N; \\ \dfrac{1}{N} \displaystyle\sum_{n=0}^{N+m-1} x_{n-m}^* x_n, & -N < m < 0. \end{cases} \tag{3.36}$$

Можно заметить, что

$$\check{r}_{xx}[m] = \frac{N - |m|}{N}\, \widehat{r}_{xx}[m] = w_m \widehat{r}_{xx}[m], \tag{3.37}$$

где w_m — треугольное окно, накладываемое на оценку $\widehat{r}_{xx}[m]$ для уменьшения флюктуаций $\widehat{r}_{xx}[m]$ с ростом модуля задержки $|m|$.

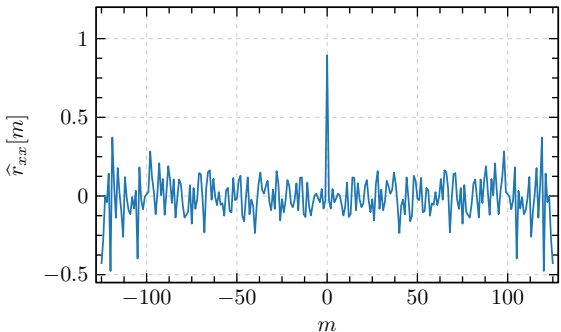

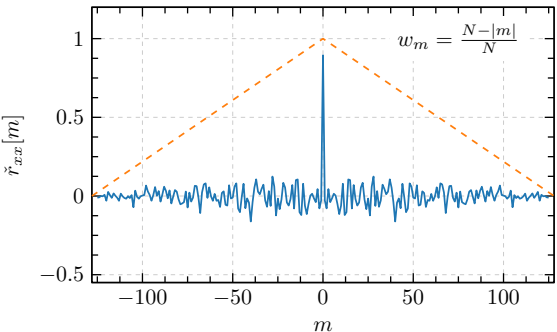

Смещение в виде треугольного окна w_m позволяет уменьшить данные флуктуации.

Смещённая оценка $\check{r}_{xx}[m]$ является более предпочтительной. При необходимости, вместо треугольного окна, может быть использована любая из известных оконная функция w_m.

Оценки взаимно-корреляционной функции процессов x_n и y_n, полученные при ограничении длины выборки N.
Несмещенная, состоятельная оценка $\widehat{r}_{xy}[m]$:

$$\widehat{r}_{xy}[m] = \widehat{\mathrm{E}}\big[x_{n+m}y_n^*\big] = \begin{cases} \dfrac{1}{N-m}\displaystyle\sum_{n=0}^{N-m-1} x_{n+m}y_n^*, & 0 \le m < N; \\ \dfrac{1}{N+m}\displaystyle\sum_{n=0}^{N+m-1} y_{n-m}^*x_n, & -N < m < 0. \end{cases} \tag{3.38}$$

Смещённая, состоятельная оценка $\check{r}_{xy}[m]$:

$$\check{r}_{xy}[m] = \frac{N-|m|}{N}\,\widehat{r}_{xy}[m] = w_m\widehat{r}_{xy}[m]. \tag{3.39}$$

Еще раз поясним смещение и состоятельность оценок.

Лекция 3. Основные статистические свойства сигнала

§3.6. Корреляционная матрица случайного процесса

С $2M+1$ центральными значениями автокорреляционной функцией $r_{xx}[m]$ связано понятие корреляционной матрицы $\mathbf{R}_{xx}$:

$$\mathbf{R}_{xx} = \begin{bmatrix} r_{xx}[0] & r_{xx}[-1] & r_{xx}[-2] & \dots & r_{xx}[-M] \\ r_{xx}[1] & r_{xx}[0] & r_{xx}[-1] & \dots & r_{xx}[-M+1] \\ r_{xx}[2] & r_{xx}[1] & r_{xx}[0] & \dots & r_{xx}[-M+2] \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ r_{xx}[m] & r_{xx}[M-1] & r_{xx}[M-2] & \dots & r_{xx}[0] \end{bmatrix}. \tag{3.40}$$

учтем, что $r_{xx}[-m] = r_{xx}^*[m]$, тогда:

$$\mathbf{R}_{xx} = \begin{bmatrix} r_{xx}[0] & r_{xx}^*[1] & r_{xx}^*[2] & \dots & r_{xx}^*[m] \\ r_{xx}[1] & r_{xx}[0] & r_{xx}^*[1] & \dots & r_{xx}^*[M-1] \\ r_{xx}[2] & r_{xx}[1] & r_{xx}[0] & \dots & r_{xx}^*[M-2] \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ r_{xx}[m] & r_{xx}[M-1] & r_{xx}[M-2] & \dots & r_{xx}[0] \end{bmatrix} = \mathbf{R}_{xx}^H. \tag{3.41}$$

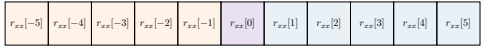
$r_{xx}[-5]$
$r_{xx}[-4]$
$r_{xx}[-3]$
$r_{xx}[-2]$
$r_{xx}[-1]$
$r_{xx}[0]$
$r_{xx}[1]$
$r_{xx}[2]$
$r_{xx}[3]$
$r_{xx}[4]$
$r_{xx}[5]$

§3.7. Выборочные оценки корреляционной матрицы

Пусть дана выборка сигнала длины N и необходимо оценить корреляционную матрицу размерности $M < N$. Исходя из структуры корреляционной матрицы:

$$\mathbf{R}_{xx} = \begin{bmatrix} r_{xx}[0] & r_{xx}[-1] & r_{xx}[-2] & \dots & r_{xx}[-M] \\ r_{xx}[1] & r_{xx}[0] & r_{xx}[-1] & \dots & r_{xx}[-M+1] \\ r_{xx}[2] & r_{xx}[1] & r_{xx}[0] & \dots & r_{xx}[-M+2] \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ r_{xx}[m] & r_{xx}[M-1] & r_{xx}[M-2] & \dots & r_{xx}[0] \end{bmatrix}. \tag{3.42}$$

Можно заметить:

$$\mathbf{R}_{xx}[m,\, p] = r_{xx}[m-p] = r^*_{xx}[p-m], \qquad m, p = 0 \dots M \tag{3.43}$$

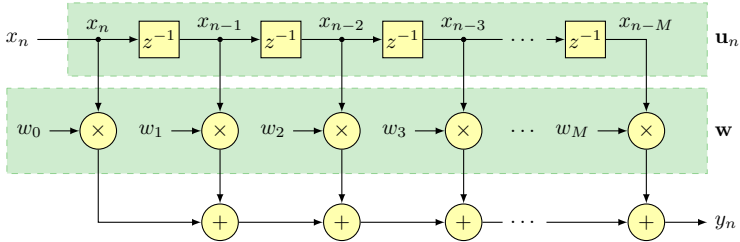

Рассмотрим квадратную матрицу $\mathbf{P}_n$ размерности $M+1$, которая представляет собой векторное произведение векторов состояния КИХ-фильтра.

$$\mathbf{P}_n = \left[\mathbf{u}_n \mathbf{u}_n^H\right]^T = \mathbf{u}_n^* \mathbf{u}_n^T. \tag{3.44}$$

Элемент $\mathbf{P}_n[m,\, p]$ можно представить как:

$$\mathbf{P}_n[m,\, p] = x_{n-m}^* x_{n-p}, \qquad m,\, p = 0 \ldots M. \tag{3.45}$$

Усредненим по времени матрицы $\mathbf{P}_n$ и получим квадратную матрицу $\mathbf{Q} = \mathrm{E}\left[\mathbf{P}_n\right]$.

Тогда элемент $\mathbf{Q}[m,p]$ равен:

$$\mathbf{Q}[m,\,p] = \mathrm{E}\left[x^*_{n-m}x_{n-p}\right], \qquad m,\,p = 0\ldots M. \tag{3.46}$$

Обозначим $k = n - m$, тогда $n - p = k + m - p$ и можно записать:

$$\mathbf{Q}[m,\,p] = \mathrm{E}\left[x_{k+m-p}x^*_k\right], \tag{3.47}$$

откуда с учётом (3.43):

$$\mathbf{Q}[m,\,p] = r_{xx}[m-p] = \mathbf{R}_{xx}[m,\,p]. \tag{3.48}$$

Окончательно можно записать выражение для корреляционной матрицы для блочной оценки:

$$\check{\mathbf{R}}_{xx} = \frac{1}{N}\sum_{n=0}^{N-1}\mathbf{u}^*_n\mathbf{u}^T_n \tag{3.49}$$

В предельном переходе при устремлении N к бесконечности:

$$\lim_{N\to\infty}\check{\mathbf{R}}_{xx} = \mathrm{E}\left[\mathbf{u}^*_n\mathbf{u}^T_n\right] \tag{3.50}$$

При блочной обработке, векторы-строки $\mathbf{u}_n^T$ могут быть объединены в матрицу $\mathbf{U}$ размерности $[N \times M+1]$, тогда оценку корреляционной матрицы можно записать в матричной форме:

$$\check{\mathbf{R}}_{xx} = \frac{1}{N}\mathbf{U}^H\mathbf{U}, \tag{3.51}$$

где $\mathbf{U}$ — матрица состояния системы при блочной обработки, которую мы вводили ранее:

$$\mathbf{U} = \begin{bmatrix} x_0 & 0 & 0 & \dots & 0 \\ x_1 & x_0 & 0 & \dots & 0 \\ x_2 & x_1 & x_0 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_m & x_{M-1} & x_{M-2} & \dots & x_0 \\ x_{M+1} & x_m & x_{M-1} & \dots & x_1 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{N-1} & x_{N-2} & x_{N-3} & \dots & x_{N-M-1} \end{bmatrix}. \tag{3.52}$$

§3.8. Основные свойства корреляционной матрицы

- Корреляционная матрица $\mathbf{R}_{xx}$ является эрмитовой, т.е. $\mathbf{R}_{xx} = \mathbf{R}_{xx}^H$.
- Корреляционная матрица $\mathbf{R}_{xx}$ является теплицевой, т.е. все элементы на диагоналях главного направления равны.
- Элементы главной диагонали равны среднему квадрату сигнала.
- $\mathbf{R}_{xx}$ является неотрицательно-определённой матрицей, т.е. для произвольного вектора $\mathbf{a}$ выполняется условие $\mathbf{a}^H \mathbf{R}_{xx} \mathbf{a} \geq 0$. Для доказательства воспользуемся (3.50):

$$\mathbf{a}^H \mathbf{R}_{xx} \mathbf{a} = \mathbf{a}^H \, \mathrm{E}\left[\mathbf{u}_n^* \mathbf{u}_n^T\right] \mathbf{a} = \mathrm{E}\left[\underbrace{\mathbf{a}^H \mathbf{u}_n^*}_{y_n^*} \underbrace{\mathbf{u}_n^T \mathbf{a}}_{y_n}\right] = \mathrm{E}\left[y_n^* y_n\right] \geq 0. \tag{3.53}$$

- Корреляционная матрица $\mathbf{R}_{xx}$ суммы двух независимых процессов $x_n = a_n + b_n$ равна сумме корреляционных матриц этих процессов:

$$\mathbf{R}_{xx} = \mathbf{R}_{aa} + \mathbf{R}_{bb}. \tag{3.54}$$

- Корреляционная матрица белого гауссова шума ξ_n с нулевым средним равна:

$$\mathbf{R}_{\xi\xi} = \mathrm{Var}\left[\xi_n\right]\mathbf{I}. \tag{3.55}$$

- Корреляционная матрица $\mathbf{R}_{xx}$ суммы сигнала и белого гауссова шума $x_n = a_n + \xi_n$ всегда невырожденная. Это означает, что для такого сигнала всегда существует обратная матрица $\mathbf{R}_{xx}^{-1}$.
- Блочная структура. Пусть имеется корреляционная матрица $\mathbf{R}_{xx}$ размерности $[(M+1)\times(M+1)]$ и мы хотим получить расширение данной матрицы до размера $[(M+2)\times(M+2)]$.

$$\underset{[(M+1)\times(M+1)]}{\mathbf{R}_{xx}} = \left[\begin{array}{ccc|c|c} & & & r_{xx}[M-1] & r_{xx}[M] \\ & \mathbf{R}_{xx} & & \vdots & r_{xx}[M-1] \\ & [M\times M] & & r_{xx}[1] & \vdots \\ \hline r_{xx}^*[M-1] & \cdots & r_{xx}^*[1] & r_{xx}[0] & r_{xx}[1] \\ \hline r_{xx}^*[M] & r_{xx}^*[M-1] & \cdots & r_{xx}^*[1] & r_{xx}[0] \end{array}\right]$$

§3.9. Выборочные оценки спектральной плотности мощности случайного процесса

Выборочные оценки спектральной плотности мощности (СПМ) делят на непараметрические и параметрические.

Непараметрические оценки:

- Метод коррелограмм
- Метод периодограмм
- Модифицированный метод периодограмм
- Метод периодограмм Бартлетта
- Метод периодограмм Уэлча

Параметрические оценки:

- АРСС методы
- Метод Прони
- Метод Писаренко
- Метод MUSIC

Марпл.-мл. С.Л. Цифровой спектральный анализ и его приложения. —М.: Мир, 1990. —584с. ISBN 5-03-001191-9

Метод коррелограмм

$$\hat{X}(f) = T \sum_{n=-D}^{D} w_n \hat{r}_{xx}[n] \exp\left(-j2\pi f n T\right) \tag{3.56}$$

Представляет собой оценку СПМ через дискретно-временное преобразование Фурье взвешенной оценки АКФ.

Может давать как смещенную (при использовании оконного сглаживания w_n), так и несмещенную оценку.

Оценка является состоятельной (флуктуации уменьшаются с ростом длины выборки).

Не рекомендуется использовать окна, чей спектр имеет отрицательные боковые лепестки (Хемминга, Блэкмана и т.д.).

$$x_n = \cos(2\pi 0.26n) + 0.1\cos(2\pi 0.2n) + 0.1\xi_n$$

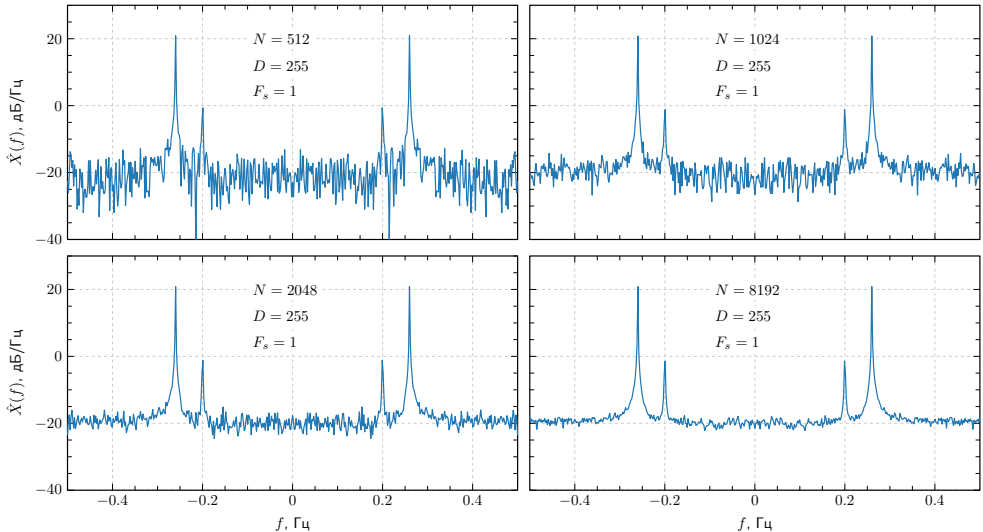

Метод периодограмм

$$\hat{X}(f) = \frac{1}{UF_s} \left| \sum_{n=0}^{N-1} w_n x_n \exp\left(-j2\pi f n\right) \right|^2 \tag{3.57}$$

$$U = \sum_{n=0}^{N-1} w_n^2 \tag{3.58}$$

Использует аппарат преобразования Фурье для анализа СПМ временно́го ряда x_n.
Оценка является смещенной и несостоятельной.

$$x_n = \cos(2\pi 0.26n) + 0.1\cos(2\pi 0.2n) + 0.1\xi_n$$

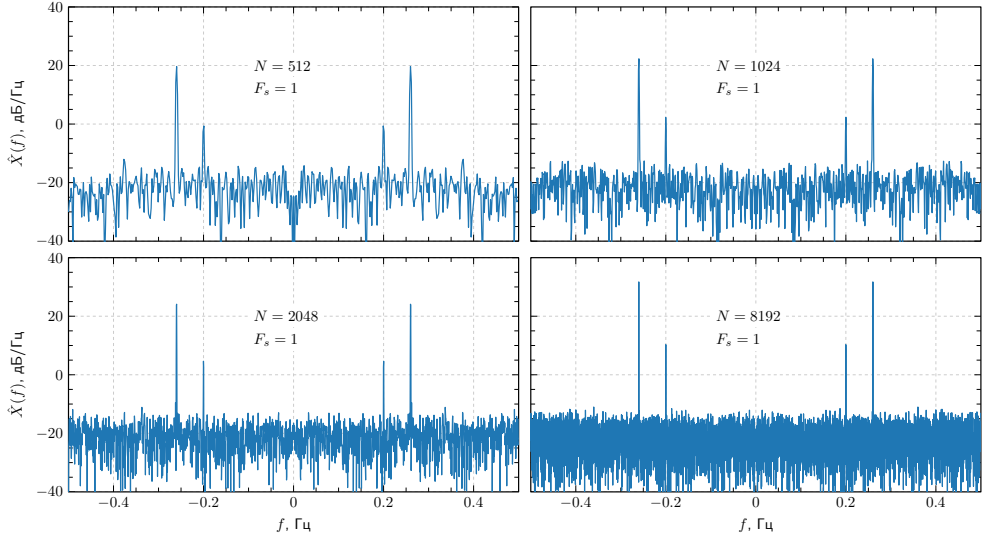

Метод Бартлетта

$$\hat{X}(f) = \frac{1}{NF_s} \sum_{p=0}^{P-1} \left| \sum_{m=0}^{n_{\mathsf{FFT}}-1} x_{m+pn_{\mathsf{FFT}}} \exp\left(-j2\pi fm\right) \right|^2, \tag{3.59}$$

где F_s — частота дискретизации (Гц), $P = N/n_{\mathsf{FFT}}$ – количество сегментов смещений выборки сигналов размера n_{FFT}.

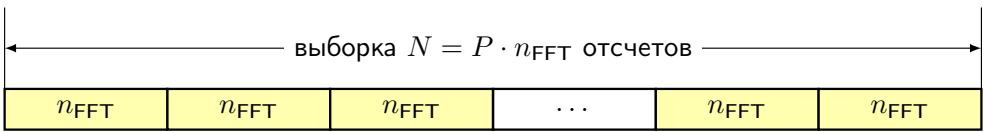

Метод Бартлетта заключается в разбиении выборки данных на сегменты и усредение периодограмм каждого сегмента. Оценка получается смещенной, но состоятельной.

Недостаток: отсутствие оконного сглаживания оценки (эффекты растекания при вычислении ДПФ).

Недостаток: отсутствие оконного сглаживания оценки (эффекты растекания при вычислении ДПФ).

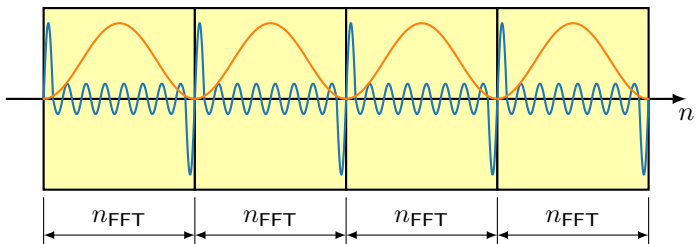

«Существенная неоднородность» в сигнале, которая попадает на границы блоков данных длины n_{FFT} будет подавлена окном.

$$x_n = \cos(2\pi 0.26n) + 0.1\cos(2\pi 0.2n) + 0.1\xi_n$$

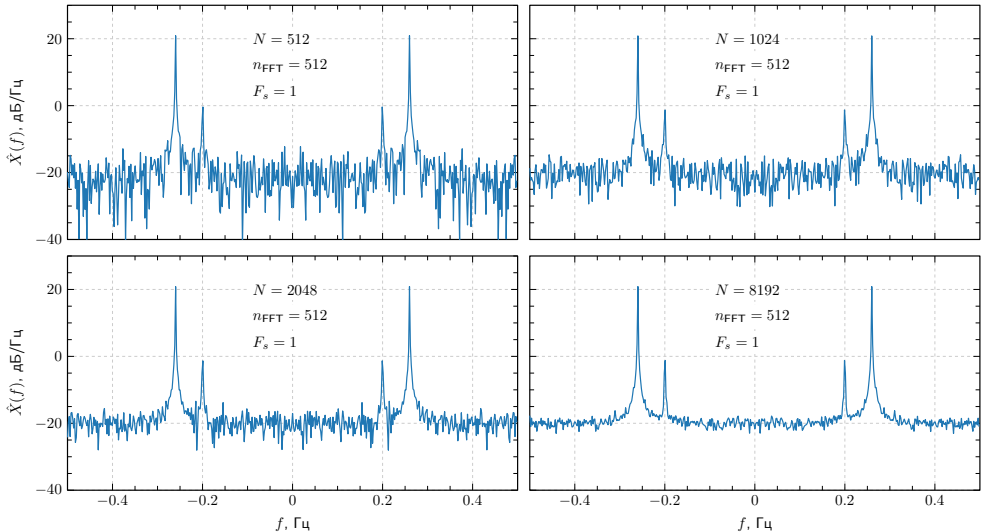

Метод Уэлча:

$$\hat{X}(f) = \frac{1}{UPF_s} \sum_{p=0}^{P-1} \left| \sum_{m=0}^{n_{\mathsf{FFT}}-1} w_m x_{m+pn_{\mathsf{overlap}}} \exp\left(-j2\pi fm\right) \right|^2 \tag{3.60}$$

где F_s — частота дискретизации (Гц), $P = n/n_{\mathsf{FFT}}$ – количество сегментов смещений выборки сигналов размера n_{FFT}.

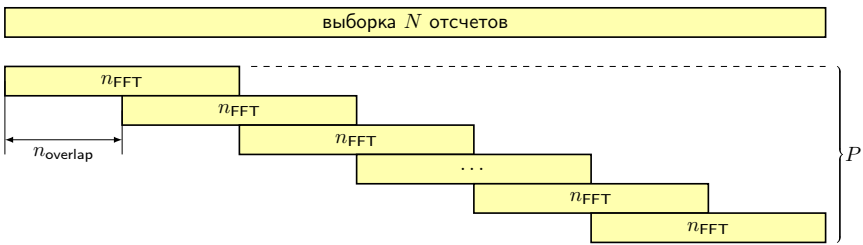

Метод Уэлча наиболее распространенный метод непараметрического оценивания СПМ.

$$x_n = \cos(2\pi 0.26n) + 0.1\cos(2\pi 0.2n) + 0.1\xi_n$$

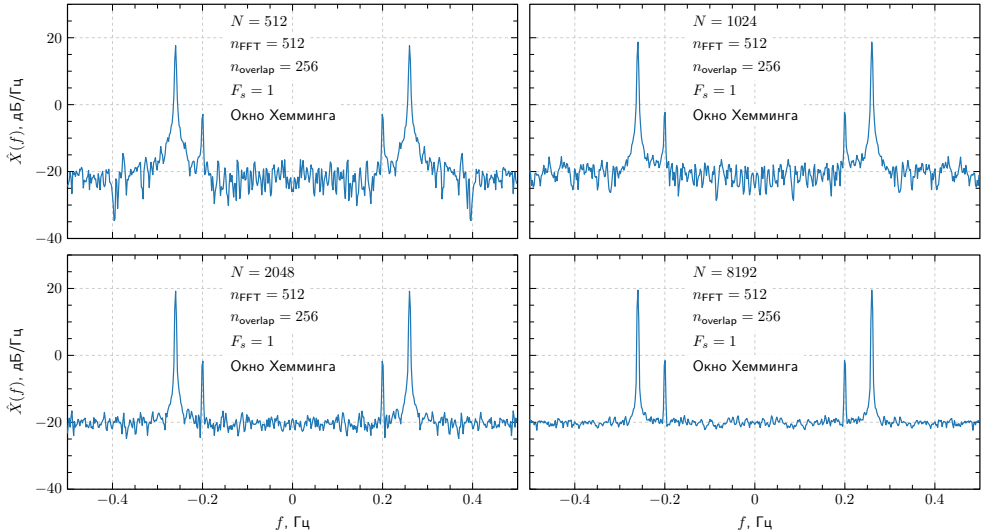

§4.1. Функции скалярного, векторного и матричного аргумента

Функции могут иметь на входе скаляр, вектор, матрицу.

Функции могут возвращать скаляр, вектор, матрицу.

Функции могут принимать и возвращать как вещественные, так и комплексные значения в произвольной комбинации.

	$f(\bullet)$	$\mathbf{f}(\bullet)$	$\mathbf{F}(\bullet)$
$x \in \mathbb{R}$ или $\mathbb{C}$	$f(x)$	$\mathbf{f}(x)$	$\mathbf{F}(x)$
$\mathbf{x} \in \mathbb{R}^N$ или $\mathbb{C}^N$	$f(\mathbf{x})$	$\mathbf{f}(\mathbf{x})$	$\mathbf{F}(\mathbf{x})$
$\mathbf{X} \in \mathbb{R}^{N\times M}$ или $\mathbb{C}^{N\times M}$	$f(\mathbf{X})$	$\mathbf{f}(\mathbf{X})$	$\mathbf{F}(\mathbf{X})$

Например $\mathbf{f}(x) \in \mathbb{C}^N$, $x \in \mathbb{R}$ — комплексная векторная функция вещественного скалярного аргумента.

Критерий минимума среднего квадрата ошибки:

$$J(\mathbf{w}) = \mathrm{E}\left[e_n e_n^*\right] \to \min_{\mathbf{w}} \tag{4.1}$$

Тогда выражение (4.1) представляет собой вещественнозначную скалярную функцию комплексного векторного аргумента $\mathbf{w}$.

Для комплексных чисел и векторов операции сравнения не определены, поэтому минимизировать можно только вещественнозначные скалярные функции.

$$f(x),\ f(\mathbf{x}),\ f(\mathbf{X}) \in \mathbb{R} \tag{4.2}$$

Ограничения на аргумент функции не накладывается. Аргумент может быть как вещественным (скалярным, векторным или матричным), так и комплексным.

В данной части мы будем рассматривать вещественнозначные функции вещественного векторного аргумента. Функции комплексного аргумента будут рассмотрены в следующих разделах.

Известно, что $f(x) \in \mathbb{R}$, $x \in \mathbb{R}$ достигает минимума в точке $x = x_{\text{opt}}$, если

$$\frac{d}{dx} f(x_{\text{opt}}) = 0, \quad \text{и} \quad \frac{d^2}{dx^2} f(x_{\text{opt}}) \geq 0. \tag{4.3}$$

Заметим, что при соблюдении условия $\frac{d^2}{dx^2} f(x_{\text{opt}}) > 0$ функция имеет сильный минимум, а при $\frac{d^2}{dx^2} f(x_{\text{opt}}) = 0$ — слабый минимум («плоское дно»).

Рассмотрим $f(\mathbf{x})$ — скалярную вещественную функция вещественного векторного аргумента $\mathbf{x} \in \mathbb{R}^N$.

При $N = 2$ получим функцию двух переменных, которую можно представить в виде 3D графика или двумерной проекции линий постоянного уровня на плоскость $\mathbf{x}$.

$$\mathbf{x} = \begin{bmatrix} x_0 \\ x_1 \end{bmatrix} = [x_0, \quad x_1]^T. \tag{4.4}$$

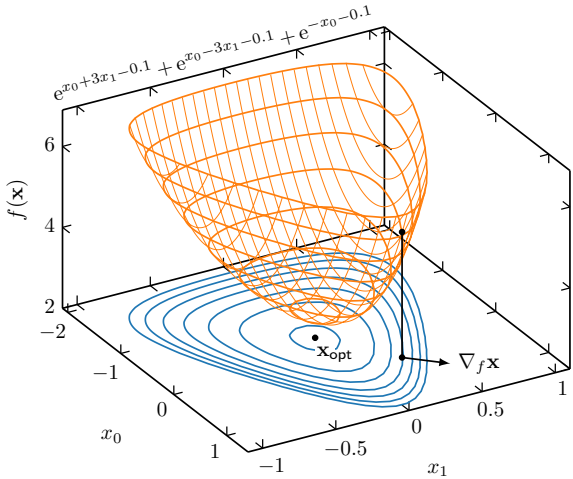

Градиентом функции $\nabla_f(\mathbf{x})$ называется вектор частных производных вида:

$$\nabla_f(\mathbf{x}) = \begin{bmatrix} \dfrac{\partial f(\mathbf{x})}{\partial x_0} \\ \dfrac{\partial f(\mathbf{x})}{\partial x_1} \end{bmatrix} \tag{4.5}$$

Градиент $\nabla_f(\mathbf{x})$ это векторная функция векторного аргумента, значение которой для каждой фиксированной точки $\mathbf{x_0}$ возвращает направление максимального роста $f(\mathbf{x})$ относительно точки $\mathbf{x_0}$.

Градиент из точки $\mathbf{x_0}$ всегда перпендикулярен линии уровня проходящей через эту точку.

Для векторной функции $\mathbf{f}(\mathbf{x}) \in \mathbb{R}^M$ векторного аргумента $\mathbf{x} \in \mathbb{R}^N$ матрицей Якоби $\mathbf{J}_\mathbf{f}(\mathbf{x}) \in \mathbb{R}^{M \times N}$ называется матрица частных производных вида:

$$\mathbf{J}_\mathbf{f}(\mathbf{x}) = \begin{bmatrix} \dfrac{\partial f_0(\mathbf{x})}{\partial x_0} & \dfrac{\partial f_0(\mathbf{x})}{\partial x_1} & \dfrac{\partial f_0(\mathbf{x})}{\partial x_2} & \cdots & \dfrac{\partial f_0(\mathbf{x})}{\partial x_{N-1}} \\ \dfrac{\partial f_1(\mathbf{x})}{\partial x_0} & \dfrac{\partial f_1(\mathbf{x})}{\partial x_1} & \dfrac{\partial f_1(\mathbf{x})}{\partial x_2} & \cdots & \dfrac{\partial f_1(\mathbf{x})}{\partial x_{N-1}} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \dfrac{\partial f_{M-1}(\mathbf{x})}{\partial x_0} & \dfrac{\partial f_{M-1}(\mathbf{x})}{\partial x_1} & \dfrac{\partial f_{M-1}(\mathbf{x})}{\partial x_2} & \cdots & \dfrac{\partial f_{M-1}(\mathbf{x})}{\partial x_{N-1}} \end{bmatrix} = \begin{bmatrix} \nabla^T_{f_0}(\mathbf{x}) \\ \nabla^T_{f_1}(\mathbf{x}) \\ \vdots \\ \nabla^T_{f_{M-1}}(\mathbf{x}) \end{bmatrix} \tag{4.6}$$

Матрица Якоби вектора градиента $\nabla_f(\mathbf{x})$ называется матрицей Гессе и представляет собой квадратную матрицу вторых частных производных:

$$\mathbf{J}_{\nabla_f}(\mathbf{x}) = \mathbf{H} = \begin{bmatrix} \dfrac{\partial^2 f(\mathbf{x})}{\partial x_0^2} & \dfrac{\partial^2 f(\mathbf{x})}{\partial x_1 \partial x_0} & \dfrac{\partial^2 f(\mathbf{x})}{\partial x_2 \partial x_0} & \cdots & \dfrac{\partial^2 f(\mathbf{x})}{\partial x_{N-1} \partial x_0} \\ \dfrac{\partial^2 f(\mathbf{x})}{\partial x_0 \partial x_1} & \dfrac{\partial^2 f(\mathbf{x})}{\partial x_1^2} & \dfrac{\partial^2 f(\mathbf{x})}{\partial x_2 \partial x_1} & \cdots & \dfrac{\partial^2 f(\mathbf{x})}{\partial x_{N-1} \partial x_1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \dfrac{\partial^2 f(\mathbf{x})}{\partial x_0 \partial x_{N-1}} & \dfrac{\partial^2 f(\mathbf{x})}{\partial x_1 \partial x_{N-1}} & \dfrac{\partial^2 f(\mathbf{x})}{\partial x_2 \partial x_{N-1}} & \cdots & \dfrac{\partial^2 f(\mathbf{x})}{\partial x_{N-1}^2} \end{bmatrix}. \quad (4.7)$$

Заметим, что если $f(\mathbf{x})$ является непрерывной, то порядок дифференцирования при вычислении вторых частных производных можно изменить:

$$\frac{\partial^2 f(\mathbf{x})}{\partial x_i \partial x_j} = \frac{\partial^2 f(\mathbf{x})}{\partial x_j \partial x_i}, \quad i, j = 0 \dots N-1. \tag{4.8}$$

Тогда матрица Гёссе (матрица Якоби градиента) является симметричной, т.е.

$$\mathbf{H}_f(\mathbf{x}) = \mathbf{H}_f^T(\mathbf{x}) = \mathbf{J}_{\nabla_f}(\mathbf{x}) = \mathbf{J}_{\nabla_f}^T(\mathbf{x}). \tag{4.9}$$

Для удобства, функции векторного аргумента записывают в матричных формах. Например:

$$f(\mathbf{x}) = a_0 x_0 + a_1 x_1 + \dots a_{N-1} x_{N-1} = \mathbf{a}^T \mathbf{x}, \quad \mathbf{a},\ \mathbf{x} \in \mathbb{R}^N. \tag{4.10}$$

$$f(\mathbf{x}) = \sum_{n=0}^{N-1} \sum_{m=0}^{M-1} a_{n,m} x_m y_n = \mathbf{y}^T \mathbf{A} \mathbf{x}, \tag{4.11}$$

где $\mathbf{y} \in \mathbb{R}^M$, $\mathbf{A} \in \mathbb{R}^{M \times N}$, $\mathbf{x} \in \mathbb{R}^N$ и $f(\mathbf{x}) \in \mathbb{R}$.

Квадратичная форма задаётся выражением:

$$f(\mathbf{x}) = \sum_{n=0}^{N-1} \sum_{m=0}^{N-1} a_{n,m} x_m x_n = \mathbf{x}^T \mathbf{A} \mathbf{x}, \quad \mathbf{x} \in \mathbb{R}^N,\ \mathbf{A} \in \mathbb{R}^{N \times N}. \tag{4.12}$$

§4.2. Дифференцирование функций в матричной форме

Компактные представления функций в матричной форме делают привлекательным дифференцирование функций по векторному аргументу. Например рассмотрим

$$f(\mathbf{x}) = \mathbf{a}^T\mathbf{x} = \mathbf{x}^T\mathbf{a} = \sum_{n=0}^{N-1} a_n x_n, \qquad \mathbf{x}, \mathbf{a} \in \mathbb{R}^N \tag{4.13}$$

Вектор градиента данной функции равен

$$\nabla_f(\mathbf{x}) = \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_{N-1} \end{bmatrix} = \mathbf{a} = \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}^T} = \frac{\partial \mathbf{x}^T\mathbf{a}}{\partial \mathbf{x}^T} \tag{4.14}$$

Аналогично для $f(\mathbf{x}) = \mathbf{y}^T\mathbf{A}\mathbf{x}$, где $\mathbf{x}, \mathbf{y} \in \mathbb{R}^N$, $\mathbf{A} \in \mathbb{R}^{N\times N}$:

$$\nabla_f(\mathbf{x}) = \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}^T} = \frac{\partial \mathbf{y}^T\mathbf{A}\mathbf{x}}{\partial \mathbf{x}^T} = \frac{\partial \mathbf{x}^T\mathbf{A}^T\mathbf{y}}{\partial \mathbf{x}^T} = \mathbf{A}^T\mathbf{y}. \tag{4.15}$$

Квадратичная форма $f(\mathbf{x}) = \mathbf{x}^T\mathbf{A}\mathbf{x}$. Рассмотрим квадратичную форму как скалярное произведение двух векторных функций векторного аргумента:

$$f(\mathbf{x}) = \mathbf{g}^T(\mathbf{x})\mathbf{h}(\mathbf{x}), \quad \mathbf{g}(\mathbf{x}) = \mathbf{x}, \quad \mathbf{h}(\mathbf{x}) = \mathbf{A}\mathbf{x}. \tag{4.16}$$

тогда можно представить $f(\mathbf{x})$ в виде:

$$f(\mathbf{x}) = \sum_{n=0}^{N-1} g_n(\mathbf{x})h_n(\mathbf{x}). \tag{4.17}$$

Вектор градиента можно записать как

$$\nabla_f(\mathbf{x}) = \begin{bmatrix} \dfrac{\partial}{\partial x_0} \displaystyle\sum_{n=0}^{N-1} g_n(\mathbf{x})h_n(\mathbf{x}) \\ \dfrac{\partial}{\partial x_1} \displaystyle\sum_{n=0}^{N-1} g_n(\mathbf{x})h_n(\mathbf{x}) \\ \vdots \\ \dfrac{\partial}{\partial x_{N-1}} \displaystyle\sum_{n=0}^{N-1} g_n(\mathbf{x})h_n(\mathbf{x}) \end{bmatrix} \tag{4.18}$$

$$\nabla f(\mathbf{x}) = \begin{bmatrix} \sum_{n=0}^{N-1} h_n(\mathbf{x}) \frac{\partial}{\partial x_0} g_n(\mathbf{x}) + \sum_{n=0}^{N-1} g_n(\mathbf{x}) \frac{\partial}{\partial x_0} h_n(\mathbf{x}) \\ \sum_{n=0}^{N-1} h_n(\mathbf{x}) \frac{\partial}{\partial x_1} g_n(\mathbf{x}) + \sum_{n=0}^{N-1} g_n(\mathbf{x}) \frac{\partial}{\partial x_1} h_n(\mathbf{x}) \\ \vdots \\ \underbrace{\sum_{n=0}^{N-1} h_n(\mathbf{x}) \frac{\partial}{\partial x_{N-1}} g_n(\mathbf{x})}_{\mathbf{J}_{\mathbf{g}}^T(\mathbf{x})\mathbf{h}(\mathbf{x})} + \underbrace{\sum_{n=0}^{N-1} g_n(\mathbf{x}) \frac{\partial}{\partial x_{N-1}} h_n(\mathbf{x})}_{\mathbf{J}_{\mathbf{h}}^T(\mathbf{x})\mathbf{g}(\mathbf{x})} \end{bmatrix} \tag{4.19}$$

$$\nabla f(\mathbf{x}) = \mathbf{J}_{\mathbf{g}}^T(\mathbf{x})\mathbf{h}(\mathbf{x}) + \mathbf{J}_{\mathbf{h}}^T(\mathbf{x})\mathbf{g}(\mathbf{x}) \tag{4.20}$$

$$\nabla_f(\mathbf{x}) = \mathbf{J}_{\mathbf{g}}^T(\mathbf{x})\mathbf{h}(\mathbf{x}) + \mathbf{J}_{\mathbf{h}}^T(\mathbf{x})\mathbf{g}(\mathbf{x})$$

Для квадратичной формы $f(\mathbf{x}) = \mathbf{x}^T\mathbf{A}\mathbf{x}$, $\mathbf{g}(\mathbf{x}) = \mathbf{x}$, $\mathbf{h}(\mathbf{x}) = \mathbf{A}\mathbf{x}$, тогда

$$\mathbf{J}_{\mathbf{g}}(\mathbf{x}) = \mathbf{I}, \quad \mathbf{J}_{\mathbf{h}}(\mathbf{x}) = \mathbf{A}, \tag{4.21}$$

и окончательно можно записать

$$\nabla_f(\mathbf{x}) = \mathbf{I}\mathbf{A}\mathbf{x} + \mathbf{A}^T\mathbf{x} = (\mathbf{A} + \mathbf{A}^T)\mathbf{x}. \tag{4.22}$$

Следствие: $f(\mathbf{x}) = \mathbf{x}^T\mathbf{x} = \mathbf{x}^T\mathbf{I}\mathbf{x}$:

$$\nabla_f(\mathbf{x}) = \left(\mathbf{I} + \mathbf{I}^T\right)\mathbf{x} = 2\mathbf{x}. \tag{4.23}$$

$f(\mathbf{x})$	$\nabla_f(\mathbf{x}) = \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}^T}$	$\nabla_f^T(\mathbf{x}) = \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}}$	$\mathbf{H} = \frac{\partial^2 f(\mathbf{x})}{\partial \mathbf{x} \partial \mathbf{x}^T}$
$\mathbf{a}^T\mathbf{b} = \mathbf{b}^T\mathbf{a}$	$\mathbf{0}$	$\mathbf{0}$	
$\mathbf{a}^T\mathbf{x} = \mathbf{x}^T\mathbf{a}$	$\mathbf{a}$	$\mathbf{a}^T$	$\mathbf{0}$
$\mathbf{y}^T\mathbf{A}\mathbf{x} = \mathbf{x}^T\mathbf{A}^T\mathbf{y}$	$\mathbf{A}^T\mathbf{y}$	$\mathbf{y}^T\mathbf{A}$	$\mathbf{0}$
$\mathbf{x}^T\mathbf{A}\mathbf{x}$	$(\mathbf{A}^T + \mathbf{A})\mathbf{x}$	$\mathbf{x}^T(\mathbf{A}^T + \mathbf{A})$	$\mathbf{A}^T + \mathbf{A}$
$\mathbf{x}^T\mathbf{x}$	$2\mathbf{x}$	$2\mathbf{x}^T$	$2\mathbf{I}$

$f(\mathbf{x}) = \mathbf{g}^T(\mathbf{x})\mathbf{h}(\mathbf{x}) = \mathbf{h}^T(\mathbf{x})\mathbf{g}(\mathbf{x})$, тогда

$$\nabla_f(\mathbf{x}) = \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}^T} = \mathbf{J}_{\mathbf{g}}^T(\mathbf{x})\mathbf{h}(\mathbf{x}) + \mathbf{J}_{\mathbf{h}}^T(\mathbf{x})\mathbf{g}(\mathbf{x})$$

$$\nabla_f^T(\mathbf{x}) = \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} = \mathbf{h}^T(\mathbf{x})\mathbf{J}_{\mathbf{g}}(\mathbf{x}) + \mathbf{g}^T(\mathbf{x})\mathbf{J}_{\mathbf{h}}^T(\mathbf{x})$$

Дифференцирование сложной функции $f\big(\mathbf{h}(\mathbf{x})\big)$, $\mathbf{x} \in \mathbb{R}^N$, $\mathbf{h}(\mathbf{x}) \in \mathbb{R}^M$.

$$\nabla_f(\mathbf{x}) = \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}^T} = \begin{bmatrix} \dfrac{\partial f(\mathbf{x})}{\partial x_0} \\ \vdots \\ \dfrac{\partial f(\mathbf{x})}{\partial x_{N-1}} \end{bmatrix}; \qquad \mathbf{J}_{\mathbf{h}}(\mathbf{x}) = \frac{\partial \mathbf{h}(\mathbf{x})}{\partial \mathbf{x}} = \begin{bmatrix} \dfrac{\partial h_0(\mathbf{x})}{\partial x_0} & \cdots & \dfrac{\partial h_0(\mathbf{x})}{\partial x_{N-1}} \\ \vdots & \ddots & \vdots \\ \dfrac{\partial h_{M-1}(\mathbf{x})}{\partial x_0} & \cdots & \dfrac{\partial h_{M-1}(\mathbf{x})}{\partial x_{N-1}} \end{bmatrix}. \quad (4.24)$$

Для начала рассмотрим векторную функцию $\mathbf{h}(x) \in \mathbb{R}^M$ скалярного аргумента $x \in \mathbb{R}$, тогда

$$\frac{\partial \mathbf{h}(x)}{\partial x} = \begin{bmatrix} \dfrac{\partial h_0(x)}{\partial x} \\ \vdots \\ \dfrac{\partial h_{M-1}(x)}{\partial x} \end{bmatrix}. \quad (4.25)$$

Теперь рассмотрим сложную функцию $f(\mathbf{h}(x))$. Ее производная по x может быть записана как:

$$\frac{\partial f(\mathbf{h}(x))}{\partial x} = \sum_{m=0}^{M-1} \frac{\partial f}{\partial h_m} \cdot \frac{\partial h_m}{\partial x} = \sum_{m=0}^{M-1} \frac{\partial h_m}{\partial x} \cdot \frac{\partial f}{\partial h_m} \tag{4.26}$$

Если сложная функция $f(\mathbf{h}(\mathbf{x}))$ зависит от многих переменных $\mathbf{x}$, то

$$\nabla_f(\mathbf{x}) = \begin{bmatrix} \dfrac{\partial f(\mathbf{h}(\mathbf{x}))}{\partial x_0} \\ \vdots \\ \dfrac{\partial f(\mathbf{h}(\mathbf{x}))}{\partial x_{N-1}} \end{bmatrix} = \begin{bmatrix} \displaystyle\sum_{m=0}^{M-1} \dfrac{\partial h_m}{\partial x_0} \cdot \dfrac{\partial f}{\partial h_m} \\ \vdots \\ \displaystyle\sum_{m=0}^{M-1} \dfrac{\partial h_m}{\partial x_{N-1}} \cdot \dfrac{\partial f}{\partial h_m} \end{bmatrix} = \mathbf{J}_{\mathbf{h}}^T(\mathbf{x}) \nabla_f(\mathbf{h}) \tag{4.27}$$

i-ый элемент вектора градиента есть результат скалярного произведения i-столбца матрицы Якоби $\mathbf{J}_{\mathbf{h}}(\mathbf{x})$ на вектор градиента $\nabla_f(\mathbf{h})$.

Окончательно можно записать:

$$\nabla_f(\mathbf{x}) = \frac{\partial f\big(\mathbf{h}(\mathbf{x})\big)}{\partial \mathbf{x}^T} = \underbrace{\left(\frac{\partial \mathbf{h}(\mathbf{x})}{\partial \mathbf{x}}\right)^T}_{\mathbb{R}^{N\times M}} \cdot \underbrace{\frac{\partial f(\mathbf{h})}{\partial \mathbf{h}^T}}_{\mathbb{R}^M} = \mathbf{J}_{\mathbf{h}}^T(\mathbf{x})\nabla_f(\mathbf{h}). \tag{4.28}$$

Например

$$f\big(\mathbf{h}(\mathbf{x})\big) = \mathbf{h}^T(\mathbf{x})\mathbf{B}\mathbf{h}(\mathbf{x}), \quad \mathbf{h}(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b}, \tag{4.29}$$

где
$\mathbf{x} \in \mathbb{R}^N$, $\mathbf{A} \in \mathbb{R}^{M\times N}$, $\mathbf{b} \in \mathbb{R}^M$, $\mathbf{h}(\mathbf{x}) \in \mathbb{R}^M$, $\mathbf{B} \in \mathbb{R}^{M\times M}$.
Тогда

$$\frac{\partial f(\mathbf{h})}{\partial \mathbf{h}^T} = (\mathbf{B}^T + \mathbf{B})\mathbf{h}(\mathbf{x}), \qquad \frac{\partial \mathbf{h}(\mathbf{x})}{\partial \mathbf{x}} = \mathbf{A}, \tag{4.30}$$

$$\nabla_f(\mathbf{x}) = \underbrace{\mathbf{A}^T}_{\mathbb{R}^{N\times M}} \underbrace{(\mathbf{B}^T + \mathbf{B})}_{\mathbb{R}^{M\times M}} \underbrace{(\mathbf{A}\mathbf{x} + \mathbf{b})}_{\mathbb{R}^{M\times 1}}. \tag{4.31}$$

§4.3. Квадратичная функция многих переменных и ее свойства

Важнейшее практическое значение имеет квадратичная функция $p(\mathbf{x})$:

$$p(\mathbf{x}) = \frac{1}{2}\mathbf{x}^T\mathbf{A}\mathbf{x} + \mathbf{b}^T\mathbf{x} + c, \tag{4.32}$$

где $\mathbf{x} \in \mathbb{R}^N$ — N-мерный векторный аргумент скалярной функции $p(\mathbf{x})$, $\mathbf{A} \in \mathbb{R}^{N\times N}$ — квадратная матрица размерности N, $\mathbf{b} \in \mathbb{R}^N$ — вектор линейной формы, c — свободное слагаемое (скаляр).

Градиент квадратичной функции равен:

$$\nabla_p(\mathbf{x}) = \frac{\partial p(\mathbf{x})}{\partial \mathbf{x}^T} = \frac{1}{2}\left(\mathbf{A}^T + \mathbf{A}\right)\mathbf{x} + \mathbf{b}. \tag{4.33}$$

$$\nabla_p(\mathbf{x}) = \underbrace{\frac{1}{2}\left(\mathbf{A}^T + \mathbf{A}\right)}_{\mathbf{H}=\frac{\partial \nabla_p(\mathbf{x})}{\partial \mathbf{x}}}\mathbf{x} + \mathbf{b}, \tag{4.34}$$

и квадратичная функция $p(\mathbf{x})$ имеет точку экстремума при $\nabla_p(\mathbf{x}) = \mathbf{0}$:

$$\mathbf{H}\mathbf{x} = -\mathbf{b}. \tag{4.35}$$

Заметим, что если $\mathbf{A} = \mathbf{A}^T$, т.е. является симметричной матрицей, то $\mathbf{H} = \mathbf{A}$.

В зависимости от матрицы $\mathbf{H}$ система может иметь единственное решение, не иметь решений, или иметь множество решений.

Так если $\mathbf{H}$ является невырожденной, то система имеет единственное решение, которое может быть минимум, максимумом или седловой точкой.

Если же матрица $\mathbf{H}$ вырождена, то система может не иметь ни одного решения, или иметь множество решений.

Для того чтобы проанализировать поведение квадратичной функции необходимо проверить матрицу $\mathbf{H}$ на определенность.

$$p(\mathbf{x}) = \frac{1}{2}\mathbf{x}^T\mathbf{A}\mathbf{x} + \mathbf{b}^T\mathbf{x} + c,$$

$$\mathbf{A} = \begin{bmatrix} 5 & 2 \\ 2 & 5 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \quad c = 5, \qquad (4.36)$$

$$\mathbf{H} = \mathbf{A}, \quad \lambda = \begin{bmatrix} 7 \\ 3 \end{bmatrix}. \qquad (4.37)$$

Если $\mathbf{H}$ является положительно определенной матрицей (т.е. все ее собственные числа λ являются отличными от нуля и положительными), то для всех значений $\mathbf{x}$ выполняется строгое неравенство $\mathbf{x}^T\mathbf{H}\mathbf{x} > 0$.

В этом случае имеется единственная точка, которая является точкой сильного минимума.

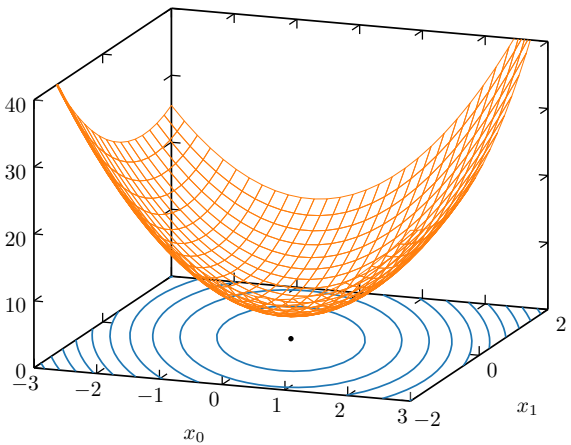

$$p(\mathbf{x}) = \frac{1}{2}\mathbf{x}^T\mathbf{A}\mathbf{x} + \mathbf{b}^T\mathbf{x} + c,$$

$$\mathbf{A} = \begin{bmatrix} 9 & 0 \\ 0 & 0 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \quad c = 5, \qquad (4.38)$$

$$\mathbf{H} = \mathbf{A}, \quad \lambda = \begin{bmatrix} 9 \\ 0 \end{bmatrix}. \qquad (4.39)$$

Если $\mathbf{H}$ является положительно полуопределенной матрицей (т.е. все ее собственные числа являются положительными и имеются также нулевые собственные числа), то для всех значений $\mathbf{x}$ выполняется неравенство $\mathbf{x}^T\mathbf{H}\mathbf{x} \geq 0$.

В этом случае матрица $\mathbf{H}$ является вырожденной, и имеется множество точек, которые определяют слабый минимум.

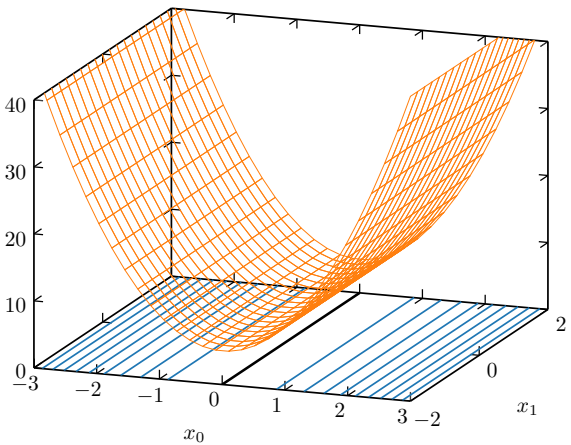

$$p(\mathbf{x}) = \frac{1}{2}\mathbf{x}^T\mathbf{A}\mathbf{x} + \mathbf{b}^T\mathbf{x} + c,$$

$$\mathbf{A} = \begin{bmatrix} 5 & 0 \\ 0 & -5 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \quad c = 20, \quad (4.40)$$

$$\mathbf{H} = \mathbf{A}, \quad \lambda = \begin{bmatrix} -5 \\ 5 \end{bmatrix}. \quad (4.41)$$

$\mathbf{A}$ является невырожденной, но неопределенной матрицей (т.е. ее собственные числа имеют различные знаки).

В этом случае квадратичная функция имеет единственный экстремум в виде седловой точки.

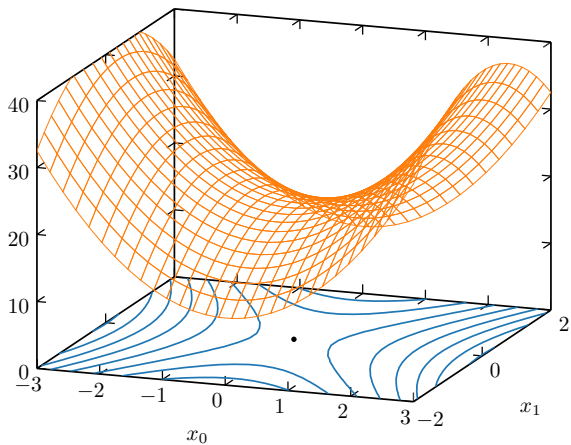

$$p(\mathbf{x}) = \frac{1}{2}\mathbf{x}^T\mathbf{A}\mathbf{x} + \mathbf{b}^T\mathbf{x} + c,$$

$$\mathbf{A} = \begin{bmatrix} -6 & 0 \\ 0 & -6 \end{bmatrix}, \qquad \mathbf{b} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \qquad c = 40, \tag{4.42}$$

$$\mathbf{H} = \mathbf{A}, \quad \lambda = \begin{bmatrix} -6 \\ -6 \end{bmatrix}. \tag{4.43}$$

Если $\mathbf{A}$ является отрицательно определенной матрицей (т.е. все ее собственные числа являются отличными от нуля и отрицательными), то для всех значений $\mathbf{x}$ выполняется строгое неравенство $\mathbf{x}^T\mathbf{A}\mathbf{x} < 0$.

В этом случае имеется единственный экстремум, который является точкой сильного максимума

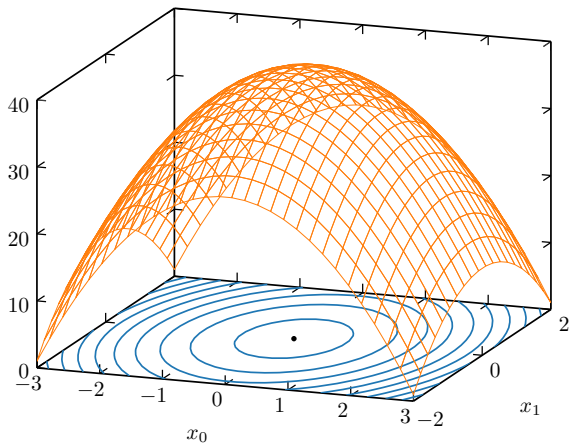

Лекция 5. Минимизация вещественнозначных функций векторного аргумента

§5.1. Методы оптимизации используемые для адаптации коэффициентов фильтров

Краткий обзор методов оптимизации:

- Метод прямого перебора. Используется на фиксированное сетке значения, когда другие методы не могут быть использованы.
- Метод покоординатного спуска. Используется при невозможности оценки градиента функции.
- Метод градиентного спуска. Наиболее часто используемый метод, ввиду линейной сходимости. Требует оценки градиента функции.
- Метод Ньютона. Метод квадратичной сходимости. Требует оценки градиента и матрицы Гёссе. Вычислительно сложный метод из-за необходимости инверсии матрицы Гёссе.
- Квазиньютоновские методы. Компромиссные методы, используют аппроксимации матрицы Гёссе основанные на оценки градиента. Сходимость сверхлинейная, вычислительная сложность ниже метода Ньютона.

Лекция 5. Минимизация вещественнозначных функций векторного аргумента

§5.2. Метод градиентного спуска

Метод градиентного спуска заключается в итеративном приближении к точке минимума при движении в направлении, противоположном направлению максимального роста.

Рассмотрим случай одномерной минимизации скалярной функции $f(x)$ скалярного аргумента x на некотором интервале $x \in [a,\ b]$.

Предположим, что $f(x)$ является дифференцируемой функцией, причем производная функции удовлетворяет на заданном интервале $x \in [a,\ b]$ условию Липшица с константой L , т.е.

$$\left| \frac{d}{dx} f(x_0) - \frac{d}{dx} f(x_1) \right| \leq L|x_0 - x_1| \quad \text{для всех} \quad x_0, x_1 \in [a,\ b]. \tag{5.1}$$

Константа Липшица L задает верхнее значение скорости изменения модуля производной функции $f(x)$.

Для получения очередного приближения к оптимуму на шаге n используется значение производной $\frac{d}{dx}f(x)$ функции $f(x)$ на предыдущем шаге x_{n-1}.
Тогда следующее приближение x_n к точке оптимума равно

$$x_n = x_{n-1} - \mu \frac{df(x)}{dx}\bigg|_{x=x_{n-1}}, \tag{5.2}$$

где μ — размер шага.
Пусть $f(\mathbf{x})$ — скалярная функция векторного аргумента $\mathbf{x}$, градиент которой удовлетворяет условию Липшица:

$$\Big\|\nabla_f(\mathbf{x}_0) - \nabla_f(\mathbf{x}_1)\Big\| < L\|\mathbf{x}_0 - \mathbf{x}_1\|. \tag{5.3}$$

Приближение к оптимуму производится путем движения в сторону, противоположную направлению вектора градиента:

$$\mathbf{x}_n = \mathbf{x}_{n-1} - \mu\nabla_f(\mathbf{x}_{n-1}). \tag{5.4}$$

Важной особенностью является уменьшение шага при приближении к точке оптимума, ввиду уменьшения величины производной (длины вектора градиента).

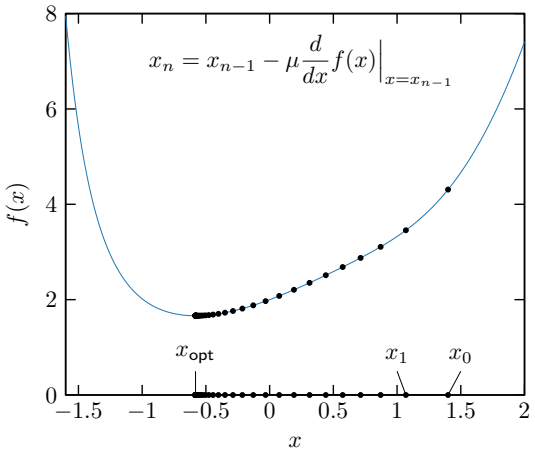

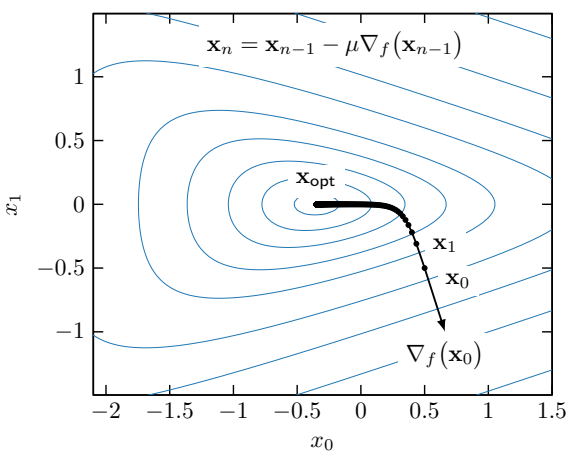

Для ускорения скорости сходимости метода градиентного спуска разработано множество модификаций и различные алгоритмы изменения шага μ.

Для того чтобы процесс минимизации методом градиентного спуска сходился быстрее необходимо увеличивать размер шага μ. Однако увеличение размера шага может привести к расхождению алгоритма.
Для каждой функции существует критическое значение шага $\mu_{\text{кр}}$ алгоритма градиентного спуска при превышении которого алгоритм начинает расходится. Численно критическое значение шага равно половине константы Липшица $\mu_{\text{кр}} = L/2$ данной функции.

Рассмотрим пример. Пусть $f(x) = (x-1)^2 + 0.5$, тогда

$$\frac{d}{dx} f(x) = 2(x-1), \tag{5.5}$$

и условие Липшица имеет вид:

$$\big|2(x_0 - 1) - 2(x_1 - 1)\big| \leq L|x_0 - x_1|. \tag{5.6}$$

равенство будет достигаться при $L = 2$, тогда максимальный шаг минимизации $f(x) = (x-1)^2 + 0.5$ методом градиентного спуска $\mu_{\text{кр}} = L/2 = 1$.

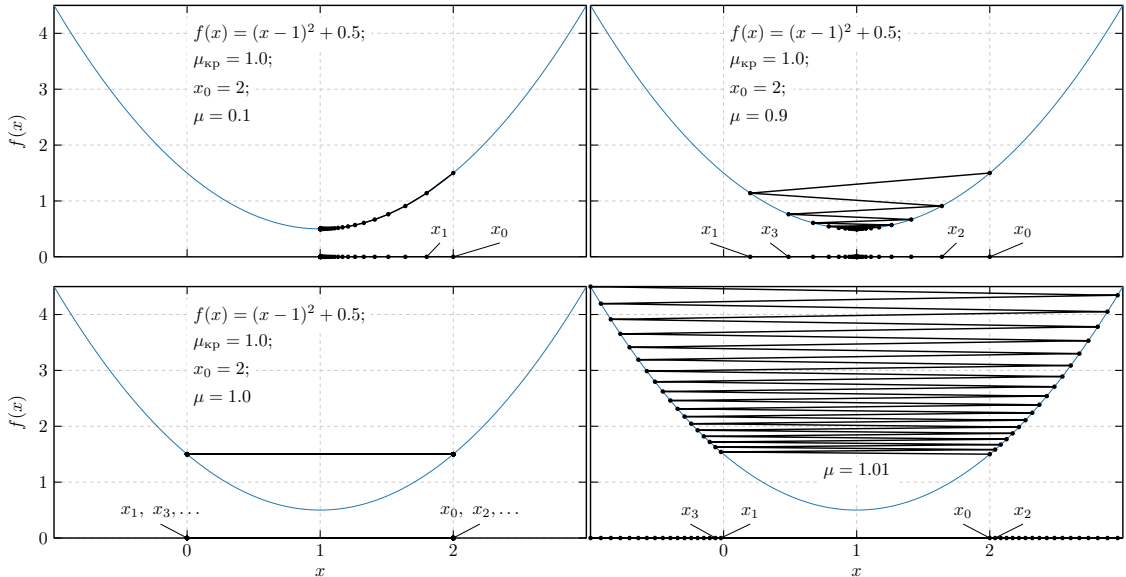
$f(x) = (x-1)^2 + 0.5;$
$\mu_{кр} = 1.0;$
$x_0 = 2;$
$\mu = 0.1$
x_1
x_0
$f(x) = (x-1)^2 + 0.5;$
$\mu_{кр} = 1.0;$
$x_0 = 2;$
$\mu = 0.9$
x_1
x_3
x_2
x_0
$f(x) = (x-1)^2 + 0.5;$
$\mu_{кр} = 1.0;$
$x_0 = 2;$
$\mu = 1.0$
$x_1,\ x_3, \ldots$
$x_0,\ x_2, \ldots$
$\mu = 1.01$
x_3
x_1
x_0
x_2
$f(x)$
x
0
1
2
3
4

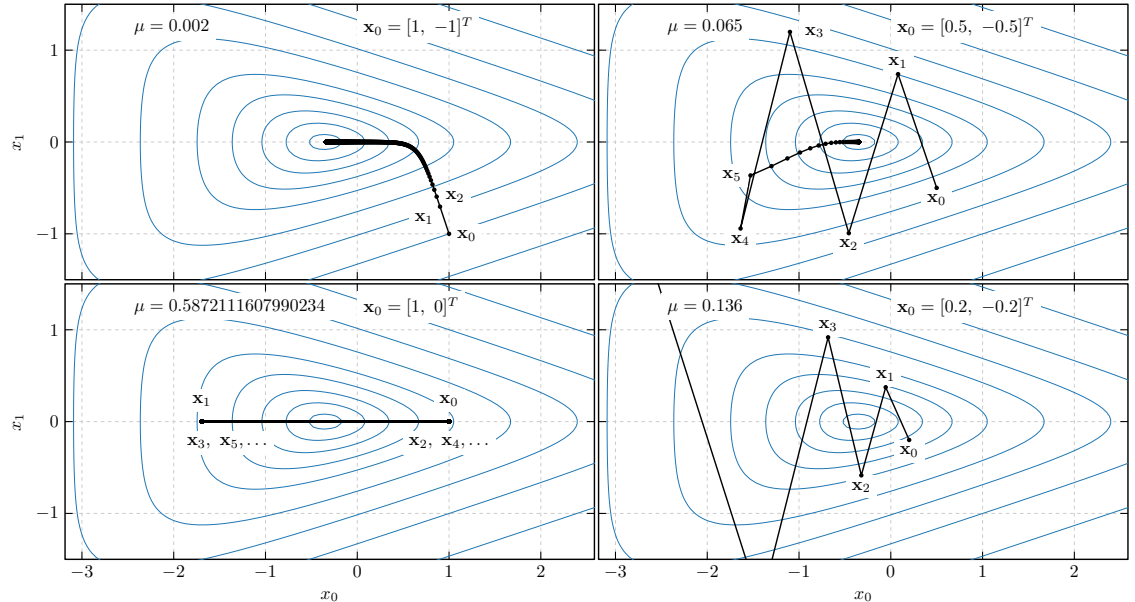
$\mu = 0.002$
$\mathbf{x}_0 = [1,\ -1]^T$
$\mathbf{x}_2$
$\mathbf{x}_1$
$\mathbf{x}_0$
$\mu = 0.065$
$\mathbf{x}_0 = [0.5,\ -0.5]^T$
$\mathbf{x}_3$
$\mathbf{x}_1$
$\mathbf{x}_5$
$\mathbf{x}_0$
$\mathbf{x}_4$
$\mathbf{x}_2$
$\mu = 0.5872111607990234$
$\mathbf{x}_0 = [1,\ 0]^T$
$\mathbf{x}_1$
$\mathbf{x}_0$
$\mathbf{x}_3,\ \mathbf{x}_5, \ldots$
$\mathbf{x}_2,\ \mathbf{x}_4, \ldots$
$\mu = 0.136$
$\mathbf{x}_0 = [0.2,\ -0.2]^T$
$\mathbf{x}_3$
$\mathbf{x}_1$
$\mathbf{x}_0$
$\mathbf{x}_2$
x_0
x_1

Лекция 5. Минимизация вещественнозначных функций векторного аргумента

§5.3. Метод Ньютона

Бесконечно-дифференцируемая функция $f(x)$ может быть представлена рядом Тейлора в окрестности точки $x = a$ как:

$$f(x) = f(a) + f'(a)(x-a) + \frac{1}{2}f''(a)(x-a)^2 + \ldots$$
$$\ldots + \frac{1}{n!}f^{(n)}(a)(x-a)^n + \ldots = \sum_{n=0}^{\infty} \frac{1}{n!}f^{(n)}(a)(x-a)^n, \quad (5.7)$$

где $f^{(n)}(a)$ — значение производной порядка n функции $f(x)$ в заданной точке $x = a$.

Ограничившись некоторым числом конечных членов ряда Тейлора, мы получим аппроксимацию функции $f(x)$ в окрестности точки $x = a$. Так при использовании первых двух членов ряда мы получим линейную аппроксимацию функции $f(x)$, а при использовании первых трех членов ряда — квадратичную:

$$f(x) \approx f(a) + f'(a)(x-a) + \frac{1}{2}f''(a)(x-a)^2. \quad (5.8)$$

Пусть имеется функция одной переменной $f(x)$ и мы можем получить значения ее первых двух производных в любой точке x.

Зададим некоторую начальную точку $x = x_0$, тогда квадратичная функция $p(x)$, которая является аппроксимацией $f(x)$ в точке x_0 равна:

$$f(x) \approx p_0(x) = f(x_0) + f'(x_0)(x - x_0) + \frac{1}{2} f''(x_0)(x - x_0)^2. \tag{5.9}$$

Предположим, что функция $f(x)$ является выпуклой, и ее вторая производная $f''(x) \geq 0$ для всех значений x, причем существуют x для которых $f''(x) \neq 0$.

Тогда ее квадратичная аппроксимация $p_0(x)$ также является выпуклой, поскольку коэффициент при квадратичном члене неотрицателен, а значит имеет глобальный экстремум, который является минимумом.

Это означает, что мы можем найти минимум квадратичной функции $p_0(x)$, который будет достигаться в точке

$$\frac{dp_0(x)}{dx} = 0, \quad \text{откуда} \quad f'(x_0) + f''(x_0)(x - x_0) = 0, \tag{5.10}$$

и окончательно можно записать

$$x = x_1 = x_0 - \big(f''(x_0)\big)^{-1} f'(x_0). \tag{5.11}$$

В этом случае $x = x_1$ представляет собой минимум квадратичной аппроксимации $f(x)$ и может считаться следующим приближением x_1 к точке оптимума x_{opt}.

Тогда можно снова построить квадратичную аппроксимацию $p_1(x)$ исходной функции $f(x)$, но уже в окрестности точки $x = x_1$:

$$f(x) \approx p_1(x) = f(x_1) + f'(x_1)(x - x_1) + \frac{1}{2} f''(x_1)(x - x_1)^2, \tag{5.12}$$

и найти следующее приближение к точке оптимума:

$$\frac{dp_1(x)}{dx} = 0, \quad \text{откуда} \quad x = x_2 = x_1 - \big(f''(x_1)\big)^{-1} f'(x_1). \tag{5.13}$$

Продолжая рекуррентный поиск оптимального значения можно записать алгоритм последовательного приближения как:

$$x_n = x_{n-1} - \big(f''(x_{n-1})\big)^{-1} f'(x_{n-1}). \tag{5.14}$$

В случае функции многих переменных $f(\mathbf{x})$, квадратичная аппроксимация в окрестности точки $\mathbf{x} = \mathbf{a}$ имеет вид:

$$f(\mathbf{x}) \approx f(\mathbf{a}) + (\mathbf{x} - \mathbf{a})^T \nabla_f(\mathbf{a}) + \frac{1}{2}(\mathbf{x} - \mathbf{a})^T \mathbf{H}_f(\mathbf{a})(\mathbf{x} - \mathbf{a}), \tag{5.15}$$

где $\nabla_f(\mathbf{a})$ и $\mathbf{H}_f(\mathbf{a})$ — значения вектора градиента и матрицы Гёссе функции $f(\mathbf{x})$ в точке $\mathbf{x} = \mathbf{a}$.

Предполагается, что функция $f(\mathbf{x})$ имеет конечные значения всех частных производных второго порядка, входящих в матрицу Гёссе.

Зададим начальную точку $\mathbf{x}_0$, тогда квадратичная функция

$$p_0(\mathbf{x}) = f(\mathbf{x}_0) + (\mathbf{x} - \mathbf{x}_0)^T \nabla_f(\mathbf{x}_0) + \frac{1}{2}(\mathbf{x} - \mathbf{x}_0)^T \mathbf{H}_f(\mathbf{x}_0)(\mathbf{x} - \mathbf{x}_0) \tag{5.16}$$

представляет собой квадратичную аппроксимацию исходной многомерной функции $f(\mathbf{x})$ в окрестности точки $\mathbf{x}_0$.

Предположим, что матрица Гёссе $\mathbf{H}_f(\mathbf{x})$ является положительно определенной для всех значений вектора $\mathbf{x}$. Это означает, что квадратичная аппроксимация является выпуклой, и мы можем найти единственную точку минимума $p_0(\mathbf{x})$.

Рассчитаем градиент $\nabla_{p_0}(\mathbf{x})$, используя правила дифференцирования функций векторного аргумента в матричной форме:

$$\nabla_{p_0}(\mathbf{x}) = \frac{\partial p_0(\mathbf{x})}{\partial \mathbf{x}^T} = \nabla_f(\mathbf{x}_0) + \frac{1}{2}\Big(\mathbf{H}_f(\mathbf{x}_0) + \mathbf{H}_f^T(\mathbf{x}_0)\Big)\Big(\mathbf{x} - \mathbf{x}_0\Big). \tag{5.17}$$

Функция $p_0(\mathbf{x})$ будет достигать минимума если ее градиент будет равен нуль-вектору. Тогда, с учетом симметрии матрицы Гёссе можно записать уравнение:

$$\nabla_{p_0}(\mathbf{x}) = \nabla_f(\mathbf{x}_0) + \mathbf{H}_f(\mathbf{x}_0)(\mathbf{x} - \mathbf{x}_0) = \mathbf{0}. \tag{5.18}$$

Тогда

$$\mathbf{H}_f(\mathbf{x}_0)\mathbf{x} = \mathbf{H}_f(\mathbf{x}_0)\mathbf{x}_0 - \nabla_f(\mathbf{x}_0), \tag{5.19}$$

и выражение для следующего приближения к точке оптимума равно:

$$\mathbf{x} = \mathbf{x}_1 = \underbrace{\mathbf{H}_f^{-1}(\mathbf{x}_0)\mathbf{H}_f(\mathbf{x}_0)}_{\mathbf{I}}\mathbf{x}_0 - \mathbf{H}_f^{-1}(\mathbf{x}_0)\nabla_f(\mathbf{x}_0). \tag{5.20}$$

Рекуррентное соотношение для приближения к точки минимума $\mathbf{x}_n$ на шаге n из точки на предыдущем шаге $\mathbf{x}_{n-1}$ на основе квадратичной аппроксимации функции $f(\mathbf{x})$ в окрестности $\mathbf{x} = \mathbf{x}_{n-1}$ можно окончательно записать:

$$\mathbf{x}_n = \mathbf{x}_{n-1} - \mathbf{H}_f^{-1}(\mathbf{x}_{n-1})\nabla_f(\mathbf{x}_{n-1}). \tag{5.21}$$

Выражение (5.21) представляет собой метод Ньютона многомерной оптимизации.

Квадратичная скорость сходимости к точке минимума означает, что выполняется условие:

$$\left\|\mathbf{x}_n - \mathbf{x}_{\text{opt}}\right\| \leq \alpha \left\|\mathbf{x}_{n-1} - \mathbf{x}_{\text{opt}}\right\|^2, \tag{5.22}$$

где α — некоторая константа, $\mathbf{x}_n$ и $\mathbf{x}_{n-1}$ — приближения к точке минимума $\mathbf{x}_{\text{opt}}$ на шаге n и $n-1$.

Таким образом, при небольшом расстоянии начальной точки от точки оптимума метод Ньютона сходится очень быстро.

Например при $\alpha = 1$ и начальном расстоянии $\left\|\mathbf{x}_0 - \mathbf{x}_{\text{opt}}\right\| = 0.1$, мы уже на первом шаге будем иметь приближение $\left\|\mathbf{x}_1 - \mathbf{x}_{\text{opt}}\right\| = 0.01$, на втором $\left\|\mathbf{x}_2 - \mathbf{x}_{\text{opt}}\right\| = 10^{-4}$, и в результате уже на четвертом шаге достигнем $\left\|\mathbf{x}_4 - \mathbf{x}_{\text{opt}}\right\| = 10^{-16}$, т.е. расстояние от оптимальной точки будет меньше возможного представления 64-битного числа с плавающей точкой двойной точности.

- Важным преимуществом метода Ньютона является быстрая сходимость к точке минимума. Поскольку метод Ньютона привлекает информацию о второй производной, то его называют методом второго порядка, который характеризуется квадратичной сходимостью.

- Кроме того, если исходная функция $f(\mathbf{x})$ является квадратичной, с положительно-определенной матрицей, то метод Ньютона гарантирует нахождение ее минимума за один шаг. Это крайне важное свойство, которое позволяет решать многие задачи адаптивной фильтрации без использования алгоритмов рекуррентной адаптации.

- Однако метод Ньютона требует больших вычислительных затрат так как встает необходимость инверсии матрицы Гёссе, которая в свою очередь требует больших объемов памяти для хранения.

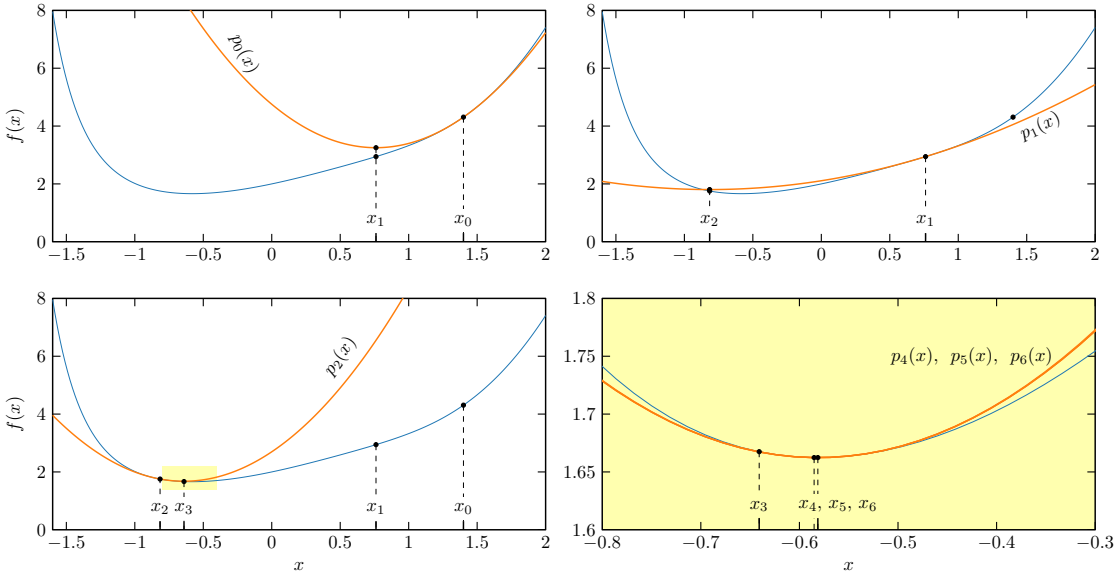
$p_0(x)$
$p_1(x)$
$p_2(x)$
$p_4(x),\ p_5(x),\ p_6(x)$
$f(x)$
x
x_0
x_1
x_2
x_3
$x_4,\ x_5,\ x_6$

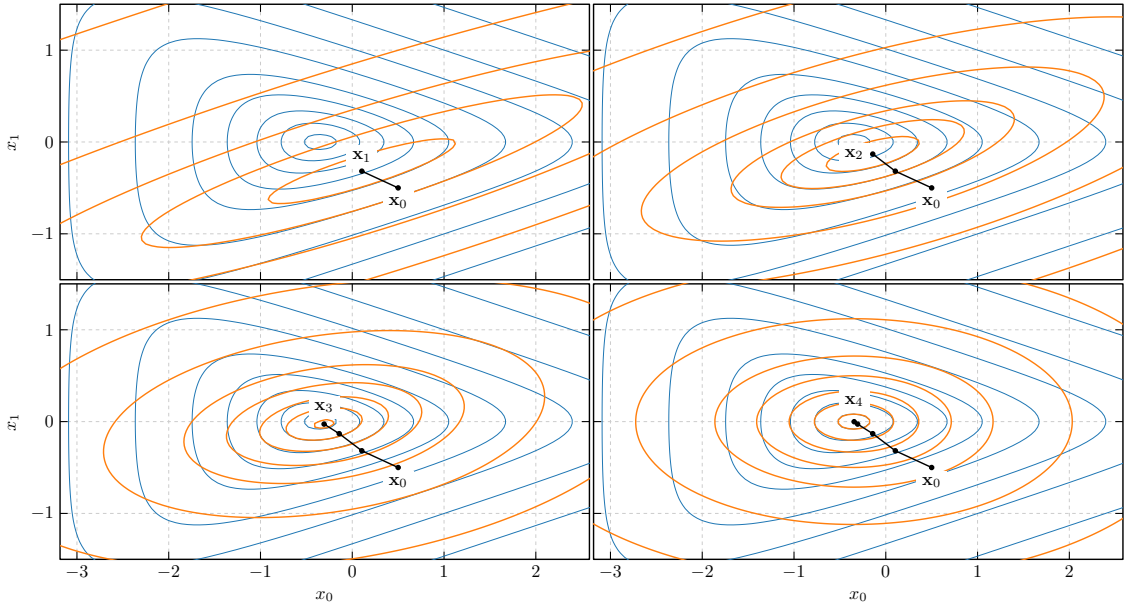
$\mathbf{x}_1$
$\mathbf{x}_0$
$\mathbf{x}_2$
$\mathbf{x}_0$
$\mathbf{x}_3$
$\mathbf{x}_0$
$\mathbf{x}_4$
$\mathbf{x}_0$
x_1
x_0
1
0
−1
−3
−2
−1
0
1
2

Метод Ньютона может расходиться, если начальная точка выбрана достаточно далеко от искомого минимума.

Например $f(x) = \ln\left(x^2 + 1\right)$ метод Ньютона расходится, если $|x_0| > 1/\sqrt{3}$:

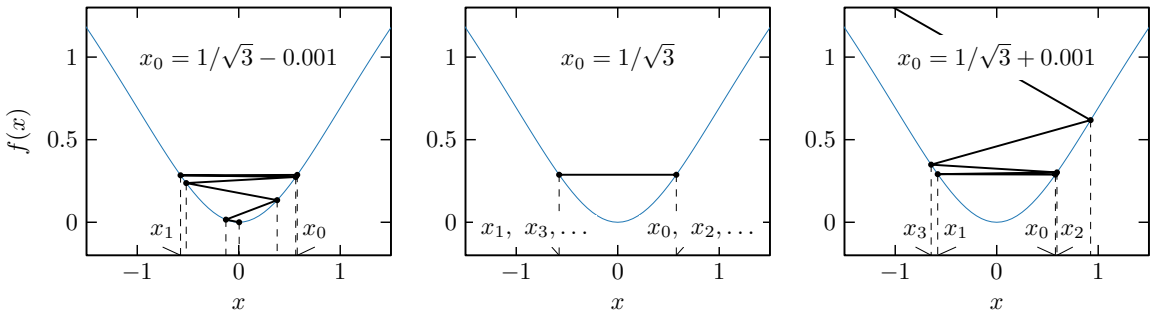

Заметим, что при строгом равенстве $x_0 = 1/\sqrt{3}$ алгоритм «зацикливается» $x_0 = \pm 1/\sqrt{3}$.

Для обеспечения глобальной сходимости метода Ньютона используют его модификации: демпфированный метод Ньютона и алгоритм Левенберга–Марквардта.

Лекция 5. Минимизация вещественнозначных функций векторного аргумента

§5.4. Демпфированный метод Ньютона

Причина расхождения метода Ньютона заключается в том, что квадратичная функция $p(x)$, которая описывает поведение исходной функции $f(x)$ в некоторой точке x_n неправильно описывает поведение функции $f(x)$ в области близкой к оптимальному значению x_{opt}.
В результате очередной шаг не приближается к искомой точке x_{opt}, а отдаляется от нее.

Поэтому естественной идеей стабилизации метода является ограничение длины шага:

$$\mathbf{x}_n = \mathbf{x}_{n-1} - \alpha_n \mathbf{H}_f^{-1}(\mathbf{x}_{n-1}) \nabla_f(\mathbf{x}_{n-1}), \tag{5.23}$$

где $0 < \alpha_n \leq 1$ подбирается на каждом шаге для обеспечения сходимости алгоритма.

Вектор

$$\mathbf{g}_n = \mathbf{H}_f^{-1}(\mathbf{x}_{n-1})\nabla_f(\mathbf{x}_{n-1}) \tag{5.24}$$

задает направление шага, а параметр α_n должен быть подобран таким образом, чтобы значение функции

$$f(\mathbf{x}_{n-1} - \alpha_n \mathbf{g}_n) < f(\mathbf{x}_{n-1}) \tag{5.25}$$

уменьшилось при движении в направлении $\mathbf{g}_n$ с шагом α_n.

Такая модификация позволяет обеспечить глобальную сходимость метода Ньютона, и широко применяется на практике ввиду простоты реализации и высокой надежности.

Стратегия выбора величины α_n может быть самой разнообразной, но так или иначе сводится к одномерному поиску параметра, что не вносит существенного усложнения, поскольку направление шага $\mathbf{g}_n$ не меняется.

Лекция 5. Минимизация вещественнозначных функций векторного аргумента

§5.5. Алгоритм Левенберга–Марквардта (Levenberg—Marquardt)

Алгоритм Левенберга–Марквардта использует следующую модификацию шага многомерной оптимизации:

$$\mathbf{x}_n = \mathbf{x}_{n-1} - \big(\mathbf{H}_f(\mathbf{x}_{n-1}) + \lambda_n \mathbf{I}\big)^{-1} \nabla f(\mathbf{x}_{n-1}), \tag{5.26}$$

где λ_n — положительное число, а $\mathbf{I}$ — единичная матрица.

Идея заключается в том, чтобы модифицировать матрицу Гёссе путем добавления к ней диагонали с весом λ_n. При $\lambda_n = 0$ получаем шаг по методу Ньютона, а при увеличении λ_n направление корректируется в сторону антиградиента (который как мы знаем указывает направление убывания функции).

В пределе:

$$\lim_{\lambda_n \to \infty} \big(\mathbf{H}_f(\mathbf{x}_{n-1}) + \lambda_n \mathbf{I}\big)^{-1} = \mu \mathbf{I}, \quad \mu \to 0, \tag{5.27}$$

получаем бесконечно малый шаг в направлении антиградиента.
Оптимизация параметра λ_n на каждом шаге минимизации позволяет обеспечить глобальную сходимость алгоритма.

Лекция 6. Минимизация вещественнозначных функций комплексного переменного

§6.1. Условия дифференцируемости функций комплексных переменных. Производные Виртингера

Рассмотрим функцию $f(z)$ комплексного аргумента $z = x + jy$, x,$y \in \mathbb{R}$. Тогда $f(z)$ можно представить в виде:

$$f(z) = u(x, y) + jv(x, y) = \operatorname{Re}\big[f(z)\big] + j \operatorname{Im}\big[f(z)\big], \tag{6.1}$$

где $u(x, y) = \operatorname{Re}\big[f(z)\big]$ и $v(x, y) = \operatorname{Im}\big[f(z)\big]$ — вещественные функции двух переменных x и y описывающие реальную и мнимую части функции $f(z)$ соответственно.
В теории функции комплексного переменного доказывается, что производная $\frac{df(z)}{dz}$ в точке $z_0 = x_0 + jy_0$ существует при соблюдении условий Коши-Римана:

$$\frac{\partial u(x, y)}{\partial x} = \frac{\partial v(x, y)}{\partial y}; \qquad \frac{\partial u(x, y)}{\partial y} = -\frac{\partial v(x, y)}{\partial x}. \tag{6.2}$$

При соблюдении условий (6.2), а также при непрерывности частных производных $\frac{\partial u(x,y)}{\partial x}$ и $\frac{\partial u(x,y)}{\partial y}$, функция $f(z)$ называется аналитической.
Нетрудно показать, что выражение (6.2) эквивалентно условиям:

$$\frac{\partial f(z)}{\partial x} + j\frac{\partial f(z)}{\partial y} = 0, \quad \text{или} \quad \frac{\partial f(z)}{\partial z^*} = 0, \tag{6.3}$$

где дифференцирование по комплексно-сопряженной переменной z^* ведется как по независимой от z.
Можно заметить, что аналитическая функция $f(z)$ не зависит от сопряженного z^*.

Если $f(z)$ — вещественнозначная функция комплексного аргумента z, то $\mathrm{Im}[f(z)] = 0$, откуда $v(x, y) = 0$ и условия Коши-Римана не выполняются.

Это означает, что данная функция недифференцируема в классическом смысле, и классический аппарат теории функции комплексного переменного не позволяет дифференцировать вещественнозначную функцию $J(\mathbf{w})$ по комплексному аргументу $\mathbf{w}$, где $J(\mathbf{w})$ описывает критерий минимума среднего квадрата ошибки при адаптации комплексного коэффициента w.

В первой половине XX века был разработан математический аппарат позволяющий дифференцировать неаналитические вещественнозначные функции, который мы будем применять для адаптации цифровых фильтров для комплексных сигналов.

Запишем некоторые соотношения для комплексных чисел и их дифференциалов:

$$\begin{aligned} z &= x + jy; & dz &= dx + j\,dy; \\ z^* &= x - jy; & dz^* &= dx - j\,dy; \\ x &= \frac{z + z^*}{2}; & dx &= \frac{dz + dz^*}{2}; \\ y &= \frac{z - z^*}{2j}; & dy &= \frac{dz - dz^*}{2j}. \end{aligned} \tag{6.4}$$

Если $f(z) = u(x, y)$ — веществennозначная функция комплексной переменной z, то ее можно рассматривать как вещественную функцию двух переменных $u(x, y)$, так как мнимая часть функции равна нулю.

Тогда по определению полного дифференциала:

$$df(z) = du(x,y) = \frac{\partial u(x,y)}{\partial x}\,dx + \frac{\partial u(x,y)}{\partial y}\,dy. \tag{6.5}$$

С учётом $f(z) = u(x,y)$:

$$df(z) = \frac{\partial f(z)}{\partial x}\,dx + \frac{\partial f(z)}{\partial y}\,dy \tag{6.6}$$

Подставляем (6.4):

$$df(z) = \frac{\partial f(z)}{\partial x} \cdot \frac{dz + dz^*}{2} + \frac{\partial f(z)}{\partial y} \cdot \frac{dz - dz^*}{2j}. \tag{6.7}$$

После преобразования получим:

$$df(z) = \underbrace{\frac{1}{2}\left(\frac{\partial f(z)}{\partial x} - j\,\frac{\partial f(z)}{\partial y}\right)}_{\frac{\partial f(z)}{\partial z}}\,dz + \underbrace{\frac{1}{2}\left(\frac{\partial f(z)}{\partial x} + j\,\frac{\partial f(z)}{\partial y}\right)}_{\frac{\partial f(z)}{\partial z^*}}\,dz^*. \tag{6.8}$$

Окончательно можно записать полный дифференциал неаналитической функции:

$$df(z) = \frac{\partial f(z)}{\partial z}\, dz + \frac{\partial f(z)}{\partial z^*}\, dz^*. \tag{6.9}$$

Частные производные $\frac{\partial f(z)}{\partial z}$ и $\frac{\partial f(z)}{\partial z^*}\, dz^*$ берутся относительно независимых переменных z и z^*:

$$\frac{\partial f(z)}{\partial z} = \frac{1}{2}\left(\frac{\partial f(z)}{\partial x} - j\,\frac{\partial f(z)}{\partial y}\right); \tag{6.10}$$

$$\frac{\partial f(z)}{\partial z^*} = \frac{1}{2}\left(\frac{\partial f(z)}{\partial x} + j\,\frac{\partial f(z)}{\partial y}\right). \tag{6.11}$$

Выражения (6.10) и (6.11) носят названия производные Виртингера (Wirtinger Calculus) и позволяют формально рассчитвать производные веществennозначных функций комплексного переменного.

Выражение (6.6), и вытекающие из него производные Виртингера (6.10) и (6.11) справедливы и для комплекснозначных функций, неудовлетворяющих условиям Коши-Римана.
Рассмотрим $f(z) = u(x,y) + jv(x,y)$, тогда дифференциал

$$\begin{aligned} df(z) &= du(x,y) + jdv(x,y) = \\ &= \frac{\partial u(x,y)}{\partial x}dx + \frac{\partial u(x,y)}{\partial y}dy + j\frac{\partial v(x,y)}{\partial x}dx + j\frac{\partial v(x,y)}{\partial y}dy = \\ &= \frac{\partial u(x,y) + j\partial v(x,y)}{\partial x}dx + \frac{\partial u(x,y) + j\partial v(x,y)}{\partial y}dy = \\ &= \frac{\partial f(z)}{\partial x}dx + \frac{\partial f(z)}{\partial y}dy. \end{aligned} \tag{6.12}$$

Таким образом формальный переход от дифференциала к производным Виртингера будет такой же, и производные (6.10) и (6.11) также можно использовать для комплекснозначных неаналитических функций.

Пример 1. $f(z) = z = x + jy$, тогда

$$\frac{\partial z}{\partial z} = \frac{1}{2}\left(\frac{\partial(x+jy)}{\partial x} - j\,\frac{\partial(x+jy)}{\partial y}\right) = \frac{1}{2}(1-j^2) = 1; \tag{6.13}$$

$$\frac{\partial z}{\partial z^*} = \frac{1}{2}\left(\frac{\partial(x+jy)}{\partial x} + j\,\frac{\partial(x+jy)}{\partial y}\right) = \frac{1}{2}(1+j^2) = 0; \tag{6.14}$$

Пример 2. $f(z) = z^* = x - jy$, тогда

$$\frac{\partial z^*}{\partial z} = \frac{1}{2}\left(\frac{\partial(x-jy)}{\partial x} - j\,\frac{\partial(x-jy)}{\partial y}\right) = \frac{1}{2}(1+j^2) = 0; \tag{6.15}$$

$$\frac{\partial z^*}{\partial z^*} = \frac{1}{2}\left(\frac{\partial(x-jy)}{\partial x} + j\,\frac{\partial(x-jy)}{\partial y}\right) = \frac{1}{2}(1-j^2) = 1; \tag{6.16}$$

Пример 3. $f(z) = \mathrm{Re}[z] = x$, тогда

$$\frac{\partial \mathrm{Re}[z]}{\partial z} = \frac{1}{2}\left(\frac{\partial x}{\partial x} - j\,\frac{\partial x}{\partial y}\right) = \frac{1}{2}; \tag{6.17}$$

$$\frac{\partial \mathrm{Re}[z]}{\partial z^*} = \frac{1}{2}\left(\frac{\partial x}{\partial x} + j\,\frac{\partial x}{\partial y}\right) = \frac{1}{2}. \tag{6.18}$$

Пример 4. $f(z) = \mathrm{Im}[z] = y$, тогда

$$\frac{\partial \mathrm{Im}[z]}{\partial z} = \frac{1}{2}\left(\frac{\partial y}{\partial x} - j\,\frac{\partial y}{\partial y}\right) = \frac{1}{2j}; \tag{6.19}$$

$$\frac{\partial \mathrm{Im}[z]}{\partial z^*} = \frac{1}{2}\left(\frac{\partial y}{\partial x} + j\,\frac{\partial y}{\partial y}\right) = -\frac{1}{2j}. \tag{6.20}$$

Пример 5. $f(z) = zz^* = x^2 + y^2$, тогда

$$\frac{\partial zz^*}{\partial z} = \frac{1}{2}\left(\frac{\partial(x^2+y^2)}{\partial x} - j\,\frac{\partial(x^2+y^2)}{\partial y}\right) = \frac{1}{2}(2x - j2y) = z^*; \tag{6.21}$$

$$\frac{\partial zz^*}{\partial z^*} = \frac{1}{2}\left(\frac{\partial(x^2+y^2)}{\partial x} + j\,\frac{\partial(x^2+y^2)}{\partial y}\right) = \frac{1}{2}(2x + j2y) = z. \tag{6.22}$$

К расчёту производных $\frac{\partial f(z)}{\partial z}$ и $\frac{\partial f(z)}{\partial z^*}$ применимы известные правила дифференцирования. Заметим, что частные производные сопряжённой функции $f^*(z)$ равны:

$$\frac{\partial f^*(z)}{\partial z} = \left(\frac{\partial f(z)}{\partial z^*}\right)^*; \qquad \frac{\partial f^*(z)}{\partial z^*} = \left(\frac{\partial f(z)}{\partial z}\right)^*. \tag{6.23}$$

Пусть $f\big(g(z)\big)$ — сложная функция, зависящая как от $g(z)$, так и от $g^*(z)$, причем сами $g(z)$, и $g^*(z)$ зависят как от z, так и от z^*.

Тогда функцию $f\big(g(z)\big)$ можно записать как $f\big(g(z,z^*),g^*(z,z^*)\big)$, где явно представлены зависимости от функций $g(z)$, и $g^*(z)$ и переменных z, и z^*.

Производная $f\big(g(z)\big)$ по переменной z равна:

$$\frac{\partial}{\partial z}f\big(g(z)\big)=\frac{\partial}{\partial z}f\big(g(z,z^*),g^*(z,z^*)\big)=\frac{\partial f}{\partial g}\cdot\frac{\partial g}{\partial z}+\frac{\partial f}{\partial g^*}\cdot\frac{\partial g^*}{\partial z}. \tag{6.24}$$

Производная $f\big(g(z)\big)$ по комплексно-сопряженной переменной z^* равна:

$$\frac{\partial}{\partial z^*}f\big(g(z)\big)=\frac{\partial}{\partial z^*}f\big(g(z,z^*),g^*(z,z^*)\big)=\frac{\partial f}{\partial g}\cdot\frac{\partial g}{\partial z^*}+\frac{\partial f}{\partial g^*}\cdot\frac{\partial g^*}{\partial z^*}. \tag{6.25}$$

Лекция 6. Минимизация вещественнозначных функций комплексного переменного

§6.2. Минимизация вещественнозначных функций комплексного векторного аргумента

Рассмотрим выпуклую вещественнозначную функцию $f(z) \in \mathbb{R}$ комплексной переменной $z \in \mathbb{C}$. Поскольку функция $f(z)$ вещественнозначная и выпуклая, то мы можем ее минимизировать, т.е. найти точку z_{opt}, которая обеспечивает минимум $f(z)$. Простейший пример: $f(z) = zz^* = |z|^2$.

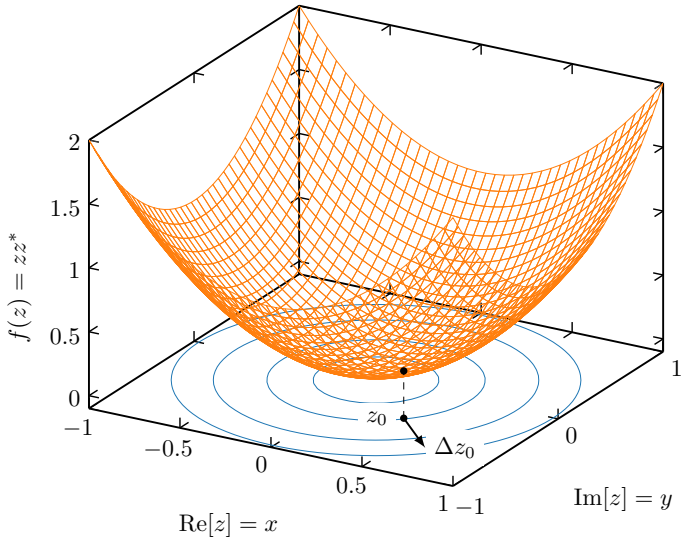

.

Данную вещественнозначную функцию комплексного аргумента $z = x + jy$ можно представить как функцию вещественного векторного аргумента $\mathbf{v} = [x, \quad y]^T$. Тогда из некоторой точки $\mathbf{v}_0 = z_0$ на комплексной плоскости мы можем рассчитать вектор градиента вида:

$$\nabla_f(\mathbf{v}) = \frac{\partial f(\mathbf{v})}{\partial \mathbf{v}} = \left[\frac{\partial f(\mathbf{v})}{\partial x}, \quad \frac{\partial f(\mathbf{v})}{\partial y}\right]^T. \tag{6.26}$$

Тогда $f(z)$ будет иметь максимальный рост в если перейти из точки z_0 в точку $z_0 + \Delta z_0$, где

$$\Delta z_0 = \left(\frac{\partial f(\mathbf{v})}{\partial x} + j\frac{\partial f(\mathbf{v})}{\partial y}\right)\Bigg|_{\mathbf{v}=\mathbf{v_0}=z_0}. \tag{6.27}$$

Учтём, что векторная переменная $\mathbf{v}$ соответствует комплексной z, то

$$\Delta z_0 = \left(\frac{\partial f(z)}{\partial x} + j \frac{\partial f(z)}{\partial y} \right) \Bigg|_{z=z_0}. \tag{6.28}$$

Использовав производные Виртингера можно окончательно записать, что направление максимального роста вещественнозначной функции определяется как:

$$\Delta z_0 = 2 \cdot \frac{\partial f(z)}{\partial z^*} \Big|_{z=z_0}. \tag{6.29}$$

Точка экстремума достигается если

$$\frac{\partial f(z)}{\partial z^*} \Big|_{z=z_0} = 0. \tag{6.30}$$

Для проверки на минимум необходимо рассчитать вторую производную и оценить ее знак:

$$\frac{\partial^2 f(z)}{\partial z \partial z^*} \Big|_{z=z_0}. \tag{6.31}$$

Лекция 6. Минимизация вещественнозначных функций комплексного переменного

§6.3. Минимизация вещественнозначных функций комплексного векторного аргумента

Расширим вышеизложенные выражения для функций одного комплексного аргумента на случай функции $f(\mathbf{z})$, зависящей от комплексного векторного аргумента $\mathbf{z}$:

$$\mathbf{z} = \left[z_0,\ z_1,\ z_2,\ \ldots,\ z_{m-1}\right]^T. \tag{6.32}$$

Примером может быть функция $f(\mathbf{z}) = \mathbf{z}^H\mathbf{z}$, где $\mathbf{z}^H$ — эрмитово-сопряженный вектор. Вектор градиента $\nabla_f(\mathbf{z})$, задающий направление максимального роста функции равен:

$$\nabla_f(\mathbf{z}) = \frac{\partial f(\mathbf{z})}{\partial \mathbf{z}^H} = \left[\frac{\partial f(\mathbf{z})}{\partial z_0^*},\ \frac{\partial f(\mathbf{z})}{\partial z_1^*},\ \frac{\partial f(\mathbf{z})}{\partial z_2^*},\ \ldots,\ \frac{\partial f(\mathbf{z})}{\partial z_{m-1}^*}\right]^T, \tag{6.33}$$

тогда точка экстремума $f(\mathbf{z})$ достигается при

$$\frac{\partial f(\mathbf{z})}{\partial \mathbf{z}^H}\Big|_{\mathbf{z}=\mathbf{z}_{\mathbf{opt}}} = \mathbf{0}. \tag{6.34}$$

Матрицей Гёссе $\mathbf{H}_f(\mathbf{z})$ вещественнозначной функцией комплексного вектора аргумента является квадратная матрица вторых частных производных вида

$$\mathbf{H}_f(\mathbf{z}) = \frac{\partial^2 f(\mathbf{z})}{\partial \mathbf{z} \partial \mathbf{z}^H} = \begin{bmatrix} \dfrac{\partial^2 f(\mathbf{z})}{\partial z_0 \partial z_0^*} & \dfrac{\partial^2 f(\mathbf{z})}{\partial z_1 \partial z_0^*} & \dfrac{\partial^2 f(\mathbf{z})}{\partial z_2 \partial z_0^*} & \cdots & \dfrac{\partial^2 f(\mathbf{z})}{\partial z_{N-1} \partial z_0^*} \\ \dfrac{\partial^2 f(\mathbf{z})}{\partial z_0 \partial z_1^*} & \dfrac{\partial^2 f(\mathbf{z})}{\partial z_1 \partial z_1^*} & \dfrac{\partial^2 f(\mathbf{z})}{\partial z_2 \partial z_1^*} & \cdots & \dfrac{\partial^2 f(\mathbf{z})}{\partial z_{N-1} \partial z_1^*} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \dfrac{\partial^2 f(\mathbf{z})}{\partial z_0 \partial z_{N-1}^*} & \dfrac{\partial^2 f(\mathbf{z})}{\partial z_1 \partial z_{N-1}^*} & \dfrac{\partial^2 f(\mathbf{z})}{\partial z_2 \partial z_{N-1}^*} & \cdots & \dfrac{\partial^2 f(\mathbf{z})}{\partial z_{N-1} \partial z_{N-1}^*} \end{bmatrix}. \quad (6.35)$$

Производные для некоторых широко используемых функций приведены в таблице:

№	$f(\mathbf{z})$	$\frac{\partial f(\mathbf{z})}{\partial \mathbf{z}^H}$	$\frac{\partial f(\mathbf{z})}{\partial \mathbf{z}}$
(1)	$\mathbf{a}^T\mathbf{z} = \mathbf{z}^T\mathbf{a}$	$\mathbf{0}$	$\mathbf{a}^T$
(2)	$\mathbf{a}^H\mathbf{z} = \mathbf{z}^T\mathbf{a}^*$	$\mathbf{0}$	$\mathbf{a}^H$
(3)	$\mathbf{a}^T\mathbf{z}^* = \mathbf{z}^H\mathbf{a}$	$\mathbf{a}$	$\mathbf{0}$
(4)	$\mathbf{a}^H\mathbf{z}^* = \mathbf{z}^H\mathbf{a}^*$	$\mathbf{a}^*$	$\mathbf{0}$
(5)	$\mathbf{z}^T\mathbf{z}$	$\mathbf{0}$	$2\mathbf{z}^T$
(6)	$\mathbf{z}^H\mathbf{z}^*$	$2\mathbf{z}^*$	$\mathbf{0}$
(7)	$\mathbf{z}^H\mathbf{z}$	$\mathbf{z}$	$\mathbf{z}^H$
(8)	$\mathbf{z}^H\mathbf{A}\mathbf{z}$	$\mathbf{A}\mathbf{z}$	$\mathbf{z}^H\mathbf{A}^H$

Лекция 6. Минимизация вещественнозначных функций комплексного переменного

§6.4. Вещественнозначная квадратичная функция комплексного векторного аргумента

По аналогии с квадратичной функцией реального векторного аргумента введем $f(\mathbf{z})$, зависящую от комплексного векторного аргумента $\mathbf{z}$:

$$f(\mathbf{z}) = \mathbf{z}^H \mathbf{A} \mathbf{z} + \mathbf{b}^H \mathbf{z} + \mathbf{z}^H \mathbf{b} + c \tag{6.36}$$

$\mathbf{z}, \mathbf{b} \in \mathbb{C}^M$, $\mathbf{A} \in \mathbb{C}^{M \times M}$ — положительно определенная квадратная матрица, $c \in \mathbb{R}$. Заметим, что

$$\mathbf{b}^H \mathbf{z} + \mathbf{z}^H \mathbf{b} = \left(\mathbf{b}^T \mathbf{z}^*\right)^* + \mathbf{b}^T \mathbf{z}^* = 2 \operatorname{Re}\left[\mathbf{b}^T \mathbf{z}^*\right] = 2 \operatorname{Re}\left[\mathbf{z}^H \mathbf{b}\right] \tag{6.37}$$

Квадратичная форма $\mathbf{z}^H \mathbf{A} \mathbf{z} > 0$ при положительно-определенной матрице $\mathbf{A}$, в этом случае имеем функцию с единственной точкой минимума.

$$f(\mathbf{z}) = \mathbf{z}^H \mathbf{A}\mathbf{z} + \mathbf{b}^H \mathbf{z} + \mathbf{z}^H \mathbf{b} + c \tag{6.38}$$

Вектор градиента:

$$\nabla_f(\mathbf{z}) = \frac{\partial f(\mathbf{z})}{\partial \mathbf{z}^H} = \mathbf{A}\mathbf{z} + \mathbf{b}. \tag{6.39}$$

Условие оптимальности $\nabla_f(\mathbf{z}) = \mathbf{0}$. Поскольку градиент линейно зависит от $\mathbf{z}$, то можно записать:

$$\mathbf{A}\mathbf{z} + \mathbf{b} = \mathbf{0}; \tag{6.40}$$

$$\mathbf{A}\mathbf{z} = -\mathbf{b}; \tag{6.41}$$

$$\mathbf{z} = -\mathbf{A}^{-1}\mathbf{b}. \tag{6.42}$$

Для квадратичной функции можно не рассчитывать матрицу Гессе, а сразу приравнивать градиент к нулю.

Действительно

$$\mathbf{H}_f(\mathbf{z}) = \frac{\partial \nabla_f(\mathbf{z})}{\partial \mathbf{z}} = \mathbf{A}. \tag{6.43}$$

Тогда шаг метода Ньютона из произвольной начальной точки $\mathbf{z}_0$ приведет к точке $\mathbf{z}_1$:

$$\mathbf{z}_1 = \mathbf{z}_0 - \mathbf{H}_f^{-1}(\mathbf{z})\nabla_f(\mathbf{z}), \tag{6.44}$$

$$\mathbf{z}_1 = \mathbf{z}_0 - \mathbf{A}^{-1}\big(\mathbf{A}\mathbf{z}_0 + \mathbf{b}\big), \tag{6.45}$$

$$\mathbf{z}_1 = \mathbf{z}_0 - \mathbf{A}^{-1}\mathbf{A}\mathbf{z}_0 - \mathbf{A}^{-1}\mathbf{b} = -\mathbf{A}^{-1}\mathbf{b}. \tag{6.46}$$

Таким образом, для квадратичной вещественнозначной функции комплексного вектора аргумента, метод Ньютона сходится за один шаг без необходимости расчета матрицы Гессе.

Лекция 7. Методы адаптации линейных фильтров

§7.1. Уравнение Винера–Хопфа

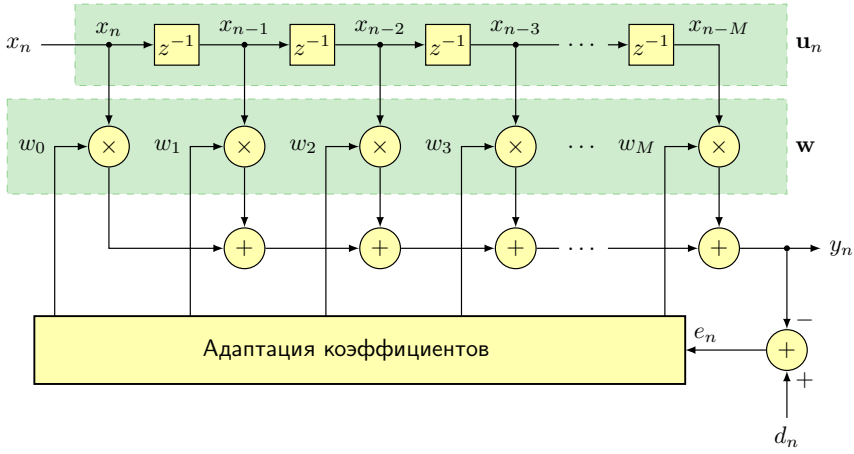

$$\mathbf{u}_n = [x_n,\ x_{n-1},\ x_{n-2},\ \ldots,\ x_{n-M}]^T \tag{7.1}$$

$$\mathbf{w} = [w_0,\ w_1,\ w_2,\ \ldots,\ w_M]^T \tag{7.2}$$

$e_n = d_n - y_n$ — ошибка адаптации.

Критерий адаптации — минимум СКО:

$$J(\mathbf{w}) = \mathrm{E}\left[e_n e_n^*\right] \to \min_{\mathbf{w}}. \tag{7.3}$$

Ошибка адаптации

$$e_n = d_n - y_n = d_n - \mathbf{u}_n^T \mathbf{w}, \tag{7.4}$$

тогда критерий адаптации можно переписать

$$J(\mathbf{w}) = \mathrm{E}\left[\left(d_n - \mathbf{u}_n^T \mathbf{w}\right)\left(d_n - \mathbf{u}_n^T \mathbf{w}\right)^*\right] = \mathrm{E}\left[\left(d_n^* - \mathbf{u}_n^H \mathbf{w}^*\right)\left(d_n - \mathbf{u}_n^T \mathbf{w}\right)\right] \to \min_{\mathbf{w}}. \tag{7.5}$$

$J(\mathbf{w})$ является веществennозначной функцией комплексного векторного аргумента $\mathbf{w}$, которая достигаем экстремума в точке $\mathbf{w}_{\mathsf{opt}}$, если вектор градиента $\nabla_J(\mathbf{w}_{\mathsf{opt}}) = \mathbf{0}$ равен нуль-вектору.

$$\nabla_J(\mathbf{w}) = \frac{\partial}{\partial \mathbf{w}^H} J(\mathbf{w}). \tag{7.6}$$

Рассчитаем вектор градиента функции $J(\mathbf{w})$:

$$\nabla_J(\mathbf{w}) = \frac{\partial}{\partial \mathbf{w}^H} \mathrm{E}\left[\left(d_n^* - \mathbf{u}_n^H \mathbf{w}^*\right)\left(d_n - \mathbf{u}_n^T \mathbf{w}\right)\right]. \tag{7.7}$$

Поскольку оператор математического ожидания является линейным, то можно производную внести под знак математического ожидания:

$$\nabla_J(\mathbf{w}) = \mathrm{E}\left[\frac{\partial}{\partial \mathbf{w}^H}\left(d_n^* - \mathbf{u}_n^H \mathbf{w}^*\right)\left(d_n - \mathbf{u}_n^T \mathbf{w}\right)\right], \tag{7.8}$$

откуда по правилу производной произведения:

$$\nabla_J(\mathbf{w}) = \mathrm{E}\left[\left(d_n - \mathbf{u}_n^T\mathbf{w}\right)\frac{\partial}{\partial \mathbf{w}^H}\left(d_n^* - \mathbf{u}_n^H\mathbf{w}^*\right) + \left(d_n^* - \mathbf{u}_n^H\mathbf{w}^*\right)\frac{\partial}{\partial \mathbf{w}^H}\left(d_n - \mathbf{u}_n^T\mathbf{w}\right)\right]. \quad (7.9)$$

Учтем правила вычисления производной по векторному аргументу:

$$\frac{\partial}{\partial \mathbf{w}^H}d_n^* = \frac{\partial}{\partial \mathbf{w}^H}d_n = \mathbf{0}, \quad (7.10)$$

$$\frac{\partial}{\partial \mathbf{w}^H}\mathbf{u}_n^H\mathbf{w}^* = \mathbf{u}_n^*, \qquad \frac{\partial}{\partial \mathbf{w}^H}\mathbf{u}_n^T\mathbf{w} = \mathbf{0}. \quad (7.11)$$

Тогда

$$\nabla_J(\mathbf{w}) = \mathrm{E}\left[-\mathbf{u}_n^*\Big(d_n - \mathbf{u}_n^T\mathbf{w}\Big)\right]. \quad (7.12)$$

В предположении стационарности и эргодичности входного и опорного сигнала, т.е. их характеристики не меняются во времени, можно заключить, что и вектор оптимальных коэффициентов также будет от времени не зависеть. Тогда умножение на вектор коэффициентов можно вынести из под оператора математического усреднения:

$$\nabla_J(\mathbf{w}) = -\,\mathrm{E}\left[\mathbf{u}_n^* d_n\right] + \mathrm{E}\left[\mathbf{u}_n^* \mathbf{u}_n^T\right]\mathbf{w}. \tag{7.13}$$

Как мы рассматривали выше, операторы математического усреднения, в которых участвуют вектора состояния линейного КИХ-фильтра описывают взаимно-корреляционные связи. Так первый оператор описывает ничто иное как вектор взаимной корреляции $\mathbf{r}_{dx}$ размера $M+1$, между опорным и входным сигналами:

$$\mathrm{E}\left[\mathbf{u}_n^* d_n\right] = \mathbf{r}_{dx}, \tag{7.14}$$

а второй оператор описывает корреляционную матрицу сигнала $\mathbf{R}_{xx}$ размерности $\big[(M+1)\times(M+1)\big]$:

$$\mathrm{E}\left[\mathbf{u}_n^* \mathbf{u}_n^T\right] = \mathbf{R}_{xx}, \tag{7.15}$$

Тогда окончательно вектор градиента можно представить как:

$$\nabla_J(\mathbf{w}) = -\mathbf{r}_{dx} + \mathbf{R}_{xx}\mathbf{w}. \tag{7.16}$$

Приравнивая градиент к нулю, получим уравнение Винера-Хопфа для вектора оптимальных коэффициентов:

$$-\mathbf{r}_{dx} + \mathbf{R}_{xx}\mathbf{w} = \mathbf{0}, \quad \text{откуда} \quad \mathbf{w}_{\mathsf{opt}} = \mathbf{R}_{xx}^{-1}\mathbf{r}_{dx}. \tag{7.17}$$

По сути уравнение Винера-Хопфа представляет собой один шаг метода Ньютона минимизации квадратичной целевой функции $J(\mathbf{w})$, достаточный для достижения минимума.

Действительно для произвольного начального вектора коэффициентов $\mathbf{w}_0$, вектор градиента

$$\nabla_J(\mathbf{w}_0) = -\mathbf{r}_{dx} + \mathbf{R}_{xx}\mathbf{w}_0, \tag{7.18}$$

матрица Гёссе представляет собой корреляционную матрицу сигнала:

$$\frac{\partial}{\partial \mathbf{w}}\nabla_J(\mathbf{w}) = \mathbf{R}_{xx}, \tag{7.19}$$

тогда первая итерация метода Ньютона приводит к оптимальным коэффициентам $\mathbf{w}_{\text{opt}}$:

$$\begin{aligned}
\mathbf{w}_1 &= \mathbf{w}_0 - \mathbf{H}^{-1}(\mathbf{w}_0)\nabla_J(\mathbf{w}_0) = \\
&= \mathbf{w}_0 - \mathbf{R}_{xx}^{-1}\Big(-\mathbf{r}_{dx} + \mathbf{R}_{xx}\mathbf{w}_0\Big) = \\
&= \mathbf{w}_0 + \mathbf{R}_{xx}^{-1}\mathbf{r}_{dx} - \underbrace{\mathbf{R}_{xx}^{-1}\mathbf{R}_{xx}}_{\mathbf{I}}\mathbf{w}_0 = \\
&= \mathbf{w}_0 + \mathbf{R}_{xx}^{-1}\mathbf{r}_{dx} - \mathbf{w}_0 = \mathbf{R}_{xx}^{-1}\mathbf{r}_{dx} = \mathbf{w}_{\text{opt}}.
\end{aligned} \tag{7.20}$$

Лекция 7. Методы адаптации линейных фильтров

§7.2. Алгоритм LS

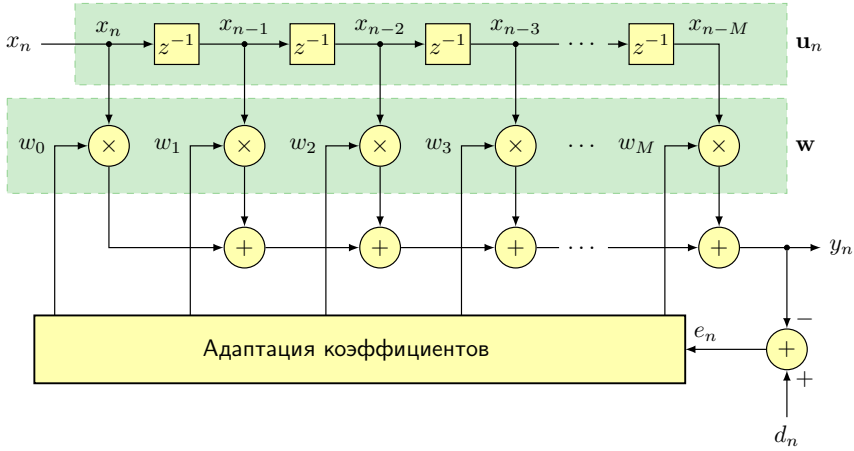

Пусть входной и опорный сигналы x_n и d_n переставляют собой стационарные эргодические процессы и нам даны выборки данных сигналов длительности N отсчетов, записанные в векторы $\mathbf{x}$ и $\mathbf{d}$ размерности $[N \times 1]$ соответственно.

Необходимо произвести оценку оптимальных коэффициентов КИХ-фильтра $\widehat{\mathbf{w}}_{\text{opt}}$ порядка M (размерность вектора $\widehat{\mathbf{w}}_{\text{opt}}$ равна $[(M+1)\times 1]$), обеспечивающих минимум СКО на выходе:

$$J(\mathbf{w}) = \mathbf{e}^H\mathbf{e} = (\mathbf{d}-\mathbf{y})^H(\mathbf{d}-\mathbf{y}) \to \min_{\mathbf{w}}, \tag{7.21}$$

где $\mathbf{y}$ — вектор сигнала на выходе линейного фильтра, который можно описать как $\mathbf{y} = \mathbf{U}\mathbf{w}$ с использовании матрицы $\mathbf{U}$ размерности $[N\times(M+1)]$, каждая строка которой есть транспонированный вектор состояния фильтра $\mathbf{u}_n^T$ для момента времени n.

Тогда окончательно можно записать

$$J(\mathbf{w}) = (\mathbf{d} - \mathbf{U}\mathbf{w})^H(\mathbf{d} - \mathbf{U}\mathbf{w}) \to \min_{\mathbf{w}}. \tag{7.22}$$

Заметим, что

$$J(\mathbf{w}) = \mathbf{w}^H\mathbf{U}^H\mathbf{U}\mathbf{w} - \mathbf{w}^H\mathbf{U}^H\mathbf{d} - \mathbf{d}^H\mathbf{U}\mathbf{w} + \mathbf{d}^H\mathbf{d}. \tag{7.23}$$

Функция $J(\mathbf{w})$ представляет собой квадратичную вещественнозначную функцию комплексного аргумента $\mathbf{w}$. Тогда градиент $\nabla_J(\mathbf{w})$ равен:

$$\nabla_J(\mathbf{w}) = \frac{\partial}{\partial \mathbf{w}^H}(\mathbf{d} - \mathbf{U}\mathbf{w})^H(\mathbf{d} - \mathbf{U}\mathbf{w}) = \mathbf{U}^H\mathbf{U}\mathbf{w} - \mathbf{U}^H\mathbf{d}. \tag{7.24}$$

Приравниваем градиент к нулю и получаем:

$$\mathbf{U}^H\mathbf{U}\mathbf{w} - \mathbf{U}^H\mathbf{d} = \mathbf{0}, \tag{7.25}$$

откуда оценка вектора коэффициентов равна

$$\widehat{\mathbf{w}}_{\text{opt}} = \left(\mathbf{U}^H\mathbf{U}\right)^{-1}\mathbf{U}^H\mathbf{d}. \tag{7.26}$$

Оценка (8.3) носит название LS оценки (Least squares method) и применяется для рассчета вектора оптимальных коэффициентов по ограниченной выборке входного и опорного сигналов.
$\mathbf{U}^H\mathbf{U} = \check{\mathbf{R}}_{xx}$ — смещенная выборочная оценка корреляционной матрицы сигнала, а $\mathbf{U}^H\mathbf{d} = \check{\mathbf{r}}_{dx}$ — смещенная оценка вектора взаимной корреляции входного и опорного сигналов. Тогда:

$$\widehat{\mathbf{w}}_{\text{opt}} = \check{\mathbf{R}}_{xx}^{-1}\check{\mathbf{r}}_{dx}. \tag{7.27}$$

Лекция 7. Методы адаптации линейных фильтров

§7.3. Временны́е соотношения алгоритма LS

Пусть дан фильтр чётного порядка $M = 2D$. Тогда выход фильтра y_n будет задержан относительно входного сигнала x_n на некоторую величину задержки D_{FIR}, которая зависит от коэффициентов фильтра и определяется величинами групповой и фазовой задержки фильтра. Тогда при расчёте матрица $\mathbf{U}$ должна иметь вид:

$$\mathbf{U} = \begin{bmatrix} x_0 & 0 & 0 & 0 & 0 & 0 & 0 \\ x_1 & x_0 & 0 & 0 & 0 & 0 & 0 \\ x_2 & x_1 & x_0 & 0 & 0 & 0 & 0 \\ x_3 & x_2 & x_1 & x_0 & 0 & 0 & 0 \\ x_4 & x_3 & x_2 & x_1 & x_0 & 0 & 0 \\ x_5 & x_4 & x_3 & x_2 & x_1 & x_0 & 0 \\ x_6 & x_5 & x_4 & x_3 & x_2 & x_1 & x_0 \\ x_7 & x_6 & x_5 & x_4 & x_3 & x_2 & x_1 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ x_{N-2} & x_{N-3} & x_{N-4} & x_{N-5} & x_{N-6} & x_{N-7} & x_{N-8} \\ x_{N-1} & x_{N-2} & x_{N-3} & x_{N-4} & x_{N-5} & x_{N-6} & x_{N-7} \end{bmatrix} = \begin{bmatrix} 0 \\ \\ \\ \\ \\ \\ \\ \\ \\ \\ \end{bmatrix}$$

N

$M + 1$

Для корректного расчета ошибки e_n необходимо обеспечить вычитание сигналов y_n и d_n, которые выровнены во времени. Таким образом, мы должны произвести задержку сигнала d_n на величину D_{FIR}.

Сложность: мы не можем получить значение D_{FIR} задержки сигнала на выходе фильтра пока у нас нет коэффициентов фильтра, но для расчета коэффициентов мы должны знать задержку фильтра, чтобы правильно рассчитать ошибку e_n.

На практике для разрешения данного противоречия удобно ввести понятие центра модели, т.е. задать величину задержки фильтра D_{FIR}, произвести временно́е выравнивание сигналов x_n, d_n и y_n с учётом данной задержки и производить расчёт коэффициентов фильтра, которые в результате адаптации обеспечат заданную задержку D_{FIR}.

При этом для возможности реализации линейно-фазового КИХ фильтра целесообразно задать $D_{FIR} = D$, т.е. совместить центр модели с центральным отводом КИХ фильтра чётного порядка.

Пример матрицы состояния КИХ фильтра 6-го порядка при задержанном выходе y_n относительно входа x_n:

$$\mathbf{U} = \begin{bmatrix} x_3 & x_2 & x_1 & x_0 & 0 & 0 & 0 \\ x_4 & x_3 & x_2 & x_1 & x_0 & 0 & 0 \\ x_5 & x_4 & x_3 & x_2 & x_1 & x_0 & 0 \\ x_6 & x_5 & x_4 & x_3 & x_2 & x_1 & x_0 \\ x_7 & x_6 & x_5 & x_4 & x_3 & x_2 & x_1 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ x_{N-2} & x_{N-3} & x_{N-4} & x_{N-5} & x_{N-6} & x_{N-7} & x_{N-8} \\ x_{N-1} & x_{N-2} & x_{N-3} & x_{N-4} & x_{N-5} & x_{N-6} & x_{N-7} \\ 0 & x_{N-1} & x_{N-2} & x_{N-3} & x_{N-4} & x_{N-5} & x_{N-6} \\ 0 & 0 & x_{N-1} & x_{N-2} & x_{N-3} & x_{N-4} & x_{N-5} \\ 0 & 0 & 0 & x_{N-1} & x_{N-2} & x_{N-3} & x_{N-4} \end{bmatrix} = \begin{bmatrix} & & & & & 0 & \\ & & & & & & 0 \\ & & & & & & \\ & & & & & & \\ & & & & & & \\ & & & & & & \\ & & & & & & \\ & & & & & & \\ & & & & & & \\ & & & & & & \\ 0 & & & & & & \end{bmatrix} \begin{matrix} \\ \\ \\ \\ \\ \\ \\ \\ \\ \\ \\ \end{matrix} \begin{matrix} \\ \\ \\ \\ \\ \\ \\ \\ \\ \\ N \end{matrix}$$

$$M + 1$$

Построение адаптивного фильтра с заданным центром модели позволяет учесть задержку на выходе фильтра, и математически мы можем записать свертку как:

$$y_n = \sum_{m=-D}^{D} x_{n-m} w_m \tag{7.28}$$

Таким образом, сигнал на выходе фильтра имеет нулевую задержку относительно входа.

Важно понять мы не нарушаем принцип причинности!

Реальный фильтр будет иметь задержку на выходе относительно входа ровно D отсчетов.

Мы именно это потребовали, чтобы он имел задержку ровно D, и после этого учли в уравнениях, как будто исходный сигнал также задержан на D отсчетов.

§7.4. Метод градиентного спуска при блочной оценке коэффициентов адаптивного фильтра

Метод градиентного спуска заключается в итерационном приближении к точке оптимума при движении в сторону антиградиента с некоторым шагом μ. Тогда приближение вектора коэффициентов $\mathbf{w}_{k+1}$ на следующем шаге можно получить из вектора коэффициентов $\mathbf{w}_k$ на текущем шаге как[2]:

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \mu \nabla_J\big(\mathbf{w}_k\big). \tag{7.29}$$

Поскольку вектор коэффициентов будет меняться от итерации к итерации, то и значение функции минимума среднего квадрата ошибки $J(\mathbf{w}_k)$ также меняются, как и вектор ошибки зависящий от вектора коэффициентов $\mathbf{w}_k$:

$$J(\mathbf{w}_k) = \mathbf{e}_k^H \mathbf{e}_k = \big(\mathbf{d} - \mathbf{U}\mathbf{w}_k\big)^H \big(\mathbf{d} - \mathbf{U}\mathbf{w}_k\big) \tag{7.30}$$

Вектор градиента получим, дифференцируя (7.30) по эрмитово-сопряженному вектору коэффициентов:

$$\nabla_J\big(\mathbf{w}_k\big) = \frac{\partial}{\partial \mathbf{w}_k^H} \big(\mathbf{d} - \mathbf{U}\mathbf{w}_k\big)^H \big(\mathbf{d} - \mathbf{U}\mathbf{w}_k\big). \tag{7.31}$$

[2]Здесь и далее переменная k индексирует номер итерации градиентного спуска, а вектор $\mathbf{w}_k$ означает вектор коэффициентов, полученный на шаге k.

Используя правила дифференцирования по векторному комплексному аргументу получим:

$$\nabla_J(\mathbf{w}_k) = -\mathbf{U}^H \underbrace{(\mathbf{d} - \mathbf{U}\mathbf{w}_k)}_{\mathbf{e}_k} = -\mathbf{U}^H \mathbf{e}_k, \tag{7.32}$$

откуда

$$\mathbf{w}_{k+1} = \mathbf{w}_k + \mu \mathbf{U}^H \mathbf{e}_k. \tag{7.33}$$

Каждая итерация заключается:

- Применяем текущий вектор коэффициентов $\mathbf{w}_k$ ко всему блоку данных.
- Рассчитываем вектор ошибки $\mathbf{e}_k$ для всего блока данных длины N.
- Обновляем вектор коэффициентов согласно (7.33) для использования на следующей итерации $k+1$.

Градиентный спуск в блочном режиме не требует инверсии корреляционной матрицы, но все ещё требует накопления матрицы $\mathbf{U}$, а значит коэффициенты будут адаптироваться с задержкой. На каждой итерации k мы можем оценивать значение исходной целевой функции $J(\mathbf{w}_k) = \mathbf{e}_k^H \mathbf{e}_k$ и выводить на график значение нормированной СКО

$$\mathrm{NMSE}_k = 10 \lg \left(\frac{\mathbf{e}_k^H \mathbf{e}_k}{\mathbf{x}^H \mathbf{x}} \right), \quad [\text{дБ}], \tag{7.34}$$

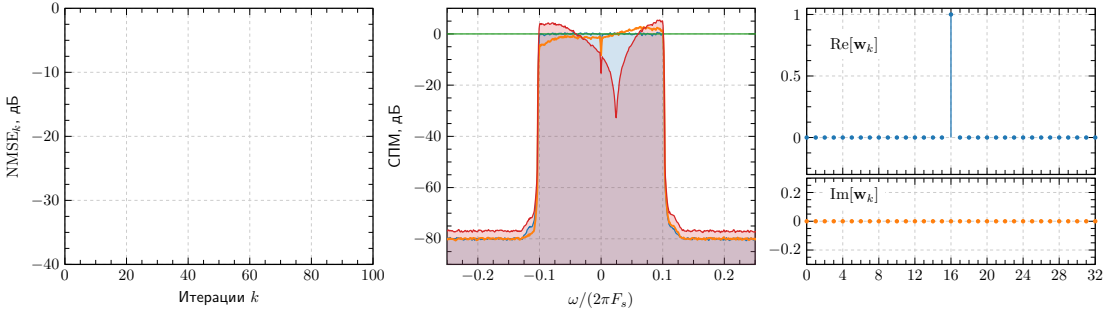

§7.5. Переход от блочной оценки градиента к стохастическому спуску. Алгоритм LMS

Выражение (7.33), с учетом $\mathbf{e}_k = \mathbf{d} - \mathbf{U}\mathbf{w}_k$, можно переписать в следующем виде:

$$\mathbf{w}_{k+1} = \mathbf{w}_k + \mu \mathbf{U}^H \big(\mathbf{d} - \mathbf{U}\mathbf{w}_k\big), \tag{7.35}$$

откуда раскрыв скобки:

$$\mathbf{w}_{k+1} = \mathbf{w}_k + \mu \left(\mathbf{U}^H\mathbf{d} - \mathbf{U}^H\mathbf{U}\mathbf{w}_k\right). \tag{7.36}$$

Вспомним, что $\mathbf{U}^H\mathbf{d} = \check{\mathbf{r}}_{dx}$ ничто иное как оценка вектора взаимной корреляции опорного и входного сигналов, а $\mathbf{U}^H\mathbf{U} = \check{\mathbf{R}}_{xx}$ — корреляционная матрица сигнала, то можно записать:

$$\nabla_J\big(\mathbf{w}_k\big) = \check{\mathbf{R}}\mathbf{w}_k - \check{\mathbf{r}}_{dx} \tag{7.37}$$

С другой стороны:

$$\mathrm{E}\left[-\mathbf{u}_n^* e_n\right] = \mathrm{E}\left[-\mathbf{u}_n^*\big(d_n - \mathbf{u}_n^T\mathbf{w}_k\big)\right] = \\ = \mathrm{E}\left[\mathbf{u}_n^*\mathbf{u}_n^T\right]\mathbf{w}_k - \mathrm{E}\left[\mathbf{u}_n^* d_n\right] = \mathbf{R}_{xx}\mathbf{w}_k - \mathbf{r}_{xd}. \tag{7.38}$$

Переменная k индексирует блочные итерации градиентного алгоритма, а n —номер отсчёта внутри блока. Тогда сравнивая (7.37) и (7.38):

$$\mathbf{w}_{k+1} = \mathbf{w}_k - \mu \underbrace{\mathrm{E}\left[-\mathbf{u}_n^* e_n\right]}_{\nabla_J(\mathbf{w}_k)} = \mathbf{w}_k + \mu\,\mathrm{E}\left[\mathbf{u}_n^* e_n\right]. \tag{7.39}$$

Таким образом, одна итерация обновления коэффициентов в блочном режиме требует усреднения во времени (индекс n) произведения $\mathbf{u}_n^* e_n$ сопряженного вектора состояния фильтра на текущее значение сигнала ошибки, соответствующее коэффициентам $\mathbf{w}_k$.
В блочном градиентном спуске мы использовали для усреднения $\mathbf{u}_n^* e_n$ весь блок данных, поэтому алгоритм градиентного спуска в блочном режиме не зависит от времени n.
Однако выражение (7.39) дает возможность «отвязать» индексы итераций k от блока данных, и мы будем обновлять коэффициенты $\mathbf{w}_k$ несколько раз на протяжении блока данных.

Рассмотрим на примере. Пусть длина блока данных $N = 10000$ отсчетов. Оценку $\mathrm{E}\left[\mathbf{u}_n^* e_n\right]$ мы будем вести по 1000 отсчетов. Так за один блок данных мы произведем 10 обновлений коэффициентов фильтра.
При этом встает вопрос: а как часто мы можем обновлять коэффициенты? Сколько отсчетов требуется для усреднения $\mathrm{E}\left[\mathbf{u}_n^* e_n\right]$?
Оказывается, при малом значении μ мы можем накопление градиента вести непосредственно с накоплением коэффициентов и перейти от блочной обработки к обработке по одному отсчёту:

$$\mathbf{w}_{n+1} = \mathbf{w}_n + \mu \mathbf{u}_n^* e_n, \quad \text{где} \quad e_n = d_n - \mathbf{u}_n^T \mathbf{w}_n. \tag{7.40}$$

Обновление коэффициентов «поотсчетно» возможно поскольку выражение (7.40) и есть интегратор, который накапливает произведения $\mathbf{u}_n^* e_n$.
Необходимо сделать важное замечание. Очень часто алгоритм LMS записывают в следующем виде:

$$\mathbf{w}_n = \mathbf{w}_{n-1} + \mu \mathbf{u}_n^* e_n, \quad \text{где} \quad e_n = d_n - \mathbf{u}_n^T \mathbf{w}_{n-1}. \tag{7.41}$$

Обе записи являются эквивалентными.

Алгоритм LMS стохастического градиентного спуска также можно пояснить следующим образом. Пусть целевая функция представляет собой минимум СКО $J(\mathbf{w}) = \mathrm{E}[e_n^* e_n]$.

Тогда градиент

$$\nabla_J(\mathbf{w}) = \frac{\partial}{\partial \mathbf{w}^H} \mathrm{E}[e_n^* e_n] = \mathrm{E}\left[\frac{\partial}{\partial \mathbf{w}^H}\left(e_n^* e_n\right)\right] = \mathrm{E}\left[\nabla_{f_n}(\mathbf{w})\right], \tag{7.42}$$

где $f_n(\mathbf{w}) = e_n^* e_n$ — квадрат модуля мгновенной ошибки.

Градиент функции СКО равен усредненным градиентам функций мгновенной ошибки.

При этом уравнение обновления коэффициентов.

$$\mathbf{w}_{n+1} = \mathbf{w}_n + \mu \mathbf{u}_n^* e_n, \quad \text{где} \quad e_n = d_n - \mathbf{u}_n^T \mathbf{w}_n. \tag{7.43}$$

и есть интегратор усредняющий $\nabla_{f_n}(\mathbf{w})$ одновременно с изменение коэффициентов.

Крайне важно обновлять ошибку e_n, применяя накопленные коэффициенты, иначе алгоритм может разойтись.

Граф алгоритма

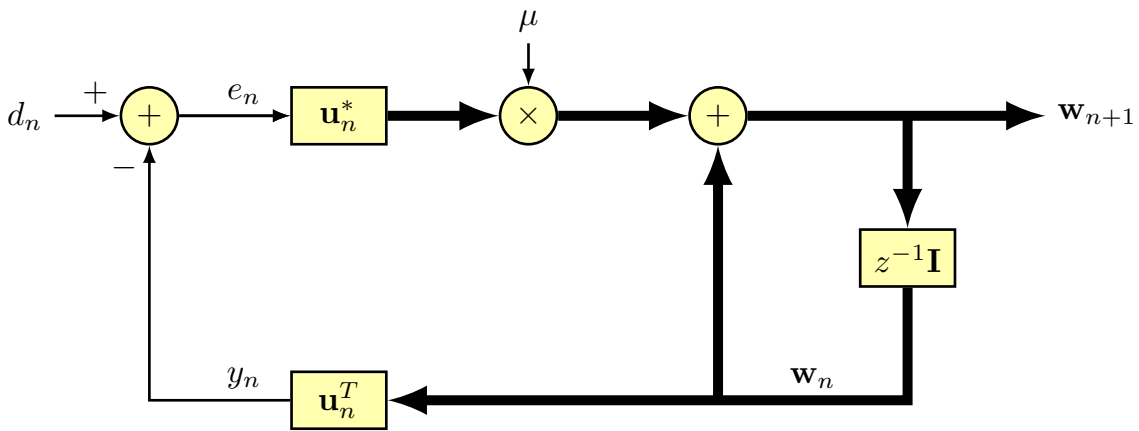

Лекция 7. Методы адаптации линейных фильтров

§7.6. Временны́е соотношения алгоритма LMS

Алгоритм LMS заменяет блочный градиентный спуск при адаптации коэффициентов поотсчетным накоплением, при этом временны́е соотношения алгоритма LMS должны согласовываться с соотношениями в блочном режиме, как это показано на рисунке:

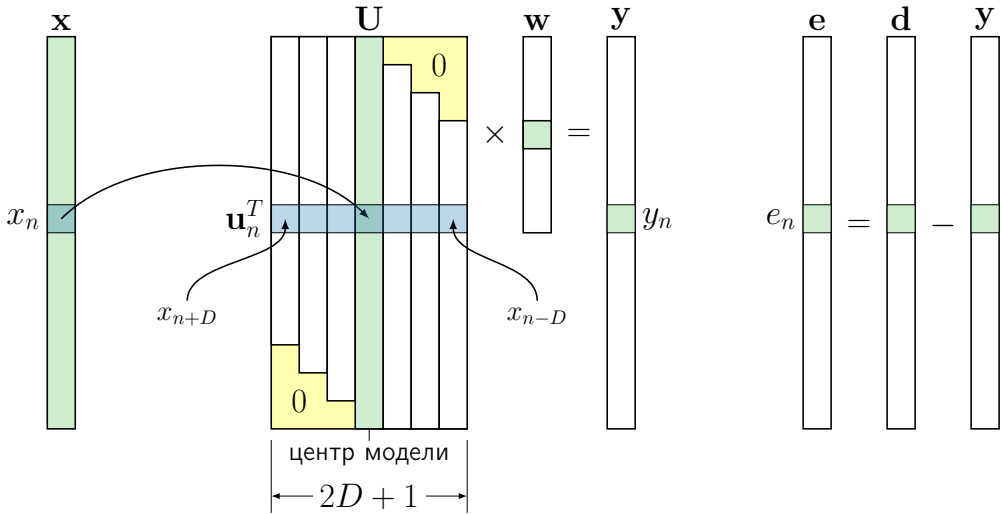

§7.7. Выбор шага адаптации при использовании алгоритма LMS. Эффект переобучения.

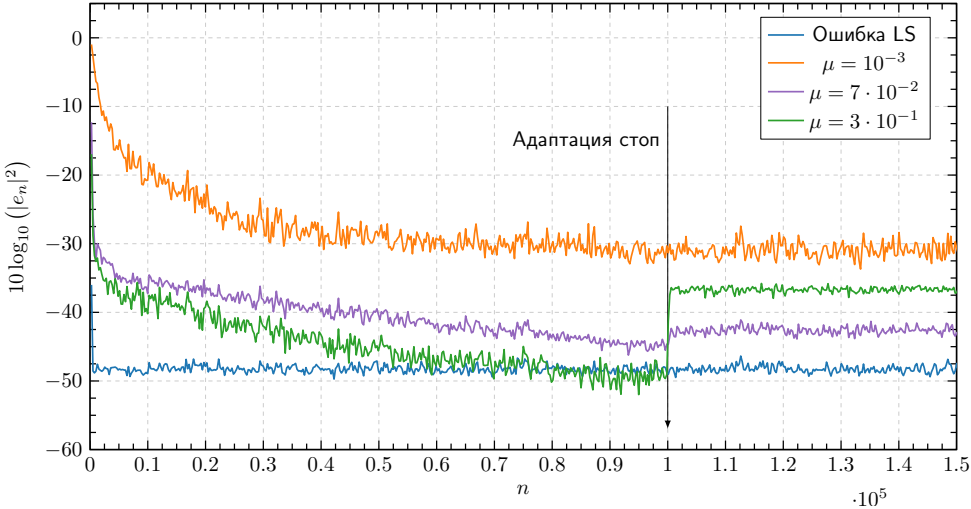

Основное правило, которое мы должны усвоить из приведенного примера заключается в том, что ошибку стохастической адаптации необходимо всегда верифицировать при остановке адаптации и фиксации коэффициентов, чтобы исключить ложные выводы основанные на эффекте переобучения.

Лекция 7. Методы адаптации линейных фильтров

§7.8. Рекурсивный LS алгоритм (RLS)

Рассмотрим LS алгоритм для блока данных длины N:

$$\mathbf{w} = \left(\mathbf{U}^H\mathbf{U}\right)^{-1}\mathbf{U}^H\mathbf{d} = \check{\mathbf{R}}_{xx}^{-1}\check{\mathbf{r}}_{dx}. \tag{7.44}$$

Оценку корреляционной матрицы можно получить в результате накопления векторных произведений $\mathbf{u}_n$:

$$\check{\mathbf{R}}_{xx} = \frac{1}{N}\sum_{n=0}^{N-1}\mathbf{u}_n^*\mathbf{u}_n^T. \tag{7.45}$$

Аналогично вектор $\check{\mathbf{r}}_{xd}$ можно получить накоплением произведения сопряженного вектора состояния $\mathbf{u}_n^*$ на значения опорного сигнала:

$$\check{\mathbf{r}}_{dx} = \frac{1}{N}\sum_{n=0}^{N-1}\mathbf{u}_n^*d_n, \tag{7.46}$$

Множитель $\frac{1}{N}$ можно опустить при накоплении корреляционной матрицы и вектора взаимной корреляции, поскольку согласно уравнению LS оценки (7.44) данный множитель сократится.

Введем обозначение $\mathbf{R}_{N-1} = \check{\mathbf{R}}_{xx}$, что соответствует оценки корреляционной матрицы при суммировании всех N векторных произведений. Тогда оценка корреляционной матрицы равна

$$\mathbf{R}_{N-1} = \sum_{n=0}^{N-1} \mathbf{u}_n^* \mathbf{u}_n^T = \underbrace{\sum_{n=0}^{N-2} \mathbf{u}_n^* \mathbf{u}_n^T}_{\mathbf{R}_{N-2}} + \mathbf{u}_{N-1}^* \mathbf{u}_{N-1}^T \tag{7.47}$$

Аналогично введем обозначение для оценки вектора взаимной корреляции $\check{\mathbf{r}}_{xd} = \mathbf{r}_{N-1}$, тогда

$$\mathbf{r}_{N-1} = \sum_{n=0}^{N-1} \mathbf{u}_n^* d_n = \underbrace{\sum_{n=0}^{N-2} \mathbf{u}_n^* d_n}_{\mathbf{r}_{N-2}} + \mathbf{u}_{N-1}^* d_{N-1}, \tag{7.48}$$

Производя накопление корреляционной матрицы и вектора взаимной корреляции во времени можно записать рекуррентные соотношения:

$$\mathbf{R}_n = \mathbf{R}_{n-1} + \mathbf{u}_n^* \mathbf{u}_n^T; \qquad \mathbf{r}_n = \mathbf{r}_{n-1} + \mathbf{u}_n^* d_n. \tag{7.49}$$

Тогда оценку оптимальных коэффициентов можно вести рекурсивно и для момента времени n можно записать:

$$\mathbf{w}_n = \left(\mathbf{R}_{n-1} + \mathbf{u}_n^* \mathbf{u}_n^T\right)^{-1} \left(\mathbf{r}_{n-1} + \mathbf{u}_n^* d_n\right) \tag{7.50}$$

Лемма об инверсии матрицы:

$$(\mathbf{A} + \mathbf{UCV})^{-1} = \mathbf{A}^{-1} - \mathbf{A}^{-1}\mathbf{U}\left(\mathbf{C}^{-1} + \mathbf{VA}^{-1}\mathbf{U}\right)^{-1}\mathbf{VA}^{-1} \tag{7.51}$$

Здесь $\mathbf{A} = \mathbf{R}_{n-1}$, $\mathbf{U} = \mathbf{u}_n^*$, $\mathbf{C} = 1$ и $\mathbf{V} = \mathbf{u}_n^T$. Тогда

$$\mathbf{R}_n^{-1} = \mathbf{R}_{n-1}^{-1} - \frac{\mathbf{R}_{n-1}^{-1}\mathbf{u}_n^*\mathbf{u}_n^T\mathbf{R}_{n-1}^{-1}}{1 + \mathbf{u}_n^T\mathbf{R}_{n-1}^{-1}\mathbf{u}_n^*} \tag{7.52}$$

Обозначим $\mathbf{R}_{n-1}^{-1} = \mathbf{P}_{n-1}$, тогда $\mathbf{R}_n^{-1} = \mathbf{P}_n$ и

$$\mathbf{P}_n = \mathbf{P}_{n-1} - \underbrace{\frac{\mathbf{P}_{n-1}\mathbf{u}_n^*}{1 + \mathbf{u}_n^T\mathbf{P}_{n-1}\mathbf{u}_n^*}}_{\mathbf{k}_n} \mathbf{u}_n^T\mathbf{P}_{n-1} \tag{7.53}$$

$$\mathbf{P}_n = \mathbf{P}_{n-1} - \mathbf{k}_n \mathbf{u}_n^T \mathbf{P}_{n-1} \tag{7.54}$$

Заметим, что

$$\mathbf{k}_n + \mathbf{k}_n \mathbf{u}_n^T \mathbf{P}_{n-1} \mathbf{u}_n^* = \mathbf{P}_{n-1} \mathbf{u}_n^*. \tag{7.55}$$

Для доказательства подставить выражение для $\mathbf{k}_n$ и преобразовать:

$$\frac{\mathbf{P}_{n-1}\mathbf{u}_n^*}{1 + \mathbf{u}_n^T \mathbf{P}_{n-1}\mathbf{u}_n^*} + \frac{\mathbf{P}_{n-1}\mathbf{u}_n^*}{1 + \mathbf{u}_n^T \mathbf{P}_{n-1}\mathbf{u}_n^*} \mathbf{u}_n^T \mathbf{P}_{n-1}\mathbf{u}_n^* =$$

$$= \mathbf{P}_{n-1}\mathbf{u}_n^* \frac{1}{1 + \mathbf{u}_n^T \mathbf{P}_{n-1}\mathbf{u}_n^*} + \mathbf{P}_{n-1}\mathbf{u}_n^* \frac{\mathbf{u}_n^T \mathbf{P}_{n-1}\mathbf{u}_n^*}{1 + \mathbf{u}_n^T \mathbf{P}_{n-1}\mathbf{u}_n^*} = \tag{7.56}$$

$$= \mathbf{P}_{n-1}\mathbf{u}_n^* \frac{1 + \mathbf{u}_n^T \mathbf{P}_{n-1}\mathbf{u}_n^*}{1 + \mathbf{u}_n^T \mathbf{P}_{n-1}\mathbf{u}_n^*} = \mathbf{P}_{n-1}\mathbf{u}_n^*.$$

Тогда из (7.55) следует:

$$\mathbf{k}_n = \mathbf{P}_{n-1}\mathbf{u}_n^* - \mathbf{k}_n\mathbf{u}_n^T\mathbf{P}_{n-1}\mathbf{u}_n^* = \underbrace{\Big(\mathbf{P}_{n-1} - \mathbf{k}_n\mathbf{u}_n^T\mathbf{P}_{n-1}\Big)}_{\mathbf{P}_n}\mathbf{u}_n^* = \mathbf{P}_n\mathbf{u}_n^*. \tag{7.57}$$

Возвращаясь к (7.50) можно записать:

$$\mathbf{w}_n = \mathbf{P}_n\Big(\mathbf{r}_{n-1} + \mathbf{u}_n^* d_n\Big) = \Big(\mathbf{P}_{n-1} - \mathbf{k}_n\mathbf{u}_n^T\mathbf{P}_{n-1}\Big)\mathbf{r}_{n-1} + \mathbf{P}_n\mathbf{u}_n^* d_n \tag{7.58}$$

Раскрываем скобки:

$$\mathbf{w}_n = \underbrace{\mathbf{P}_{n-1}\mathbf{r}_{n-1}}_{\mathbf{w}_{n-1}} - \mathbf{k}_n\underbrace{\mathbf{u}_n^T\mathbf{P}_{n-1}\mathbf{r}_{n-1}}_{\mathbf{u}_n^T\mathbf{w}_{n-1}=y_n} + \underbrace{\mathbf{P}_n\mathbf{u}_n^* d_n}_{\mathbf{k}_n d_n} \tag{7.59}$$

Таким образом RLS алгоритм имеет вид:

$$\mathbf{w}_n = \mathbf{w}_{n-1} - \mathbf{k}_n y_n + \mathbf{k}_n d_n, \tag{7.60}$$

$d_n - y_n = e_n$ — ошибка адаптации окончательно можно записать:

$$\mathbf{w}_n = \mathbf{w}_{n-1} + \mathbf{k}_n e_n. \tag{7.61}$$

Алгоритм RLS состоит из двух этапов:

1. Предсказание выхода по оцененным параметрам системы (матрица $\mathbf{P}_{n-1}$и вектор коэффициентов $\mathbf{w}_{n-1}$) и текущему вектору состояния $\mathbf{u}_n$.
2. Обновление матрицы $\mathbf{P}_n$ и вектора коэффициентов $\mathbf{w}_n$.

Инициализация алгоритма: $\mathbf{P}(-1) = \sigma\mathbf{I}$, $\mathbf{w}(-1) = \mathbf{0}$.
На каждом шаге $k = 0, 1, \ldots$ производится расчёт ошибки $e_n = d_n - y_n$, где $y_n = \mathbf{u}_n^T\mathbf{w}_{n-1}$, а также коэффициента усиления $\mathbf{k}_n$:

$$\mathbf{k}_n = \frac{\mathbf{P}_{n-1}\mathbf{u}_n^*}{1 + \mathbf{u}_n^T\mathbf{P}_{n-1}\mathbf{u}_n^*} \tag{7.62}$$

После этого обновляем вектор коэффициентов $\mathbf{w}_n$:

$$\mathbf{w}_n = \mathbf{w}_{n-1} + \mathbf{k}_n e_n. \tag{7.63}$$

а также матрицу $\mathbf{P}_n$:

$$\mathbf{P}_n = \mathbf{P}_{n-1} - \mathbf{k}_n\mathbf{u}_n^T\mathbf{P}_{n-1} \tag{7.64}$$

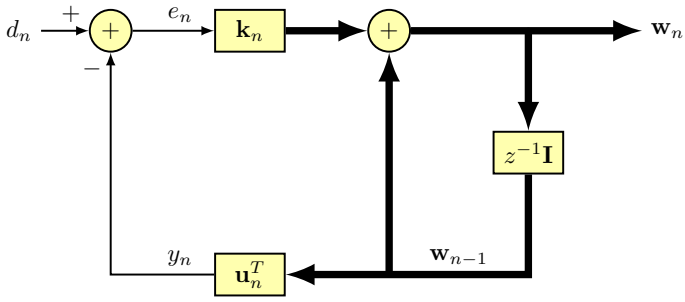

Инициализация $\mathbf{P}_{-1} = \sigma\mathbf{I}$, $\mathbf{w}_{-1} = \mathbf{0}$.

`for` $n = 0,\ 1,\ 2, \ldots,\ N$:

$$y_n = \mathbf{u}_n^T \mathbf{w_{n-1}}$$

$$e_n = d_n - y_n$$

$$\mathbf{k}_n = \frac{\mathbf{P}_{n-1}\mathbf{u}_n^*}{1 + \mathbf{u}_n^T \mathbf{P}_{n-1}\mathbf{u}_n^*}$$

$$\mathbf{w}_n = \mathbf{w}_{n-1} + \mathbf{k}_n e_n$$

$$\mathbf{P}_n = \mathbf{P}_{n-1} - \mathbf{k}_n \mathbf{u}_n^T \mathbf{P}_{n-1}$$

Алгоритм RLS — частный случай рекурсивного фильтра Калмана.

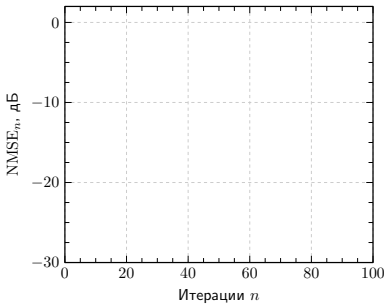
NMSE_n, дБ
0
−10
−20
−30
0
20
40
60
80
100
Итерации n

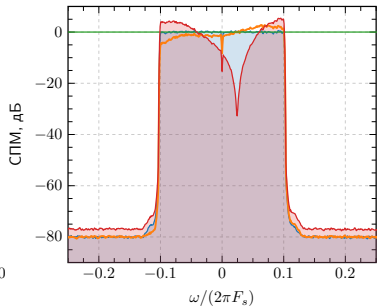
СПМ, дБ
0
−20
−40
−60
−80
−0.2
−0.1
0
0.1
0.2
$\omega/(2\pi F_s)$

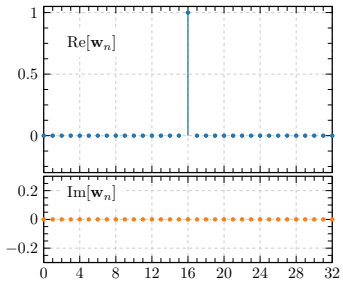
$\mathrm{Re}[\mathbf{w}_n]$
1
0.5
0
$\mathrm{Im}[\mathbf{w}_n]$
0.2
0
−0.2
0
4
8
12
16
20
24
28
32

Лекция 8. Численная устойчивость алгоритмов адаптации линейных фильтров

§8.1. Проблема численной устойчивости при адаптации фильтров

Пусть входной сигнал x_n поступает на вход линейного канала с частотной характеристикой $H(\omega)$, и на выходе получаем искажённый сигнал z_n. Для построения адаптивного корректора входной сигнал содержит известные пилот последовательности.

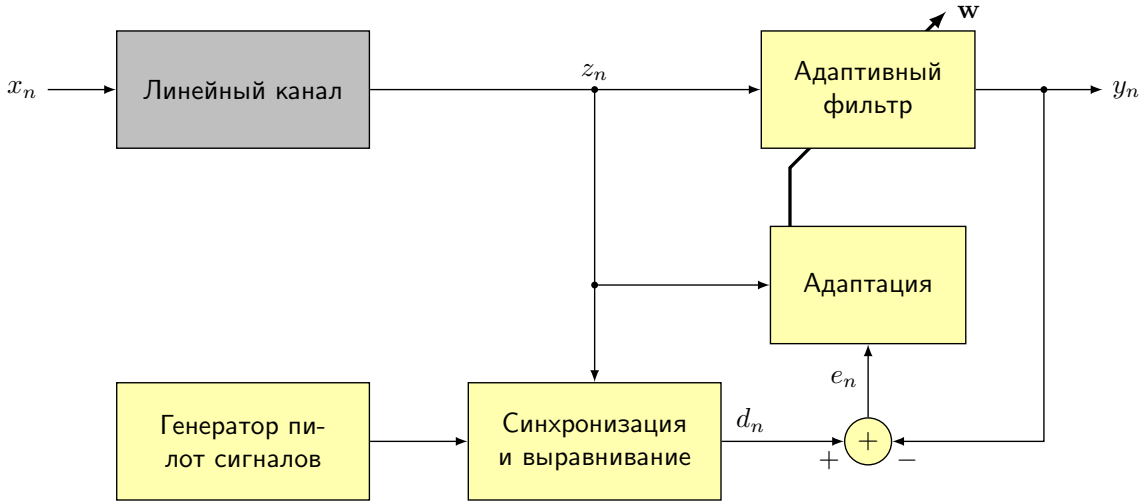

Прохождение сигнала x_n через канал с частотной характеристикой $H(\omega)$ можно представить как $Z(\omega) = X(\omega)H(\omega)$, где $Z(\omega)$ и $X(\omega)$ — спектры сигналов z_n и x_n соответственно.

Тогда спектр сигнала $Y(\omega)$ на выходе адаптивного фильтра можно представить в частотной области как:

$$Y(\omega) = Z(\omega)W(\omega) = X(\omega)H(\omega)W(\omega), \tag{8.1}$$

где $W(\omega)$ — частотная характеристика адаптивного фильтра корректора с вектором коэффициентов $\mathbf{w}$.

Частотную характеристику $W(\omega)$, обеспечивающую компенсацию искажений канала можно представить как:

$$W(\omega) = \frac{Y(\omega)}{Z(\omega)} = \frac{Y(\omega)}{X(\omega)H(\omega)}. \tag{8.2}$$

При идеальной компенсации $X(\omega) = Y(\omega)$ и $W(\omega) = \dfrac{1}{H(\omega)}$.

Анализ выражения (8.2) позволяет сделать два важных вывода:

- $W(\omega) = \dfrac{1}{H(\omega)}$ представляет собой дробь, что соответствует фильтру с бесконечной импульсной характеристикой. Это означает, что добиться полной компенсации искажений канала при использовании адаптивного фильтра КИХ не представляется возможным.

- Наличие в знаменателе дроби произведения $X(\omega)H(\omega)$ говорит о том, что численный поиск $W(\omega)$ может быть сопряжён с трудностями, если в числителе и в знаменателе появится отношение малых величин.

Так например если спектр сигнала $X(\omega)$ равен (или близок) нулю в некоторой полосе частот, то и спектр $Y(\omega)$ также будет близок к нулю в этой же полосе.

Наличие шума при вычислении отношения (8.2) может привести к непредсказуемому результату: $W(\omega)$ может принять произвольные огромные значения вне полосы сигнала.

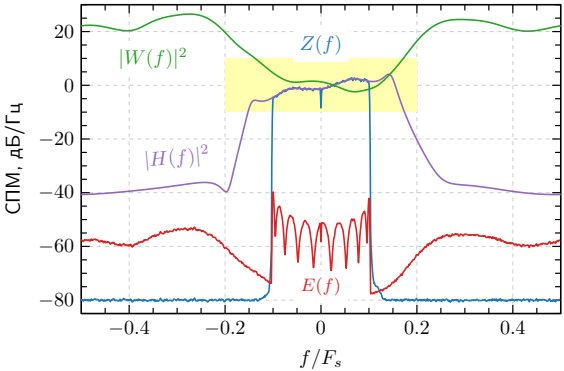

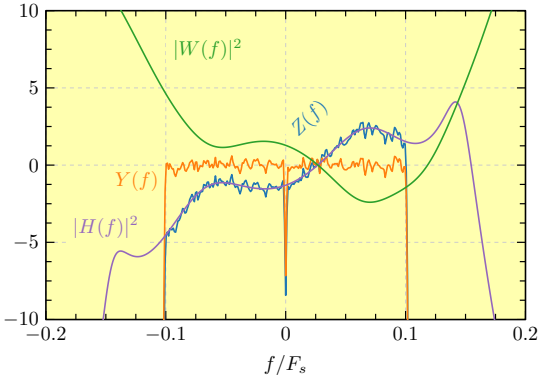

Анализ корреляционной матрицы $\mathbf{R}_{zz}$ показал, что ввиду ограниченной полосы входного сигнала она является плохо обусловленной (число обусловленности порядка 10^8), что приводит к появлению у фильтра усиления вне полосы сигнала.

Таким образом, главная цель стабилизации заключается в улучшении обусловленности корреляционной матрицы $\mathbf{R}_{zz}$.

Лекция 8. Численная устойчивость алгоритмов адаптации линейных фильтров

§8.2. Регуляризация LS оценки путем изменения корреляционной матрицы

Корреляционная матрица плохо обусловлена из-за ограниченной полосы сигнала.

Возможный путь — расширить полосу сигнала путём добавления к нему аддитивного белого гауссовского шума ξ_n с нулевым средним и некоторой дисперсией σ^2.

Тогда на входе корректора будет сигнал $v_n = z_n + \xi_n$, во всей полосе и изменением дисперсии шума мы можем влиять на поведение адаптивного фильтра вне полосы сигнала.

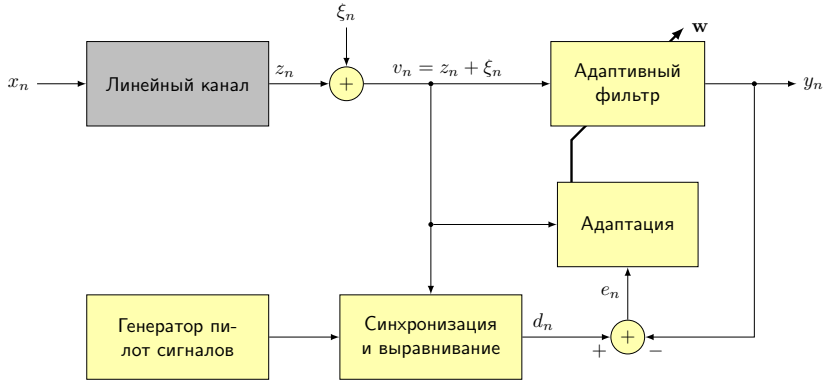

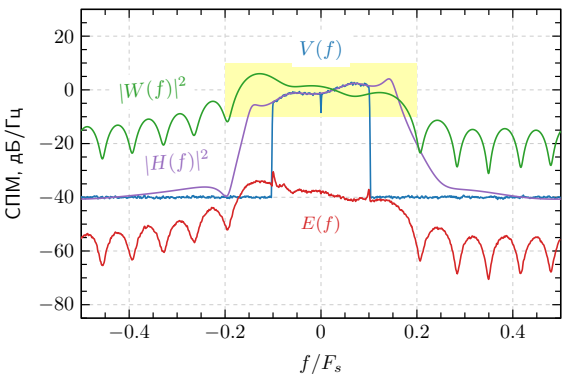

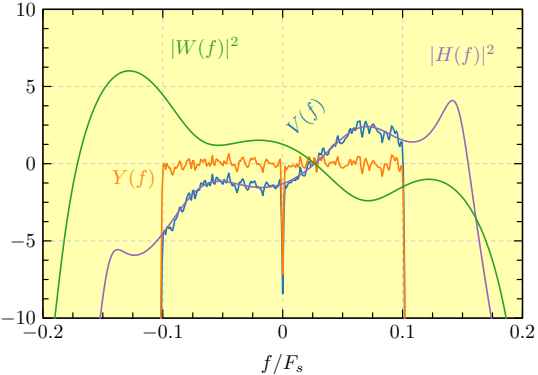

$V(f)$ — СПМ входного сигнала адаптивного корректора $v_n = z_n + \xi_n$;
$Y(f)$ — СПМ выхода корректора y_n после LS оценки вектора коэффициентов фильтра;
$E(f)$ — СПМ остаточной ошибки e_n после коррекции;
$|H(f)|^2$ — АЧХ линейного канала; $|W(f)|^2$ — АЧХ корректора после адаптации.
АЧХ корректора ограничена вне полосы сигнала. Однако сам сигнал зашумлён на уровне -40 дБ (дисперсия шума $\sigma^2 = 10^{-4}$).

Физического зашумления входного сигнала можно избежать, если вспомнить свойства корреляционной матрицы сигнала и шума.

Поскольку шум ξ_n и сигнал на выходе линейного канала является независимыми процессами, то корреляционная матрица их суммы равна сумме их корреляционных матриц $\mathbf{R}_{vv} = \mathbf{R}_{zz} + \mathbf{R}_{\xi\xi}$.

При этом корреляционная матрица белого гауссовского шума $\mathbf{R}_{\xi\xi} = \sigma^2\mathbf{I}$.
Тогда подставив в уравнение Винера-Хопфа выражение $\mathbf{R}_{vv}$ получим:

$$\widehat{\mathbf{w}} = \mathbf{R}_{vv}^{-1}\mathbf{r}_{dz} = \left(\mathbf{R}_{zz} + \sigma^2\mathbf{I}\right)^{-1}\mathbf{r}_{dz}. \tag{8.3}$$

При этом нам не требуется добавлять шум ξ_n физически, нам достаточно только изменить корреляционную матрицу в LS оценке коэффициентов.

Такой метод изменения корреляционной матрицы носит названия метода регуляризации А.Н. Тихонова.

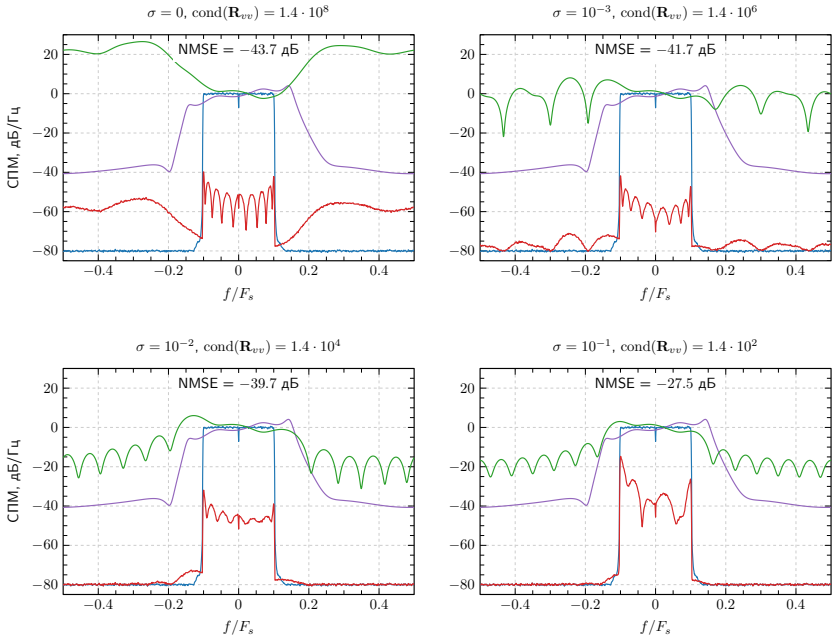
$\sigma = 0$, $\mathrm{cond}(\mathbf{R}_{vv}) = 1.4 \cdot 10^8$
NMSE = −43.7 дБ
$\sigma = 10^{-3}$, $\mathrm{cond}(\mathbf{R}_{vv}) = 1.4 \cdot 10^6$
NMSE = −41.7 дБ
$\sigma = 10^{-2}$, $\mathrm{cond}(\mathbf{R}_{vv}) = 1.4 \cdot 10^4$
NMSE = −39.7 дБ
$\sigma = 10^{-1}$, $\mathrm{cond}(\mathbf{R}_{vv}) = 1.4 \cdot 10^2$
NMSE = −27.5 дБ
СПМ, дБ/Гц
f/F_s
20
0
−20
−40
−60
−80
−0.4
−0.2
0
0.2
0.4

Лекция 8. Численная устойчивость алгоритмов адаптации линейных фильтров

§8.3. Регуляризация как изменение критерия адаптации

Использование зашумленного сигнала для обеспечения численной устойчивости LS оценки наглядно демонстрирует физический смысл метода регуляризации.

С другой стороны рост коэффициента передачи КИХ-фильтра невозможен без увеличения нормы коэффициентов $\mathbf{w}$, что позволяет применить метод штрафных функций при решении задачи.

Для ограничения нормы коэффициентов, мы можем изменить целевую функцию $J(\mathbf{w})$ (критерий адаптации):

$$J(\mathbf{w}) = (\mathbf{d} - \mathbf{U}\mathbf{w})^H(\mathbf{d} - \mathbf{U}\mathbf{w}) + \sigma^2\mathbf{w}^H\mathbf{w}. \tag{8.4}$$

Получим уравнения для LS оценки оптимального вектора коэффициентов по критерию (8.4) с учетом штрафа.

Для этого рассчитаем градиент $\nabla_J(\mathbf{w})$ и приравняем его к нулю:

$$\nabla_J(\mathbf{w}) = \frac{\partial J(\mathbf{w})}{\partial \mathbf{w}^H} = -\mathbf{U}^H(\mathbf{d} - \mathbf{U}\mathbf{w}) + \sigma^2\mathbf{w} = -\mathbf{U}^H\mathbf{d} + \left(\mathbf{U}^H\mathbf{U} + \sigma^2\mathbf{I}\right)\mathbf{w}. \tag{8.5}$$

Тогда приравнивая вектор градиента к нулю получаем уравнение для оценки оптимальных коэффициентов фильтра по критерию (8.4):

$$\hat{\mathbf{w}} = \left(\mathbf{U}^H\mathbf{U} + \sigma^2\mathbf{I}\right)^{-1}\mathbf{U}^H\mathbf{d}. \tag{8.6}$$

Можно видеть, что изменение критерия приводит к добавлению единичной матрицы в коэффициентом σ^2 при инверсии корреляционной матрицы.

Теперь становится понятно, почему с увеличением значения σ^2 ошибка компенсации возрастает. Все дело в изменении критерия, и полученные с регуляризаций коэффициенты фильтра не являются оптимальными по критерию минимума СКО, но по критерию (8.4) они оптимальны, поскольку штрафная функция не позволяет получить более точную компенсацию искажений.

Лекция 8. Численная устойчивость алгоритмов адаптации линейных фильтров

§8.4. LMS алгоритм с утечкой

LMS алгоритм обновления коэффициентов имеет вид:

$$\mathbf{w}_{n+1} = \mathbf{w}_n + \mu \mathbf{u}_n^* e_n. \tag{8.7}$$

Предположим, что входной сигнал есть сумма полезного сигнала x_n и белого гауссовского шума ξ_n с нулевым средним и дисперсией σ^2. Тогда

$$\mathbf{w}_{n+1} = \mathbf{w}_n + \mu\big(\mathbf{u}_n^* + \mathbf{r}_n^*\big) e_n, \tag{8.8}$$

где $\mathbf{r}_n$ — вектор задержанных отсчетов шума.
Ошибка

$$e_n = d_n - \big(\mathbf{u}_n^T + \mathbf{r}_n^T\big)\mathbf{w}_n. \tag{8.9}$$

Подставляем и раскрываем скобки:

$$\begin{aligned} \mathbf{w}_{n+1} =& \mathbf{w}_n + \mu \mathbf{u}_n^* e_n + \mu \mathbf{r}_n^* \Big(d_n - \big(\mathbf{u}_n^T + \mathbf{r}_n^T\big)\mathbf{w}_n \Big) = \\ =& \mathbf{w}_n + \mu \mathbf{u}_n^* e_n + \mu \mathbf{r}_n^* d_n - \mu \mathbf{r}_n^* \mathbf{u}_n^T \mathbf{w}_n - \mu \mathbf{r}_n^* \mathbf{r}_n^T \mathbf{w}_n. \end{aligned} \tag{8.10}$$

Учтем, что белый гауссовский шум ξ_n некоррелирован со входным x_n и опорным d_n сигналами:

$$\mathrm{E}\left[\mathbf{r}_n^* d_n\right] = \mathbf{0}, \quad \mathrm{E}\left[\mathbf{r}_n^* \mathbf{u}_n^T\right] = \mathbf{0}, \quad \mathrm{E}\left[\mathbf{r}_n^* \mathbf{r}_n^T\right] = \sigma^2 \mathbf{I}. \tag{8.11}$$

Тогда в процессе итеративного накопления (8.10)

$$\mathbf{w}_{n+1} = \mathbf{w}_n + \mu \mathbf{u}_n^* e_n + \mu \underbrace{\mathbf{r}_n^* d_n}_{\mathbf{0}} - \mu \underbrace{\mathbf{r}_n^* \mathbf{u}_n^T}_{\mathbf{0}} \mathbf{w}_n - \mu \underbrace{\mathbf{r}_n^* \mathbf{r}_n^T}_{\sigma^2 \mathbf{I}} \mathbf{w}_n. \tag{8.12}$$

некоррелированные произведения будут исчезать, и (8.10) можно переписать:

$$\mathbf{w}_{n+1} = \mathbf{w}_n + \mu \mathbf{u}_n^* e_n - \mu \sigma^2 \mathbf{I} \mathbf{w}_n. \tag{8.13}$$

или окончательно

$$\mathbf{w}_{n+1} = (1 - \underbrace{\mu \sigma^2}_{\lambda}) \mathbf{w}_n + \mu \mathbf{u}_n^* e_n. \tag{8.14}$$

$$\mathbf{w}_{n+1} = (1 - \lambda) \mathbf{w}_n + \mu \mathbf{u}_n^* e_n. \tag{8.15}$$

Таким образом, добавление ко входному сигналу белого гауссовского шума приводит к LMS алгоритму с утечкой.

В результате мы имеем экспоненциальное «забывание» коэффициентов в процессе адаптации, регулируемое параметром $1 - \lambda$.

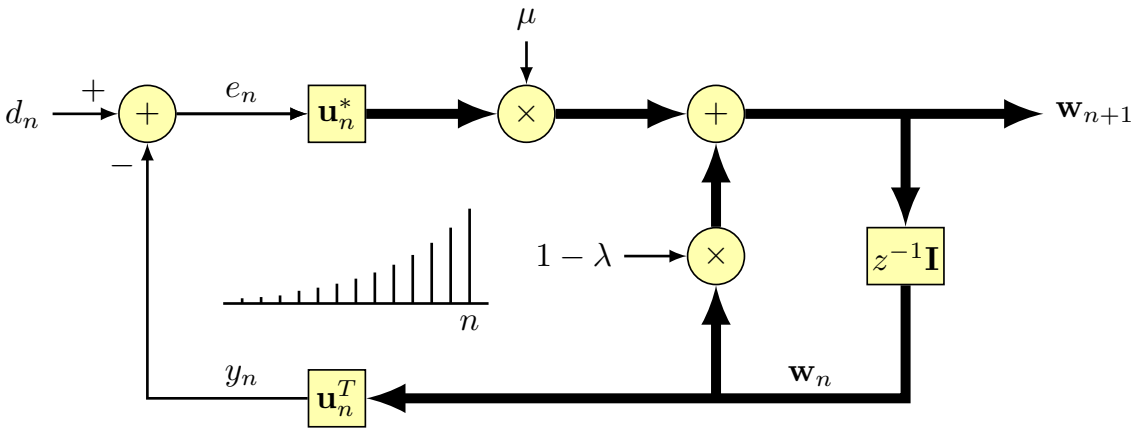

Наличие утечки также можно трактовать как изменение критерия адаптации при использовании стохастического градиентного спуска.

В методах стохастического спуска минимизируется мгновенная мощность ошибки на каждом шаге адаптации.

Таким образом критерий адаптации на каждом шаге n представляет собой $J(\mathbf{w}_n) = e_n^* e_n$, где $e_n = d_n - \mathbf{u}_n^T \mathbf{w}_n$.

Рассмотрим изменение критерия путем добавления слагаемого с весом σ^2 в виде штрафа на квадрат нормы вектора коэффициентов:

$$J(\mathbf{w}_n) = e_n^* e_n + \sigma^2 \mathbf{w}_n^H \mathbf{w}_n, \qquad e_n = d_n - \mathbf{u}_n^T \mathbf{w}_n. \tag{8.16}$$

Тогда следующий шаг стохастического градиентного спуска равен

$$\mathbf{w}_{n+1} = \mathbf{w}_n - \mu \nabla_J \big(\mathbf{w}_n\big). \tag{8.17}$$

Градиент в случает добавления штрафа в виде квадрата нормы коэффициентов равен:

$$\begin{aligned}\nabla_J\big(\mathbf{w_n}\big) =& \frac{\partial}{\partial \mathbf{w}_n^H} J(\mathbf{w}_n) = \frac{\partial}{\partial \mathbf{w}_n^H}\Big[e_n^* e_n + \sigma^2 \mathbf{w}_n^H \mathbf{w}_n\Big] = \\ =& \underbrace{\frac{\partial}{\partial \mathbf{w}_n^H} e_n^* e_n}_{-\mathbf{u}_n^* e_n} + \sigma^2 \frac{\partial}{\partial \mathbf{w}_n^H} \mathbf{w}_n^H \mathbf{w}_n = -\mathbf{u}_n^* e_n + \sigma^2 \mathbf{w}_n.\end{aligned} \tag{8.18}$$

Подставляя в уравнение стохастического спуска (8.17) получим уравнение

$$\mathbf{w}_{n+1} = \mathbf{w}_n - \mu\big(-\mathbf{u}_n^* e_n + \sigma^2 \mathbf{w}_n\big) = (1-\mu\sigma^2)\mathbf{w}_n + \mu \mathbf{u}_n^* e_n, \tag{8.19}$$

обновления коэффициентов соответствующее алгоритму LMS с утечкой (8.15), при $\lambda = \mu\sigma^2$.

Лекция 8. Численная устойчивость алгоритмов адаптации линейных фильтров

§8.5. Численная стабилизация LS при использовании сигнулярного SVD разложения

Пусть дана некоторая прямоугольная матрица $\mathbf{A} \in \mathbb{C}^{N\times M}$. Тогда матрица $\mathbf{A}^{+} \in \mathbb{C}^{M\times N}$ называется псевдообратной к $\mathbf{A}$ если:

$$\mathbf{A}\mathbf{A}^{+}\mathbf{A} = \mathbf{A}; \qquad \mathbf{A}^{+}\mathbf{A}\mathbf{A}^{+} = \mathbf{A}^{+}. \tag{8.20}$$

Выражение (8.20) является определением псевдообратной матрицы по Пенроузу.

Заметим, что процедура псевдообращения применима не только к квадратным, но и к прямоугольным матрицам. Например для матрицы

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 3 & 1 & 5 \\ 0 & 6 & 2 \\ 8 & 2 & 9 \end{bmatrix} \tag{8.21}$$

псевдообратная матрица $\mathbf{A}^{+}$ имеет вид:

$$\mathbf{A}^{+} = \begin{bmatrix} -0.3554723094057 & -0.377847524552 & 0.077756403766 & 0.311126860383 \\ -0.0839323681279 & -0.145894502379 & 0.197225878303 & 0.065201984408 \\ 0.3229725625190 & 0.378050015187 & -0.109952414701 & -0.182140326010 \end{bmatrix}. \tag{8.22}$$

При этом важно понимать, что если имеется две прямоугольные матрицы $\mathbf{A}$, $\mathbf{B} \in \mathbb{C}^{N \times M}$, а также псевдообратная матрица $\mathbf{A}^{+}$, то выполнение условий (8.20) приводит к тому, что в общем случае[3]

$$\mathbf{A}\mathbf{A}^{+}\mathbf{A} = \mathbf{A}, \quad \text{но} \quad \mathbf{A}\mathbf{A}^{+}\mathbf{B} \neq \mathbf{B}. \tag{8.23}$$

Для пояснения обратимся к листингу:

[3] В частных случаях равенство $\mathbf{A}\mathbf{A}^{+}\mathbf{B} = \mathbf{B}$ выполняется. Например если $\mathbf{A}$ — невырожденная квадратная матрица, то $\mathbf{A}^{+} = \mathbf{A}^{-1}$.
Также равенство $\mathbf{A}\mathbf{A}^{+}\mathbf{B} = \mathbf{B}$ выполняется для прямоугольной матрицы $\mathbf{A} \in \mathbb{C}^{N \times M}$, если число столбцов больше числа строк $M > N$, и ранг матрицы равен N.

```
# -*- coding: utf-8 -*-
import numpy as np

# Матрица A размерности [4 x 3]
A = np.array([[1,  2,  3],
              [3,  1,  5],
              [0,  6,  2],
              [8,  2,  9]])

# Матрица B размерности [4 x 3] отличная от A
B = np.array([[4,  7,  1],
              [0,  1, -2],
              [8,  4, -3],
              [2,  2,  0]])

# Расчет псевдоинверсной матрицы  P = A^+ размерности [3 x 4]
P = np.linalg.pinv(A)

C = A @ P @ A  # Рассчитываем C = AA^+A
```

```
# Проверяем выполнение условия A = AA^+A
print('max(|C-A|) = %.3f' % np.max(C-A))

D = A @ P @ B  # Рассчитываем D = AA^+B
# Проверяем выполнение условия B ≠ AA^+B
print('max(|D-B|) = %.3f' % np.max(D-B))

# Матрица AA^+ не является единичной
E = A @ P
np.set_printoptions(formatter={'float': '{: 0.3f} '.format})
print('E = ')
print(E)
```

Результат работы скрипта:

```
max(|C-A|) = 0.000
max(|D-B|) = 2.561
E =
[[ 0.446  0.465  0.142 -0.105]
 [ 0.465  0.611 -0.119  0.088]
 [ 0.142 -0.119  0.963  0.027]
 [-0.105  0.088  0.027  0.980]]
```

$\mathbf{C} = \mathbf{AA}^{+}\mathbf{A} = \mathbf{A}$

$\mathbf{D} = \mathbf{AA}^{+}\mathbf{B} \neq \mathbf{B}$

$\mathbf{E} = \mathbf{AA}^{+} \neq \mathbf{I}$

Теорема Мура–Пенроуза доказывает существование и единственность пседообратной матрицы для любой $\mathbf{A} \in \mathbb{C}^{N \times M}$, расчет которой производят с использованием сингулярного разложения (SVD) .
Рассмотрим некоторую прямоугольную матрицу $\mathbf{A} \in \mathbb{C}^{N \times M}$. Тогда неотрицательное вещественное число σ называется сингулярным числом матрицы $\mathbf{A}$, если

$$\mathbf{A}\mathbf{v} = \sigma\mathbf{u}, \quad \text{и} \quad \mathbf{A}^H\mathbf{u} = \sigma\mathbf{v}, \tag{8.24}$$

где $\mathbf{u} \in \mathbb{C}^N$ и $\mathbf{v} \in \mathbb{C}^M$ — правый и левый сингулярные векторы.
SVD разложение произвольной матрицы имеет вид[4]:

$$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^H, \tag{8.25}$$

где $\mathbf{U} \in \mathbb{C}^{N \times N}$ и $\mathbf{V} \in \mathbb{C}^{M \times M}$ — квадратные унитарные матрицы составленные из правых и левых сингулярных векторов, а $\mathbf{\Sigma} \in \mathbb{C}^{N \times M}$ — диагональная матрица, содержащая сингулярные числа, отсортированные в порядке убывания.

[4] В данном параграфе вектор $\mathbf{u}$ и матрицу $\mathbf{U}$ не стоит путать с вектором и матрицей состояния фильтра.

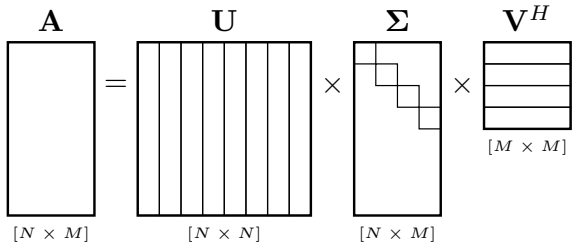

Ввиду унитарности матриц[5] $\mathbf{U} \in \mathbb{C}^{N \times N}$ и $\mathbf{V} \in \mathbb{C}^{M \times M}$, то псевдообратная матрица $\mathbf{A}^+$ может быть найдена как:

$$\mathbf{A}^+ = \mathbf{V}\mathbf{\Sigma}^{-1}\mathbf{U}^H. \tag{8.26}$$

Можно заметить, что обращение матриц $\mathbf{U} \in \mathbb{C}^{N \times N}$ и $\mathbf{V} \in \mathbb{C}^{M \times M}$ сводится к их эрмитову сопряжению, что является устойчивой процедурой, а обращение диагональной матрицы $\mathbf{\Sigma} \in \mathbb{C}^{N \times M}$ сводится к транспонированию и замене диагональных элементов σ_{ii} на $1/\sigma_{ii}$.

[5] Напомним, что матрица $\mathbf{U}$ является унитарной, если $\mathbf{U}^{-1} = \mathbf{U}^H$.

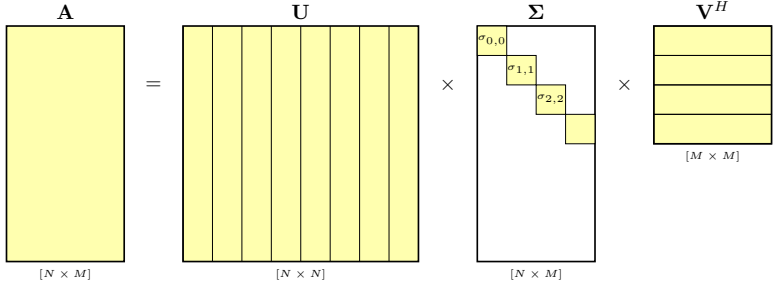
A
U
Σ
V^H
=
×
×
$\sigma_{0,0}$
$\sigma_{1,1}$
$\sigma_{2,2}$
$[N \times M]$
$[N \times N]$
$[N \times M]$
$[M \times M]$

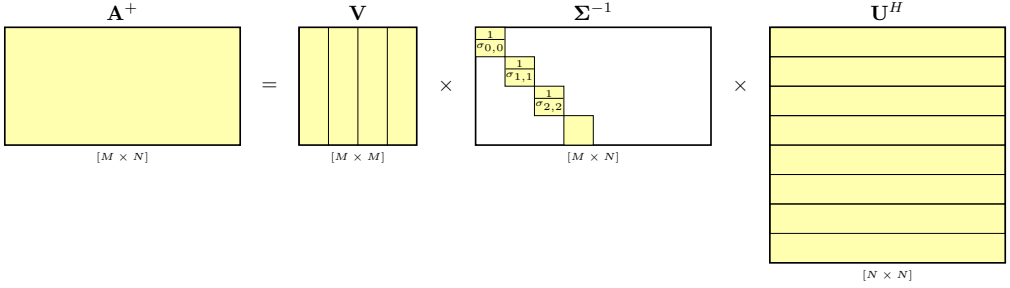
A^+
V
Σ^{-1}
U^H
=
×
×
$\frac{1}{\sigma_{0,0}}$
$\frac{1}{\sigma_{1,1}}$
$\frac{1}{\sigma_{2,2}}$
$[M \times N]$
$[M \times M]$
$[M \times N]$
$[N \times N]$

Таким образом причина численной неустойчивости кроется в малых сингулярных числах на диагонали матрицы $\mathbf{\Sigma}$, которые при обращении дадут большие значения инвертированной матрицы $\mathbf{\Sigma}^{-1}$.

Однако можно заметить, что малые диагональные элементы матрицы $\mathbf{\Sigma}$ вносят малый вклад в SVD представление (8.25), т.к. они масштабируют векторные произведения сингулярных векторов.

Таким образом, мы можем обнулить малые сингулярные числа матрицы $\mathbf{\Sigma}$ ниже некоторого порога, в результате чего использовать при псевдоинверсии только оставшиеся ненулевые сингулярные числа.

В результате мы будем рассчитывать псеводинверсию близкой матрицы, однако отсутствие малых сингулярных чисел в матрице $\mathbf{\Sigma}$ приведет к существенному повышению численной устойчивости алгоритма.

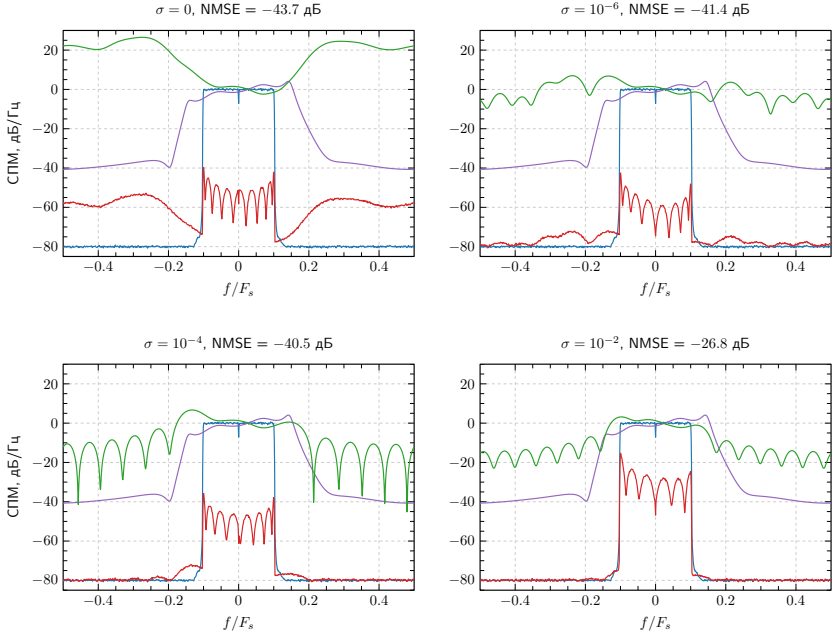
$\sigma = 0$, NMSE = -43.7 дБ
$\sigma = 10^{-6}$, NMSE = -41.4 дБ
$\sigma = 10^{-4}$, NMSE = -40.5 дБ
$\sigma = 10^{-2}$, NMSE = -26.8 дБ
СПМ, дБ/Гц
f/F_s
20
0
−20
−40
−60
−80
−0.4
−0.2
0
0.2
0.4

Лекция 8. Численная устойчивость алгоритмов адаптации линейных фильтров

§8.6. Алгоритм RLS с утечкой

Рекуррентные соотношения при накоплении матрицы и вектора с экспоненциальным забыванием:

$$\mathbf{R}_n = \lambda \mathbf{R}_{n-1} + \mathbf{u}_n^* \mathbf{u}_n^T; \tag{8.27}$$

$$\mathbf{r}_n = \lambda \mathbf{r}_{n-1} + \mathbf{u}_n^* d_n. \tag{8.28}$$

Тогда оценку оптимальных коэффициентов можно вести рекурсивно и для момента времени n можно записать:

$$\mathbf{w}_n = \underbrace{\left(\lambda \mathbf{R}_{n-1} + \mathbf{u}_n^* \mathbf{u}_n^T\right)^{-1}}_{\mathbf{R}_n^{-1}} \left(\lambda \mathbf{r}_{n-1} + \mathbf{u}_n^* d_n\right) \tag{8.29}$$

Лемма об инверсии матрицы:

$$(\mathbf{A} + \mathbf{UCV})^{-1} = \mathbf{A}^{-1} - \mathbf{A}^{-1}\mathbf{U}\left(\mathbf{C}^{-1} + \mathbf{V}\mathbf{A}^{-1}\mathbf{U}\right)^{-1}\mathbf{V}\mathbf{A}^{-1}. \tag{8.30}$$

Здесь $\mathbf{A} = \lambda \mathbf{R}_{n-1}$, $\mathbf{U} = \mathbf{u}_n^*$, $\mathbf{C} = 1$ и $\mathbf{V} = \mathbf{u}_n^T$.

$$(\mathbf{A}+\mathbf{UCV})^{-1}=\mathbf{A}^{-1}-\mathbf{A}^{-1}\mathbf{U}\left(\mathbf{C}^{-1}+\mathbf{VA}^{-1}\mathbf{U}\right)^{-1}\mathbf{VA}^{-1},$$

$\mathbf{A}=\lambda\mathbf{R}_{n-1}$, $\mathbf{U}=\mathbf{u}_n^*$, $\mathbf{C}=1$ и $\mathbf{V}=\mathbf{u}_n^T$.

Тогда

$$\mathbf{R}_n^{-1}=\lambda^{-1}\mathbf{R}_{n-1}^{-1}-\frac{\lambda^{-1}\mathbf{R}_{n-1}^{-1}\mathbf{u}_n^*\mathbf{u}_n^T\lambda^{-1}\mathbf{R}_{n-1}^{-1}}{1+\mathbf{u}_n^T\lambda^{-1}\mathbf{R}_{n-1}^{-1}\mathbf{u}_n^*} \tag{8.31}$$

Обозначим $\mathbf{R}_{n-1}^{-1}=\mathbf{P}_{n-1}$, тогда $\mathbf{R}_n^{-1}=\mathbf{P}_n$ и

$$\mathbf{P}_n=\lambda^{-1}\mathbf{P}_{n-1}-\underbrace{\frac{\lambda^{-1}\mathbf{P}_{n-1}\mathbf{u}_n^*}{1+\lambda^{-1}\mathbf{u}_n^T\mathbf{P}_{n-1}\mathbf{u}_n^*}}_{\mathbf{k}_n}\mathbf{u}_n^T\lambda^{-1}\mathbf{P}_{n-1} \tag{8.32}$$

И получаем соотношение:

$$\mathbf{P}_n=\lambda^{-1}\mathbf{P}_{n-1}-\lambda^{-1}\mathbf{k}_n\mathbf{u}_n^T\mathbf{P}_{n-1} \tag{8.33}$$

Заметим, что

$$\mathbf{k}_n + \lambda^{-1}\mathbf{k}_n\mathbf{u}_n^T\mathbf{P}_{n-1}\mathbf{u}_n^* = \lambda^{-1}\mathbf{P}_{n-1}\mathbf{u}_n^*. \tag{8.34}$$

Для доказательства подставить выражение для $\mathbf{k}_n$ и преобразовать.

Тогда

$$\mathbf{k}_n = \lambda^{-1}\mathbf{P}_{n-1}\mathbf{u}_n^* - \lambda^{-1}\mathbf{k}_n\mathbf{u}_n^T\mathbf{P}_{n-1}\mathbf{u}_n^* = \underbrace{\left(\lambda^{-1}\mathbf{P}_{n-1} - \lambda^{-1}\mathbf{k}_n\mathbf{u}_n^T\mathbf{P}_{n-1}\right)}_{\mathbf{P}_n}\mathbf{u}_n^* = \mathbf{P}_n\mathbf{u}_n^*. \tag{8.35}$$

Возвращаясь к (8.29) можно записать:

$$\mathbf{w}_n = \mathbf{P}_n\Big(\lambda\mathbf{r}_{n-1} + \mathbf{u}_n^* d_n\Big) = \Big(\lambda^{-1}\mathbf{P}_{n-1} - \lambda^{-1}\mathbf{k}_n\mathbf{u}_n^T\mathbf{P}_{n-1}\Big)\lambda\mathbf{r}_{n-1} + \mathbf{P}_n\mathbf{u}_n^* d_n \tag{8.36}$$

Раскрываем скобки:

$$\mathbf{w}_n = \underbrace{\mathbf{P}_{n-1}\mathbf{r}_{n-1}}_{\mathbf{w}_{n-1}} - \mathbf{k}_n \underbrace{\mathbf{u}_n^T \mathbf{P}_{n-1}\mathbf{r}_{n-1}}_{\mathbf{u}_n^T\mathbf{w}_{n-1}=y_n} + \underbrace{\mathbf{P}_n \mathbf{u}_n^* d_n}_{\mathbf{k}_n d_n} \tag{8.37}$$

Таким образом RLS алгоритм с утечкой имеет вид:

$$\mathbf{w}_n = \mathbf{w}_{n-1} - \mathbf{k}_n y_n + \mathbf{k}_n d_n, \tag{8.38}$$

Учтём, что $d_n - y_n = e_n$ — ошибка адаптации окончательно можно записать:

$$\mathbf{w}_n = \mathbf{w}_{n-1} + \mathbf{k}_n e_n. \tag{8.39}$$

Алгоритм RLS состоит из двух этапов:

1. Предсказание выхода по оцененным параметрам системы (матрица $\mathbf{P}_{n-1}$и вектор коэффициентов $\mathbf{w}_{n-1}$) и текущему вектору состояния $\mathbf{u}_n$.

2. Обновление матрицы $\mathbf{P}_n$ и вектора коэффициентов $\mathbf{w}_n$.

Инициализация алгоритма: $\mathbf{P}_{-1} = \sigma\mathbf{I}$, $\mathbf{w}_{-1} = \mathbf{0}$.
На каждом шаге $k = 0, 1, \ldots$ производится расчёт ошибки $e_n = d_n - y_n$, где $y_n = \mathbf{u}_n^T\mathbf{w}_{n-1}$, а также коэффициента усиления $\mathbf{k}_n$:

$$\mathbf{k}_n = \frac{\lambda^{-1}\mathbf{P}_{n-1}\mathbf{u}_n^*}{1 + \lambda^{-1}\mathbf{u}_n^T\mathbf{P}_{n-1}\mathbf{u}_n^*} = \frac{\mathbf{P}_{n-1}\mathbf{u}_n^*}{\lambda + \mathbf{u}_n^T\mathbf{P}_{n-1}\mathbf{u}_n^*}. \tag{8.40}$$

После этого обновляем вектор коэффициентов $\mathbf{w}_n$:

$$\mathbf{w}_n = \mathbf{w}_{n-1} + \mathbf{k}_n e_n, \tag{8.41}$$

а также матрицу $\mathbf{P}_n$:

$$\mathbf{P}_n = \lambda^{-1}\mathbf{P}_{n-1} - \lambda^{-1}\mathbf{k}_n\mathbf{u}_n^T\mathbf{P}_{n-1}. \tag{8.42}$$

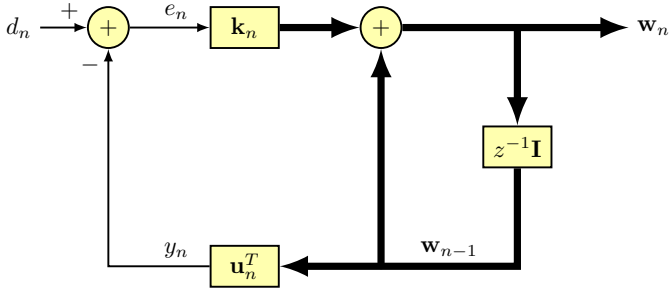

Инициализация $\mathbf{P}_{-1} = \sigma\mathbf{I}$, $\mathbf{w}_{-1} = \mathbf{0}$.

`for` $n = 0,\ 1,\ 2, \ldots,\ N$:

$$y_n = \mathbf{u}_n^T \mathbf{w_{n-1}}$$

$$e_n = d_n - y_n$$

$$\mathbf{k}_n = \frac{\mathbf{P}_{n-1}\mathbf{u}_n^*}{\lambda + \mathbf{u}_n^T \mathbf{P}_{n-1}\mathbf{u}_n^*}$$

$$\mathbf{w}_n = \mathbf{w}_{n-1} + \mathbf{k}_n e_n$$

$$\mathbf{P}_n = \lambda^{-1}\mathbf{P}_{n-1} - \lambda^{-1}\mathbf{k}_n \mathbf{u}_n^T \mathbf{P}_{n-1}$$

Обычно параметр λ принимает значения $0.9 \ldots 1$.

Лекция 9. Адаптации каскада линейных фильтров

§9.1. Адаптация фильтров по сумме выходов

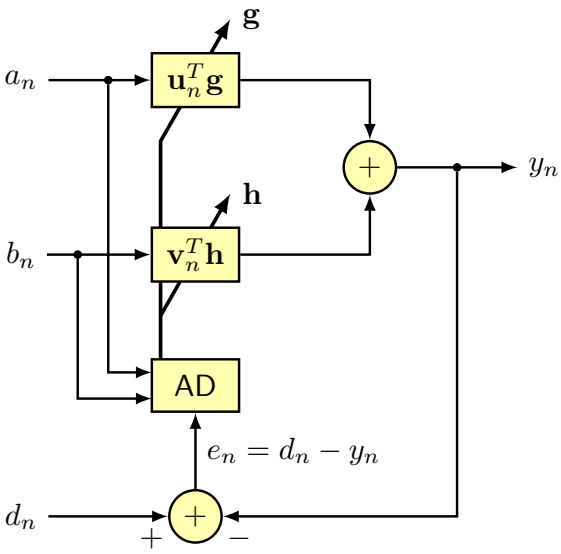

$a_n, b_n \in \mathbb{C}$, $\mathbf{u}_n$, $\mathbf{g} \in \mathbb{C}^{M_g}$, $\mathbf{v}_n$, $\mathbf{h} \in \mathbb{C}^{M_h}$.

Выход модели $y_n = \mathbf{u}_n^T\mathbf{g} + \mathbf{v}_n^T\mathbf{h}$.

Вектор коэффициентов модели: $\mathbf{w} = \begin{bmatrix}\mathbf{g}\\ \mathbf{h}\end{bmatrix}$.

Целевая функция: $J(\mathbf{w}) = J(\mathbf{g}, \mathbf{h}) = e_n^* e_n$ минимизирует квадрат мгновенной ошибки.

Алгоритм LMS:

$$\mathbf{g}_n = \mathbf{g}_{n-1} - \mu \frac{\partial J(\mathbf{g}, \mathbf{h})}{\partial \mathbf{g}^H}; \qquad (9.1)$$

$$\mathbf{h}_n = \mathbf{h}_{n-1} - \mu \frac{\partial J(\mathbf{g}, \mathbf{h})}{\partial \mathbf{h}^H}. \qquad (9.2)$$

Рассчитываем производные:

$$\frac{\partial J(\mathbf{g},\mathbf{h})}{\partial \mathbf{g}^H} = \frac{\partial}{\partial \mathbf{g}^H}(d_n - \mathbf{u}_n^T\mathbf{g} - \mathbf{v}_n^T\mathbf{h})^*(d_n - \mathbf{u}_n^T\mathbf{g} - \mathbf{v}_n^T\mathbf{h}) = -\mathbf{u}_n^* e_n; \tag{9.3}$$

$$\frac{\partial J(\mathbf{g},\mathbf{h})}{\partial \mathbf{h}^H} = \frac{\partial}{\partial \mathbf{h}^H}(d_n - \mathbf{u}_n^T\mathbf{g} - \mathbf{v}_n^T\mathbf{h})^*(d_n - \mathbf{u}_n^T\mathbf{g} - \mathbf{v}_n^T\mathbf{h}) = -\mathbf{v}_n^* e_n. \tag{9.4}$$

Окончательно уравнения:

$$\mathbf{g}_n = \mathbf{g}_{n-1} + \mu \mathbf{u}_n^* e_n; \tag{9.5}$$

$$\mathbf{h}_n = \mathbf{h}_{n-1} + \mu \mathbf{v}_n^* e_n. \tag{9.6}$$

Вывод: сумму фильтров можно адаптировать независимо по одной ошибке.
Коэффициенты фильтров не зависят друг от друга.

Рассмотрим алгоритм LS оценки для блоков данных $\mathbf{a}$, $\mathbf{b} \in \mathbb{C}^N$ длительности N отсчетов.

Выход модели: $\mathbf{y} = \mathbf{U}\mathbf{g} + \mathbf{V}\mathbf{h}$, где $\mathbf{U} \in \mathbb{C}^{N \times M_g}$, $\mathbf{V} \in \mathbb{C}^{N \times M_h}$, $\mathbf{g} \in \mathbb{C}^{M_g}$, $\mathbf{h} \in \mathbb{C}^{M_h}$.

Вектор ошибки $\mathbf{e} = \mathbf{d} - \mathbf{y}$. Критерий адаптации: $J(\mathbf{g}, \mathbf{h}) = \mathbf{e}^H\mathbf{e}$.

Градиент целевой функции $J(\mathbf{g}, \mathbf{h})$:

$$\begin{bmatrix} \nabla_J(\mathbf{g}) \\ \nabla_J(\mathbf{h}) \end{bmatrix} = \begin{bmatrix} \dfrac{\partial J(\mathbf{g},\mathbf{h})}{\partial \mathbf{g}^H} \\ \dfrac{\partial J(\mathbf{g},\mathbf{h})}{\partial \mathbf{h}^H} \end{bmatrix} = \begin{bmatrix} -\mathbf{U}^H\big(\mathbf{d} - \mathbf{U}\mathbf{g} - \mathbf{V}\mathbf{h}\big) \\ -\mathbf{V}^H\big(\mathbf{d} - \mathbf{U}\mathbf{g} - \mathbf{V}\mathbf{h}\big) \end{bmatrix} = \tag{9.7}$$

$$= \begin{bmatrix} -\mathbf{U}^H\mathbf{d} + \mathbf{U}^H\mathbf{U}\mathbf{g} + \mathbf{U}^H\mathbf{V}\mathbf{h} \\ -\mathbf{V}^H\mathbf{d} + \mathbf{V}^H\mathbf{U}\mathbf{g} + \mathbf{V}^H\mathbf{V}\mathbf{h} \end{bmatrix} = -\begin{bmatrix} \mathbf{U}^H \\ \mathbf{V}^H \end{bmatrix}\mathbf{d} + \begin{bmatrix} \mathbf{U}^H\mathbf{U} & \mathbf{U}^H\mathbf{V} \\ \mathbf{V}^H\mathbf{U} & \mathbf{V}^H\mathbf{V} \end{bmatrix}\begin{bmatrix} \mathbf{g} \\ \mathbf{h} \end{bmatrix}$$

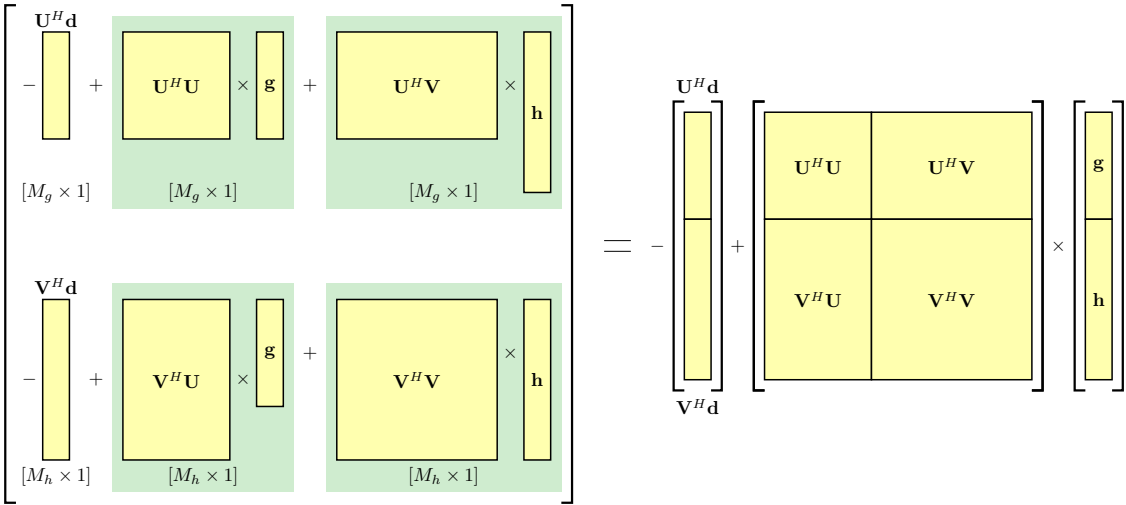
$\mathbf{U}^H\mathbf{d}$
$-$
$+$
$\mathbf{U}^H\mathbf{U}$
$\times$
$\mathbf{g}$
$+$
$\mathbf{U}^H\mathbf{V}$
$\times$
$\mathbf{h}$
$[M_g \times 1]$
$[M_g \times 1]$
$[M_g \times 1]$
$\mathbf{V}^H\mathbf{d}$
$-$
$+$
$\mathbf{V}^H\mathbf{U}$
$\times$
$\mathbf{g}$
$+$
$\mathbf{V}^H\mathbf{V}$
$\times$
$\mathbf{h}$
$[M_h \times 1]$
$[M_h \times 1]$
$[M_h \times 1]$
$=$
$\mathbf{U}^H\mathbf{d}$
$-$
$+$
$\mathbf{U}^H\mathbf{U}$
$\mathbf{U}^H\mathbf{V}$
$\mathbf{V}^H\mathbf{U}$
$\mathbf{V}^H\mathbf{V}$
$\times$
$\mathbf{g}$
$\mathbf{h}$
$\mathbf{V}^H\mathbf{d}$

Введем обозначение $\mathbf{F} = [\mathbf{U},\ \mathbf{V}]$ — горизонтальная конкатенация матриц состояния фильтров $\mathbf{U}$ и $\mathbf{V}$, а также $\mathbf{w} = \begin{bmatrix}\mathbf{g}\\ \mathbf{h}\end{bmatrix}$ — вертикальная конкатенация векторов коэффициентов.

Тогда уравнение для градиента целевой функции $J(\mathbf{g}, \mathbf{h})$ модели можно записать как:

$$\nabla_J(\mathbf{g}, \mathbf{h}) = -\mathbf{F}^H\mathbf{d} + \mathbf{F}^H\mathbf{F}\mathbf{w}. \tag{9.8}$$

Приравнивая градиент к нулю, находим LS оценку оптимального вектора коэффициентов $\mathbf{w} = \begin{bmatrix}\mathbf{g}\\ \mathbf{h}\end{bmatrix}$:

$$\mathbf{w} = \left(\mathbf{F}^H\mathbf{F}\right)^{-1}\mathbf{F}^H\mathbf{d}. \tag{9.9}$$

Лекция 9. Адаптации каскада линейных фильтров

§9.2. Адаптация фильтра при масштабировании выхода

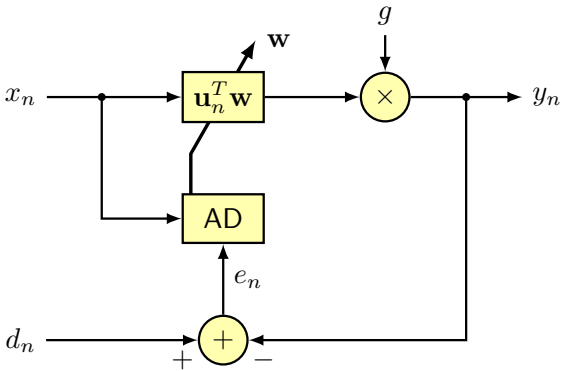

$x_n, d_n \in \mathbb{C}$, $\mathbf{u}_n \in \mathbb{C}^M$.

g — произвольный комплексный множитель по выходу адаптивного фильтра. Выход модели $y_n = \mathbf{u}_n^T \mathbf{w} g$. Ошибка адаптации:

$$e_n = d_n - \mathbf{u}_n^T \mathbf{w} g \tag{9.10}$$

Целевая функция: $J(\mathbf{w}) = e_n^* e_n$ минимизирует квадрат мгновенной ошибки. Алгоритм LMS:

$$\mathbf{w}_n = \mathbf{w}_{n-1} - \mu \frac{\partial J(\mathbf{w})}{\partial \mathbf{w}^H} \tag{9.11}$$

$$\frac{\partial J(\mathbf{w})}{\partial \mathbf{w}^H} = -g^* \mathbf{u}_n^* e_n \tag{9.12}$$

Окончательно:

$$\mathbf{w}_n = \mathbf{w}_{n-1} + \mu g^* \mathbf{u}_n^* e_n \tag{9.13}$$

$$\mathbf{w}_n = \mathbf{w}_{n-1} + \mu \mathbf{u}_n^* \underbrace{g^* e_n}_{\tilde{e}_n} \tag{9.14}$$

$$\mathbf{w}_n = \mathbf{w}_{n-1} + \mu \mathbf{u}_n^* \tilde{e}_n \tag{9.15}$$

Рассмотрим алгоритм LS оценки для блоков данных $\mathbf{x} \in \mathbb{C}^N$ длительности N отсчетов.

Выход модели: $\mathbf{y} = \mathbf{U}\mathbf{w}g$, где $\mathbf{U} \in \mathbb{C}^{N \times M}$.

Вектор ошибки $\mathbf{e} = \mathbf{d} - \mathbf{y} = \mathbf{d} - \mathbf{U}\mathbf{w}g$. Критерий адаптации: $J(\mathbf{w}) = \mathbf{e}^H\mathbf{e}$.

Градиент целевой функции $J(\mathbf{w})$:

$$\begin{aligned} \nabla_J(\mathbf{w}) = \frac{\partial J(\mathbf{w})}{\partial \mathbf{w}^H} = \frac{\partial}{\partial \mathbf{w}^H}(\mathbf{d} - \mathbf{U}\mathbf{w}g)^H(\mathbf{d} - \mathbf{U}\mathbf{w}g) = \\ = -\mathbf{U}^H g^*(\mathbf{d} - \mathbf{U}\mathbf{w}g) = -\tilde{\mathbf{U}}^H(\mathbf{d} - \tilde{\mathbf{U}}\mathbf{w}), \end{aligned} \tag{9.16}$$

где $\tilde{\mathbf{U}} = \mathbf{U}g$ — обновленная матрица состояния, учитывающая влияние выходного множителя g. Приравнивая градиент к нулю получим LS оценку вида:

$$\mathbf{w} = \left(\tilde{\mathbf{U}}^H\tilde{\mathbf{U}}\right)^{-1}\tilde{\mathbf{U}}^H\mathbf{d}. \tag{9.17}$$

§9.3. Адаптация каскада линейных фильтров

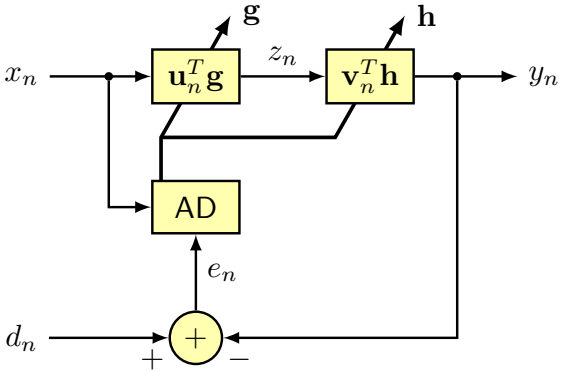

$x_n, d_n \in \mathbb{C}$, $\mathbf{u}_n$, $\mathbf{g} \in \mathbb{C}^{M_g}$, $\mathbf{v}_n$, $\mathbf{h} \in \mathbb{C}^{M_h}$,

$z_n = \mathbf{u}_n^T\mathbf{g}$, выход каскада $y_n = \mathbf{v}_n^T\mathbf{h}$,

$$\mathbf{v}_n^T = [z_{n+D}, \ldots, z_{n+1}, z_n, z_{n-1}, \ldots, z_{n-D}]^T,$$

z_n зависит от коэффициентов $\mathbf{g}$.

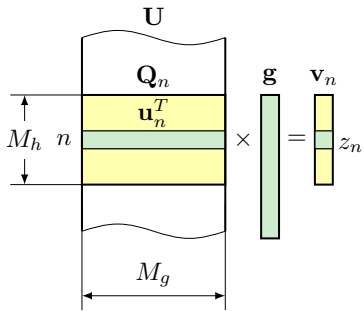

$$\mathbf{v}_n = \mathbf{Q}_n\mathbf{g}, \quad \mathbf{Q}_n \in \mathbb{C}^{M_h \times M_g} \tag{9.18}$$

Выход каскада:

$$\mathbf{y}_n = \mathbf{v}_n^T\mathbf{h} = \mathbf{g}^T\mathbf{Q}_n^T\mathbf{h} \tag{9.19}$$

Целевая функция: $J(\mathbf{g}, \mathbf{h}) = e_n^* e_n$ минимизирует квадрат мгновенной ошибки.
Алгоритм LMS (стохастический градиентный спуск):

$$\mathbf{g}_n = \mathbf{g}_{n-1} - \mu \frac{\partial J(\mathbf{g}, \mathbf{h})}{\partial \mathbf{g}^H} \tag{9.20}$$

$$\mathbf{h}_n = \mathbf{h}_{n-1} - \mu \frac{\partial J(\mathbf{g}, \mathbf{h})}{\partial \mathbf{h}^H} \tag{9.21}$$

$$\frac{\partial J(\mathbf{g}, \mathbf{h})}{\partial \mathbf{g}^H} = \frac{\partial}{\partial \mathbf{g}^H}(d_n - \mathbf{g}^T \mathbf{Q}_n^T \mathbf{h})^*(d_n - \mathbf{g}^T \mathbf{Q}_n^T \mathbf{h}) = -\mathbf{Q}_n^H \mathbf{h}^* e_n \tag{9.22}$$

$$\frac{\partial J(\mathbf{g}, \mathbf{h})}{\partial \mathbf{h}^H} = \frac{\partial}{\partial \mathbf{h}^H}(d_n - \mathbf{g}^T \mathbf{Q}_n^T \mathbf{h})^*(d_n - \mathbf{g}^T \mathbf{Q}_n^T \mathbf{h}) = -\mathbf{Q}_n^* \mathbf{g}^* e_n = \mathbf{v}_n^* e_n. \tag{9.23}$$

Окончательно:

$$\mathbf{g}_n = \mathbf{g}_{n-1} + \mu \mathbf{Q}_n^H \mathbf{h}^* e_n \tag{9.24}$$

$$\mathbf{h}_n = \mathbf{h}_{n-1} + \mu \mathbf{Q}_n^* \mathbf{g}^* e_n \tag{9.25}$$

Рассмотрим оценку коэффициентов $\mathbf{g}$ и $\mathbf{h}$ для блока данных длины N отсчетов. Выход каскада в блочном режиме $\mathbf{y} = \mathbf{V}\mathbf{h}$, где $\mathbf{V} \in \mathbb{C}^{N \times M_h}$ — матрица состояния выходного каскада, хранящая задержанные значение выхода первого каскада z_n. Получим выход модели в матричной форме относительно коэффициентов $\mathbf{g}$:

$$y_n = \sum_{p=-D_h}^{D_h} z_{n-p} h_p, \qquad z_n = \sum_{m=-D_g}^{D_g} x_{n-m} g_m \tag{9.26}$$

$$\begin{aligned} y_n &= \sum_{p=-D_h}^{D_h} \sum_{m=-D_g}^{D_g} x_{n-m-p} g_m h_p = \\ &= \sum_{m=-D_g}^{D_g} g_m \underbrace{\sum_{p=-D_h}^{D_h} x_{n-m-p} h_p}_{\tilde{u}_{n,m}} = \sum_{m=-D_g}^{D_g} \tilde{u}_{n,m} g_m = \tilde{\mathbf{u}}_n^T \mathbf{g}. \end{aligned} \tag{9.27}$$

$\tilde{\mathbf{u}}_n$ — обновленное состояние первого фильтра, учитывающие влияние второго каскада.

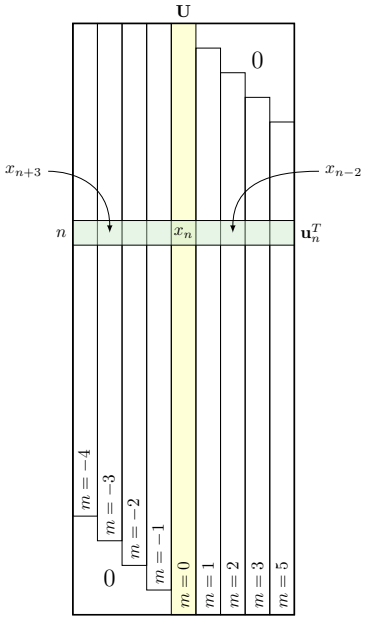

Таким образом объединив выходы y_n в один выходной вектор можно записать:

$$\mathbf{y} = \tilde{\mathbf{U}}\mathbf{g} = \mathbf{V}\mathbf{h}. \tag{9.28}$$

Из уравнения (9.27) можно видеть, что

$$\tilde{u}_{n,m} = \sum_{p=-D_h}^{D_h} x_{n-m-p} h_p, \tag{9.29}$$

т.е. столбец с индексом m обновленного вектора состояния $\tilde{\mathbf{u}}_n$ есть результат свертки задержанного на m отсчетов входного сигнала x_{n-m} с коэффициентами выходного фильтра $\mathbf{h}$.

Матрица $\tilde{\mathbf{U}}$ получается из исходной матрицы $\mathbf{U}$ путем фильтрации каждого столбца матрицы фильтром $\mathbf{h}$.

Критерий адаптации в блочном режиме:

$$J(\mathbf{h},\mathbf{g}) = \mathbf{e}^H\mathbf{e} = \big(\mathbf{d} - \tilde{\mathbf{U}}\mathbf{g}\big)^H\big(\mathbf{d} - \tilde{\mathbf{U}}\mathbf{g}\big) = \big(\mathbf{d} - \mathbf{V}\mathbf{h}\big)^H\big(\mathbf{d} - \mathbf{V}\mathbf{h}\big). \tag{9.30}$$

Вектор градиента целевой функции равен:

$$\nabla_J(\mathbf{h},\mathbf{g}) = \begin{bmatrix} \dfrac{\partial}{\partial \mathbf{g}^H} J(\mathbf{h},\mathbf{g}) \\ \dfrac{\partial}{\partial \mathbf{h}^H} J(\mathbf{h},\mathbf{g}) \end{bmatrix} = \begin{bmatrix} -\tilde{\mathbf{U}}^H\mathbf{e} \\ -\mathbf{V}^H\mathbf{e} \end{bmatrix} \tag{9.31}$$

Адаптация методом блочного градиентного спуска:

$$\mathbf{g}_k = \mathbf{g}_{k-1} + \mu\tilde{\mathbf{U}}^H\mathbf{e}_k; \tag{9.32}$$

$$\mathbf{h}_k = \mathbf{h}_{k-1} + \mu\mathbf{V}^H\mathbf{e}_k. \tag{9.33}$$

здесь $\mathbf{e}_k = \mathbf{d} - \tilde{\mathbf{U}}\mathbf{g}_{k-1} = \mathbf{d} - \tilde{\mathbf{V}}\mathbf{h}_{k-1}$.

Поскольку матрица $\tilde{\mathbf{U}}$ зависит от коэффициентов $\mathbf{h}$, а матрица $\mathbf{V}$ зависит от коэффициентов $\mathbf{g}$, то функция $J(\mathbf{h}, \mathbf{g})$ не является квадратичной, и для адаптации методом второго порядка необходимо использовать метод Ньютона.

Матрица Гессе:
$$\mathbf{H} = \begin{bmatrix} \dfrac{\partial^2 J(\mathbf{g},\mathbf{h})}{\partial \mathbf{g} \partial \mathbf{g}^H} & \dfrac{\partial^2 J(\mathbf{g},\mathbf{h})}{\partial \mathbf{h} \partial \mathbf{g}^H} \\ \dfrac{\partial^2 J(\mathbf{g},\mathbf{h})}{\partial \mathbf{g} \partial \mathbf{h}^H} & \dfrac{\partial^2 J(\mathbf{g},\mathbf{h})}{\partial \mathbf{h} \partial \mathbf{h}^H} \end{bmatrix}, \tag{9.34}$$

$$\frac{\partial^2 J(\mathbf{g},\mathbf{h})}{\partial \mathbf{g} \partial \mathbf{g}^H} = \frac{\partial}{\partial \mathbf{g}}\big(-\tilde{\mathbf{U}}^H \mathbf{e}\big) = -\tilde{\mathbf{U}}^H \frac{\partial}{\partial \mathbf{g}}\big(\mathbf{d} - \tilde{\mathbf{U}}\mathbf{g}\big) = \tilde{\mathbf{U}}^H \tilde{\mathbf{U}}; \tag{9.35}$$

$$\frac{\partial^2 J(\mathbf{g},\mathbf{h})}{\partial \mathbf{h} \partial \mathbf{g}^H} = \frac{\partial}{\partial \mathbf{h}}\big(-\tilde{\mathbf{U}}^H \mathbf{e}\big) = -\tilde{\mathbf{U}}^H \frac{\partial}{\partial \mathbf{h}}\big(\mathbf{d} - \mathbf{V}\mathbf{h}\big) = \tilde{\mathbf{U}}^H \mathbf{V}; \tag{9.36}$$

$$\frac{\partial^2 J(\mathbf{g},\mathbf{h})}{\partial \mathbf{g} \partial \mathbf{h}^H} = \frac{\partial}{\partial \mathbf{g}}\big(-\mathbf{V}^H \mathbf{e}\big) = -\mathbf{V}^H \frac{\partial}{\partial \mathbf{g}}\big(\mathbf{d} - \tilde{\mathbf{U}}\mathbf{g}\big) = \mathbf{V}^H \tilde{\mathbf{U}}; \tag{9.37}$$

$$\frac{\partial^2 J(\mathbf{g},\mathbf{h})}{\partial \mathbf{h} \partial \mathbf{h}^H} = \frac{\partial}{\partial \mathbf{h}}\big(-\mathbf{V}^H \mathbf{e}\big) = -\mathbf{V}^H \frac{\partial}{\partial \mathbf{h}}\big(\mathbf{d} - \mathbf{V}\mathbf{h}\big) = \mathbf{V}^H \mathbf{V}. \tag{9.38}$$

Тогда адаптация каскадной модели методом Ньютона производится итеративно для общего вектора коэффициентов :

$$\mathbf{w}_k = \mathbf{w}_{k-1} - \mathbf{H}_J^{-1}(\mathbf{w}_{k-1})\nabla_J(\mathbf{w}_{k-1}), \quad \mathbf{w}_{k-1} = \begin{bmatrix} \mathbf{g}_{k-1} \\ \mathbf{h}_{k-1} \end{bmatrix}, \tag{9.39}$$

$$\nabla_J(\mathbf{w}_{k-1}) = \begin{bmatrix} -\tilde{\mathbf{U}}\mathbf{e}_k \\ -\mathbf{V}\mathbf{e}_k \end{bmatrix}, \quad \mathbf{H}_J(\mathbf{w}_{k-1}) = \begin{bmatrix} \tilde{\mathbf{U}}^H\tilde{\mathbf{U}} & \tilde{\mathbf{U}}^H\mathbf{V} \\ \mathbf{V}^H\tilde{\mathbf{U}} & \mathbf{V}^H\mathbf{V} \end{bmatrix}. \tag{9.40}$$

Инициализируем начальный вектор коэффициентов $\mathbf{w}_{-1}$ и формируем матрицу состояния первого фильтра $\mathbf{U}$.
Первый шаг, $k = 0$:

- Прямой проход. Используем инициализированные коэффициенты $\mathbf{g}_{-1}$ и $\mathbf{h}_{-1}$ для расчета выхода каскада фильтров и ошибки $\mathbf{e}_0$.
- Используя выход первого каскада (коэффициенты $\mathbf{g}_{-1}$) формируем матрицу $\mathbf{V}$.
- Используя коэффициенты второго каскада $\mathbf{h}_{-1}$ формируем матрицу $\tilde{\mathbf{U}}$ путем фильтрации по столбцам матрицы $\mathbf{U}$.

- Рассчитываем вектор градиента $\nabla_J(\mathbf{w}_{-1})$ и матрицу Гессе $\mathbf{H}_J(\mathbf{w}_{-1})$.

$$\nabla_J(\mathbf{w}_{-1}) = \begin{bmatrix} -\tilde{\mathbf{U}}\mathbf{e}_0 \\ -\mathbf{V}\mathbf{e}_0 \end{bmatrix}, \quad \mathbf{H}_J(\mathbf{w}_{-1}) = \begin{bmatrix} \tilde{\mathbf{U}}^H\tilde{\mathbf{U}} & \tilde{\mathbf{U}}^H\mathbf{V} \\ \mathbf{V}^H\tilde{\mathbf{U}} & \mathbf{V}^H\mathbf{V} \end{bmatrix}. \tag{9.41}$$

- Обновляем коэффициенты:

$$\mathbf{w}_0 = \mathbf{w}_{-1} - \mathbf{H}_J^{-1}(\mathbf{w}_{-1})\nabla_J(\mathbf{w}_{-1}). \tag{9.42}$$

Второй и последующие шаги, $k = 1, 2, \ldots$ аналогичны первому, но используются коэффициенты полученные на предыдущем шаге. На основе полученных коэффициентов обновляется ошибка, матрицы состояния и пересчитывается градиент и матрица Гессе.

§9.4. Инициализация коэффициентов и перетекание усиления при адаптации каскада фильтров

Целевая функция $J(\mathbf{g}, \mathbf{h})$ не является выпуклой, из-за каскадной структуры модели. Это порождает две проблемы:
1. Инициализация начальных коэффициентов для достижения локального минимума.
2. Распределение усиления между каскадами.

Рассмотрим начальную инициализацию коэффициентов для старта блочного градиентного спуска:

$$\mathbf{g}_k = \mathbf{g}_{k-1} + \mu \tilde{\mathbf{U}}^H \mathbf{e}_k; \tag{9.43}$$

$$\mathbf{h}_k = \mathbf{h}_{k-1} + \mu \mathbf{V}^H \mathbf{e}_k; \tag{9.44}$$

Точка $\mathbf{w}_{-1} = \mathbf{0}$, $\mathbf{h}_{-1} = \mathbf{0}$ является седловой точкой. Поэтому инициализация обоих каскадов нулевыми значениями недопустимо.
Так при $\mathbf{w}_{-1} = \mathbf{0}$ матрица $\mathbf{V} = \mathbf{0}$ и $\mathbf{h}_{k+1} = \mathbf{h}_k$.
Если $\mathbf{h}_{-1} = \mathbf{0}$, то матрица $\tilde{\mathbf{U}} = \mathbf{0}$ и $\mathbf{w}_{k+1} = \mathbf{w}_k$.

Если инициализировать оба каскада нулевыми коэффициентами, то модель не сможет адаптироваться.

Для адаптации модели как правило выбирают один из способов инициализации:
1. $\mathbf{w}_0 = \mathbf{0}$, $\mathbf{h}_0 = \delta[D]$
2. $\mathbf{w}_0 = \mathrm{rand}(P+1)$, $\mathbf{h}_0 = \mathrm{rand}(2D+1)$.
Это позволяет стартовать адаптацию не из седловой точки и достигнуть локального минимума.

Из-за каскадной структуры, модель имеет бесконечное множество локальных минимумов.

Если $\mathbf{w}_{\text{опт}}$ и $\mathbf{h}_{\text{опт}}$ — точка локального минимума, то $\mathbf{w}_{\text{опт}}/\alpha$ и $\alpha\mathbf{h}_{\text{опт}}$, $\alpha \neq 0$ также является равнозначной точкой минимума.

Данное свойство порождает вторую проблему: перетекание усиления между каскадами.

К счастью, методы градиентного спуска обладают полезным свойством нормализации усиления между каскадами.

Представим, что на некоторой итерации k мы внесли разбалансировку усиления.
Например $\mathbf{w}_k/100$, $\mathbf{h}_k \cdot 100$.
Тогда на следующем $k+1$ шаге

$$\mathbf{w}_{k+1} = \mathbf{w}_k + \mu\tilde{\mathbf{U}}^H\mathbf{e}; \tag{9.45}$$

$$\mathbf{h}_{k+1} = \mathbf{h}_k + \mu\mathbf{V}^H\mathbf{e}; \tag{9.46}$$

где $\tilde{\mathbf{U}}$ в результате сверки приобретет вес в 100 раз выше, чем на предыдущем шаге, в то время как матрица $\mathbf{V}$ наоборот будет в 100 раз ослаблена.
Тогда можно заключить, что

$$\mathbf{w}_{k+1} = \mathbf{w}_k + 100 \cdot \mu\tilde{\mathbf{U}}^H\mathbf{e}; \tag{9.47}$$

$$\mathbf{h}_{k+1} = \mathbf{h}_k + 0.01 \cdot \mu\mathbf{V}^H\mathbf{e}; \tag{9.48}$$

Ослабленные коэффициенты адаптируются с увеличенным в 100 раз шагом, а усиленные — с уменьшенным в 100 раз. Нормы коэффициентов стремятся выравняться.

Лекция 10. Адаптивная компенсация искажений квадратурного смесителя

§10.1. Амплитудный разбаланс квадратур смесителя передатчика

Квадратурный смеситель представляет собой устройство переноса комплексной огибающей сигнала $z(t) = i(t) + jq(t)$ на несущую частоту ω_0 и формирования радиосигнала

$$s(t) = a(t)\cos\big(\omega_0 t + \phi(t)\big), \quad z(t) = i(t) + jq(t) = a(t)\exp\big(j\phi(t)\big), \tag{10.1}$$

здесь $a(t)$ и $\phi(t)$ — изменение амплитуды и фазы несущего колебания радиосигнала во времени.

Полосовой радиосигнал на выходе квадратурного смесителя передающего устройства представляет собой реальную часть произведение комплексной огибающей $z(t)$ и комплексной экспоненты несущей частоты $\exp(j\omega_0 t)$:

$$s(t) = \mathrm{Re}\left[z(t)\exp(j\omega_0 t)\right] = i(t)\cos(\omega_0 t) - q(t)\sin(\omega_0 t). \tag{10.2}$$

Также заметим, что

$$s(t) = \mathrm{Re}\left[z(t)\exp(j\omega_0 t)\right] = \frac{1}{2}\Big(z(t)\exp(j\omega_0 t) + z^*(t)\exp(-j\omega_0 t)\Big). \tag{10.3}$$

При реализации квадратурного смесителя необходимо обеспечить максимальный баланс амплитуд синфазной $i(t)$ и квадратурной $q(t)$ составляющих комплексной огибающей $z(t)$, а также фазовую синхронизацию косинусоидальной и синусоидальной компонент комплексной экспоненты несущей частоты.

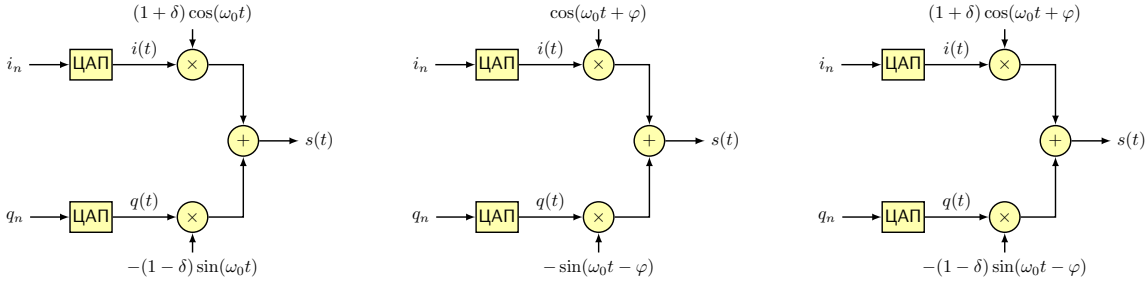

а — амплитудный разбаланс; б — фазовый разбаланс; в — амплитудно-фазовый разбаланс

Рассмотрим сигнал на выходе смесителя, когда квадратуры имеют разбаланс по амплитуде:

$$s(t) = i(t)(1+\delta)\cos(\omega_0 t) - q(t)(1-\delta)\sin(\omega_0 t). \tag{10.4}$$

Тогда сигнал на выходе смесителя может быть записан в виде:

$$s(t) = \underbrace{i(t)\cos(\omega_0 t) - q(t)\sin(\omega_0 t)}_{\mathrm{Re}\left[z(t)\exp(j\omega_0 t)\right]} + \delta \underbrace{\left(i(t)\cos(\omega_0 t) + q(t)\sin(\omega_0 t)\right)}_{\mathrm{Re}\left[z^*(t)\exp(j\omega_0 t)\right]}. \tag{10.5}$$

Первые два слагаемых дают неискаженный радиосигнал на выходе смесителя, а вторые два слагаемых можно представить как реальную часть произведения комплексно-сопряженной огибающей на комплексную экспоненту несущей частоты. Тогда

$$\begin{aligned} s(t) &= \mathrm{Re}\left[z(t)\exp(j\omega_0 t)\right] + \delta\,\mathrm{Re}\left[z^*(t)\exp(j\omega_0 t)\right] = \\ &= \mathrm{Re}\left[z(t)\exp(j\omega_0 t) + \delta z^*(t)\exp(j\omega_0 t)\right] = \\ &= \mathrm{Re}\left[\left(z(t) + \delta z^*(t)\right)\exp(j\omega_0 t)\right]. \end{aligned} \tag{10.6}$$

Амплитудный разбаланс квадратур описывается как слагаемое комплексно-сопряженной огибающей на нулевой частоте с вещественным коэффициентом δ.
В частотной области появление в приведенной огибающей комплексно-сопряженного слагаемого приводит к появлению зеркально отраженной относительно нулевой частоты компоненты.
В случае, кода исходная комплексная огибающая $z(t)$ находится на нулевой частоте, то и зеркальная компонента соответствующая $\delta z^*(t)$ также находится внутри полосы сигнала $z(t)$.
При этом данная зеркальная компонента имеет относительный уровень мощности равный δ^2 раз. Например при $\delta = 0.01$, что соответствует амплитудной разбалансировке каналов

$$10 \lg \left((1+\delta)^2 \right) = 10 \lg 1.01^2 = 0.0864 \text{ дБ}, \tag{10.7}$$

уровень сопряженной составляющей будет

$$10 \lg \left(\delta^2 \right) = 10 \lg 0.01^2 = -40 \text{ дБ} \tag{10.8}$$

относительно полезного сигнала.

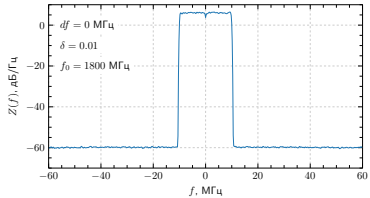
df = 0 МГц
δ = 0.01
f_0 = 1800 МГц
$Z(f)$, дБ/Гц
f, МГц

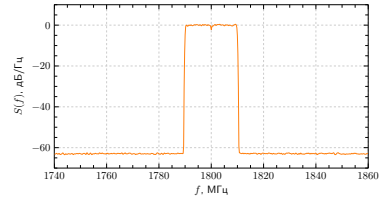
$S(f)$, дБ/Гц
f, МГц

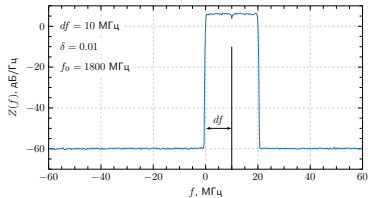
df = 10 МГц
δ = 0.01
f_0 = 1800 МГц
df
$Z(f)$, дБ/Гц
f, МГц

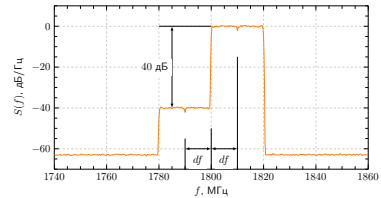
40 дБ
df
df
$S(f)$, дБ/Гц
f, МГц

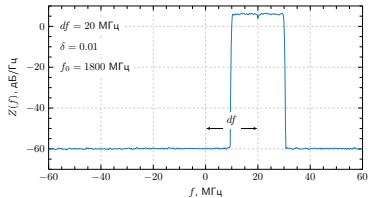
df = 20 МГц
δ = 0.01
f_0 = 1800 МГц
df
$Z(f)$, дБ/Гц
f, МГц

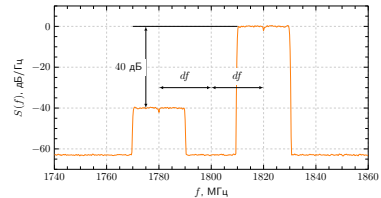
40 дБ
df
df
$S(f)$, дБ/Гц
f, МГц

Лекция 10. Адаптивная компенсация искажений квадратурного смесителя

§10.2. Фазовый разбаланс квадратур смесителя передатчика

Рассмотрим сигнал на выходе смесителя, когда квадратуры имеют разбаланс по фазе:

$$s(t) = i(t)\cos(\omega_0 t + \varphi) - q(t)\sin(\omega_0 t - \varphi). \tag{10.9}$$

Применив тригонометрические тождества можно переписать:

$$\begin{aligned} s(t) =& i(t)\cos(\omega_0 t)\cos\varphi - i(t)\sin(\omega_0 t)\sin\varphi - \\ &- q(t)\sin(\omega_0 t)\cos\varphi + q(t)\cos(\omega_0 t)\sin\varphi. \end{aligned} \tag{10.10}$$

Сгруппируем слагаемые:

$$\begin{aligned} s(t) =& \underbrace{\big(i(t)\cos(\omega_0 t) - q(t)\sin(\omega_0 t)\big)}_{\mathrm{Re}\left[z(t)\exp(j\omega_0 t)\right]}\cos\varphi + \\ &+ \underbrace{\big(q(t)\cos(\omega_0 t) - i(t)\sin(\omega_0 t)\big)}_{\mathrm{Re}\left[jz^*(t)\exp(j\omega_0 t)\right]}\sin\varphi \end{aligned} \tag{10.11}$$

Окончательно можно записать:

$$s(t) = \mathrm{Re}\left[z(t)\exp(j\omega_0 t)\right]\cos\varphi + \mathrm{Re}\left[jz^*(t)\exp(j\omega_0 t)\right]\sin\varphi = \\ = \mathrm{Re}\left[\left(z(t)\cos\varphi + jz^*(t)\sin\varphi\right)\exp(j\omega_0 t)\right]. \quad (10.12)$$

Фазовый разбаланс квадратур смесителя также может быть описано как слагаемое комплексно-сопряженной огибающей на нулевой частоте, умноженное на чисто мнимый коэффициент $j\sin\varphi$.
Спектральное представление выхода смесителя при фазовом разбалансе аналогично представлению на выходе смесителя при амплитудном разбалансе. При этом параметр $\sin\varphi$ имеет тот же смысл, что и параметр δ. Например при фазовом разбалансе $\varphi = 1^\circ$ получаем уровень «зеркальной» компоненты

$$10\lg(\sin 1^\circ)^2 = -35.16 \text{ дБ}, \quad (10.13)$$

что является недопустимо высоким уровнем в практических задачах.

Лекция 10. Адаптивная компенсация искажений квадратурного смесителя

§10.3. Амплитудно-фазовый разбаланс квадратур смесителя передатчика

Объединим оба эффекта и рассмотрим сигнал на выходе смесителя, когда квадратуры имеют разбаланс как по амплитуде, так и по фазе:

$$s(t) = i(t)(1+\delta)\cos(\omega_0 t + \varphi) - q(t)(1-\delta)\sin(\omega_0 t - \varphi). \tag{10.14}$$

Тогда

$$\begin{aligned} s(t) =& i(t)\cos(\omega_0 t + \varphi) - q(t)\sin(\omega_0 t - \varphi) + \\ &+\delta\big(i(t)\cos(\omega_0 t + \varphi) + q(t)\sin(\omega_0 t - \varphi)\big). \end{aligned} \tag{10.15}$$

Первые два слагаемых описывают фазовый разбаланс (10.12). Преобразовав сумму в скобках можно показать:

$$\begin{aligned} & i(t)\cos(\omega_0 t + \varphi) + q(t)\sin(\omega_0 t - \varphi) = \\ =& i(t)\cos(\omega_0 t)\cos\varphi - i(t)\sin(\omega_0 t)\sin\varphi + \\ &+ q(t)\sin(\omega_0 t)\cos\varphi - q(t)\cos(\omega_0 t)\sin\varphi = \\ =& \big(i(t)\cos(\omega_0 t) + q(t)\sin(\omega_0 t)\big)\cos\varphi - \\ &- \big(i(t)\sin(\omega_0 t) + q(t)\cos(\omega_0 t)\big)\sin\varphi. \end{aligned} \tag{10.16}$$

Как нетрудно заметить:

$$i(t)\cos(\omega_0 t) + q(t)\sin(\omega_0 t) = \mathrm{Re}\left[z^*(t)\exp(j\omega_0 t)\right], \tag{10.17}$$

$$i(t)\sin(\omega_0 t) + q(t)\cos(\omega_0 t) = \mathrm{Re}\left[-jz(t)\exp(j\omega_0 t)\right], \tag{10.18}$$

Тогда окончательно

$$\begin{aligned} s(t) = &\mathrm{Re}\left[\left(z(t)\cos\varphi + jz^*(t)\sin\varphi\right)\exp(j\omega_0 t)\right] + \\ &+ \mathrm{Re}\left[\left(\delta\cos\varphi z^*(t) + j\delta\sin\varphi z(t)\right)\exp(j\omega_0 t)\right] = \\ = &\mathrm{Re}\left[\left(z(t)(\cos\varphi + j\delta\sin\varphi) + z^*(t)(\delta\cos\varphi + j\sin\varphi)\right)\exp(j\omega_0 t)\right]. \end{aligned} \tag{10.19}$$

Таким образом, наличие амплитудного и фазового разбаланса одновременно проявляется на нулевой частоте как сумма огибающей $z(t)$, умноженной на комплексный коэффициент $\cos\varphi + j\delta\sin\varphi$, и комплексно-сопряженного огибающей $z^*(t)$, умноженной на комплексный коэффициент $\delta\cos\varphi + j\sin\varphi$.

Лекция 10. Адаптивная компенсация искажений квадратурного смесителя

§10.4. Выделение комплексной огибающей в канале приемника

Полосовой сигнал имеет вид:

$$s(t) = a(t)\cos(\omega_0 t + \phi(t)), \tag{10.20}$$

где $a(t) = |z(t)|$ — амплитудная огибающая, а $\phi(t) = \angle z(t)$ — изменение фазы несущего колебания.

Выделение комплексной огибающей $\hat{z}(t)$ заключается в умножении на комплексную экспоненту несущей частоты $-\omega_0$ с последующей фильтрацией

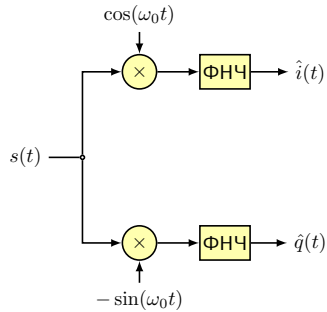

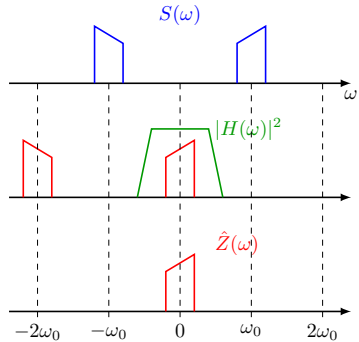

Входной вещественный радиосигнал с симметричной относительно нулевой частоты СПМ $|S(\omega)|^2$, умножается на комплексную экспоненту $\exp(-j\omega_0 t)$, в результате получаем синфазную составляющую:

$$\begin{aligned}\hat{i}(t) =& s(t)\cos(\omega_0 t) = a(t)\cos\big(\omega_0 t + \phi(t)\big)\cos(\omega_0 t) = \\ =& \frac{a(t)}{2}\cos\big(\phi(t)\big) + \underbrace{\frac{a(t)}{2}\cos\big(2\omega_0 t + \phi(t)\big)}_{\text{Отфильтровывается ФНЧ}} = \frac{a(t)}{2}\cos\big(\phi(t)\big),\end{aligned} \tag{10.21}$$

а также квадратурную составляющую:

$$\begin{aligned}\hat{q}(t) =& -s(t)\sin(\omega_0 t) = -a(t)\cos\big(\omega_0 t + \phi(t)\big)\sin(\omega_0 t) = \\ =& \frac{a(t)}{2}\sin\big(\phi(t)\big) - \underbrace{\frac{a(t)}{2}\cos\big(2\omega_0 t + \phi(t)\big)}_{\text{Отфильтровывается ФНЧ}} = \frac{a(t)}{2}\sin\big(\phi(t)\big).\end{aligned} \tag{10.22}$$

Тогда оценка комплексной огибающей $\hat{z}(t)$ на нулевой частоте повторяет[6] передаваемую огибающую $z(t)$:

$$\begin{aligned}\hat{z}(t) =& \hat{i}(t) + j\hat{q}(t) = \frac{a(t)}{2}\cos\big(\phi(t)\big) + j\frac{a(t)}{2}\sin\big(\phi(t)\big) = \\ =& \frac{a(t)}{2}\exp\big(j\phi(t)\big) = \frac{z(t)}{2}.\end{aligned} \tag{10.23}$$

При амплитудном разбалансе смесителя приемника получаем принятые синфазную и квадратурную компоненты в следующем виде:

$$\hat{i}(t) = a(t)(1+\delta)\cos\big(\omega_0 t + \phi(t)\big)\cos(\omega_0 t) = \frac{a(t)}{2}(1+\delta)\cos\big(\phi(t)\big) \tag{10.24}$$

$$\hat{q}(t) = -a(t)(1-\delta)\cos\big(\omega_0 t + \phi(t)\big)\sin(\omega_0 t) = \frac{a(t)}{2}(1-\delta)\sin\big(\phi(t)\big) \tag{10.25}$$

[6] Коэффициент $1/2$ можно не учитывать, поскольку он компенсируется регулировкой усиления

Тогда оценка комплексной огибающей $\hat{z}(t)$ на нулевой частоте равна:

$$\begin{aligned}\hat{z}(t) =& i(t) + jq(t) = \\ =& \frac{a(t)}{2}\cos\big(\phi(t)\big) + \frac{\delta a(t)}{2}\cos\big(\phi(t)\big) + \\ &+ j\frac{a(t)}{2}\sin\big(\phi(t)\big) - j\frac{\delta a(t)}{2}\sin\big(\phi(t)\big) = \\ =& \frac{a(t)}{2}\exp\big(j\phi(t)\big) + \frac{\delta a(t)}{2}\exp\big(-j\phi(t)\big) = \frac{z(t) + \delta z^*(t)}{2}.\end{aligned} \tag{10.26}$$

Как можно видеть из (10.26) амплитудный разбаланс в смесителе приемника также приводит к появлению слагаемого комплексно-сопряженной огибающей $z^*(t)$ с весом δ.

Наличие фазового разбаланса квадратур смесителя приводит к оценке синфазной компоненты вида:

$$\begin{aligned}\hat{i}(t) =& a(t)\cos\big(\omega_0 t+\phi(t)\big)\cos(\omega_0 t+\varphi) = \\ =& a(t)\cos\varphi\cos\big(\omega_0 t+\phi(t)\big)\cos(\omega_0 t) - \\ &- a(t)\sin\varphi\cos\big(\omega_0 t+\phi(t)\big)\sin(\omega_0 t),\end{aligned} \tag{10.27}$$

откуда после тригонометрических преобразований, с учетом подавления сигнала на частоте $2\omega_0$ и приведения подобных можно записать:

$$\hat{i}(t) = \frac{a(t)\cos\varphi}{2}\cos\big(\phi(t)\big) + \frac{a(t)\sin\varphi}{2}\sin\big(\phi(t)\big). \tag{10.28}$$

Квадратурная компонента:

$$\begin{aligned}\hat{q}(t) =& -a(t)\cos\big(\omega_0 t+\phi(t)\big)\sin(\omega_0 t-\varphi) = \\ =& a(t)\sin\varphi\cos\big(\omega_0 t+\phi(t)\big)\cos(\omega_0 t) - \\ &- a(t)\cos\varphi\cos\big(\omega_0 t+\phi(t)\big)\sin(\omega_0 t).\end{aligned} \tag{10.29}$$

Окончательно после преобразования с учетом подавления сигнала на частоте $2\omega_0$:

$$\hat{q}(t) = \frac{a(t)\cos\varphi}{2}\sin\big(\phi(t)\big) + \frac{a(t)\sin\varphi}{2}\cos\big(\phi(t)\big). \tag{10.30}$$

Оценка комплексной огибающей $\hat{z}(t)$ на нулевой частоте при фазовом разбалансе смесителя:

$$\begin{aligned}
\hat{z}(t) =& \hat{i}(t) + j\hat{q}(t) = \\
=& \frac{a(t)\cos\varphi}{2}\cos\big(\phi(t)\big) + \frac{a(t)\sin\varphi}{2}\sin\big(\phi(t)\big) + \\
&+ j\frac{a(t)\cos\varphi}{2}\sin\big(\phi(t)\big) + j\frac{a(t)\sin\varphi}{2}\cos\big(\phi(t)\big) = \\
=& \frac{a(t)\cos\varphi}{2}\exp\big(j\phi(t)\big) + \frac{ja(t)\sin\varphi}{2}\exp\big(-j\phi(t)\big) = \\
=& \frac{z(t)\cos\varphi + (j\sin\varphi)z^*(t)}{2}.
\end{aligned} \tag{10.31}$$

Как и в случае с амплитудным разбалансом появляется слагаемое комплексно-сопряженной огибающей, уровень которого зависит от угла фазового разбаланса φ.

Добавим амплитудный разбаланс к оценкам синфазной (10.28) и квадратурной (10.30) компонентам на выходе смесителя приемника с чисто фазовым разбалансом. Тогда оценка комплексной огибающей равна:

$$\begin{aligned}\hat{z}(t) =&(1+\delta)\hat{\hat{i}}(t) + j(1-\delta)\hat{q}(t) = \\ =&\frac{(1+\delta)a(t)\cos\varphi}{2}\cos\big(\phi(t)\big) + \frac{(1+\delta)a(t)\sin\varphi}{2}\sin\big(\phi(t)\big) + \\ &+j\frac{(1-\delta)a(t)\cos\varphi}{2}\sin\big(\phi(t)\big) + j\frac{(1-\delta)a(t)\sin\varphi}{2}\cos\big(\phi(t)\big).\end{aligned} \tag{10.32}$$

Раскроем скобки и преобразуем:

$$
\begin{aligned}
\hat{z}(t) =& \frac{1}{2}a(t)\cos\varphi\cos\big(\phi(t)\big) + \frac{1}{2}a(t)\sin\varphi\sin\big(\phi(t)\big) + \\
&+\frac{\delta}{2}a(t)\cos\varphi\cos\big(\phi(t)\big) + \frac{\delta}{2}a(t)\sin\varphi\sin\big(\phi(t)\big) + \\
&+j\frac{1}{2}a(t)\cos\varphi\sin\big(\phi(t)\big) + j\frac{1}{2}a(t)\sin\varphi\cos\big(\phi(t)\big) - \\
&-j\frac{\delta}{2}a(t)\cos\varphi\sin\big(\phi(t)\big) - j\frac{\delta}{2}a(t)\sin\varphi\cos\big(\phi(t)\big) = \\
&= \cos\varphi\frac{a(t)\big[\cos\big(\phi(t)\big) + j\sin\big(\phi(t)\big)\big]}{2} + \sin\varphi\frac{a(t)\big[\sin\big(\phi(t)\big) + j\cos\big(\phi(t)\big)\big]}{2} + \\
&+\delta\cos\varphi\frac{a(t)\big[\cos\big(\phi(t)\big) - j\sin\big(\phi(t)\big)\big]}{2} + \delta\sin\varphi\frac{a(t)\big[\sin\big(\phi(t)\big) - j\cos\big(\phi(t)\big)\big]}{2} = \\
&= \frac{1}{2}z(t)\cos\varphi + jz^*(t)\sin\varphi + \frac{1}{2}z^*(t)\delta\cos\varphi - jz(t)\delta\sin\varphi.
\end{aligned}
\tag{10.33}
$$

Таким образом, влияние разбаланса квадратур смесителя приемника аналогично передатчику. Пример искажений сигнала на выходе смесителя приемника, $\delta = 0.03$ и $\varphi = 3^\circ$.

$$e(t) = \frac{z(t)}{2} - \hat{z}(t) = \frac{z(t)\big(1 - \cos\varphi + j\delta\sin\varphi\big) + z^*(t)\big(\delta\cos\varphi + j\sin\varphi\big)}{2} \tag{10.34}$$

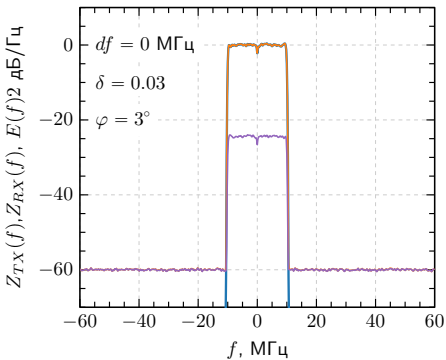

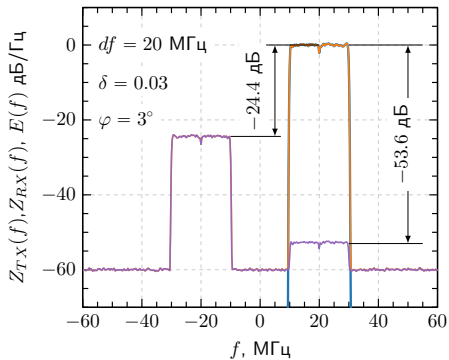

Лекция 10. Адаптивная компенсация искажений квадратурного смесителя

§10.5. Компенсация квадратурного разбаланса смесителя в канале передатчика

На практике параметры квадратурного разбаланса δ и φ являются неизвестными параметрами, которые также имеют частотную зависимость и могут меняться во времени. Обозначим через $\hat{z}(t)$ — приведенную комплексную огибающую на выходе квадратурного смесителя. В случае выхода смесителя приемника $\hat{z}(t) = \alpha z(t) + \beta z^*(t)$ представляет собой оценку огибающей, где

$$\alpha = \cos\varphi - j\delta\sin\varphi, \quad \beta = \delta\cos\varphi + j\sin\varphi. \tag{10.35}$$

В случае квадратурного смесителя передатчика $\hat{z}(t) = \alpha z(t) + \beta z^*(t)$ представляет собой приведенную огибающую, которая пройдя через идеальный смеситель даст такие же искажения как и исходная огибающая $z(t)$, на выходе реального смесителя. Коэффициенты α и β для квадратурного смесителя передатчика в соответствии с (10.19) равны:

$$\alpha = \cos\varphi + j\delta\sin\varphi, \quad \beta = \delta\cos\varphi + j\sin\varphi. \tag{10.36}$$

Компенсация эффекта квадратурного разбаланса заключается в модификации огибающей сигнала:

$$\tilde{z}(t) = \kappa z(t) - \gamma z^*(t). \tag{10.37}$$

Тогда приведенная комплексная огибающая на выходе квадратурного смесителя

$$\begin{aligned}\hat{z}(t) &= \alpha\tilde{z}(t) + \beta\tilde{z}^*(t) = \alpha\big(\kappa z(t) - \gamma z^*(t)\big) + \beta\big(\kappa^* z^*(t) - \gamma^* z(t)\big) = \\ &= \alpha\kappa z(t) - \alpha\gamma z^*(t) + \beta\kappa^* z^*(t) - \beta\gamma^* z(t) = \\ &= z(t)\big(\alpha\kappa - \beta\gamma^*\big) + z^*(t)\big(\beta\kappa^* - \alpha\gamma\big).\end{aligned} \tag{10.38}$$

Для исключения разбаланса необходимо, чтобы $\hat{z}(t) = z(t)$, тогда:

$$\begin{cases}\beta\kappa^* - \alpha\gamma = 0; \\ \alpha\kappa - \beta\gamma^* = 1.\end{cases} \quad \Rightarrow \quad \begin{cases}\gamma = \dfrac{\beta\kappa^*}{\alpha}; \\ \alpha\kappa - \dfrac{\beta\beta^*\kappa}{\alpha^*} = 1.\end{cases} \quad \Rightarrow \quad \begin{cases}\gamma = \dfrac{\beta}{|\alpha|^2 - |\beta|^2}; \\ \kappa = \dfrac{\alpha^*}{|\alpha|^2 - |\beta|^2}.\end{cases} \tag{10.39}$$

Таким образом компенсация квадратурного разбаланса передатчика:

$$\tilde{z}(t) = \frac{\alpha^* z(t) - \beta z^*(t)}{|\alpha|^2 - |\beta|^2}. \tag{10.40}$$

На практике $\alpha = \cos\varphi + j\delta\sin\varphi \approx 1$,а $\beta = \delta\cos\varphi + j\sin\varphi \ll \alpha$, тогда знаменатель близок к 1, и можно использовать упрощенную компенсацию $\tilde{z}(t) = z(t) - \beta z^*(t)$:

$$\begin{aligned}\hat{z}(t) =& \alpha\tilde{z}(t) + \beta\tilde{z}^*(t) = \alpha\big(z(t) - \beta z^*(t)\big) + \beta\big(z^*(t) - \beta^* z(t)\big) = \\ =& \alpha z(t) - \alpha\beta z^*(t) + \beta z^*(t) - |\beta|^2 z(t) = \big(\alpha - |\beta|^2\big)z(t) + (1-\alpha)\beta z^*(t).\end{aligned} \tag{10.41}$$

Например если фазовый разбаланс $\varphi = 3^\circ$, то $\alpha = \cos\varphi = 0.99863$ и остаточный уровень сопряженной компоненты $(1-\alpha)\beta z^*(t) = 0.00137 \cdot \beta z^*(t)$, что обеспечивает уровень подавления 57 дБ.
Если при этом амплитудный разбаланс $\delta = 0.01$, то $\beta = 0.009986 + 0.0523j$, и уровень линейного искажения: $\big(\alpha - |\beta|^2\big)z(t) = 0.99579 \cdot z(t)$.
Исходные параметры α и β неизвестны, кроме того, они меняются по частоте, поэтому искажения смесителя передатчика устраняются адаптивным фильтром.

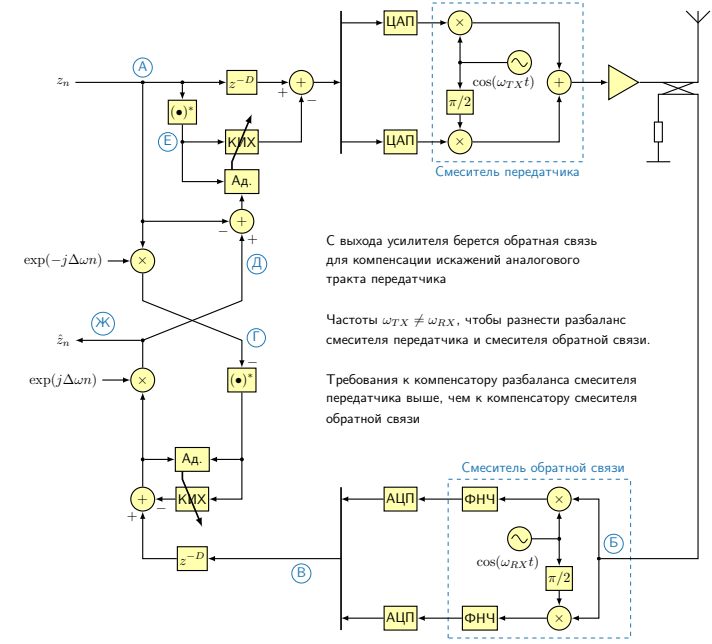

С выхода усилителя берется обратная связь для компенсации искажений аналогового тракта передатчика

Частоты $\omega_{TX} \neq \omega_{RX}$, чтобы разнести разбаланс смесителя передатчика и смесителя обратной связи.

Требования к компенсатору разбаланса смесителя передатчика выше, чем к компенсатору смесителя обратной связи

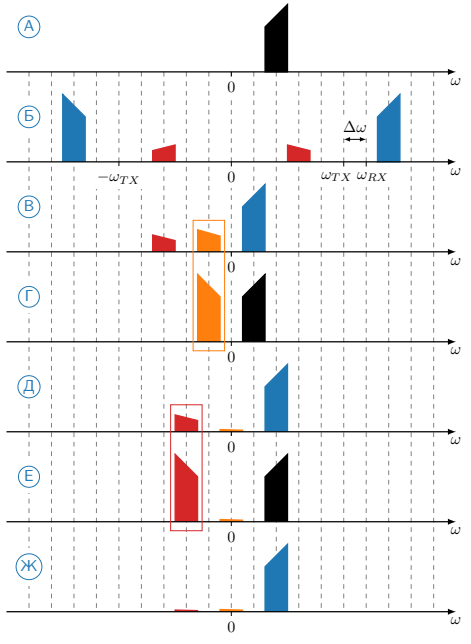

Лекция 10. Адаптивная компенсация искажений квадратурного смесителя

§10.6. Слепая компенсация квадратурного разбаланса смесителя в канале приемника

Дана комплексная огибающая $z(t)$ из которой формируется радиосигнал $s(t)$ на несущей частоте ω_0:

$$s(t) = i(t)\cos(\omega_0 t) - q(t)\sin(\omega_0 t) = \frac{1}{2}\Big(z(t)\,\mathrm{e}^{j\omega_0 t} + z^*(t)\,\mathrm{e}^{-j\omega_0 t}\Big). \tag{10.42}$$

Для упрощения анализа мы можем учесть $1/2$ в усилении и опустить в дальнейшем:

$$s(t) = z(t)\,\mathrm{e}^{j\omega_0 t} + z^*(t)\,\mathrm{e}^{-j\omega_0 t}\,. \tag{10.43}$$

В приемнике происходит восстановление $\hat{z}(t) = \hat{i}(t) + j\hat{q}(t)$ путем умножения на сигнал осциллятора приемника $x_{LO}(t) = \mathrm{e}^{-j\omega_0 t} = \cos(\omega_0 t) - j\sin(\omega_0 t)$:

$$\begin{aligned}\hat{r}(t) =& s(t)x_{LO}(t) = s(t)\,\mathrm{e}^{-j\omega_0 t} = \big(z(t)\,\mathrm{e}^{j\omega_0 t} + z^*(t)\,\mathrm{e}^{-j\omega_0 t}\big)\,\mathrm{e}^{-j\omega_0 t} = \\ =& z(t) + \underbrace{z^*(t)\,\mathrm{e}^{-j2\omega_0 t}}_{\text{Удаляется ФНЧ}} = z(t).\end{aligned} \tag{10.44}$$

В реальном квадратурном смесителе имеет место разбаланс квадратур, тогда

$$x_{LO}(t) = (1+\delta)\cos(\omega_0 t + \varphi) - j(1+\delta)\sin(\omega_0 t - \varphi). \tag{10.45}$$

Передатчик

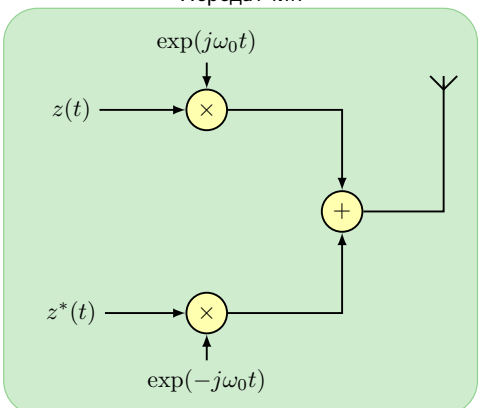

Приемник с разбалансом квадратур

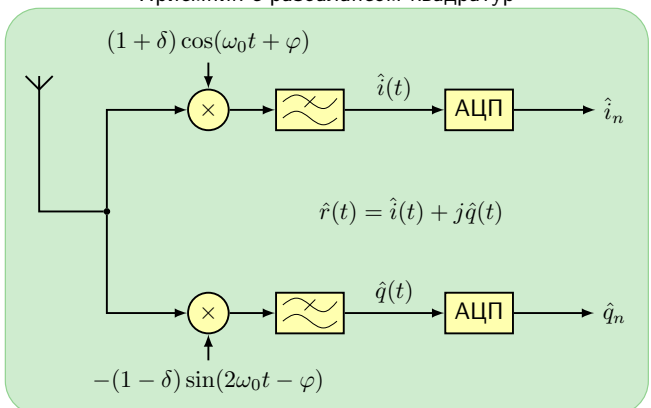

Преобразуем:

$$
\begin{aligned}
x_{LO}(t) =& (1+\delta)\cos(\omega_0 t+\varphi) - j(1-\delta)\sin(\omega_0 t-\varphi) = \\
=& (1+\delta)\frac{\mathrm{e}^{j(\omega_0 t+\varphi)} + \mathrm{e}^{-j(\omega_0 t+\varphi)}}{2} - j(1-\delta)\frac{\mathrm{e}^{j(\omega_0 t-\varphi)} - \mathrm{e}^{-j(\omega_0 t-\varphi)}}{2j} = \\
=& \frac{1+\delta}{2}\Big(\mathrm{e}^{j\varphi}\,\mathrm{e}^{j\omega_0 t} + \mathrm{e}^{-j\varphi}\,\mathrm{e}^{-j\omega_0 t}\Big) - \frac{1-\delta}{2}\Big(\mathrm{e}^{-j\varphi}\,\mathrm{e}^{j\omega_0 t} - \mathrm{e}^{j\varphi}\,\mathrm{e}^{-j\omega_0 t}\Big) = \\
=& \underbrace{\Big(\frac{1+\delta}{2}\,\mathrm{e}^{-j\varphi} + \frac{1-\delta}{2}\,\mathrm{e}^{j\varphi}\Big)}_{K_1}\mathrm{e}^{-j\omega_0 t} + \underbrace{\Big(\frac{1+\delta}{2}\,\mathrm{e}^{j\varphi} - \frac{1-\delta}{2}\,\mathrm{e}^{-j\varphi}\Big)}_{K_2}\mathrm{e}^{j\omega_0 t} = \\
=& K_1\,\mathrm{e}^{-j\omega_0 t} + K_2\,\mathrm{e}^{j\omega_0 t}\,.
\end{aligned}
\tag{10.46}
$$

Тогда на выходе смесителя приемника будем иметь комплексную огибающую вида:

$$\begin{aligned}\hat{r}(t) =& s(t)x_{LO}(t) = \left(z(t)\,\mathrm{e}^{j\omega_0 t} + z^*(t)\,\mathrm{e}^{-j\omega_0 t}\right)\left(K_1\,\mathrm{e}^{-j\omega_0 t} + K_2\,\mathrm{e}^{j\omega_0 t}\right) = \\ =& K_1 z(t) + K_2 z^*(t) + \underbrace{K_1 z^*(t)\,\mathrm{e}^{-j2\omega_0 t} + K_2 z(t)\,\mathrm{e}^{j2\omega_0 t}}_{\text{Удаляются ФНЧ}} = K_1 z(t) + K_2 z^*(t).\end{aligned} \tag{10.47}$$

Основная проблема: исходная огибающая $z(t)$ неизвестна, как неизвестны и параметры K_1 и K_2.

Задача слепой коррекции заключается в восстановлении передаваемой огибающей $z(t)$ из принятой огибающей $\hat{r}(t)$

$$\hat{r}(t) = K_1 z(t) + K_2 z^*(t) \tag{10.48}$$

Сопряженная принятая огибающая:

$$\hat{r}^*(t) = K_1^* z^*(t) + K_2^* z(t). \tag{10.49}$$

Переписав (10.48) и (10.49) в матричной форме

$$\begin{bmatrix} \hat{r}(t) \\ \hat{r}^*(t) \end{bmatrix} = \begin{bmatrix} K_1 & K_2 \\ K_2^* & K_1^* \end{bmatrix} \begin{bmatrix} z(t) \\ z^*(t) \end{bmatrix}; \quad \text{или} \quad \hat{\mathbf{r}}(t) = \mathbf{K}\mathbf{z}(t). \tag{10.50}$$

Если мы сможем оценить параметры K_1 и K_2, то:

$$\mathbf{z}(t) = \mathbf{K}^{-1}\hat{\mathbf{r}}(t), \tag{10.51}$$

откуда

$$\mathbf{K}^{-1} = \begin{bmatrix} K_1 & K_2 \\ K_2^* & K_1^* \end{bmatrix}^{-1} = \frac{1}{|K_1|^2 - |K_2|^2} \begin{bmatrix} K_1^* & -K_2 \\ -K_2^* & K_1 \end{bmatrix}. \tag{10.52}$$

Огибающие исходного передаваемого сигнала (10.51):

$$\begin{bmatrix} z(t) \\ z^*(t) \end{bmatrix} = \frac{1}{|K_1|^2 - |K_2|^2} \begin{bmatrix} K_1^* & -K_2 \\ -K_2^* & K_1 \end{bmatrix} \begin{bmatrix} \hat{r}(t) \\ \hat{r}^*(t) \end{bmatrix}. \tag{10.53}$$

Для компенсации достаточно только первого сигнала $z(t)$:

$$z(t) = \frac{K_1^*\hat{r}(t) - K_2\hat{r}^*(t)}{|K_1|^2 - |K_2|^2}. \tag{10.54}$$

Основная проблема оценки матрицы $\mathbf{K}$ заключается в том, что мы имеем только искаженный сигнал $\hat{r}(t)$.
Предположим, что исходная огибающая $z(t) = i(t) + jq(t)$ удовлетворяет следующим свойствам:

- $z(t)$ и сопряженная огибающая $z^*(t)$ некоррелированы;
- Синфазная и квадратурная компоненты также некоррелированы:

$$\mathrm{E}\left[i(t)q(t)\right] = 0, \tag{10.55}$$

  и имеют равные мощности:

$$\mathrm{E}\left[i^2(t)\right] = \mathrm{E}\left[q^2(t)\right]; \tag{10.56}$$

- Коэффициенты $K_1 \neq K_2$ (иначе матрица $\mathbf{K}$ будет вырожденой).

Тогда статистика второго порядка:

$$\mathrm{E}\left[z^2(t)\right] = \mathrm{E}\left[\left(z^*(t)\right)^2\right] = \mathrm{E}\left[i^2(t)\right] - \mathrm{E}\left[q^2(t)\right] + j2\,\mathrm{E}\left[i(t)q(t)\right] = 0. \tag{10.57}$$

Рассмотрим статистики второго порядка принятой огибающей $\hat{r}(t)$:

$$\begin{aligned}\mathrm{E}\left[\hat{r}^2(t)\right] &= \mathrm{E}\left[\left(K_1 z(t) + K_2 z^*(t)\right)^2\right] = \\ &= K_1^2\,\mathrm{E}\left[z^2(t)\right] + 2K_1K_2\,\mathrm{E}\left[z(t)z^*(t)\right] + K_2^2\,\mathrm{E}\left[\,(z^*(t))^2\,\right] = \\ &= 2K_1K_2\,\mathrm{E}\left[z(t)z^*(t)\right] \neq 0.\end{aligned} \tag{10.58}$$

С другой стороны статистика $\mathrm{E}\left[\hat{r}(t)\hat{r}^*(t)\right]$:

$$\begin{aligned}\mathrm{E}\left[\hat{r}(t)\hat{r}^*(t)\right] &= \mathrm{E}\left[\left(K_1 z(t) + K_2 z^*(t)\right)\left(K_1^* z^*(t) + K_2^* z(t)\right)\right] = \\ &= \Big(|K_1|^2\,\mathrm{E}\left[z(t)z^*(t)\right] + K_1^*K_2\,\mathrm{E}\left[\,(z^*(t))^2\,\right] + \\ &+ K_1K_2^*\,\mathrm{E}\left[z^2(t)\right] + |K_2|^2\,\mathrm{E}\left[z(t)z^*(t)\right]\Big) = \\ &= \left(|K_1|^2 + |K_2|^2\right)\mathrm{E}\left[z(t)z^*(t)\right].\end{aligned} \tag{10.59}$$

Тогда получаем систему:

$$\begin{cases} \mathrm{E}\left[\hat{r}^2(t)\right] = K_1 K_2 \, \mathrm{E}\left[z(t) z^*(t)\right]; \\ \mathrm{E}\left[\hat{r}(t)\hat{r}^*(t)\right] = \left(|K_1|^2 + |K_2|^2\right) \mathrm{E}\left[z(t) z^*(t)\right]. \end{cases} \tag{10.60}$$

Поделим первое уравнение на второе и получим параметр D:

$$D = \frac{\mathrm{E}\left[\hat{r}^2(t)\right]}{\mathrm{E}\left[\hat{r}(t)\hat{r}^*(t)\right]} = \frac{2K_1 K_2}{|K_1|^2 + |K_2|^2}. \tag{10.61}$$

Из отношения статистик принятой огибающей найти отдельно K_1 и K_2.
Вспомним выражения (10.47) для K_1 и K_2, и преобразуем:

$$\begin{aligned} K_1 &= \frac{1+\delta}{2} \, \mathrm{e}^{-j\varphi} + \frac{1-\delta}{2} \, \mathrm{e}^{j\varphi} = \frac{\mathrm{e}^{-j\varphi} + \delta \, \mathrm{e}^{-j\varphi} + \mathrm{e}^{j\varphi} - \delta \, \mathrm{e}^{j\varphi}}{2} = \cos\varphi - j\delta \sin\varphi; \\ K_2 &= \frac{1+\delta}{2} \, \mathrm{e}^{j\varphi} - \frac{1-\delta}{2} \, \mathrm{e}^{-j\varphi} = \frac{\mathrm{e}^{j\varphi} + \delta \, \mathrm{e}^{j\varphi} - \mathrm{e}^{-j\varphi} + \delta \, \mathrm{e}^{-j\varphi}}{2} = \delta \cos\varphi + j \sin\varphi. \end{aligned} \tag{10.62}$$

Тогда

$$\begin{aligned} 2K_1K_2 =& 2\big(\cos\varphi - j\delta\sin\varphi\big)\big(\delta\cos\varphi + j\sin\varphi\big) = \\ =& 2\big(\delta\cos^2\varphi + \delta\sin^2\varphi - j\delta^2\sin\varphi\cos\varphi + j\sin\varphi\cos\varphi\big) = \\ =& 2\delta + j(1-\delta^2)\sin(2\varphi) \end{aligned} \tag{10.63}$$

$$|K_1|^2 + |K_2|^2 = \cos^2\varphi + \delta^2\sin^2\varphi + \delta^2\cos^2\varphi + \sin^2\varphi = 1 + \delta^2. \tag{10.64}$$

$$D = \frac{2K_1K_2}{|K_1|^2 + |K_2|^2} = \frac{2\delta}{1+\delta^2} + j\frac{1-\delta^2}{1+\delta^2}\sin(2\varphi) \tag{10.65}$$

откуда при малых $|\delta| \ll 1$, $1+\delta^2 \approx 1$, $\frac{1-\delta^2}{1+\delta^2} \approx 1$, получим

$$D = \mathrm{Re}[D] + j\,\mathrm{Im}[D] = 2\delta + j\sin(2\varphi), \quad \Rightarrow \quad \begin{cases} \delta = \mathrm{Re}[D]/2; \\ \varphi = \arcsin\Big(\mathrm{Im}[D]\Big)/2. \end{cases} \tag{10.66}$$

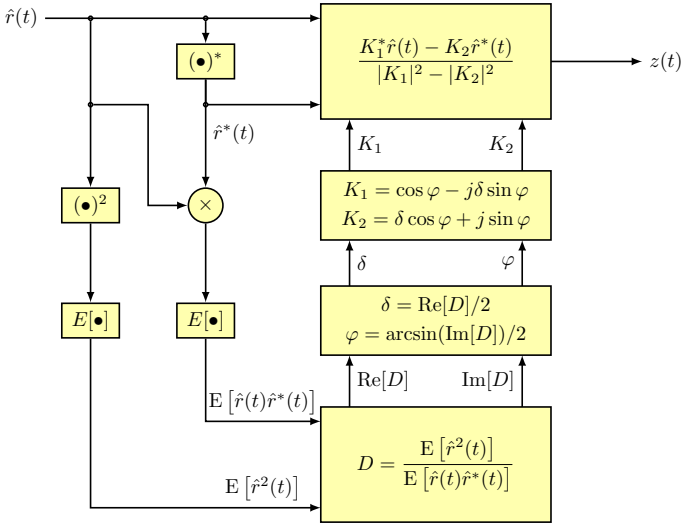

- Непрерывное накопление статистик второго порядка принятой огибающей $\hat{r}(t)$;
- Оценка комплексного коэффициента D;
- Разделение параметров амплитудного и фазового разбаланса δ и φ;
- Восстановление K_1 и K_2;
- Компенсация разбаланса.

Чем дольше аккумулируются статистики для расчета параметра D, тем точнее оценка δ и φ.

Лекция 11. Введение в адаптивные нелинейные фильтры

§11.1. Постановка задачи нелинейной аппроксимации

Пусть имеются два связанных друг с другом физических параметра x и y, и мы имеем возможность произвести N измерений данных параметров.

Мы не накладываем ограничений на очередность следования данных x_n, т.е. условие, что следующее измеряемое значение $x_n > x_{n-1}$ может не выполняться.

Необходимо по имеющемуся набору измеренных данных оценить зависимость $y = f(x)$, которой удовлетворяют измеренные данные.

$$\frac{1}{N}\sum_{n=0}^{N-1}\big(y_n - f(x_n)\big)^2 \to \min \qquad (11.1)$$

в классе выбранных нелинейных функций $f(x)$.

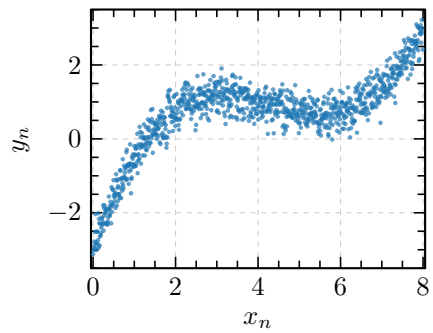

В качестве таких нелинейных функций могут выступать полиномы, сплайны, тригонометрические функции и др., которые зависят он некоторых параметров (коэффициентов), обеспечивающих минимум (11.1).

Пусть нелинейная функция $f(x) = p_m(x)$ представляет собой полином степени p

$$f(x) = a_0 + a_1 x + a_2 x^2 + \ldots + a_p x^p = \sum_{m=0}^{p} a_m x^m, \tag{11.2}$$

зависящий от коэффициентов a_m. Заметим, расчет полинома можно записать как скалярное произведения вектора состояния $\mathbf{u}^T$ и вектора коэффициентов:

$$f(x) = \sum_{m=0}^{p} a_m x^m = \mathbf{u}^T \mathbf{a}. \tag{11.3}$$

Здесь $\mathbf{u}$ содержит степени x, а вектор $\mathbf{a}$ — значения коэффициентов соответствующих степеням x:

$$\mathbf{u}^T = [x^0 \; x^1 \; x^2 \; \ldots \; x^p], \qquad \mathbf{a} = [a_0 \; a_1 \; a_2 \; \ldots \; a_m]^T. \tag{11.4}$$

При этом задача сводится к поиску вектора коэффициентов полинома, обеспечивающих минимум среднего квадрата ошибки:

$$J(\mathbf{a}) = \sum_{n=0}^{N-1} \big(\underbrace{y_n - \mathbf{u}_n^T \mathbf{a}}_{e_n} \big)^2 \to \min_{\mathbf{a}}. \tag{11.5}$$

Мы можем избавится от суммы, если перейдем к скалярному произведению векторов ошибок:

$$J(\mathbf{a}) = \sum_{n=0}^{N-1} e_n^2 = \mathbf{e}^T\mathbf{e} \to \min, \qquad \mathbf{e} = \mathbf{y} - \mathbf{U}\mathbf{a}, \tag{11.6}$$

где $\mathbf{y}$ — вектор размерности N, который содержит все измеренные значения y_n, а матрица $\mathbf{U}$ размерности $N \times (p+1)$ содержит все строки $\mathbf{u}_n^T$.

$$\mathbf{U} = \begin{bmatrix} 1 & x_0 & x_0^2 & \dots & x_0^p \\ 1 & x_1 & x_1^2 & \dots & x_1^p \\ 1 & x_2 & x_2^2 & \dots & x_2^p \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{N-1} & x_{N-1}^2 & \dots & x_{N-1}^p \end{bmatrix}. \tag{11.7}$$

Можно легко показать, что $J(\mathbf{a})$ является квадратичной функцией вещественного векторного аргумента $\mathbf{a}$:

$$J(\mathbf{a}) = \mathbf{e}^T\mathbf{e} = \big(\mathbf{y} - \mathbf{U}\mathbf{a}\big)^T\big(\mathbf{y} - \mathbf{U}\mathbf{a}\big) = \mathbf{a}^T\mathbf{U}^T\mathbf{U}\mathbf{a} - 2\mathbf{a}^T\mathbf{U}^T\mathbf{y} + \mathbf{y}^T\mathbf{y} \tag{11.8}$$

с неотрицательно определенной матрицей квадратичной формы $\mathbf{U}^T\mathbf{U}$.

Тогда минимизация (11.8) заключается в расчете вектора градиента $\nabla_J(\mathbf{a})$ и приравнивания его к нулю:

$$\nabla_J(\mathbf{a}) = \frac{\partial}{\partial \mathbf{a}^T}J(\mathbf{a}) = \frac{\partial}{\partial \mathbf{a}^T}\mathbf{a}^T\mathbf{U}^T\mathbf{U}\mathbf{a} - 2\frac{\partial}{\partial \mathbf{a}^T}\mathbf{a}^T\mathbf{U}^T\mathbf{y} + \frac{\partial}{\partial \mathbf{a}^T}\mathbf{y}^T\mathbf{y} = \\ = \Big(\big(\mathbf{U}^T\mathbf{U}\big)^T + \mathbf{U}^T\mathbf{U}\Big)\,\mathbf{a} - 2\mathbf{U}^T\mathbf{y} = 2\mathbf{U}^T\mathbf{U}\mathbf{a} - 2\mathbf{U}^T\mathbf{y}. \tag{11.9}$$

Приравнивая к нулю градиент $\nabla_J(\mathbf{a})$ получим систему линейных алгебраических уравнений:

$$2\mathbf{U}^T\mathbf{U}\mathbf{a} - 2\mathbf{U}^T\mathbf{y} = 0, \tag{11.10}$$

решением которого является LS оценку вектора коэффициентов полинома вектора коэффициентов полинома $\mathbf{a}$:

$$\mathbf{a} = \left(\mathbf{U}^T\mathbf{U}\right)^{-1}\mathbf{U}^T\mathbf{y}. \tag{11.11}$$

Матрица состояния $\mathbf{U}$ хранит степенные значения исходного параметра x_n, в отличии от матрицы состояния линейного фильтра, которая хранила задержанные значения сигнала.

Произведение $\mathbf{U}^T\mathbf{U}$ при этом можно трактовать как аналог корреляционной матрицы, показывающий взаимосвязь степенных функций от x_n.

$\mathbf{U}^T\mathbf{U}$ представляет собой квадратную положительно-опрделенную матрицу полного ранга, если число различных ненулевых значений в выборке исходного параметра x_n больше числа коэффициентов полинома.

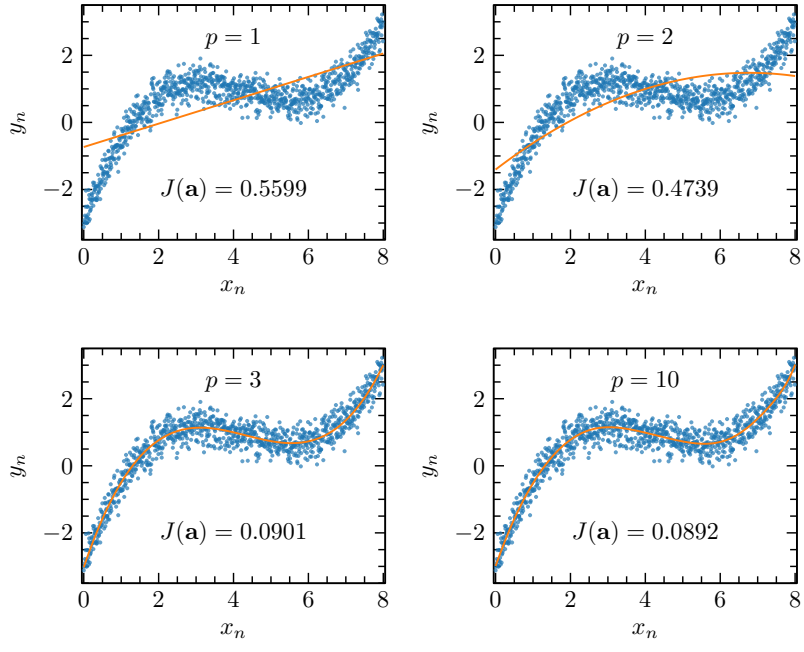
$p = 1$
$J(\mathbf{a}) = 0.5599$
$p = 2$
$J(\mathbf{a}) = 0.4739$
$p = 3$
$J(\mathbf{a}) = 0.0901$
$p = 10$
$J(\mathbf{a}) = 0.0892$
y_n
x_n

Можно видеть, что при порядке полинома $p = 20$ и $p = 30$ при $x_n > 1$ наблюдаются ошибки аппроксимации. Главным образом, это обусловлено двумя причинами:

- Коэффициенты при различных степенях неравновесны. Так при $x_n > 1$, требования к точности оценки коэффициента при старших степенях существенно выше чем требования к точности оценки коэффициента при младших степенях, поскольку рост старших степеней значительно быстрее.
- Численная устойчивость процедуры обращения матрицы $\mathbf{U}^T\mathbf{U}$ при расчете коэффициентов полинома.

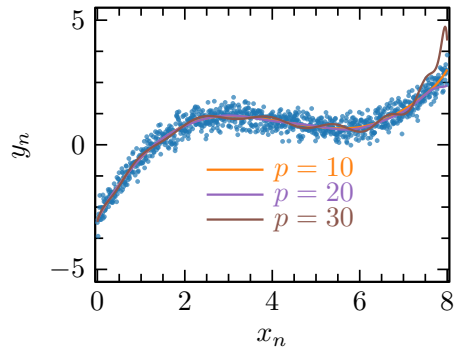

Функции x_n^{p-1} и x_n^p не являются ортогональными, и с ростом p это приводит с ухудшению обусловленности матрицы $\mathbf{U}^T\mathbf{U}$.

Улучшить обусловленность матрицы $\mathbf{U}^T\mathbf{U}$ можно путем изменения системы базисных функций на ортогональные, обеспечивающие равновесность коэффициентов. Тогда аппроксимирующей функцией будет являться

$$f(x) = \sum_{m=0}^{p} a_m \varphi_m(x) = \mathbf{u}^T \mathbf{a}, \tag{11.12}$$

где a_m — коэффициенты разложение в системе базисных функций $\varphi_m(x)$.

Напомним, что система функций $\varphi_m(x)$ называется ортогональной на отрезке $[a,\ b]$ с весом $w(x)$, если

$$\int_a^b \varphi_n(x)\varphi_m(x)w(x)\ dx = \begin{cases} h_m, & \text{если} \quad n = m, \\ 0, & \text{если} \quad n \neq m. \end{cases} \tag{11.13}$$

Здесь коэффициент h_m является нормой, зависящей от порядка полинома.

Ортогональные полиномы Лежандра $L_n(x)$:
Обеспечивают ортогональность на интервале $[-1,\,1]$ с минимальным среднеквадратическим отклонением от нуля. Рекуррентная формула:

$$L_n(x) = \frac{2n-1}{n} x\, L_{n-1}(x) - \frac{n-1}{n}\, L_{n-2}(x), \quad n \geq 2 \tag{11.14}$$

Начальные условия $L_0(x) = 1$, $L_1(x) = x$. Весовая функция обеспечивающая ортогональность $w(x) = 1$. Норма полиномов Лежандра равна $h_n = 2/(2n+1)$.

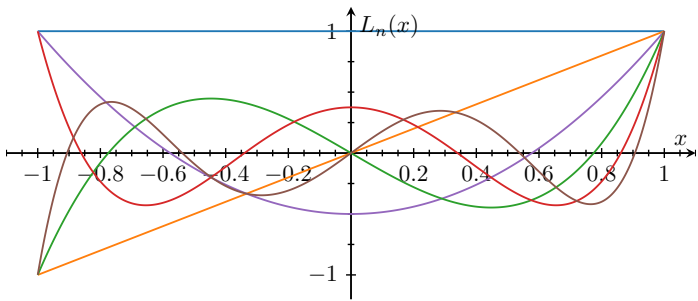

Ортогональные полиномы Чебышева первого рода $T_n(x)$:
Обеспечивают ортогональность на интервале $[-1,\,1]$ с минимальным абсолютным отклонением от нуля. Ортогональность обеспечивается весовой функцией $w(x) = 1/\sqrt{1-x^2}$. Рекуррентное соотношение:

$$T_n(x) = 2xT_{n-1}(x) - T_{n-2}(x), \quad n \geq 2. \tag{11.15}$$

Начальные условия $T_0(x) = 1$, $T_1(x) = x$.
Скалярное произведение на интервале $[-1,\,1]$ возвращает норму $h_n = \pi/2$ для всех порядков $n > 0$. В случае нулевого порядка $T_0(x)$ норма равна $h_0 = \pi$.

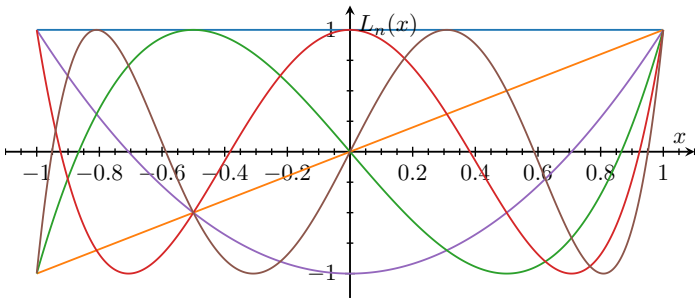

Ортогональные полиномы Чебышева второго рода $U_n(x)$:
Обеспечивают ортогональность на интервале $[-1,\,1]$ с минимальным значением интеграла модуля полинома на заданном отрезке. Ортогональность обеспечивается весовой функцией $w(x) = \sqrt{1-x^2}$. Рекуррентное соотношение такое же как и у полиномов Чебышева первого рода:

$$U_n(x) = 2xU_{n-1}(x) - U_{n-2}(x), \quad n \geq 2, \tag{11.16}$$

но начальные условия $U_0(x) = 1$, $U_1(x) = 2x$.
Скалярное произведение на интервале $[-1,\,1]$ возвращает норму $h_n = \pi/2$ для всех порядков n.

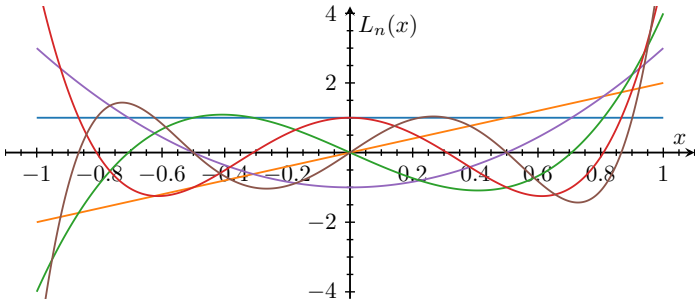

Приведенные ортогональные полиномы обеспечивают ортогональность на интервале $[-1,\ 1]$, что требует нормировки аргумента x_n в заданный диапазон значений.

Такую нормировку можно осуществить априорно, если заранее известен диапазон возможных значений x_n.

Если же диапазон значений заранее неизвестен, то масштабирование можно произвести по выборке данных x_n длительности N отсчетов:

$$x_n^{[-1,\ 1]} = \frac{x_n - b}{\max\left(|x_n - b|\right)}, \quad b = \frac{\max(x_n) - \min(x_n)}{2}. \tag{11.17}$$

Тогда в качестве аргумента ортогонального полинома можно использовать $x_n^{[-1,\ 1]}$, значения которого масштабированы в интервал ортогональности $[-1,\ 1]$.

Базис	Аргумент	p	$\mathrm{cond}(\mathbf{U}^T\mathbf{U})$
Степенной x^n	x_n	3	$1.3 \cdot 10^6$
		10	$2.9 \cdot 10^{22}$
		20	$2.0 \cdot 10^{36}$
		30	$3.6 \cdot 10^{50}$
		100	$9.4 \cdot 10^{123}$
Степенной x^n	$x_n^{[-1,\,1]}$	3	67
		10	$9.3 \cdot 10^6$
		20	$3.1 \cdot 10^{14}$
		30	$2.9 \cdot 10^{18}$
		100	$1.9 \cdot 10^{19}$
Лежандра $L_n(x)$	$x_n^{[-1,\,1]}$	3	7
		10	21
		20	40
		30	60
		100	610

Базис	Аргумент	p	$\mathrm{cond}(\mathbf{U}^T\mathbf{U})$
Степенной x^n	x_n	3	$1.3 \cdot 10^6$
		10	$2.9 \cdot 10^{22}$
		20	$2.0 \cdot 10^{36}$
		30	$3.6 \cdot 10^{50}$
		100	$9.4 \cdot 10^{123}$
Чебышева первого рода $T_n(x)$	$x_n^{[-1,\,1]}$	3	5.9
		10	13
		20	22
		30	26
		100	200
Чебышева второго рода $U_n(x)$	$x_n^{[-1,\,1]}$	3	2.5
		10	6.4
		20	13
		30	24
		100	450

§11.2. Нелинейные характеристики усилителя мощности

Полевые транзисторы на сегодняшний день являются основной элементной базой при построении выходных СВЧ усилителей систем беспроводной связи. Благодаря высоким входному и выходному сопротивлениям, полевой транзистор работает как управляемый напряжением источник тока.

[7] англ. Laterally Diffused Metal Oxide Semiconductors (смещенно-диффузная МОП технология на основе кремния).

[8] англ. High-Electron-Mobility Transistor.

Полевые транзисторы на сегодняшний день являются основной элементной базой при построении выходных СВЧ усилителей систем беспроводной связи. Благодаря высоким входному и выходному сопротивлениям, полевой транзистор работает как управляемый напряжением источник тока.

В аппаратуре стандартов связи 2G и 3G большая часть усилитетелей строилась на основе кремниевых LDMOS[7] транзисторов, однако при переходе к стандарту 3.5G и 4G LDMOS стали вытеснять транзисторы с высокой подвижностью электронов (HEMT[8]) на основе арсенида галия (GaAs) и нитрита галия (GaN). Причем последним, как правило, отдается предпочтение при построении аппаратуры с высокой выходной мощностью.

[7] англ. Laterally Diffused Metal Oxide Semiconductors (смещенно-диффузная МОП технология на основе кремния).

[8] англ. High-Electron-Mobility Transistor.

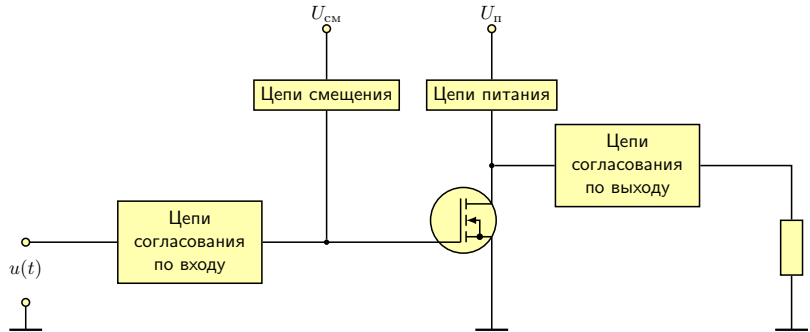

Входной сигнал $u(t)$ представляет собой управляющее напряжение, подаваемое на затвор транзистора через цепи согласования по входу.

Напряжение на затворе смещается на величину $U_{\text{см}}$ при помощи которого можно изменять режим работы усилителя.

Выходной ток транзистора через цепи согласования по выходу подается в нагрузку $R_{\text{н}}$.

Цепи согласования по входу и выходу представляют собой полосковые линии обеспечивающие согласование входного и выходного импеданса с предварительными каскадами и нагрузкой. Цепи питания и смещения, как правило пассивные фильтры на сосредоточенных элементах (емкости и индуктивности), предотвращающие влияние радиосигналов на схемы питания усилителя.

Наличие согласующих цепей по входу и выходу вносят инерционность в схему. Так значение тока на выходе будет зависеть не только от мгновенного значения управляющего воздействия $u(t)$, но также будет зависеть от значений на предшествующем интервале $u(t-\tau)$. В этом случае говорят об эффектах памяти усилителя.

Транзистор в первом приближении можно считать безынерционным. Однако при увеличении полосы сигнала, а также выходной мощности, эффекты накопления и рассасывания зарядов в транзисторе также оказывают влияние на инерционность усилителя.

Нелинейные выходные (стоковые) характеристики транзистора:

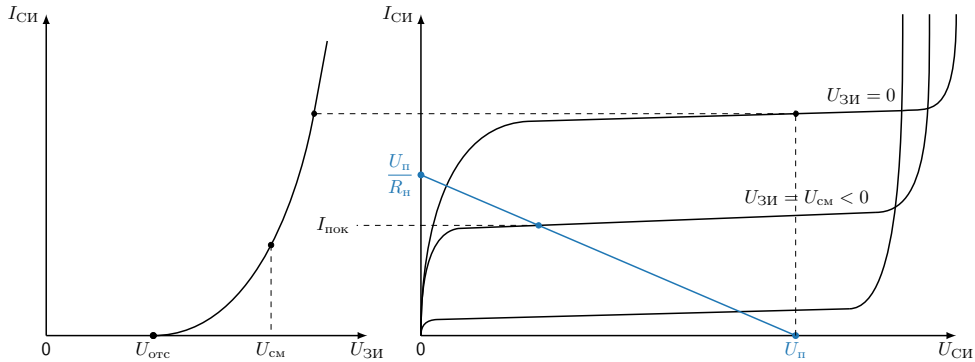

На правом графике можно видеть выходную нелинейную характеристику тока сток–исток $I_{СИ}$ от значения постоянного напряжения на затворе для некоторого значения напряжения питания $U_п$.

На левом графике можно видеть семейство зависимостей тока стока от напряжения сток–исток $U_{СИ}$ при различном значении напряжения на затворе $U_{ЗИ}$.

Транзистор с управляющим каналом n-типа является нормально закрытым, и для того чтобы перевести его в режим источника тока $I_{\text{СИ}}$ необходимо подать напряжение больше напряжения отсечки $U_{\text{отс}}$.

При этом на стоковых характеристиках мы можем выделить три участка соответствующих линейному режиму (зона увеличения $I_{\text{СИ}}$), режиму насыщения, и режиму пробоя, при котором ток сток–исток резко возрастает ввиду электрического пробоя в транзисторе, что приводит к выходу транзистора из строя.

Задание режима работы усилительного каскада заключается в выборе напряжения питания $U_{\text{п}}$, а смещения $U_{\text{см}}$ на затворе транзистора при заданных значениях сопротивления нагрузки $R_{\text{н}}$ и амплитуде входного сигнала $u(t)$, что показано нагрузочной прямой, которая соединяет точки $U_{\text{п}}$ и $U_{\text{п}}/R_{\text{н}}$.

Точка пересечения нагрузочной прямой и стоковой характеристики задает рабочую точку и ток покоя $I_{\text{пок}}$, протекающий в стоковой цепи, который влияет на КПД усилителя, поскольку протекает вне зависимости от уровня сигнала на входе и выходе.

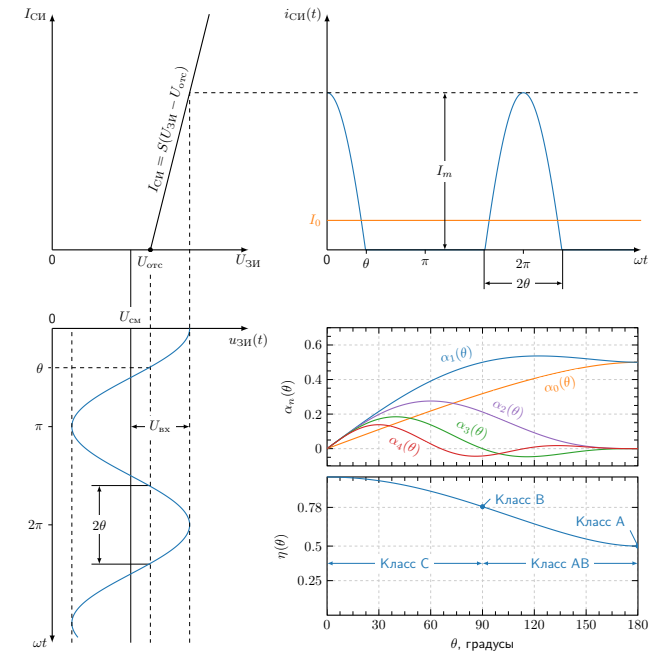

Для уменьшения тока покоя необходимо уменьшать напряжение смещения в этом случае КПД усилителя будет возрастать, однако сам усилитель переходит в более нелинейный режим. В этом случае транзистор работает в режиме отсечки.

Пусть входной сигнал представляет собой гармоническое колебание $u(t) = U_{\text{вх}} \cos(\omega t)$, тогда на затворе транзистора будет напряжение

$$u_{\text{ЗИ}}(t) = u(t) + U_{\text{см}} = U_{\text{вх}} \cos(\omega t) + U_{\text{см}}. \tag{11.18}$$

Кусочно-линейная аппроксимация задает стоковую характеристику транзистора как $I_{\text{СИ}} = S(U_{\text{ЗИ}} - U_{\text{отс}})$, где S — крутизна стоковой характеристики. При значениях напряжения на затворе ниже напряжение отсечки $U_{\text{отс}}$ транзистор закрыт и ток стока равен нулю.

При подаче на затвор напряжения $u_{\text{ЗИ}}(t)$ со смещением $U_{\text{см}}$ ток стока $i_{\text{СИ}}$ будет иметь импульсный вид, поскольку часть периода входного сигнала транзистор будет закрыт.

Для того чтобы анализ работы транзистора не зависел от частоты ω, оси абсцисс масштабированы к углу ωt, выраженного в радиан или градусах, где $\omega t = 2\pi$ соответствует одному периоду повторения $u_{\text{ЗИ}}(t)$ и $i_{\text{СИ}}(t)$.

Тогда на оси ωt можно выделить промежуток 2θ, когда транзистор открыт, и ток стока отличен от нуля. Угол θ носит название угла отсечки и является важнейшим параметром характеризующим режим работы усилителя мощности радиосигналов и его КПД.

Поскольку ток стока $i_{\text{СИ}}(t)$ носит периодический характер, и его форма зависит от угла отсечки θ, то он может быть представлен рядом Фурье при разложении только по косинусоидальным компонентам из-за четности $u_{\text{ЗИ}}(t)$ и $i_{\text{СИ}}(t)$:

$$i_{\text{СИ}}(t) = \sum_{n=0}^{\infty} I_m \alpha_n(\theta) \cos(n\omega t), \tag{11.19}$$

здесь I_m — амплитуда импульса тока стока, $\alpha_n(\theta)$ — коэффициенты разложения, зависящие от θ, которые были получены аналитически и носят название функции Берга.

Заметим, что постоянная составляющая $I_0 = I_m \alpha_0(\theta)$ задает ток, потребляемый от источника питания.

Функция $\alpha_1(\theta)$ задает амплитуду тока $I_1 = I_m \alpha_1(\theta)$ полезного сигнала на частоте ω.

Функции $\alpha_n(\theta)$ высших порядков задают амплитуды тока кратных гармоник[9], возникающих в результате отсечки.

[9] Отрицательные значения $\alpha_n(\theta)$ говорят об инверсии фазы соответствующей гармоники.

Тогда КПД усилительного каскада $\eta = P_{\sim}/P_{-}$.

При этом полезная мощность $P_{\sim} = I_1 U_m/2$, где $I_1 = \alpha_1(\theta)$ — амплитуда тока, а потребляемая мощность равна $P_{-} = I_0 U_{\text{п}}$.

Заметим, что I_0 и I_1 задаются функциями Берга нулевого и первого порядка, зависящими от θ, тогда КПД также будет зависеть от угла отсечки:

$$\eta(\theta) = \frac{P_{\sim}}{P_{-}} = \frac{I_1 U_m}{2 I_0 U_{\text{п}}} = \frac{I_m \alpha_1(\theta) U_m}{2 I_m \alpha_0(\theta) U_{\text{п}}} = \frac{\alpha_1(\theta)}{2\alpha_0(\theta)} \cdot \frac{U_m}{U_{\text{п}}}. \tag{11.20}$$

При расчете усилителя амплитуду U_m полезного сигнала стремятся сделать равной напряжению питания $U_{\text{п}}$, в результате КПД зависит только от угла отсечки как $\eta(\theta) = \alpha_1(\theta)/(2\alpha_0(\theta))$.

Оценку КПД усилителя для гармонического сигнала можно производить в частотной области путем отношения амплитуды основной гармоники к постоянной составляющей при разложении в ряд Фурье.

В зависимости от угла отсечки, различают несколько режимов работы усилителя, или так называемых классов.

- **Усилитель класса A** соответствует углу отсечки $\theta = \pi$ рад (без отсечки), $U_{\text{см}} \geq U_{\text{отс}} + U_{\text{вх}}$. Входной сигнал полностью находится на линейном участке стоковой характеристики. Максимальный КПД составляет 50%.
- **Усилитель класса B** соответствует единственной точке на кривой КПД при угле отсечки $\theta = \pi/2$ рад. Напряжение смещения $U_{\text{см}} = U_{\text{отс}}$. В этом классе транзистор закрыт половину периода входного сигнала. Теоретический предел КПД такого усилителя составляет 78%, но достигается за счет высокого уровня нелинейных искажений по выходу.
- **Усилитель класса AB** соответствует углам отсечки $\pi/2 < \theta < \pi$. Является компромиссом, позволяющим обеспечить увеличение КПД относительно линейного усилителя, с сохранением допустимого уровня нелинейных искажений.
- **Усилитель класса C** соответствует углам отсечки $\theta < \pi/2$. Напряжение смещения $U_{\text{см}} < U_{\text{отс}}$. Усилителя класса C могут имеють КПД более 90%, но уровень искажений настолько высок, что на практике усилители класса C применяются только для сигналов с постоянной амплитудной огибающей.

§11.3. Прохождение однотонального радиосигнала через нелинейный усилитель

Рассмотрим прохождение однотонального сигнала $x(t) = A\cos(\omega_0 t)$ через идеальный безынерционный линейный усилитель с коэффициентом усиления G_1. Здесь амплитуда сигнала A имеет размерность вольт, а характеристика линейного усилителя $f_{PA}(x) = G_1 x$.
Мощность сигнала на входе $P_{\text{вх}} = A^2/2$ Вт, тогда сигнал на выходе линейного усилителя $y_1(t) = G_1 A\cos(\omega_0 t)$ имеет мощность:

$$P_1 = A^2 G_1^2/2 = G_1^2 P_{\text{вх}}, \ \text{Вт}. \tag{11.21}$$

В логарифмической шкале выходная мощность линейного усилителя с коэффициентом усиления G_1 дБ задается линейным уравнением

$$P_1[\text{дБм}] = P_{\text{вх}}[\text{дБм}] + G_1[\text{дБ}], \quad P[\text{дБм}] = 10\lg(P[\text{Вт}]) + 30, \tag{11.22}$$

$$G_1[\text{дБ}] = 10\lg G_1^2 = 20\lg G_1. \tag{11.23}$$

Прохождение однотонального сигнала $x(t) = A\cos(\omega_0 t)$ через нелинейный квадратичный усилитель с характеристикой $f_{PA}(x) = G_2 x^2$. Здесь размерность коэффициента G_2 при квадратичном члене равна $1/\text{В}$. Тогда сигнал на выходе $y_2(t)$ равен:

$$y_2(t) = G_2 A^2 \cos^2(\omega_0 t) = \frac{G_2 A^2}{2} + \frac{G_2 A^2}{2}\cos(2\omega_0 t). \tag{11.24}$$

Таким образом на выходе квадратичного элемента имеем компоненту на нулевой частоте мощностью $P_0 = G_2^2 A^4/4$ Вт и компоненту на удвоенной частоте мощностью $P_2 = G_2^2 A^4/8$ Вт. Зависимость мощности второй гармоники от мощности входного сигнала:

$$P_2 = G_2^2 A^4/8 = G_2^2 P_{\text{вх}}^2/2, \ \text{Вт}, \quad \text{или} \quad P_2 = G_2 + 2P_{\text{вх}} + c_0 \ \text{дБм}, \tag{11.25}$$

где c_0 учитывает константу 2 в знаменателе, а также переход из единиц ватт в единицы децибел-милливатт.
Коэффициент линейной зависимости P_2 от $P_{\text{вх}}$ в логарифмическом масштабе равен двум, что дает более крутой наклон P_2 относительно линейной компоненты P_1.

Прохождение данного сигнала через нелинейный усилитель с кубической нелинейной характеристикой $f_{PA}(x) = G_3 x^3$. Размерность коэффициента G_3 в случае нелинейности третьей степени равна $1/\text{В}^2$. Тогда сигнал $y_3(t)$ на выходе усилителя равен:

$$y_3(t) = G_3 A^3 \cos^3(\omega_0 t) = \frac{3G_3 A^3}{4} \cos(\omega_0 t) + \frac{G_3 A^3}{4} \cos(3\omega_0 t). \tag{11.26}$$

Рассмотрим мощность третьей гармоники:

$$P_3 = G_3^2 A^6/32 = G_3^2 P_{\text{вх}}^3/4, \ \text{Вт}, \quad \text{или} \quad P_3 = G_3 + 3P_{\text{вх}} + \text{c}_1 \ \text{дБм}, \tag{11.27}$$

где c_1 учитывает константу 4 в знаменателе, а также переход из единиц ватт в единицы децибел-милливатт для третьей гармоники.
Важно заметить, что коэффициент линейной зависимости P_3 от $P_{\text{вх}}$ в логарифмическом масштабе равен трем, что дает еще более крутой наклон P_3

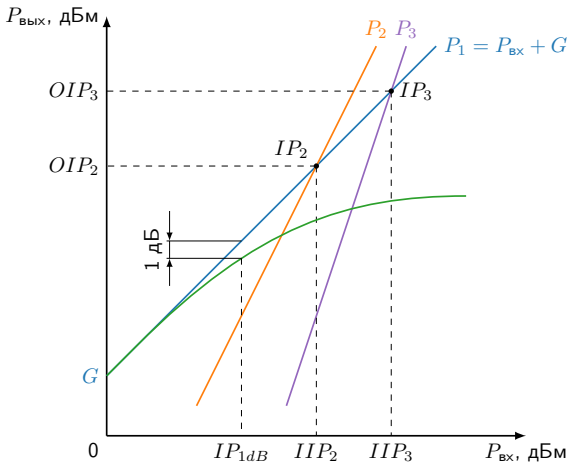

При увеличении мощности входного сигнала $P_{вх}$ мощность на выходе усилителя также увеличивается и получаем линейную зависимость $P_1(P_{вх})$.

Мощности второй и третьей гармоник растут по квадратичному и кубическому законам соответственно, и с увеличением мощности $P_{вх}$, чем мощность полезного сигнала на выходе усилителя.

Значение мощности входного сигнала при котором его усиление снижается на 1 дБ называется точкой компрессии усиления на 1 дБ и обозначена на графике как IP_{1dB}.

Значения G, IIP_2, IIP_3 и IP_{1dB} являются основными характеристиками нелинейного усилителя мощности и как правило приводятся в техническом паспорте.

Анимация демонстрирующая физический смысл точек IIP_2 и IIP_3

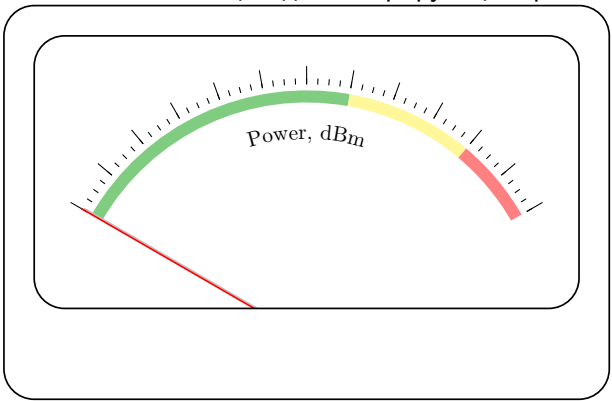

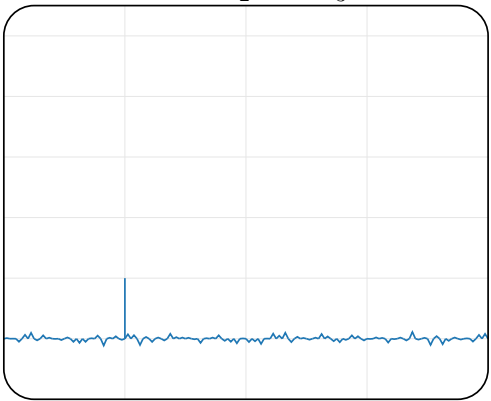

§11.4. Прохождение двухтонового радиосигнала через нелинейность четной и нечетной степеней

Рассмотрим прохождение $x(t) = A\big[\cos(\omega_0 t) + \cos(\omega_1 t)\big]$ через нелинейную цепь с характеристикой $f_{PA}(x) = G_2 x^2$. тогда сигнал $y_2(t)$ на выходе такого нелинейного элемента равен:

$$y_2(t) = G_2 x^2(t) = G_2 A^2 \big(\cos(\omega_0 t) + \cos(\omega_1 t)\big)^2 =$$
$$= G_2 A^2 + G_2 A^2 \Big[\cos\big((\omega_1 - \omega_0)t\big) + \cos\big((\omega_1 + \omega_0)t\big)\Big] +$$
$$+ \frac{G_2 A^2}{2}\Big[\cos(2\omega_0 t) + \cos(2\omega_1 t)\Big]. \quad (11.28)$$

Мощность постоянной составляющей равна $G_2^2 A^4$ Вт, мощности вторых гармоник на частотах $2\omega_0$ и $2\omega_1$ равны $G_2^2 A^4/4$ Вт, а мощности гармоник на частотах $\omega_1 - \omega_0$ и $\omega_1 + \omega_0$ равны $G_2^2 A^4/2$ Вт.

Усилитель с квадратичной характеристикой не имеет смысла, т.к. он уничтожает сигнал на несущей частоте. Это же касается любой четной характеристики $f(x) = x^{2n}$. Поэтому при проектировании радиоусилителя необходимо стремиться уменьшить четные гармоники, т.к. их появление будет снижать КПД.

Рассмотрим теперь сигнал на выходе кубической нелинейности $y_3(t) = G_3 x^3(t)$:

$$y_3(t) = G_3 x^3(t) = G_3 A^3 \big(\cos(\omega_0 t) + \cos(\omega_1 t) \big)^3 = \\ = G_3 A^3 \Big[\cos^3(\omega_0 t) + 3\cos^2(\omega_0 t)\cos(\omega_1 t) + \\ + 3\cos(\omega_0 t)\cos^2(\omega_1 t) + \cos^3(\omega_1 t) \Big]. \quad (11.29)$$

Применив тригонометрические тождества и преобразовав можно показать, что

$$y_3(t) = \frac{9 G_3 A^3}{4} \Big[\cos(\omega_0 t) + \cos(\omega_1 t) \Big] + \frac{G_3 A^3}{4} \Big[\cos(3\omega_0 t) + \cos(3\omega_1 t) \Big] + \\ + \frac{3 G_3 A^3}{4} \Big[\cos\big((2\omega_0 - \omega_1)t\big) + \cos\big((2\omega_1 - \omega_0)t\big) + \\ + \cos\big((2\omega_0 + \omega_1)t\big) + \cos\big((2\omega_1 + \omega_0)t\big) \Big]. \quad (11.30)$$

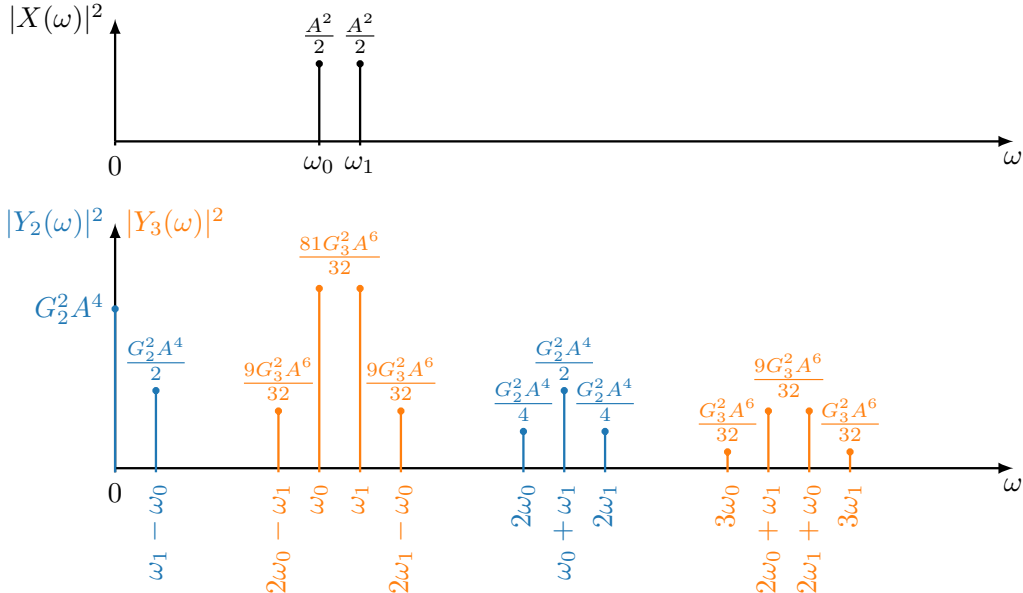
$|X(\omega)|^2$
$\frac{A^2}{2}$
$\frac{A^2}{2}$
0
ω_0
ω_1
ω
$|Y_2(\omega)|^2$
$|Y_3(\omega)|^2$
$\frac{81G_3^2A^6}{32}$
$G_2^2A^4$
$\frac{G_2^2A^4}{2}$
$\frac{9G_3^2A^6}{32}$
$\frac{9G_3^2A^6}{32}$
$\frac{G_2^2A^4}{2}$
$\frac{G_2^2A^4}{4}$
$\frac{G_2^2A^4}{4}$
$\frac{9G_3^2A^6}{32}$
$\frac{G_3^2A^6}{32}$
$\frac{G_3^2A^6}{32}$
0
ω
$\omega_1 - \omega_0$
$2\omega_0 - \omega_1$
ω_0
ω_1
$2\omega_1 - \omega_0$
$2\omega_0$
$\omega_0 + \omega_1$
$2\omega_1$
$3\omega_0$
$2\omega_0 + \omega_1$
$2\omega_1 + \omega_0$
$3\omega_1$

$|X(\omega)|^2$
0
ω_0
ω

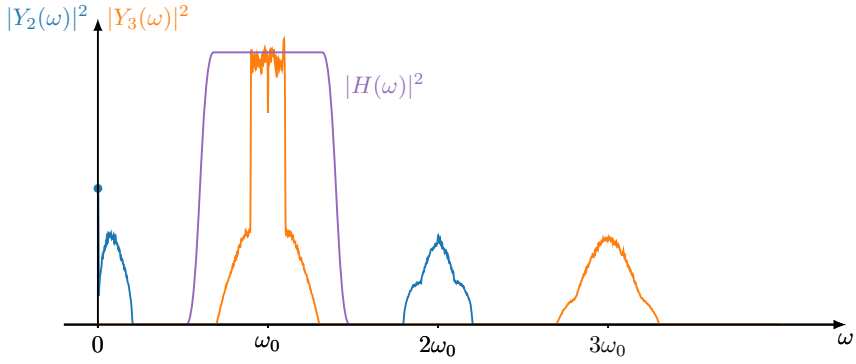
$|Y_2(\omega)|^2$
$|Y_3(\omega)|^2$
$|H(\omega)|^2$
0
ω_0
$2\omega_0$
$3\omega_0$
ω

§11.5. Измерение AM–AM и AM–PM нелинейных характеристик усилителя

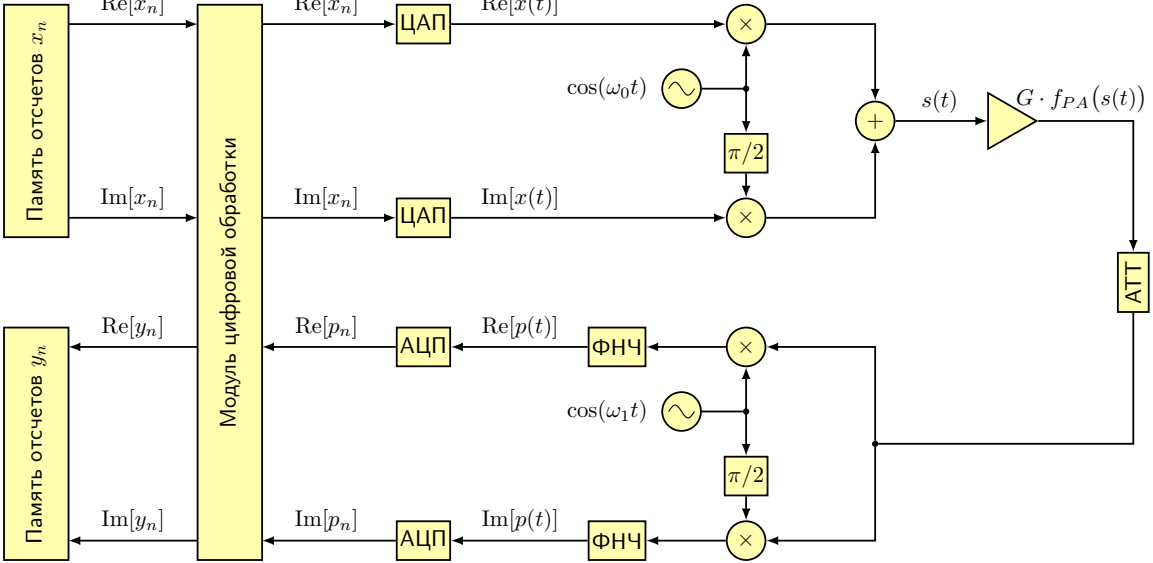
Память отсчетов x_n
$\mathrm{Re}[x_n]$
$\mathrm{Im}[x_n]$
Модуль цифровой обработки
$\mathrm{Re}[x_n]$
$\mathrm{Im}[x_n]$
ЦАП
ЦАП
$\mathrm{Re}[x(t)]$
$\mathrm{Im}[x(t)]$
$\cos(\omega_0 t)$
$\pi/2$
$s(t)$
$G \cdot f_{PA}(s(t))$
АТТ
Память отсчетов y_n
$\mathrm{Re}[y_n]$
$\mathrm{Im}[y_n]$
$\mathrm{Re}[p_n]$
$\mathrm{Im}[p_n]$
АЦП
АЦП
$\mathrm{Re}[p(t)]$
$\mathrm{Im}[p(t)]$
ФНЧ
ФНЧ
$\cos(\omega_1 t)$
$\pi/2$

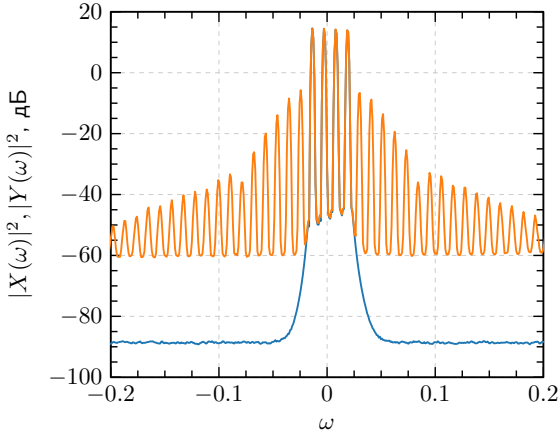

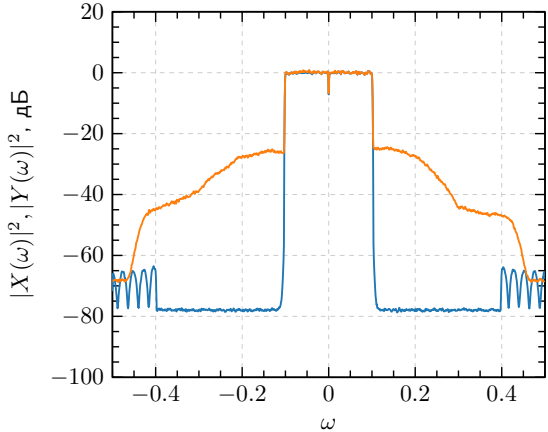

Можно видеть, что спектральный состав $|Y(\omega)|^2$ содержит множество интермодуляционных компонент на выходе усилителя в случае GSM сигнала. Для LTE сигнала на выходе усилителя присутствует характерная непрерывная по частоте «юбка». Заметим, что уровень внеполосных интермодуляционных компонент составляет $-25 \ldots -20$ дБ относительно уровня сигнала.

Поскольку сигналы x_n и y_n являются комплексными, то мы можем построить нелинейную характеристику AM–AM, как зависимость модуля выхода усилителя $|y_n|$ от модуля входного сигнала $|x_n|$ для каждого временного отсчета n.

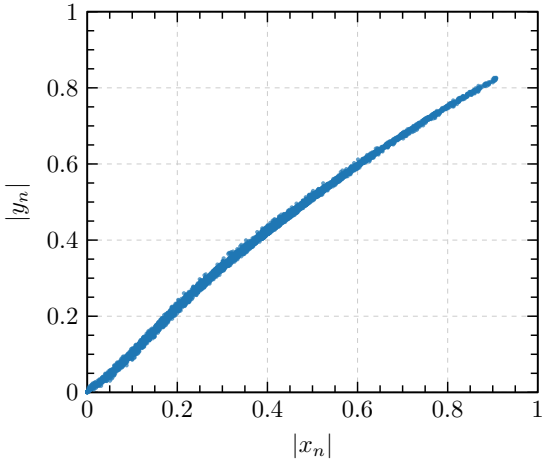

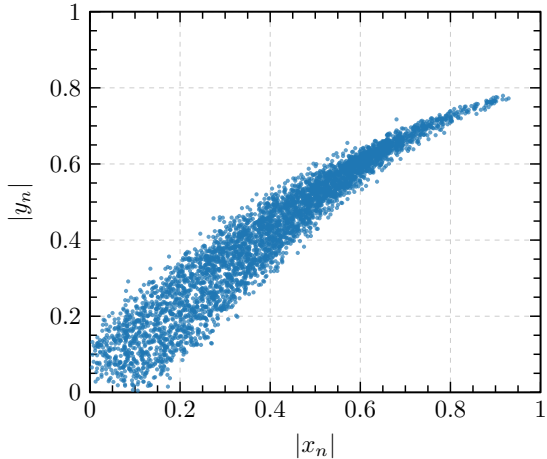

Помимо АМ–АМ характеристики в линейном масштабе, можно оценить относительную АМ–АМ характеристику в логарифмическом масштабе как зависимость $|y_n|/|x_n|$ от модуля входного сигнала $|x_n|$, выраженную в единицах децибел:

$$g(|x_n|) = 20\log_{10}(|y_n|/|x_n|) = 10\log_{10}(|y_n|^2/|x_n|^2), \quad [\text{дБ}]. \tag{11.31}$$

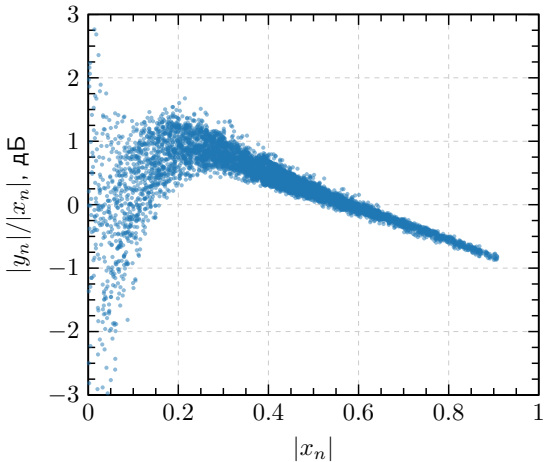

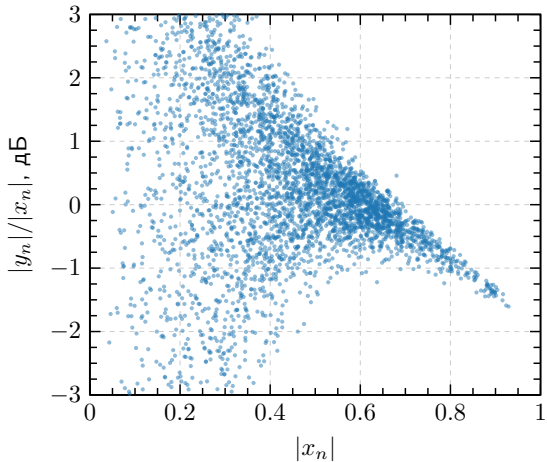

Сигналы x_n и y_n являются комплексными, то мы можем построить нелинейную зависимость АМ–РМ $\varphi(|x_n|)$ мгновенной разности фаз отсчетов x_n и y_n от амплитуды входного сигнала:

$$\varphi(|x_n|) = \angle(x_n,\ y_n) = \angle(x_n^* y_n). \tag{11.32}$$

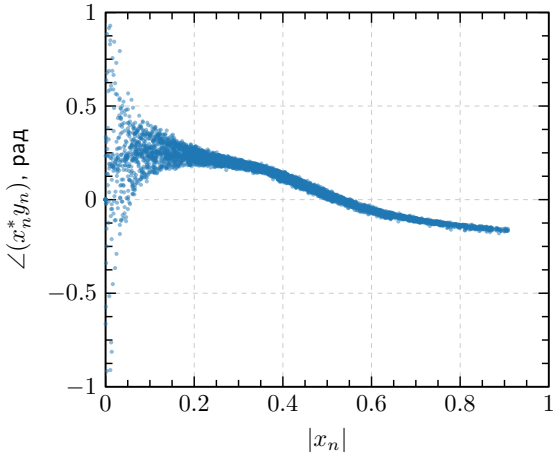

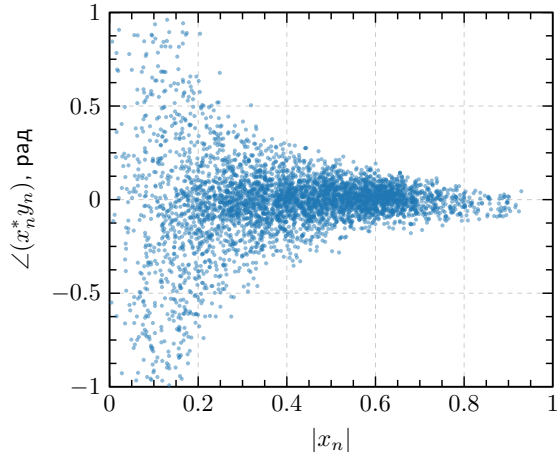

§11.6. Влияние нелинейных искажений на характеристики системы связи

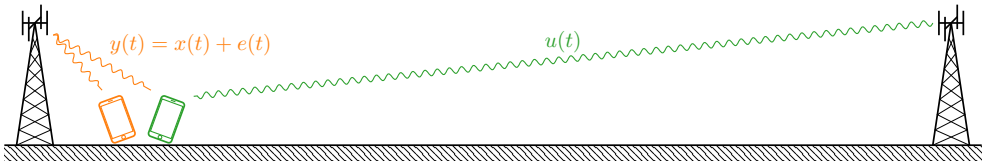
$y(t) = x(t) + e(t)$
$u(t)$

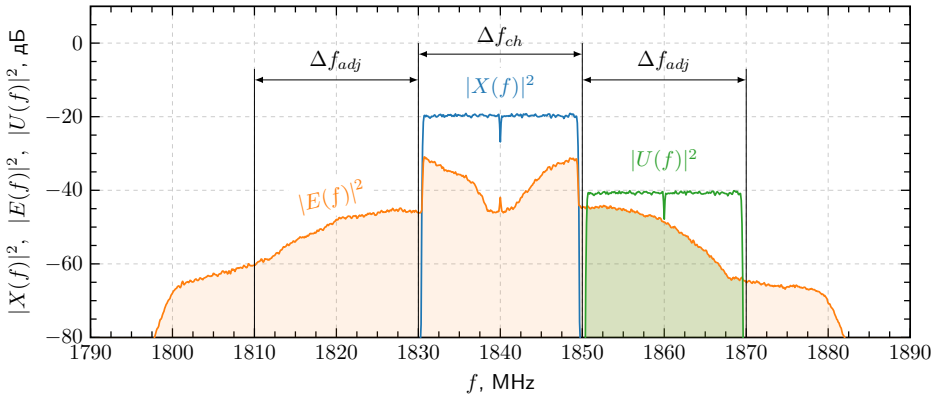
Δf_{adj}
Δf_{ch}
Δf_{adj}
$|X(f)|^2$
$|E(f)|^2$
$|U(f)|^2$
$|X(f)|^2,\ |E(f)|^2,\ |U(f)|^2$, дБ
f, MHz
0
−20
−40
−60
−80
1790
1800
1810
1820
1830
1840
1850
1860
1870
1880
1890

NMSE (normalized mean squared error) нормализованная среднеквадратическая ошибка:

$$\text{NMSE} = \frac{\mathrm{E}\left[|e(n)|^2\right]}{\mathrm{E}\left[|x(n)|^2\right]}; \qquad \text{NMSE} = \frac{\sum\limits_{n=0}^{N-1} |e(n)|^2}{\sum\limits_{n=0}^{N-1} |x(n)|^2} = \frac{\int\limits_{\Delta f} |E(f)|^2\, df}{\int\limits_{\Delta f} |X(f)|^2\, df}. \tag{11.33}$$

Выраженная в единицах дБ:

$$\text{NMSE} = 10\lg\left[\frac{\sum\limits_{n=0}^{N-1} |e(n)|^2}{\sum\limits_{n=0}^{N-1} |x(n)|^2}\right] = 10\lg\left[\frac{\int\limits_{\Delta f} |E(f)|^2\, df}{\int\limits_{\Delta f} |X(f)|^2\, df}\right], \quad \text{дБ} \tag{11.34}$$

Здесь Δf — полоса нисходящего (восходящего) каналов передачи.

ACPR (adjacent channel power ratio) относительный уровень излучения в соседнем канале:

$$\mathrm{ACPR} = \frac{\int\limits_{\Delta f_{adj}} |E(f)|^2 \, df}{\int\limits_{\Delta f_{ch}} |X(f)|^2 \, df}. \tag{11.35}$$

ACPR также принятно выражать в единицах дБ:

$$\mathrm{ACPR} = 10 \lg \left[\frac{\int\limits_{\Delta f_{adj}} |E(f)|^2 \, df}{\int\limits_{\Delta f_{ch}} |X(f)|^2 \, df} \right] \tag{11.36}$$

Пример влияния нелинейных искажений QAM256 на кривые битовой ошибки в канале АБГШ.

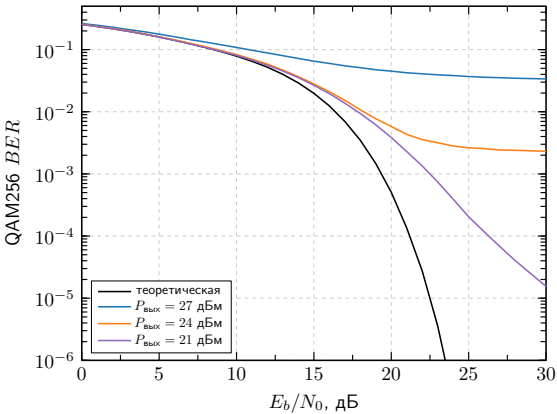

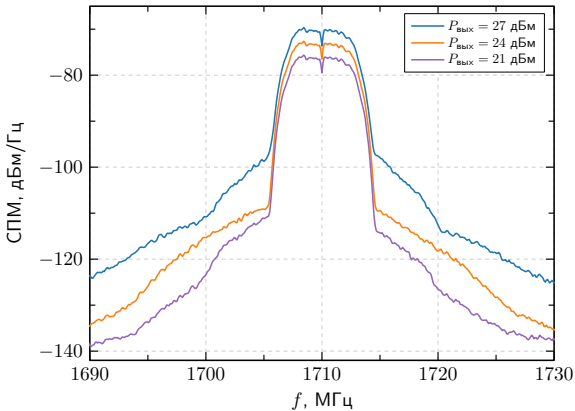

Нелинейные характеристики усилителя искажают созвездие, в результате вероятность битовой ошибки не уменьшается с ростом отношения сигнал–шум.

Влияние нелинейных искажений на сигнальное созвездие QAM256:

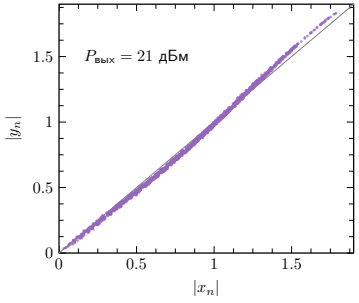

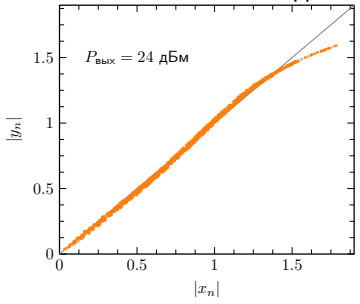

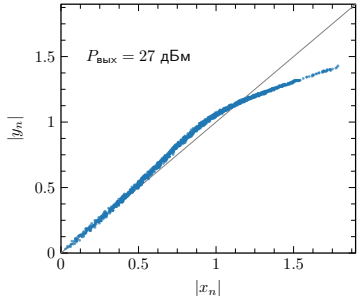

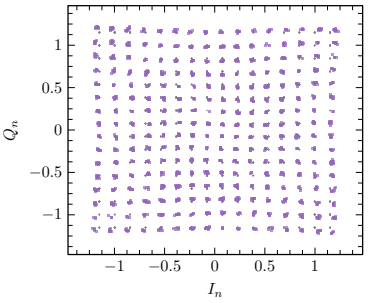

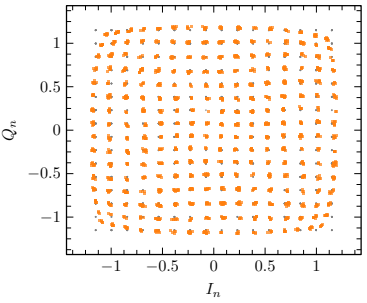

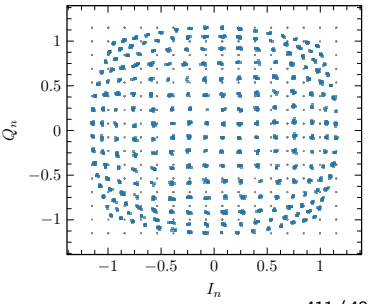

Лекция 12. Коррекция усилителя по схеме непрямого и прямого обучения

§12.1. Коррекция усилителя по схеме непрямого обучения

Нелинейный корректор и его адаптация по схеме непрямого обучения:

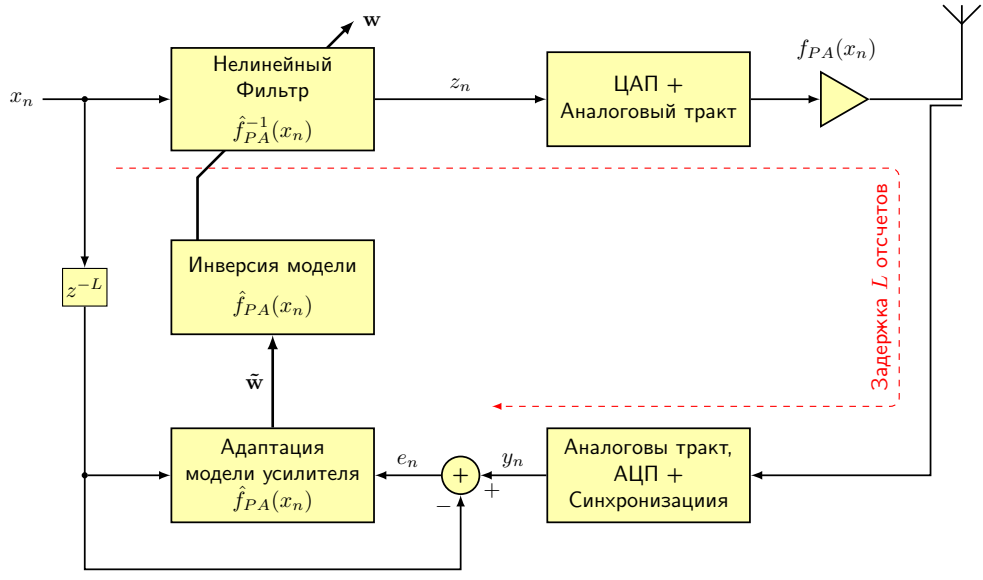

Пусть выходной усилитель мощности описывается нелинейной функцией $f_{PA}(x_n)$ относительно комплексной огибающей передаваемого сигнала x_n. Для коррекции мы должны построить нелинейный фильтр, который будет формировать инверсную функцию $f_{PA}^{-1}(x_n)$, тогда выход усилителя будет равен x_n без нелинейных искажений.

Для того чтобы построить инверсную модель мы оцениваем характеристику усилителя, путем захвата сигнала с его выхода, оцифровки о обработки в цепи обратной связи. Получаем сигнал на выходе усилителя y_n.

Модуль синхронизации производит выравнивание сигналов x_n и y_n по частоте, времени, амплитуде и фазе. После этого рассчитывается ошибка e_n, по которой производится адаптация параметров выбранной нелинейной модели усилителя $\hat{f}_{PA}(x_n)$. Элемент задержки z^{-L} компенсирует задержку распространения сигнала в цепи обратной связи для корректного расчета ошибки e_n.

Полученные в результате адаптации коэффициенты модели усилителя $\tilde{\mathbf{w}}$ передаются в модуль инверсии нелинейной модели, в которой производится пересчет данных коэффициентов в коэффициенты $\mathbf{w}$ инверсной модели $\hat{f}_{PA}^{-1}(x_n)$.

Для избежания инверсии модели можно использовать следующую структуру корректора с непрямым обучением:

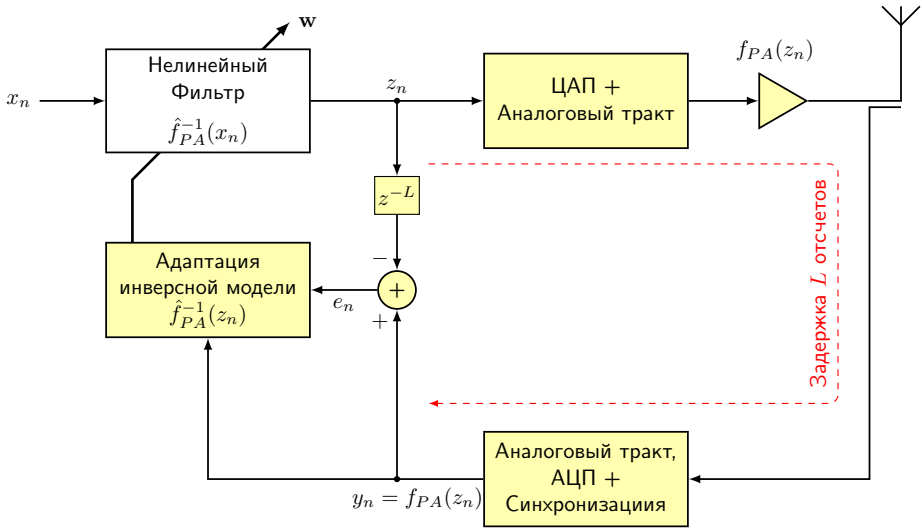

В данной схеме опорным сигналом служит сигнал выхода нелинейного фильтра z_n, который является входным сигналом усилителя. На выходе усилителя имеем сигнал $y_n = f_{PA}(z_n)$.

$$f_{PA}^{-1}(y_n) = f_{PA}^{-1}\big(f_{PA}(z_n)\big) = z_n. \tag{12.1}$$

Данный подход тоже сопряжен с рядом сложностей:

Во-первых, в процессе адаптации входной сигнал x_n напрямую не используется. "Это опасно тем, что нет возможности прямого контроля в процессе адаптации коэффициента передачи обратной функции $f_{PA}^{-1}(x_n)$. В этом случае наибольшую опасность представляет фаза коэффициента передачи нелинейного фильтра, поворот которой может привести к возникновению положительной обратной связи в следящем контуре.

Вторая проблема схемы с непрямым обучением заключается в том, что входным сигналом модуля адаптации является выход усилителя y_n, т.е. нелинейно искаженный сигнал z_n. В результате нелинейного искажения, форма y_n изменяется, и задача восстановления z_n может оказаться неразрешимой, например при нелинейном режиме работы усилителя в режиме насыщения.

Лекция 12. Коррекция усилителя по схеме непрямого и прямого обучения

§12.2. Аддитивная модель прямого обучения с извлечением ошибки

Пусть сигнал на выходе нелинейного корректора представляет собой $z_n = x_n - g(x_n)$, где $g(x)$ — нелинейная функция, которая идентифицирует ошибку $h(x)$, тогда структура аддитивного корректора с извлечением ошибки:

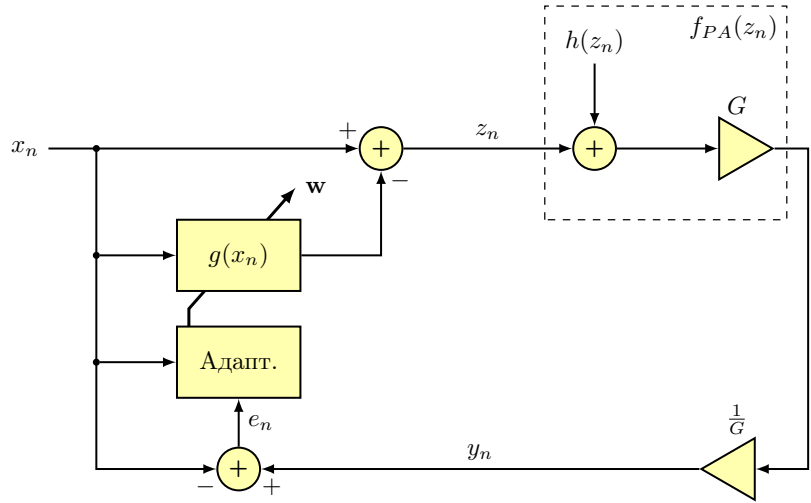

Выходной сигнал усилителя, приведенный к мощности входного сигнала равен:

$$y_n = f_{PA}(z_n)/G = x_n - g(x_n) + h\big(x_n - g(x_n)\big). \tag{12.2}$$

тогда мы можем получить сигнал ошибки:

$$e_n = y_n - x_n = h\big(x_n - g(x_n)\big) - g(x_n). \tag{12.3}$$

На начальной итерации, когда вектор коэффициентов $\mathbf{w} = \mathbf{0}$, $g(x_n) = 0$, сигнал на выходе корректора представляет собой исходный сигнал x_n, т.е. $z_n^{\{0\}} = x_n$. Тогда выход усилителя на начальной итерации равен $y_n^{\{0\}} = x_n - h(x_n)$ и ошибка возвращает все искажения усилителя $e_n^{\{0\}} = h(x_n)$. Здесь верхний индекс $^{\{0\}}$ обозначает номер итерации работы корректора.

Извлеченная ошибка на начальной итерации $e_n^{\{0\}}$ используется как опорный сигнал при построении функции $g(x)$ и предположим, мы имеет достаточную нелинейную модель для обеспечения равенства $g(x_n) = e_n^{\{0\}} = h(x_n)$, т.е. мы можем полностью описать все нелинейные эффекты усилителя. Тогда на первой итерации мы обновляем сигнал на выходе корректора

$$z_n^{\{1\}} = x_n - e_n^{\{0\}} = x_n - g(x_n) = x_n - h(x_n), \tag{12.4}$$

и получаем на выходе усилителя:

$$y_n^{\{1\}} = x_n - h(x_n) + h\big(x_n - h(x_n)\big). \tag{12.5}$$

Поскольку уровень мощности начальных искажений $h(x_n)$ существенно ниже мощности сигнала x_n, то

$$h\big(x_n - h(x_n)\big) \approx h(x_n) - h\big(h(x_n)\big) = h\big(x_n\big) + \mathcal{O}^{\{1\}}(x_n), \tag{12.6}$$

где $\mathcal{O}^{\{1\}}(x_n)$ — остаточный член после первой итерации коррекции, мощность которого ниже мощности исходных искажений.

Тогда сигнал на выходе усилителя после первой итерации коррекции равен

$$y_n^{\{1\}} = x_n - h(x_n) + h(x_n) + \mathcal{O}^{\{1\}}(x_n) = x_n + \mathcal{O}^{\{1\}}(x_n). \tag{12.7}$$

На второй итерации мы можем вновь извлечь остаточную ошибку $e_n^{\{1\}} = \mathcal{O}^{\{1\}}(x_n)$, тогда сигнал коррекции на второй итерации

$$z_n^{\{2\}} = x_n - e_n^{\{0\}} - e_n^{\{1\}} = x_n - h(x_n) - \mathcal{O}^{\{1\}}(x_n), \tag{12.8}$$

и сигнал на выходе усилителя на второй итерации равен:

$$\begin{aligned} y_n^{\{2\}} &= x_n - h(x_n) - \mathcal{O}^{\{1\}}(x_n) + h\big(x_n - h(x_n) - \mathcal{O}^{\{1\}}(x_n)\big) \approx \\ &\approx x_n - h(x_n) - \mathcal{O}^{\{1\}}(x_n) + \underbrace{h\big(x_n - h(x_n)\big)}_{h(x_n)+\mathcal{O}^{\{1\}}(x_n)} - \underbrace{h\big(\mathcal{O}^{\{1\}}(x_n)\big)}_{\mathcal{O}^{\{2\}}(x_n)} = x_n + \mathcal{O}^{\{2\}}(x_n), \end{aligned} \tag{12.9}$$

где $\mathcal{O}^{\{2\}}(x_n)$ — остаточный член, чья мощность имеет порядок малости ниже чем у $\mathcal{O}^{\{1\}}(x_n)$.

Таким образом, мы можем продолжить итеративно извлекать ошибку $e_n^{\{k\}}$ и сигнал корректора будет равен

$$z_n^{\{k+1\}} = x_n - \sum_{m=0}^{k} e_n^{\{m\}}, \tag{12.10}$$

а остаточная ошибка $e_n^{\{k+1\}}$ на следующей итерации будет иметь уровень мощности ниже предыдущей. В результате мы можем получить инверсную функцию $f_{PA}^{-1}(x)$ как

$$f_{PA}^{-1}(x_n) = x_n - g(x_n) = x_n - \sum_{m=0}^{k} e_n^{\{m\}}. \tag{12.11}$$

Лекция 12. Коррекция усилителя по схеме непрямого и прямого обучения

§12.3. Пример коррекции нелинейного устройства аддитивной моделью прямого обучения

Пусть нелинейная функция $f_{PA}(x)$, которую необходимо инвертировать для компенсации искажений при прохождении сигнала равна $f_{PA}(x) = x + 0.1x^2$. Диапазон амплитуд входного сигнала $|x_n| \leq 1$.

На начальной итерации, через усилитель проходит чистый сигнал $z_n^{\{0\}} = x_n$. Тогда при прохождении сигнала $z_n^{\{0\}} = x_n$ через нелинейный усилитель, сигнал на выходе будет равен:

$$y_n^{\{0\}} = f_{PA}(z_n^{\{0\}}) = x_n + 0.1x_n^2. \tag{12.12}$$

Извлечем ошибку $e_n^{\{0\}}$ на начальной итерации:

$$e_n^{\{0\}} = y_n^{\{0\}} - x_n = 0.1x_n^2. \tag{12.13}$$

На первой итерации произведем идентификацию ошибки, получим сигнал на выходе корректора вида

$$z_n^{\{1\}} = x_n - e_n^{\{0\}} = x_n - 0.1x_n^2, \tag{12.14}$$

т.е. мы вычитаем идентифицированную ошибку из входного сигнала.

Выход усилителя после первой итерации коррекции равен:

$$y_n^{\{1\}} = f_{PA}(z_n^{\{1\}}) = x_n - 0.1x_n^2 + 0.1(x_n - 0.1x_n^2)^2 = x_n - 0.1x^2 + \\ + 0.1(x_n^2 - 0.2x_n^3 + 0.01x_n^4) = x_n \underbrace{-0.02x_n^3 + 10^{-3}x_n^4}_{\mathcal{O}^{\{1\}}(x_n)}. \quad (12.15)$$

Можно видеть, что выход корректора имеет значительно меньший уровень остаточной ошибки $\mathcal{O}^{\{1\}}(x_n)$ после первой итерации.
На второй итерации вновь извлекаем остаточную ошибку

$$e_n^{\{1\}} = \mathcal{O}^{\{1\}}(x_n) = y_n^{\{1\}} - x_n = -0.02x_n^3 + 10^{-3}x_n^4. \quad (12.16)$$

Можно видеть, что квадратичный член был скомпенсирован, коэффициент при третей степени стал 0.02, при этом $|x_n| < 1$, что означает значительное уменьшение мощности ошибки.
Произведя идентификацию ошибки, на второй итерации, сигнал коррекции равен:

$$z_n^{\{2\}} = x_n - e^{\{0\}} - e^{\{1\}} = x_n - 0.1x_n^2 + 0.02x_n^3 - 10^{-3}x_n^4. \quad (12.17)$$

Тогда выход нелинейного усилителя после второй итерации равен:

$$y_n^{\{2\}} = f_{PA}(z_n^{\{2\}}) = x_n - 0.1x_n^2 + 0.02x_n^3 - 10^{-3}x_n^4 + \\ + 0.1(x_n - 0.1x_n^2 + 0.02x_n^3 - 10^{-3}x_n^4)^2 = \\ = x_n + \underbrace{4 \cdot 10^{-4}x_n^4 - 6 \cdot 10^{-4}x_n^5 + 6 \cdot 10^{-6}x_n^6 - 4 \cdot 10^{-6}x_n^7 + 10^{-7}x_n^8}_{\mathcal{O}^{\{2\}}(x_n)}. \quad (12.18)$$

Видим, что степень остаточного члена $\mathcal{O}^{\{2\}}(x_n)$ увеличилась до четырех, что приводит к уменьшению мощности остаточной ошибки, т.к. $|x_n| < 1$. Кроме того максимальный коэффициент уменьшается еще на порядок и теперь равен $4 \cdot 10^{-4}$.
Идентифицируя на каждой следующей итерации остаточную ошибку на выходе нелинейного элемента можно записать для итерации k:

$$z_n^{\{k+1\}} = x_n - \sum_{m=0}^{k} e_n^{\{m\}} \approx f_{PA}^{-1}(x_n). \quad (12.19)$$

Заметим, что сумма остаточных ошибок представляет собой полином, ограничив степень данного полинома можно представить на итерации k:

$$z_n^{\{k+1\}} = x_n - \sum_{p=0}^{P} w_p x_n^p \approx f_{PA}^{-1}(x_n), \tag{12.20}$$

где коэффициенты w_p можно рассчитывать путем минимизации ошибки выхода нелинейного элемента на итерации k и входного сигнала x_n.
Таким образом, мы получили аддитивную модель линеаризации $f_{PA}(x)$, основанную на прямом обучении коэффициентов полинома, который в свою очередь аппроксимирует обратную функцию $f_{PA}^{-1}(x)$ нелинейного усилителя.

Структура аддитивной модели с прямым обучением:

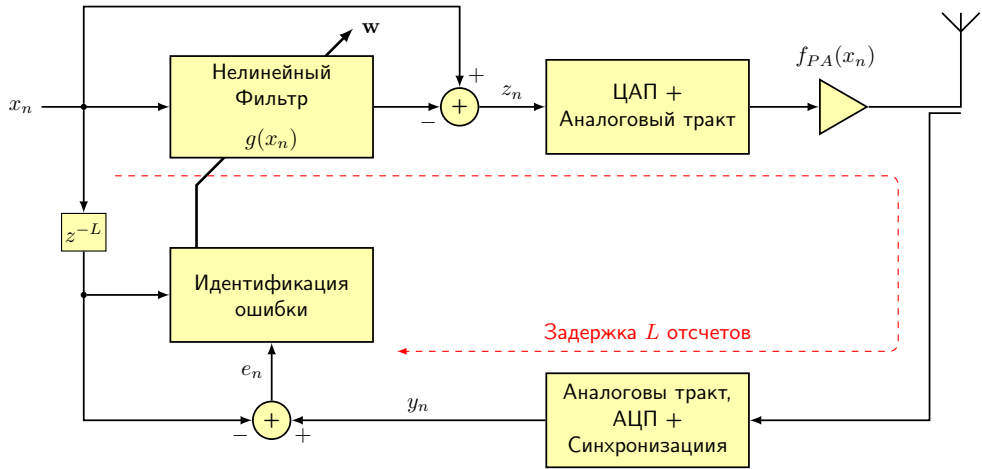

Лекция 13. Нелинейные модели искажений усилителей мощности

§13.1. Ряд Вольтерра

Пусть x_n и y_n отсчеты вещественного сигнала на входе и выходе нелинейного элемента, n — дискретное время. Тогда сигнал y_n можно представить в виде ряда:

$$y_n = \underbrace{\sum_{m=0}^{M} w_{1,m} x_{n-m}}_{\text{линейная часть}} + \underbrace{\sum_{m_0,\, m_1=0}^{M} \sum w_{2,m_0,m_1} x_{n-m_0} x_{n-m_1}}_{\text{квадратичная часть}} +$$

$$+ \underbrace{\sum_{m_0,\, m_1,\, m_2=0}^{M} \sum \sum w_{3,m_0,m_1,m_2} x_{n-m_0} x_{n-m_1} x_{n-m_2}}_{\text{кубическая часть}} +$$

$$+ \ldots + \underbrace{\sum_{m_0 \ldots m_{P-1}=0}^{M} \cdots \sum w_{P,m_0,\ldots m_{P-1}} \prod_{q=0}^{P-1} x_{n-m_q}}_{\text{нелинейность степени P}} . \quad (13.1)$$

Здесь M – определяет память нелинейного элемента, P — порядок нелинейности.

Для того чтобы получить квадратичную составляющую, необходимо сложить все M^2 произведений $x_{n-m_0}x_{n-m_1}$ с коэффициентами w_{2,m_0,m_1}. Таким образом, квадратичный член ряда описывается двойной суммой по m_0 и m_1.

Для получения члена третьей степени необходимо сложить все возможные произведения задержанных отсчетов $x_{n-m_0}x_{n-m_1}x_{n-m_2}$ с соответствующими коэффициентами w_{3,m_0,m_1,m_2}. В результате для кубического члена требуется тройная вложенная сумма. Продолжая построение ряда до порядка P получим слагаемые со все большим числом вложенных сумм и коэффициентов.

Число коэффициентов ряда растет экспоненциально с увеличением порядка нелинейности P и памяти модели M. Так при порядке нелинейности $P = 7$ и памяти $M = 5$ для линейного фильтра требуется 5 коэффициентов, для квадратичного — 25, а для нелинейности степени 7 необходимо $M^P = 78125$ коэффициентов. Всего же такая модель потребует 98655 коэффициентов. Если же увеличить память на единицу до $M = 6$, то модель уже будет требовать 335922 коэффициента!

Таким образом прямое использование ряда Вольтерра возможно лишь при малых порядках нелинейности и памяти модели.

Для задач описания усилителя мощности в системах связи мы можем исключить из ряда Вольтерра все нелинейные компоненты четной степени, поскольку они формируют гармоники на кратных частотах, подавляемые дуплексером. Таким образом ряд будет содержать только нечетные степени от 1 до $P = 2Q + 1$:

$$y_n = \underbrace{\sum_{m=0}^{M} w_{1,m} x_{n-m}}_{\text{линейная часть}} + \underbrace{\sum_{m_0,\, m_1,\, m_2=0}^{M} \sum\sum w_{3,m_0,m_1,m_2} x_{n-m_0} x_{n-m_1} x_{n-m_2}}_{\text{кубическая часть}} +$$

$$+ \underbrace{\sum_{m_0 \ldots m_4=0}^{M} \sum\sum\sum\sum\sum w_{5,m_0,\ldots m_4} x_{n-m_0} x_{n-m_1} x_{n-m_2} x_{n-m_3} x_{n-m_4}}_{\text{нелинейность степени 5}} +$$

$$+ \ldots + \underbrace{\sum_{m_0 \ldots m_{P-1}=0}^{M} \cdots \sum w_{P,m_0,\ldots m_{P-1}} \prod_{q=0}^{P-1} x_{n-m_q}}_{\text{нелинейность нечетной степени } P=2Q+1}. \quad (13.2)$$

Если построение моделей ведется на нулевой промежуточной частоте для комплексных огибающих сигналов x_n и y_n на входе и выходе усилителя, то ряд Вольтерра содержащий только нечетные степени от 1 до $P = 2Q + 1$ имеет вид:

$$y_n = \underbrace{\sum_{m=0}^{M} w_{1,m} x_{n-m}}_{\text{линейная часть}} + \underbrace{\sum_{m_0,\, m_1,\, m_2=0}^{M} \sum \sum w_{3,m_0,m_1,m_2} x_{n-m_0} x_{n-m_1} x^*_{n-m_2}}_{\text{кубическая часть}} +$$

$$+ \underbrace{\sum_{m_0 \ldots m_4=0}^{M} \sum \sum \sum \sum w_{5,m_0,\ldots m_4} x_{n-m_0} x_{n-m_1} x_{n-m_2} x^*_{n-m_3} x^*_{n-m_4}}_{\text{нелинейность степени 5}} +$$

$$+ \ldots + \underbrace{\sum_{m_0 \ldots m_{P-1}=0}^{M} \cdots \sum w_{P,m_0,\ldots m_{P-1}} \prod_{q=0}^{Q} x_{n-m_q} \prod_{r=Q+1}^{P-1} x^*_{n-m_r}}_{\text{нелинейность нечетной степени } P=2Q+1}. \quad (13.3)$$

Лекция 13. Нелинейные модели искажений усилителей мощности

§13.2. Полиномиальная модель без памяти

Зададим в ряде Вольтерра $M = 0$, в результате чего все вложенные суммы в уравнении (13.3) будут состоять из одного слагаемого, и получим модель для нечетного порядка нелинейности $P = 2Q + 1$ вида:

$$y_n = w_{1,0}x_n + w_{3,0,0,0}x_n x_n x_n^* + \\ + w_{5,0,\ldots 0}x_n x_n x_n x_n^* x_n^* + \ldots + w_{P,0,\ldots 0}\prod_{q=0}^{Q} x_n \prod_{r=Q+1}^{P-1} x_n^*. \quad (13.4)$$

Опустим нули в индексации коэффициентов, а также учтем, что $x_n x_n^* = |x_n|^2$, тогда

$$y_n = w_1 x_n + \underbrace{w_3 x_n |x_n|^2 + w_5 x_n |x_n|^4 + \ldots + w_P x_n |x_n|^{P-1}}_{Q \text{ слагаемых}}. \quad (13.5)$$

Объединив все слагаемые в сумму можно записать полиномиальную модель без памяти

$$y_n = \sum_{q=0}^{Q} w_{2q+1} x_n |x_n|^{2q}, \quad (13.6)$$

Для простоты записи мы можем переиндексировать коэффициенты ω_{2q+1} относительно переменной q как w_q, тогда

$$y_n = \sum_{q=0}^{Q} w_q x_n |x_n|^{2q}, \tag{13.7}$$

где w_0 соответствует компоненту x_n, w_1 соответствует нелинейности третьей степени $x_n|x_n|^2$ и т.д. Тогда уравнение (13.7) можно записать как результат скалярного произведения двух векторов:

$$y_n = \sum_{q=0}^{Q} w_q x_n |x_n|^{2q} = \mathbf{u}_n^T \mathbf{w}, \tag{13.8}$$

где $\mathbf{u}_n$ — вектор состояния модели без памяти в момент времени n:

$$\mathbf{u}_n = \begin{bmatrix} x_n & x_n|x_n|^2 & x_n|x_n|^4 & \dots & x_n|x_n|^{2Q} \end{bmatrix}^T, \tag{13.9}$$

где $\mathbf{w}$ — вектор коэффициентов нелинейной модели.

Заметим, что выход полиномиальной модели без памяти линейно зависит от вектора коэффициентов согласно (13.8), это означает, что мы можем использовать для расчета оптимального вектора коэффициентов нелинейной полиномиальной модели без память алгоритмы, который ранее были рассмотрены для адаптации линейных фильтров.
Если имеется блок данных на входе модели, записанных в память в виде вектора $\mathbf{x} \in \mathbb{C}^N$ размерности N отсчетов, то объединяя в матрицу состояния векторы строки $\mathbf{u}_n^T$, $n = 0 \dots N-1$ получим вектор на выходе модели $\mathbf{y} = \mathbf{U}\mathbf{w}$, где

$$\mathbf{U} = \begin{bmatrix} x_0 & x_0|x_0|^2 & x_0|x_0|^4 & \dots & x_0|x_0|^{2Q} \\ x_1 & x_1|x_1|^2 & x_1|x_1|^4 & \dots & x_1|x_1|^{2Q} \\ x_2 & x_2|x_2|^2 & x_2|x_2|^4 & \dots & x_2|x_2|^{2Q} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{N-1} & x_{N-1}|x_{N-1}|^2 & x_{N-1}|x_{N-1}|^4 & \dots & x_{N-1}|x_{N-1}|^{2Q} \end{bmatrix}. \tag{13.10}$$

Коррекцию нелинейного усилителя можно вести итеративно с использованием аддитивной модели по схеме прямого обучения. Это значит, что нам необходимо итеративно получать выборки сигналов на входе $\mathbf{x}_k$ и выходе $\mathbf{y}_k$ усилителя, выровненные по времени, частоте, амплитуде и фазе. Здесь индекс k задает номер итерации, векторы $\mathbf{x}_k$ и $\mathbf{y}_k$ являются комплексными размерности N отсчетов каждый.
По имеющимся выборкам необходимо произвести идентификацию искажений на каждой итерации, после чего обновить коэффициентов модели $\mathbf{w}_k$

$$\mathbf{w}_k = \mathbf{w}_{k-1} + \Delta\mathbf{w}_k, \tag{13.11}$$

где $\Delta\mathbf{w}_k$ вектор коэффициентов, который описывает модель остаточных искажений на текущей итерации.
Таким образом на каждой итерации k, вектор искажений (вектор ошибки) на выходе усилителя представляет собой опорный сигнал $\mathbf{e}_k = \mathbf{d}_k = \mathbf{y}_k - \mathbf{x}_k$. Выход нелинейного фильтра $\mathbf{g}_k$ должен описывать вектор искажений $\mathbf{d}_k$ по критерию минимума среднего квадрата ошибки. Тогда для адаптации модели необходимо на каждой итерации минимизировать функцию:

$$J(\Delta\mathbf{w}_k) = (\mathbf{d}_k - \mathbf{g}_k)^H(\mathbf{d}_k - \mathbf{g}_k) \to \min_{\Delta\mathbf{w}_k}, \quad \mathbf{g}_k = \mathbf{U}_k\Delta\mathbf{w}_k, \tag{13.12}$$

Заметим, что на каждой итерации мы пытаемся найти такие коэффициенты $\Delta\mathbf{w}_k$, использование которых оптимально описывает текущую остаточную ошибку $\mathbf{e}_k = \mathbf{d}_k = \mathbf{y}_k - \mathbf{x}_k$. Накопление коэффициентов на каждой итерации обеспечивает сходимость всего корректора.
Таким образом, на каждой итерации мы должны минимизировать квадратичную функцию вида:

$$J(\Delta\mathbf{w}_k) = (\mathbf{d}_k - \mathbf{U}_k\Delta\mathbf{w}_k)^H(\mathbf{d}_k - \mathbf{U}_k\Delta\mathbf{w}_k) \to \min_{\Delta\mathbf{w}_k}. \tag{13.13}$$

Для минимизации квадратичной функции можно использовать как методы первого, так и второго порядка. При использовании методов второго порядка минимум достигается за один шаг методом LS оценки по ограниченному блоку данных:

$$\Delta\mathbf{w}_k = \left(\mathbf{U}_k^H\mathbf{U}_k\right)^{-1}\mathbf{U}_k^H\mathbf{d}_k. \tag{13.14}$$

Процесс сходимости модуля нелинейной коррекции усилителя на основе полиномиальной модели без памяти:

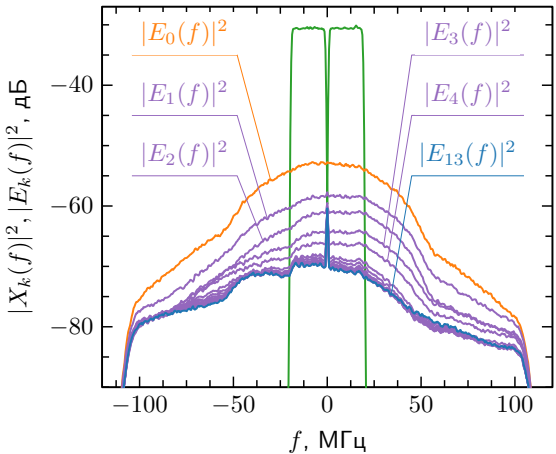

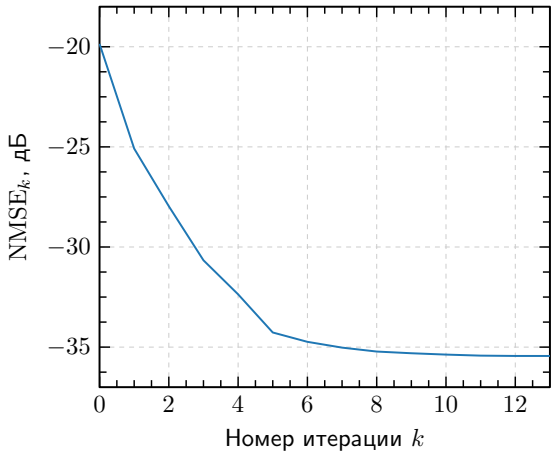

AM–AM и AM–PM характеристики до и после компенсации нелинейным корректором без памяти:

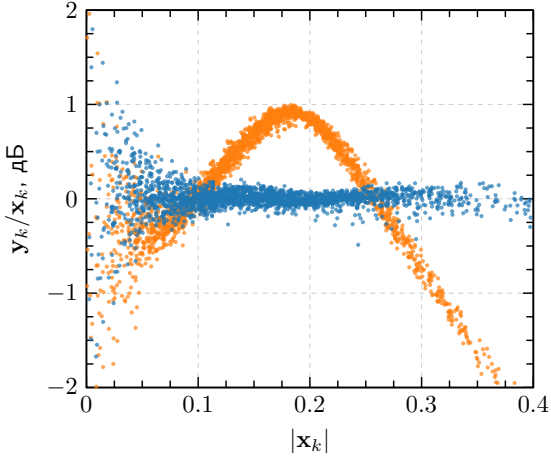

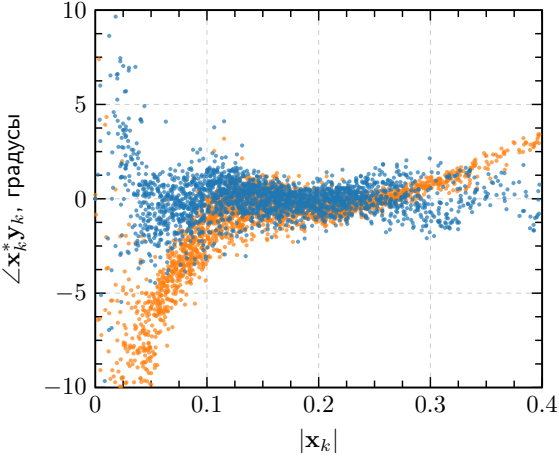

Лекция 13. Нелинейные модели искажений усилителей мощности

§13.3. Полиномиальная модель с памятью

Выход нелинейного корректора y_n согласно (13.7) зависит только от мгновенного значения сигнала и его амплитуды в момент времени n. Для учета инерционности усилителя необходимо добавить зависимость выхода модели от моментов времени отличных от n.

Линейный КИХ-фильтр обладает памятью так как использует задержанные отсчеты входного сигнала. Выход фильтра представляет собой сумму произведений задержанных отсчетов на коэффициенты. Выход нелинейной полиномиальной модели с памятью в этом случае может быть представлен суммой выходов полиномиальных моделей с разными задержками:

$$y_n = \sum_{m=0}^{M} x_{n-m} \underbrace{\sum_{q=0}^{Q} w_{m,q} |x_{n-m}|^{2q}}_{P_m\left(|x_{n-m}|\right)} = \sum_{m=0}^{M} x_{n-m} P_m\big(|x_{n-m}|\big). \tag{13.15}$$

КИХ-фильтр

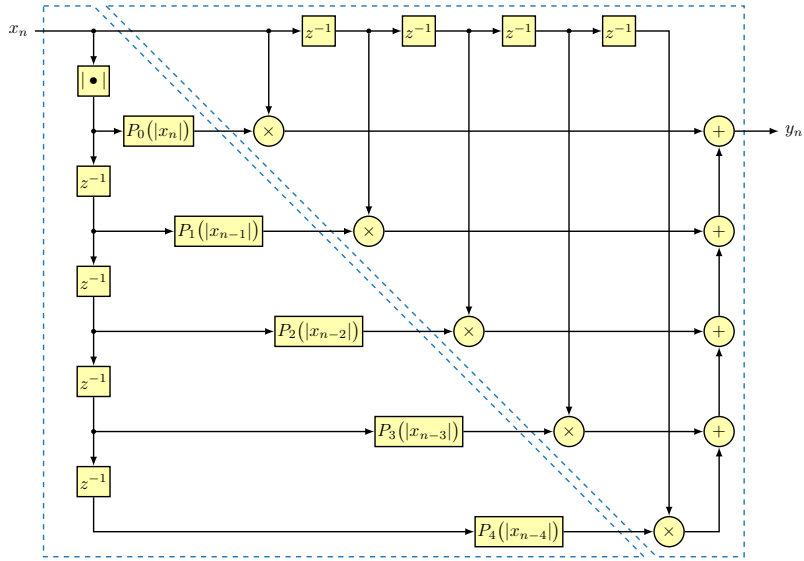

Нелинейные коэффициенты КИХ-фильтра

По сути полиномиальная модель с памятью представляет собой КИХ-фильтр, коэффициенты которого есть полиномы $P_m\big(|x_{n-m}|\big)|$ зависящие от модуля задержанных отсчетов входного сигнала x_{n-m}.

Выход полиномиальной модели можно записать в терминах вектора состояния фильтра $y_n = \mathbf{u}_n^T \mathbf{w}$, где $\mathbf{u}_n \in \mathbb{C}^{(M+1)(Q+1)}$ — вектор состояния модели, хранящий все полиномиальные компоненты модели в момент времени n, а $\mathbf{w} \in \mathbb{C}^{(M+1)(Q+1)}$ — вектор коэффициентов содержащий $w_{m,q}$ для всех $m = 0 \dots M$ и $q = 0 \dots Q$. Таким образом размерность векторов $\mathbf{u}_n$ и $\mathbf{w}$ равна $(M+1)(Q+1)$.

Для того чтобы получить выражения элементов векторов $\mathbf{u}_n[i]$ и $\mathbf{w}[i]$, где $i = 0 \dots (M+1)(Q+1) - 1$, перепишем выражение выхода модели (13.15) к виду:

$$y_n = \sum_{m=0}^{M} \sum_{q=0}^{Q} w_{m,q} x_{n-m} |x_{n-m}|^{2q}. \tag{13.16}$$

Тогда для любого значения $i = m(Q+1) + q$, где $m = 0 \dots M$, $q = 0 \dots Q$:

$$\mathbf{u}_n[i] = x_{n-m} |x_{n-m}|^{2q}, \qquad \mathbf{w}[i] = w_{m,q}. \tag{13.17}$$

Например при $M = 4$ и $Q = 5$ коэффициент $\mathbf{w}[0]$ с индексом $i = 0$ соответствует состоянию

$$\mathbf{u}_n[0] = x_n|x_n|^0 = x_n, \tag{13.18}$$

а коэффициент $\mathbf{w}[1]$ соответствует $m = 0$ и $q = 1$, тогда

$$\mathbf{u}_n[1] = x_n|x_n|^2. \tag{13.19}$$

Коэффициент $\mathbf{w}[22]$ получается при $m = 3$, $q = 4$ и соответствует состоянию

$$\mathbf{u}_n[23] = x_{n-3}|x_{n-3}|^8. \tag{13.20}$$

Последний коэффициент будет $\mathbf{w}[29]$, при $m = 4$ и $q = 5$, тогда соответствующее состояние

$$\mathbf{u}_n[29] = x_{n-4}|x_{n-4}|^{10}. \tag{13.21}$$

Таким образом мы можем заполнить вектор состояния $\mathbf{u}_n$ в момент времени n для всех индексов $i = 0 \dots 29$.

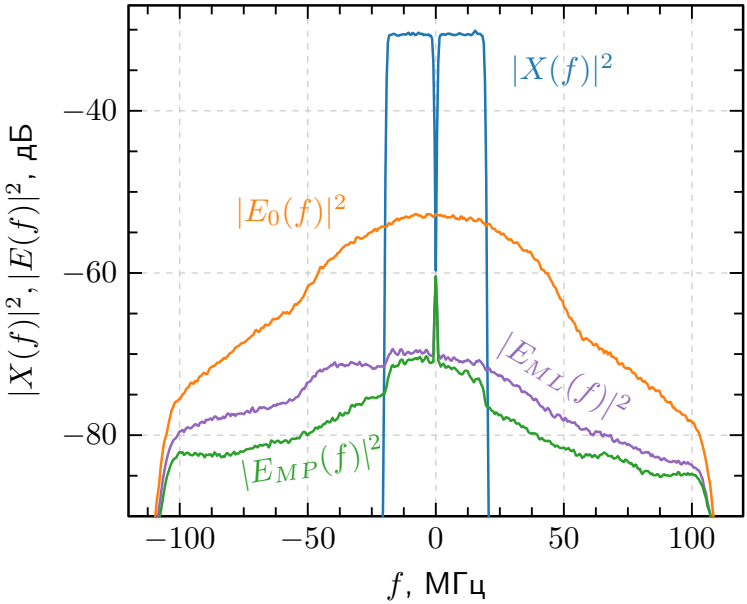
$|X(f)|^2$
$|E_0(f)|^2$
$|E_{MP}(f)|^2$
$|E_{ML}(f)|^2$
−40
−60
−80
−100
−50
0
50
100
$|X(f)|^2, |E(f)|^2$, дБ
f, МГц

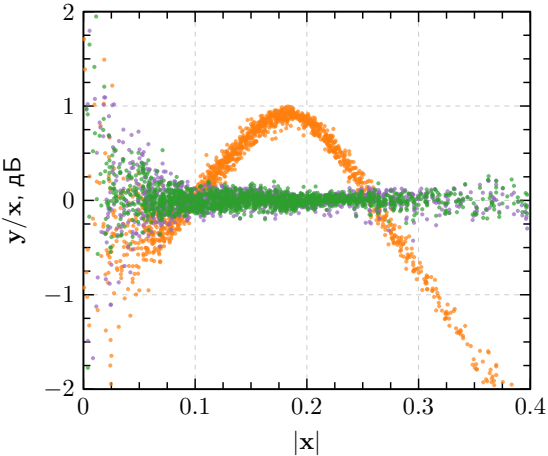
y/x, дБ
2
1
0
−1
−2
0
0.1
0.2
0.3
0.4
|x|

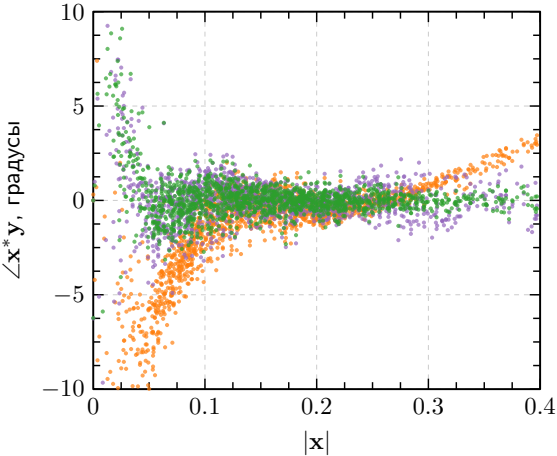
∠x*y, градусы
10
5
0
−5
−10
0
0.1
0.2
0.3
0.4
|x|

§13.4. Обобщенная полиномиальная модель (GMP)

Полиномиальная модель с памятью использует одинаковые значения задержек сигнала и полинома от модуля. Следующий шаг обобщения модели заключается во введении независимых задержек при произведении отсчетов сигнала и полинома от модуля:

$$y_n = \sum_{v=0}^{M} \sum_{m=0}^{M} x_{n-m} \underbrace{\sum_{q=0}^{Q} w_{v,m,q} |x_{n-v}|^{2q}}_{P_{v,m}\left(|x_{n-v}|\right)} = \sum_{v=0}^{M} \sum_{m=0}^{M} x_{n-m} P_{v,m}\left(|x_{n-v}|\right). \tag{13.22}$$

Здесь m и v индексируют задержки входного сигнала x_{n-m} и его модуля $|x_{n-v}|$ независимо друг от друга. В результате получаем обобщенную структуру (для $M = 2$).

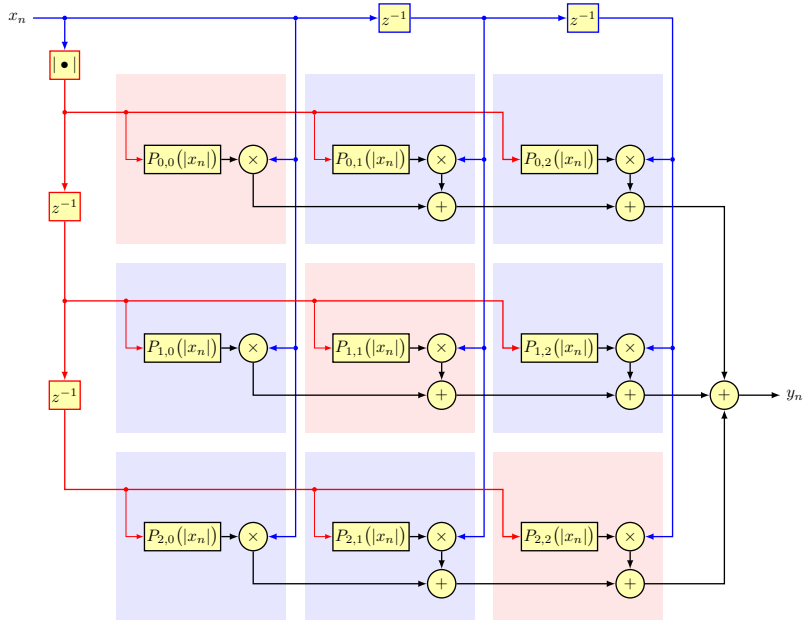
x_n
z^{-1}
z^{-1}
$|\bullet|$
z^{-1}
z^{-1}
$P_{0,0}(|x_n|)$
$P_{0,1}(|x_n|)$
$P_{0,2}(|x_n|)$
$P_{1,0}(|x_n|)$
$P_{1,1}(|x_n|)$
$P_{1,2}(|x_n|)$
$P_{2,0}(|x_n|)$
$P_{2,1}(|x_n|)$
$P_{2,2}(|x_n|)$
y_n

В результате каждый отвод сигнала перемножается с полиномом от каждого задержанного модуля, и все произведения складываются на выходе. Таким образом для GMP-модели требуется рассчитать $(M+1)^2$ полиномов, каждый из которых содержит $Q+1$ коэффициент. Итого получаем $(M+1)^2(Q+1)$ коэффициентов, которые требуется найти в процессе адаптации.

Каждый выделенный квадрат структуры содержит произведение полинома от задержанного модуля сигнала на задержанный отсчет сигнала и называется полиномиальным термом.

Заметим, что MP-модель является частью GMP-модели. На рисунке полиномиальные термы выделенные розовыми прямоугольниками отмечают произведения MP-модели, которые расположены на диагонали структурной схемы. Соответственно внедиагональные произведения являются расширением полиномиальной модели с памятью MP-модели до обобщенной GMP-модели.

Ранее рассматривался вопрос выравнивания временны́х задержек в линейном адаптивном фильтре. Мы говорили о том, что введение центра модели позволяет задать задержку сигнала на выходе фильтра и раскрыть противоречие зависимости задержки адаптивного фильтра от коэффициентов.

Аналогичная проблема существует и для полиномиальных нелинейных моделей с памятью, поскольку они представляют собой КИХ фильтр, коэффициенты которого нелинейно зависят от модуля входного сигнала. Кроме того GMP модель представляет собой сумму нелинейных термов с различными задержками сигнала и его амплитуды, в том числе и внедиагональных.

В этом случае мы по аналогии с КИХ фильтром можем ввести понятие центра нелинейной полиномиальной модели с памятью и задать центральный отвод сигнала и амплитуды на структуре модели.

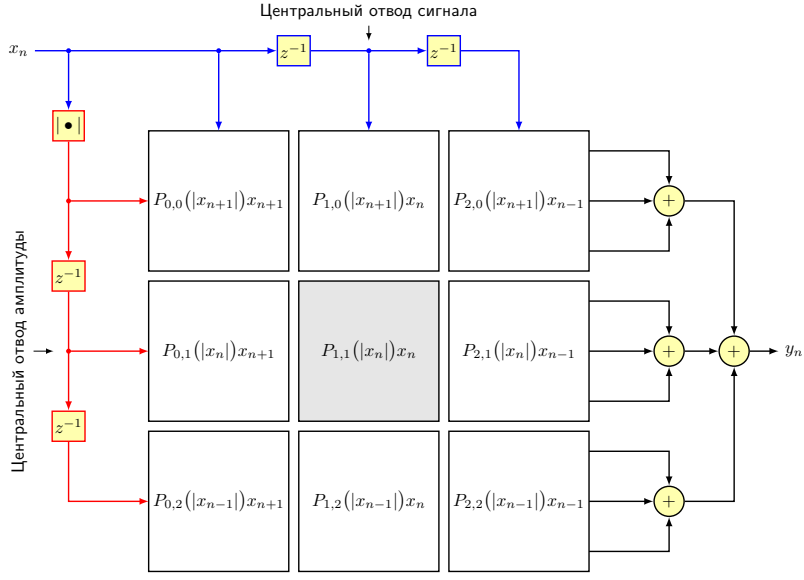
Центральный отвод сигнала
x_n
z^{-1}
z^{-1}
$|\bullet|$
Центральный отвод амплитуды
z^{-1}
z^{-1}
$P_{0,0}(|x_{n+1}|)x_{n+1}$
$P_{1,0}(|x_{n+1}|)x_n$
$P_{2,0}(|x_{n+1}|)x_{n-1}$
$P_{0,1}(|x_n|)x_{n+1}$
$P_{1,1}(|x_n|)x_n$
$P_{2,1}(|x_n|)x_{n-1}$
$P_{0,2}(|x_{n-1}|)x_{n+1}$
$P_{1,2}(|x_{n-1}|)x_n$
$P_{2,2}(|x_{n-1}|)x_{n-1}$
+
+
+
+
y_n

На приведенной схеме имеется по три отвода сигнала и амплитуды и в общей сложности 9 нелинейных термов. Центр модели задается двумя центральными отводами и серый прямоугольник показывает центральный полиномиальный терм, соответствующий сигналу x_n и его амплитуде $|x_n|$ без задержки[10].
Уравнение (13.22) GMP модели можно переписать относительно центра как:

$$y_n = \sum_{v=-D}^{D} \sum_{m=-D}^{D} x_{n-m} \underbrace{\sum_{q=0}^{Q} w_{v,m,q} |x_{n-v}|^{2q}}_{P_{v+D,m+D}\left(|x_{n-v}|\right)} = \\ = \sum_{v=-D}^{D} \sum_{m=-D}^{D} x_{n-m} P_{v+D,m+D}\left(|x_{n-v}|\right), \quad (13.23)$$

где D — заданная задержка. Центральный отвод соответствует номеру D требует D отсчетов «из будущего», а выход модели будет иметь нулевую задержку относительно входа.

[10] На практике задержка будет, но в данном случае мы точно знаем, что она будет равна $D = 1$, т.к. мы задали центральный отвод сигнала и амплитуды из трех

§13.5. Сокращение ресурсов обобщенной полиномиальной модели

Количество коэффициентов модели растет квадратично относительно памяти D.

Встает задача сокращения ресурсов GMP модели для применения в аппаратуре связи путем выбора наиболее важных полиномиальных термов GMP модели. Такое сокращение возможно по причине высокой корреляции выходов индивидуальных термов модели. Мы можем обнулить некоторые термы без существенного ухудшения качества работы нелинейного фильтра, тем самым сократить требуемое число коэффициентов, а также аппаратных ресурсов при реализации фильтра.

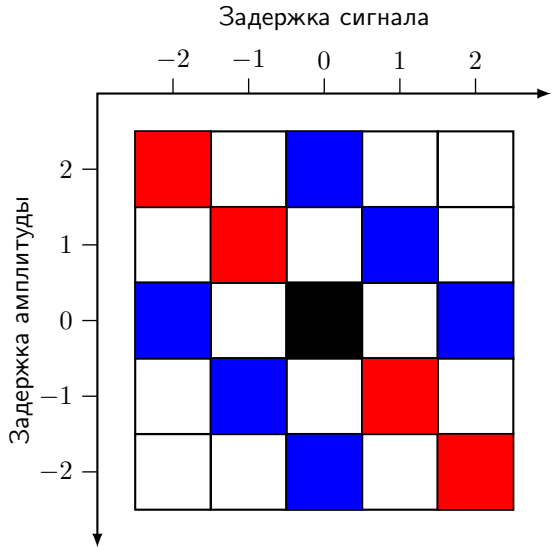

§13.6. Аппаратный расчет полинома. Схема Горнера

Рассмотрим полином:

$$P_N(t) = a_N t^N + \ldots + a_2 t^2 + a_1 t + a_0. \tag{13.24}$$

Вынесем t за скобки, получим:

$$P_N(t) = t\left(a_N t^N + \ldots + a_2 t + a_1\right) + a_0. \tag{13.25}$$

Снова вынесем t за скобки, получим:

$$P_N(t) = t\left(t\left(a_N t^N + \ldots + a_2\right) + a_1\right) + a_0. \tag{13.26}$$

Таким образом, вынося t за скобки возможное число раз, получим множество вложенных скобок:

$$P_N(t) = t\left(t\left(\ldots t\left(t a_N + a_{N-1}\right)\ldots + a_2\right) + a_1\right) + a_0. \tag{13.27}$$

Для полинома $N = 3$ порядка:

$$P_3(t) = t\left(t\left(ta_3 + a_2\right) + a_1\right) + a_0 \tag{13.28}$$

Структурная схема имеет вид:

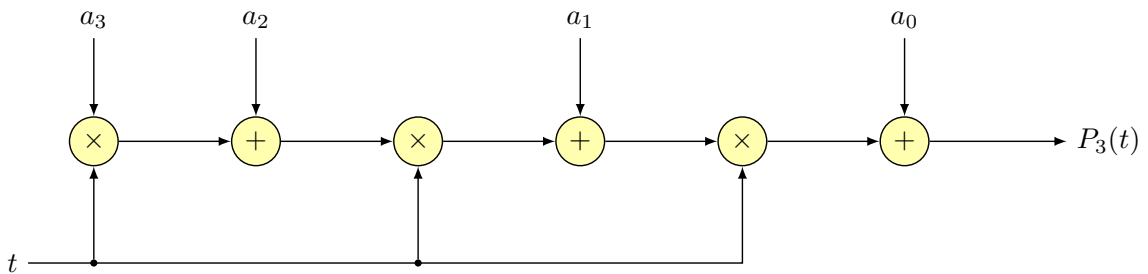

Число умножений равно порядку полинома.

Лекция 14. Модели нелинейно зависящие от коэффициентов. Модель Гаммерштейна

§14.1. Структура модели Гаммерштейна

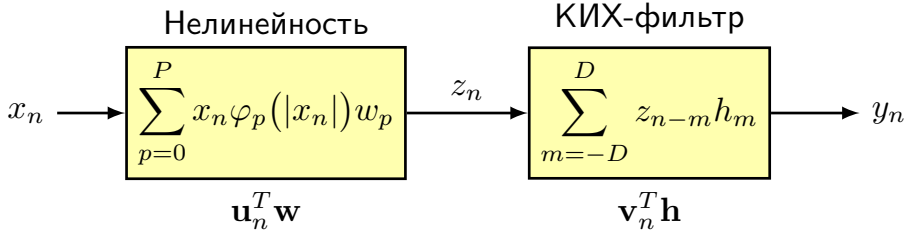

$$z_n = \mathbf{u}_n^T \mathbf{w} = \sum_{p=0}^{P} x_n \varphi_p\big(|x_n|\big) w_p, \quad \mathbf{w} \in \mathbb{C}^{P+1} \tag{14.1}$$

$$y_n = \mathbf{v}_n^T \mathbf{h} = \sum_{m=-D}^{D} z_{n-m} h_m, \quad \mathbf{h} \in \mathbb{C}^{2D+1} \tag{14.2}$$

$$y_n = \sum_{m=-D}^{D} h_m \sum_{p=0}^{P} x_{n-m} \varphi_p\big(|x_{n-m}|\big) w_p \tag{14.3}$$

Лекция 14. Модели нелинейно зависящие от коэффициентов. Модель Гаммерштейна

§14.2. Адаптация модели Гаммерштейна методом стохастического градиентного спуска

$e_n = d_n - y_n$, где d_n — опорный сигнал

Целевая функция $J(\mathbf{w}, \mathbf{h})$ в данном случае зависит от векторов коэффициентов $\mathbf{w}$ и $\mathbf{h}$ нелинейно.

Стохастический градиентный спуск основан на оценке градиента по единственной выборки ошибки:

$$\mathbf{w}_{n+1} = \mathbf{w}_n - \mu \frac{\partial J(\mathbf{w}, \mathbf{h})}{\partial \mathbf{w}^H}; \tag{14.4}$$

$$\mathbf{h}_{n+1} = \mathbf{h}_n - \mu \frac{\partial J(\mathbf{w}, \mathbf{h})}{\partial \mathbf{h}^H}; \tag{14.5}$$

$$J(\mathbf{w}, \mathbf{h}) = \big(d_n - y_n\big)^* \big(d_n - y_n\big) \tag{14.6}$$

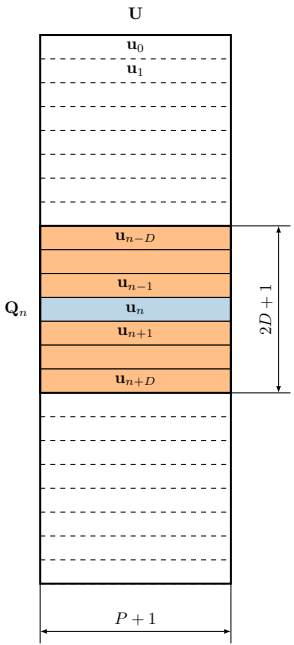

$\mathbf{U}$ —матрица состояния нелинейностей.
Выход нелинейной функции в момент времени n:

$$\mathbf{v}_n = \mathbf{Q}_n \mathbf{w} \tag{14.7}$$

Тогда выход модели

$$y_n = \big(\mathbf{Q}_n \mathbf{w}\big)^T \mathbf{h} = \mathbf{w}^T \mathbf{Q}_n^T \mathbf{h} \tag{14.8}$$

Целевая функция

$$J(\mathbf{w}, \mathbf{h}) = \big(d_n - \mathbf{w}^T \mathbf{Q}_n^T \mathbf{h}\big)^* \big(d_n - \mathbf{w}^T \mathbf{Q}_n^T \mathbf{h}\big) = \big(d_n - \mathbf{w}^H \mathbf{Q}_n^H \mathbf{h}^*\big)\big(d_n - \mathbf{w}^T \mathbf{Q}_n^T \mathbf{h}\big) \tag{14.9}$$

Тогда

$$\frac{\partial J(\mathbf{w},\mathbf{h})}{\partial \mathbf{w}^H} = -\mathbf{Q}_n^H \mathbf{h}^* \left(d_n - \mathbf{w}^T \mathbf{Q}_n^T \mathbf{h}\right) = -\mathbf{Q}_n^H \mathbf{h}^* e_n; \tag{14.10}$$

$$\frac{\partial J(\mathbf{w},\mathbf{h})}{\partial \mathbf{h}^H} = -\mathbf{Q}_n^* \mathbf{w}^* \left(d_n - \mathbf{w}^T \mathbf{Q}_n^T \mathbf{h}\right) = -\mathbf{Q}_n^* \mathbf{w}^* e_n \tag{14.11}$$

И окончательно можно записать уравнения адаптации модели в виде:

$$\mathbf{w}_{n+1} = \mathbf{w}_n + \mu \mathbf{Q}_n^H \mathbf{h}^* e_n; \tag{14.12}$$

$$\mathbf{h}_{n+1} = \mathbf{h}_n + \mu \mathbf{Q}_n^* \mathbf{w}^* e_n; \tag{14.13}$$

Данные уравнения в точности повторяют уравнения адаптации каскада линейных фильтров. Почему? Ведь модель нелинейная?

Лекция 14. Модели нелинейно зависящие от коэффициентов. Модель Гаммерштейна

§14.3. Адаптация модели Гаммерштейна в блочном режиме

Пусть имеется набор входных данных $\mathbf{x} \in \mathbb{C}^N$ и вектор опорного сигнала $\mathbf{d} \in \mathbb{C}^N$ той же длительности.

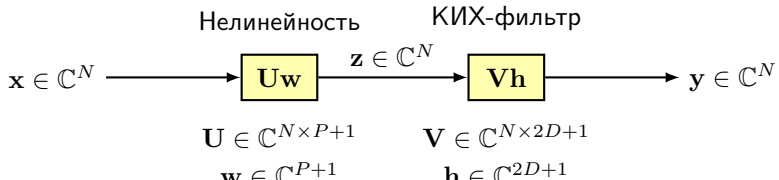

Рассмотрим адаптацию модели Гаммерштейна в блочном режиме.
Получив выход модели в виде вектора $\mathbf{y} \in \mathbb{C}^N$ для всех $n = 0 \dots N-1$, при фиксированных значениях векторов коэффициентов, мы можем оценить вектор ошибки как $\mathbf{e} = \mathbf{d} - \mathbf{y}$. Тогда целевая функция $J(\mathbf{w}, \mathbf{h}) = \mathbf{e}^H \mathbf{e}$.

Целевая функция в блочном режиме $J(\mathbf{w}, \mathbf{h}) = \mathbf{e}^H\mathbf{e}$, $\mathbf{e} = \mathbf{d} - \mathbf{y}$.
Тогда вектор градиента целевой функции в блочном режиме:

$$\nabla_J(\mathbf{w}, \mathbf{h}) = \begin{bmatrix} \dfrac{\partial J(\mathbf{w}, \mathbf{h})}{\partial \mathbf{w}^H} \\ \dfrac{\partial J(\mathbf{w}, \mathbf{h})}{\partial \mathbf{h}^H} \end{bmatrix} \tag{14.14}$$

В блочном режиме оценка ведется для всего блока данных. Тогда рассмотрим сначала производную по коэффициентам $\mathbf{h}$.
Заметим, что выход модели относительно коэффициентов $\mathbf{h}$ может быть записан в виде $\mathbf{y} = \mathbf{V}\mathbf{h}$, где $\mathbf{V}$ — матрица состояния выходного фильтра полученная при фиксированных коэффициентах нелинейной функции $\mathbf{w}$. Тогда

$$\frac{\partial J(\mathbf{w}, \mathbf{h})}{\partial \mathbf{h}^H} = \frac{\partial}{\partial \mathbf{h}^H}(\mathbf{d} - \mathbf{V}\mathbf{h})^H(\mathbf{d} - \mathbf{V}\mathbf{h}) = -\mathbf{V}^H\mathbf{e}. \tag{14.15}$$

Для оценки градиента по коэффициентам $\mathbf{w}$ необходимо учесть влияние выходного фильтра. Для этого перепишем выход модели:

$$y_n = \sum_{m=-D}^{D} h_m \sum_{p=0}^{P} x_{n-m} \varphi_p\big(|x_{n-m}|\big) w_p \tag{14.16}$$

к виду

$$y_n = \sum_{p=0}^{P} w_p \underbrace{\sum_{m=-D}^{D} x_{n-m} \varphi_p\big(|x_{n-m}|\big) h_m}_{\tilde{u}_{n,p}} \tag{14.17}$$

Т.о. выходной фильтр можно учесть как изменение текущего состояния нелинейной функции. Тогда

$$y_n = \tilde{\mathbf{u}}_n^T \mathbf{w}, \quad \mathbf{y} = \tilde{\mathbf{U}} \mathbf{w}. \tag{14.18}$$

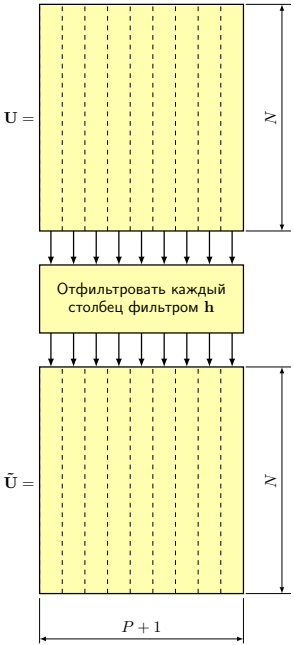

Заметим, что изменение состояния $\tilde{\mathbf{u}}_n$ заключается во временной свертке каждой базисной функции с коэффициентами выходного фильтра:

$$y_n = \sum_{p=0}^{P} w_p \underbrace{\sum_{m=-D}^{D} x_{n-m} \varphi_p\big(|x_{n-m}|\big) h_m}_{\tilde{u}_{n,p}} \tag{14.19}$$

Тогда обновленная матрица состояния представляет собой исходную матрицу, каждый столбец которой свернут с коэффициентами выходного фильтра. Свертка с нулевой задержкой!

После изменения матрицы состояния выход модели становится линейным относительно коэффициентов $\mathbf{w}$

$$\mathbf{y} = \tilde{\mathbf{U}}\mathbf{w}. \tag{14.20}$$

Тогда

$$\frac{\partial J(\mathbf{w}, \mathbf{h})}{\partial \mathbf{w}^H} = \frac{\partial}{\partial \mathbf{w}^H}(\mathbf{d} - \tilde{\mathbf{U}}\mathbf{w})^H(\mathbf{d} - \tilde{\mathbf{U}}\mathbf{w}) = -\tilde{\mathbf{U}}^H\mathbf{e}. \tag{14.21}$$

Окончательно градиент целевой функции равен:

$$\nabla_J(\mathbf{w}, \mathbf{h}) = \begin{bmatrix} \dfrac{\partial J(\mathbf{w}, \mathbf{h})}{\partial \mathbf{w}^H} \\ \dfrac{\partial J(\mathbf{w}, \mathbf{h})}{\partial \mathbf{h}^H} \end{bmatrix} = \begin{bmatrix} -\tilde{\mathbf{U}}^H\mathbf{e} \\ -\mathbf{V}^H\mathbf{e} \end{bmatrix} \tag{14.22}$$

Окончательно, уравнения обновления коэффициентов модели Гаммерштейна в блочном режиме методом градиентного спуска:

$$\mathbf{w}_{k+1} = \mathbf{w}_k + \mu \tilde{\mathbf{U}}^H \mathbf{e}; \tag{14.23}$$

$$\mathbf{h}_{k+1} = \mathbf{h}_k + \mu \mathbf{V}^H \mathbf{e}; \tag{14.24}$$

Здесь k индексирует итерации.
Итак адаптация модели Гаммерштейна в блочном режиме требует следующих шагов:

- Прямой проход с текущими фиксированными векторами коэффициентов $\mathbf{w}_k$ и $\mathbf{h}_k$ и расчет вектора ошибки $\mathbf{e}$.
- Изменение матрицы состояния нелинейной функции $\tilde{\mathbf{U}}$ путем свертки ее столбцов с коэффициентами $\mathbf{h}_k$.
- Обновление коэффициентов.

Лекция 14. Модели нелинейно зависящие от коэффициентов. Модель Гаммерштейна

§14.4. Адаптация модели Гаммерштейна в блочном режиме. Метод Ньютона.

Поскольку выход модели нелинейно зависит от коэффициентов, а целевая функция не является квадратичной, то мы не можем получить оценку оптимальных значений коэффициентов за один шаг методом второго порядка.
Необходимо адаптировать коэффициенты методом Ньютона:

$$\mathbf{g}_{k+1} = \mathbf{g}_k - \mathbf{H}^{-1}\nabla_J(\mathbf{g}); \tag{14.25}$$

где

$$\mathbf{g} = \begin{bmatrix} \mathbf{w} \\ \mathbf{h} \end{bmatrix}; \quad \nabla_J(\mathbf{g}) = \begin{bmatrix} \dfrac{\partial J(\mathbf{w},\mathbf{h})}{\partial \mathbf{w}^H} \\ \dfrac{\partial J(\mathbf{w},\mathbf{h})}{\partial \mathbf{h}^H} \end{bmatrix}; \tag{14.26}$$

$$\mathbf{H} = \begin{bmatrix} \dfrac{\partial^2 J(\mathbf{w},\mathbf{h})}{\partial \mathbf{w}\partial \mathbf{w}^H} & \dfrac{\partial^2 J(\mathbf{w},\mathbf{h})}{\partial \mathbf{h}\partial \mathbf{w}^H} \\ \dfrac{\partial^2 J(\mathbf{w},\mathbf{h})}{\partial \mathbf{w}\partial \mathbf{h}^H} & \dfrac{\partial^2 J(\mathbf{w},\mathbf{h})}{\partial \mathbf{h}\partial \mathbf{h}^H} \end{bmatrix}. \tag{14.27}$$

Вектор градиента мы уже получили:

$$\nabla_J(\mathbf{w},\mathbf{h}) = \begin{bmatrix} \dfrac{\partial J(\mathbf{w},\mathbf{h})}{\partial \mathbf{w}^H} \\ \dfrac{\partial J(\mathbf{w},\mathbf{h})}{\partial \mathbf{h}^H} \end{bmatrix} = \begin{bmatrix} -\tilde{\mathbf{U}}^H\mathbf{e} \\ -\mathbf{V}^H\mathbf{e} \end{bmatrix} \tag{14.28}$$

Нам осталось рассчитать лишь вторые частные производные:

$$\frac{\partial^2 J(\mathbf{w},\mathbf{h})}{\partial \mathbf{w}\partial \mathbf{w}^H} = -\frac{\partial}{\partial \mathbf{w}}\tilde{\mathbf{U}}^H\mathbf{e} = -\tilde{\mathbf{U}}^H\frac{\partial}{\partial \mathbf{w}}(\mathbf{d}-\tilde{\mathbf{U}}\mathbf{w}) = \tilde{\mathbf{U}}^H\tilde{\mathbf{U}}; \tag{14.29}$$

$$\frac{\partial^2 J(\mathbf{w},\mathbf{h})}{\partial \mathbf{w}\partial \mathbf{h}^H} = -\frac{\partial}{\partial \mathbf{w}}\mathbf{V}^H\mathbf{e} = -\mathbf{V}^H\frac{\partial}{\partial \mathbf{w}}(\mathbf{d}-\tilde{\mathbf{U}}\mathbf{w}) = \mathbf{V}^H\tilde{\mathbf{U}}; \tag{14.30}$$

$$\frac{\partial^2 J(\mathbf{w},\mathbf{h})}{\partial \mathbf{h}\partial \mathbf{w}^H} = -\frac{\partial}{\partial \mathbf{h}}\tilde{\mathbf{U}}^H\mathbf{e} = -\tilde{\mathbf{U}}^H\frac{\partial}{\partial \mathbf{h}}(\mathbf{d}-\mathbf{V}\mathbf{h}) = \tilde{\mathbf{U}}^H\mathbf{V}; \tag{14.31}$$

$$\frac{\partial^2 J(\mathbf{w},\mathbf{h})}{\partial \mathbf{h}\partial \mathbf{h}^H} = -\frac{\partial}{\partial \mathbf{h}}\mathbf{V}^H\mathbf{e} = -\mathbf{V}^H\frac{\partial}{\partial \mathbf{h}}(\mathbf{d}-\mathbf{V}\mathbf{h}) = \mathbf{V}^H\mathbf{V}; \tag{14.32}$$

$$\mathbf{g}_{k+1} = \mathbf{g}_k + \begin{bmatrix} \tilde{\mathbf{U}}^H\tilde{\mathbf{U}} & \tilde{\mathbf{U}}^H\mathbf{V} \\ \mathbf{V}^H\tilde{\mathbf{U}} & \mathbf{V}^H\mathbf{V} \end{bmatrix}^{-1} \begin{bmatrix} \tilde{\mathbf{U}}^H\mathbf{e} \\ \mathbf{V}^H\mathbf{e} \end{bmatrix} \tag{14.33}$$

Введем матрицу $\mathbf{G} = [\tilde{\mathbf{U}} \quad \mathbf{V}]$, которая представляет собой конкатенацию матриц состояния $\tilde{\mathbf{U}}$ и $\mathbf{V}$.
Тогда можно заметить, что

$$\begin{bmatrix} \tilde{\mathbf{U}}^H\tilde{\mathbf{U}} & \tilde{\mathbf{U}}^H\mathbf{V} \\ \mathbf{V}^H\tilde{\mathbf{U}} & \mathbf{V}^H\mathbf{V} \end{bmatrix} = \mathbf{G}^H\mathbf{G}; \quad \begin{bmatrix} \tilde{\mathbf{U}}^H\mathbf{e} \\ \mathbf{V}^H\mathbf{e} \end{bmatrix} = \mathbf{G}^H\mathbf{e}. \tag{14.34}$$

Тогда метод Ньютона для адаптации модели Гаммерштейна можно представить как:

$$\mathbf{g}_{k+1} = \mathbf{g}_k + (\mathbf{G}^H\mathbf{G})^{-1}\mathbf{G}^H\mathbf{e}. \tag{14.35}$$

Матрицу $\mathbf{G}$ можно использовать и при адаптации методом градиентного спуска:

$$\mathbf{g}_{k+1} = \mathbf{g}_k + \mu\mathbf{G}^H\mathbf{e}; \tag{14.36}$$

Адаптация модели Гаммерштейна методом Ньютона требует следующих шагов:

- Прямой проход с текущими фиксированными векторами коэффициентов $\mathbf{w}_k$ и $\mathbf{h}_k$ и расчет вектора ошибки $\mathbf{e}$.
- Изменение матрицы состояния нелинейной функции $\tilde{\mathbf{U}}$ путем свертки ее столбцов с коэффициентами $\mathbf{h}_k$.
- Конкатенация измененной матрицы состояния нелинейности и фильтра $\mathbf{G} = [\tilde{\mathbf{U}} \quad \mathbf{V}]$
- Обновление коэффициентов методом Ньютона

На практике необходимо обеспечить сходимость алгоритма путем демпфирования:

$$\mathbf{g}_{k+1} = \mathbf{g}_k + \mu(\mathbf{G}^H\mathbf{G})^{-1}\mathbf{G}^H\mathbf{e}. \tag{14.37}$$

или использования алгоритма Левенберга–Марквардта:

$$\mathbf{g}_{k+1} = \mathbf{g}_k + (\mathbf{G}^H\mathbf{G} + \lambda\mathbf{I})^{-1}\mathbf{G}^H\mathbf{e}. \tag{14.38}$$

Лекция 14. Модели нелинейно зависящие от коэффициентов. Модель Гаммерштейна

§14.5. Модель Гаммерштейна с нелинейной памятью

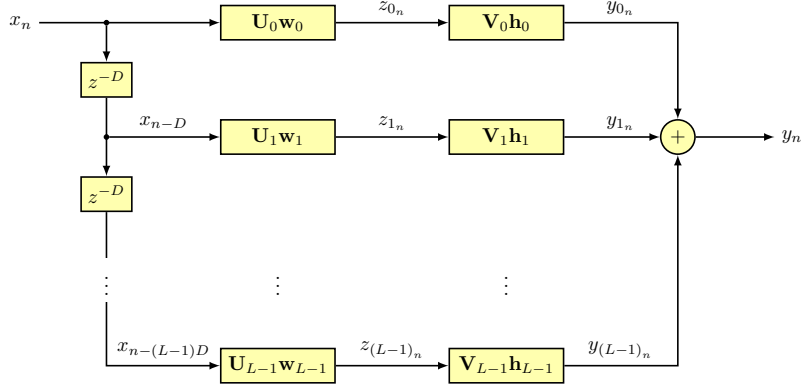

$$y_n = \sum_{l=0}^{L-1} \underbrace{\sum_{m=-D}^{D} \overbrace{\sum_{p=0}^{P} w_{lp} x_{n-m-lD} \varphi_p\big(|x_{n-m-lD}|\big)}^{z_{l_{n-m}}} h_{lm}}_{y_{l_n}} \tag{14.39}$$

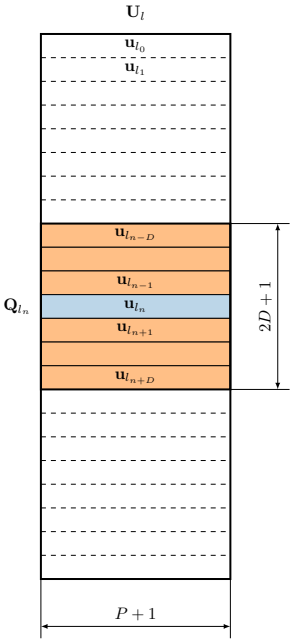

Для адаптации нет необходимости дифференцировать целевую функцию по коэффициентам.
Мы можем использовать правило адаптации по сумме выходов.
Тогда метод стохастического градиентного спуска для ветви l на момент времени n:

$$\mathbf{w}_{l_{n+1}} = \mathbf{w}_{l_n} + \mu \mathbf{Q}_{l_n}^H \mathbf{h}_l^* e_n; \tag{14.40}$$

$$\mathbf{h}_{l_{n+1}} = \mathbf{h}_{l_n} + \mu \mathbf{Q}_{l_n}^* \mathbf{w}_l^* e_n. \tag{14.41}$$

Здесь матрица $\mathbf{Q}_{l_n}$ — подматрица нелинейностей l-ветви в момент времени n.
Все ветви должны быть адаптированы по одной ошибке e_n.

В блочном режиме можно объединить коэффициенты $\mathbf{w}_l$ и $\mathbf{h}_l$ отдельных ветвей в один вектор $\mathbf{g}$.
Матрицы состояния отдельных ветвей $\mathbf{U}_l$ и $\mathbf{U}_l$ также должны быть объединены в одну матрицу $\mathbf{G}$ путем конкатенации по столбцам.

$$\mathbf{g} = \begin{bmatrix} \mathbf{w}_0 \\ \mathbf{h}_0 \\ \mathbf{w}_1 \\ \mathbf{h}_1 \\ \vdots \\ \mathbf{w}_{L-1} \\ \mathbf{h}_{L-1} \end{bmatrix}; \qquad \mathbf{G} = \begin{bmatrix} \tilde{\mathbf{U}}_0 & \mathbf{V}_0 & \tilde{\mathbf{U}}_1 & \mathbf{V}_1 & \dots & \tilde{\mathbf{U}}_{L-1} & \mathbf{V}_{L-1} \end{bmatrix}. \tag{14.42}$$

Конкатенация матрицы $\mathbf{G}$ состояния должна соответствовать порядку конкатенации коэффициентов в векторе $\mathbf{g}$.
Матрицы $\tilde{\mathbf{U}}_l$ отфильтрованы по столбцам соответсвующими фильтрами $\mathbf{h}_l$.

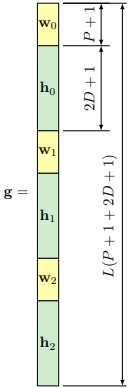

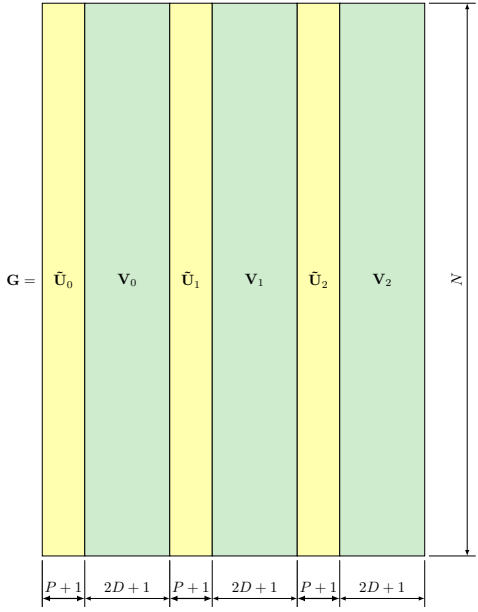

Адаптировать можно как методом блочного градиентного спуска:

$$\mathbf{g}_{k+1} = \mathbf{g}_k + \mu \mathbf{G}^H \mathbf{e}, \qquad (14.43)$$

или методом Ньютона с демпфированием:

$$\mathbf{g}_{k+1} = \mathbf{g}_k + \mu (\mathbf{G}^H \mathbf{G})^{-1} \mathbf{G}^H \mathbf{e}. \qquad (14.44)$$

или алгоритмом Левенберга–Марквардта:

$$\mathbf{g}_{k+1} = \mathbf{g}_k + (\mathbf{G}^H \mathbf{G} + \lambda \mathbf{I})^{-1} \mathbf{G}^H \mathbf{e}. \qquad (14.45)$$

Список литературы

- Оппенгейм А., Шафер Р. Цифровая обработка сигналов. —М.: Техносфера, 2012 —1048 с. ISBN 978-5-94836-329-5, 978-0-13-198842-2
- Джиган В.И. Адаптивная фильтрация сигналов: теория и алгоритмы. —М.: Техносфера, 2013. —528с. ISBN 978-5-94836-342-4
- Уидроу Б., Стринз С. Адаптивная обработка сигналов. —М.: Радио и связь, 1989. — 440с. ISBN 5-256-00180-9
- Адаптивные фильтры. Под ред. К.Ф.Н Коуэна и П.М. Гранта. —М.: Мир, 1988. —392с. ISBN 5-03-000004-6
- Марпл.-мл. С.Л. Цифровой спектральный анализ и его приложения. —М.: Мир, 1990. —584с. ISBN 5-03-001191-9
- Гилл Ф., Мюррей У., Райт М. -мл. Практическая оптимизация. —М.: Мир, 1985. —509с.
- Haykin S. Adaptive Filter Theory (5th Edition). Pearson, 2014. —912pp. ISBN-13: 978-0132671453

- Haykin S. Neural Networks and Learning Machines (3rd Edition). Pearson, 2008. —936pp. ISBN-13: 978-0131471399
- Ghannouchi F.M., Hammi O., Helaoui M. Behavioral Modelling and Predistortion of Wideband Wireless Transmitters. Wiley, 2014. —252pp.
- Aaen, P., Plá, J., Wood, J. Modeling and Characterization of RF and Microwave Power FETs (The Cambridge RF and Microwave Engineering Series). Cambridge: Cambridge University Press. 2007. —362pp.
- Mandic D., Su Lee Goh V. Complex Valued Nonlinear Adaptive Filters: Noncircularity, Widely Linear and Neural Models. Wiley, 2009. —344pp.
- Fa-Long Luo Digital Front-End in Wireless Communications and Broadcasting. Circuits and Signal Processing. Cambridge University Press, 2011. —764pp. ISBN 9780511744839
- Hjorungnes A. Complex-Valued Matrix Derivatives With Applications in Signal Processing and Communications. Cambridge University Press. 2011. —248pp. ISBN 9780511921490